数值分析笔记

Python version

Jiaqi Z.[1]

2023 年 11 月 29 日

目录

说明

0.1 关于本笔记的版权与使用说明

- 本笔记可免费用于学习, 科研等非商业活动;
- 可以以非商业目的进行传播, 但在传播过程中必须保证笔记内容的完整性 (截止到 GitHub 仓库[1]最新发布时, " 笔记" 包括但不限于仓库内笔记 Latex 源码, pdf 文件, 演示程序代码等. 下同), 需保证作者信息完整, 不得进行修改;
- 本笔记不可用于任何商业用途 (如确有需要, 需联系作者);
- 除在 GitHub 仓库以 pull request 形式进行编辑修改外, 不允许对笔记进行修改并公开传播私自修改版本 (以 GitHub 仓库版本为标准版本);
- 本笔记著作权归作者 (Jiaqi Z.) 所有, 对本笔记进行创作的人员也可获得著作权, 其他著作权所有者不得违反上述版权说明;
- 本笔记如因违反上述说明传播而造成不良影响, 与作者和其他创作者无关, 特此声明;

以上说明解释权归 Jiaqi Z. 所有, 且如有后续更新, 以 GitHub 仓库最新版说明为准.

0.2 创作者名单

本笔记除 Jiaqi Z. 参与主要整理之外, 以下人员也参与创作:

[1] GitHub 仓库地址:https://github.com/JackyZhang00/numerical-analysis-notes

- Jiakang L. 负责” 数值积分” 章节的整理

Chapter 1

绪论

1.1 误差

1.1.1 误差来源与分类

1. (模型误差): 从实际模型中抽象出数学模型;

   例如, 一个质量为 m 的小球做自由落体运动, 则位置 s 与时间 t 的关系式满足:

   $$m\frac{\mathrm{d}^2 s}{\mathrm{d}t^2} = mg$$

   不难想见, 该式仅在不考虑阻力时成立.

2. (观测误差): 通过测量得到模型中参数的值;

3. (方法误差 (或称截断误差)): 求近似解时所引入的误差;

   例 1.1.1. *考虑函数 $f(x)$ 做 Taylor 多项式展开所导致的截断误差.*

   解. 对函数 $f(x)$ 计算 Taylor 多项式, 有

   $$P_n(x) = f(0) + \frac{f'(0)}{1!}x + \frac{f''(0)}{2!}x^2 + \cdots + \frac{f^{(n)}(0)}{n!}x^n$$

   由于有限项, 因此多项式有截断误差

   $$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}x^{n+1}$$

   其中, $\xi \in (x, 0)$ □

4. (舍入误差): 机器字长有限所引起的误差

其中, 方法误差和舍入误差是数值分析所重点考虑的误差, 同时, 方法误差是可以避免的.

1.1.2 误差概念

绝对误差与绝对误差限

定义 1.1.1 (绝对误差与绝对误差限)**.** 设 x 是准确值, x^* 是 x 的一个近似值, 则称

$$e(x^*) = x^* - x$$

为 x^* 的绝对误差, 简称误差.

同时, 误差的绝对值的上限 $\varepsilon(x^*)$, 即有

$$|e(x^*)| = |x^* - x| \leq \varepsilon(x^*)$$

$\varepsilon(x^*)$ 称为绝对误差限.

注意: 误差有正有负, 而误差限恒为正值.

习惯上, 我们把精确值和测量值的关系表示为

$$x = x^* \pm \varepsilon$$

相对误差与相对误差限

定义 1.1.2 (相对误差与相对误差限)**.** 设 x 为准确值, x^* 为近似值, 称

$$e_r^* = e_r^*(x^*) = \frac{e(x^*)}{x} = \frac{x^* - x}{x}$$

为近似值 x^* 的相对误差.

同时, 其绝对值的上限 ε_r^*, 即有

$$\left|\frac{x - x^*}{x}\right| \leq \varepsilon_r^*$$

ε_r^* 称为相对误差限.

可以证明, 当 e_r^* 较小时, 有

$$e_r^* \approx \frac{x^* - x}{x^*}$$

同时易得

$$\varepsilon_r^* = \frac{\varepsilon^*}{|x^*|}$$

有效数字

定义 1.1.3 (有效数字, 有效位数, 有效数)**.** *若近似值 x^* 误差满足*

$$|x - x^*| \leq \frac{1}{2} \times 10^{-n}$$

则称 x^* 近似表示 x 准确到小数点后第 n 位, 并从第 n 位起一直到最左边非零数字之间的一切数字称为有效数字, 位数为有效位数.

若所有数字均为有效数字, 则称为有效数

例 1.1.2. *考虑圆周率 π, 且有近似值 $\pi_1 = 3.14, \pi_2 = 3.1415, \pi_3 = 3.1416, \pi_4 = 3.14159$. 考虑它们的有效数字, 且判断是否为有效数.*

解. 对于 $\pi_1 = 3.14$, 有 $|\pi - \pi_1| \approx 0.00159 \leq 0.5 \times 10^{-2}$, 即 π_1 精确到小数点后 2 位, 有效数字是 3 位, 是有效数.

同理, 有 $|\pi - \pi_2| \approx 0.0000926 \leq 0.5 \times 10^{-3}$, 即 π_2 精确到小数点后 3 位, 有效数字是 4 位, 不是有效数.

$|\pi - \pi_3| \approx 0.0000073 \leq 0.5 \times 10^{-4}$, 即 π_3 精确到小数点后 4 位, 有效数字是 5 位, 是有效数.

$|\pi - \pi_4| \approx 0.0000026 \leq 0.5 \times 10^{-5}$, 即 π_4 精确到小数点后 5 位, 有效数字是 6 位, 是有效数. □

从上例中不难看出, 有效数通常是采取四舍五入所得到的近似值.

扩展: 我们可以简单给出关于四舍五入的证明.

证明. 设准确值为 x, 其近似值为 x^*, 考虑近似值精确到小数点后 n 位, 即

$$|x - x^*| \leq 5 \times 10^{-(n+1)}$$

若其为有效数, 则 x^* 为小数点后 n 位, 不妨设

$$x^* = a + b \cdot 10^{-n}$$

其中 $b \in [1, 10)$

特别地, 分两种情况讨论.

若 $x > x^*$, 即真实值大于近似值, 此时有

$$x \leq x^* + 5 \times 10^{-(n+1)} = a + b \cdot 10^{-n} + 5 \times 10^{-(n+1)}$$

即当小数点后第 $n+1$ 位小于等于 5 时, 舍去后面的数字可以得到有效数.

若 $x < x^*$, 即真实值小于近似值, 此时有

$$\begin{aligned} x \geq x^* - 5 \times 10^{-(n+1)} &= a + b \cdot 10^{-n} - 5 \times 10^{-(n+1)} \\ &= a + (b-1) \cdot 10^{-n} + 5 \times 10^{-(n+1)} \end{aligned}$$

即当小数点后第 $n+1$ 位大于等于 5 时, 进位可以得到有效数. □

十进制浮点表示法

定义 1.1.4. 设 x^* 为任一十进制数, 则 x^* 可表示为

$$x^* = \pm 0.a_1 a_2 \cdots a_n \cdots \times 10^m$$

其中, a_1 为 *1* 到 *9* 之间的一个数字, $a_2 \cdots a_n$ 为 *0* 到 *9* 之间的一个数字, m 为整数. 这样表示的 x^* 称为十进制浮点数 (规格化浮点数).

有效数字的等价定义 (基于浮点表示法)

定义 1.1.5. 若近似值 $x^* = \pm 0.a_1 a_2 \cdots a_n a_{n+1} \cdots a_{n+p} \times 10^m (a_1 \neq 0)$ 的误差限是某一位上的半个单位, 即

$$|x - x^*| \leq \frac{1}{2} \times 10^{m-n} \tag{1.1}$$

则称 x^* 有 n 位有效数字.

例 1.1.3. 设 $x_1^* = 0.0051, x_2^* = 5.100$, 两数均为四舍五入得到, 求两个数字的有效位数.

解. 由于有

$$\begin{aligned} \varepsilon(x_1^*) = 0.5 \times 10^{-4}, x_1^* = 0.51 \times 10^{-2} \\ \varepsilon(x_2^*) = 0.5 \times 10^{-3}, x_2^* = 0.51 \times 10^{1} \end{aligned}$$

可得

$$\begin{aligned} \varepsilon(x_1^*) = 0.5 \times 10^{-2-2} \\ \varepsilon(x_2^*) = 0.5 \times 10^{1-4} \end{aligned}$$

即, x_1^* 有两位有效数字, x_2^* 有四位有效数字. □

例 1.1.4. *设 $x_1^* = 2.180, x_2^* = 10.210$, 均具有四位有效数字, 求绝对误差限和相对误差限.*

解. 对 x_1^*, 有

$$x_1^* = 0.2180 \times 10^1$$

即 $m = 1$, 且具有四位有效数字, 即 $n = 4$, 则根据公式 (1.1), 有

$$\varepsilon(x_1^*) = 0.5 \times 10^{1-4} = 0.5 \times 10^{-3}$$

其相对误差限为

$$\varepsilon_r(x_1^*) = \frac{\varepsilon(x_1^*)}{|x_1^*|} = 0.023\%$$

同理可得, 对于 x_2^*, 有

$$\varepsilon(x_2^*) = 0.5 \times 10^{-2}, \varepsilon_r(x_2^*) = 0.049\%$$

□

1.1.3 相对误差限和有效数字的关系

关于有效数字和相对误差限之间的关系, 有如下定理.

定理 1.1.1. *对于用式 (1.1.4) 表示的近似数 x^*, 若 x^* 具有 n 位有效数字, 则其相对误差限为*

$$\varepsilon_r^* \leq \frac{1}{2a_1} \times 10^{-n}$$

证明. 由式 1.1.4可得

$$a_1 \times 10^m \leq |x^*| \leq (a_1 + 1) \times 10^m$$

当 x^* 有 n 位有效数字时, 有

$$|x - x^*| = |x^*|\varepsilon_r^* \leq (a_1 + 1) \times 10^m \times \frac{1}{2(a_1 + 1)} \times 10^{-n} = 0.5 \times 10^{m-n}$$

故 x^* 有 n 位有效数字. □

上述定理表明: 有效位数越多, 相对误差限越小.

例 1.1.5. *令 $\sqrt{20}$ 的近似值相对误差限小于 0.1%, 则需要取多少位有效数字?*

解. 由定理 1.1.1可知

$$\varepsilon_r^* \leq \frac{1}{2a_1} \times 10^{-n}$$

由于 $\sqrt{20} \approx 4.4$, 故 $a_1 = 4$, 只需要取 $n = 4$, 有

$$\varepsilon_r^* \leq 0.125 \times 10^{-3} < 10^{-3} = 0.1\%$$

即只需要对 $\sqrt{20}$ 的近似值取 4 位有效数字, 其相对误差限就可以小于 0.1%, 此时有

$$\sqrt{20} \approx 4.472.$$

□

1.2 数值运算的误差估计

1.2.1 四则运算误差估计

两个近似数分别为 x_1^* 和 x_2^*, 误差限分别为 $\varepsilon(x_1^*), \varepsilon(x_2^*)$, 进行四则运算的误差限分别为:

$$\begin{aligned}
\varepsilon(x_1^* \pm x_2^*) &= \varepsilon(x_1^*) + \varepsilon(x_2^*) \\
\varepsilon(x_1^* x_2^*) &\approx |x_1^*|\varepsilon(x_2^*) + |x_2^*|\varepsilon(x_1^*) \\
\varepsilon(x_1^*/x_2^*) &\approx \frac{|x_1^*|\varepsilon(x_2^*) + |x_2^*|\varepsilon(x_1^*)}{|x_2^*|^2}
\end{aligned}$$

下面试着给出加减法误差的证明, 对于乘法和除法的证明, 将在后面给出.

证明.

$$\begin{aligned}
|e(x_1^* \pm x_2^*)| &= |(x_1^* \pm x_2^*) - (x_1 \pm x_2)| \\
&= |(x_1^* - x_1) \pm (x_2^* - x_2)| \\
&\leq |x_1^* - x_1| + |x_2^* - x_2| \\
&\leq \varepsilon(x_1^*) + \varepsilon(x_2^*)
\end{aligned}$$

□

1.2.2 函数值误差估计

一元函数误差估计

设 $f(x)$ 是一元函数, x 的近似值为 x^*, 以 $f(x^*)$ 近似 $f(x)$, 其误差限记作 $\varepsilon(f(x^*))$, 可用 Taylor 展开

$$f(x)-f(x^*)=f'(x^*)(x-x^*)+\frac{f''(\xi)}{2}\varepsilon^2(x^*)$$

其中, ξ 介于 x, x^* 之间, 取绝对值有

$$|f(x)-f(x^*)|\leq|f'(x^*)|\varepsilon(x^*)+\frac{|f''(\xi)|}{2}\varepsilon^2(x^*)$$

假定 $f'(x^*)$ 与 $f''(x^*)$ 的比值不大, 可忽略 $\varepsilon(x^*)$ 的高阶项, 于是可得误差限为

$$\varepsilon(f(x^*))\approx|f'(x^*)|\varepsilon(x^*)$$

相对误差限为

$$\varepsilon_r(f(x^*))\approx\frac{|f'(x^*)|\varepsilon(x^*)}{|f(x^*)|}=C_p(f,x^*)\varepsilon_r(x^*)$$

其中,

$$C_p(f,x^*)=\frac{|x^*f'(x^*)|}{|f(x^*)|}$$

称为 $f(x^*)$ 的条件数.

多元函数误差估计

当 f 为多元函数时计算 $A=f(x_1,x_2,\cdots x_n)$, 如果 $x_1,x_2,\cdots x_n$ 的近似值为 $x_1^*,x_2^*,\cdots,x_n^*$, 则 A 的近似值为 $A^*=f(x_1^*,x_2^*,\cdots,x_n^*)$, 于是函数值 A^* 的误差 $e(A^*)$ 由 Taylor 展开, 得

$$\begin{aligned}e(A^*)&=A^*-A=f(x_1^*,x_2^*,\cdots,x_n^*)-f(x_1,x_2,\cdots,x_n)\\&\approx\sum_{k=1}^{n}\left(\frac{\partial f(x_1^*,x_2^*,\cdots,x_n^*)}{\partial x_k}\right)(x_k^*-x_k)=\sum_{k=1}^{n}\left(\frac{\partial f}{\partial x_k}\right)^*e_k^*\end{aligned}$$

于是误差限为

$$\varepsilon(A^*)\approx\sum_{k=1}^{n}\left|\left(\frac{\partial f}{\partial x_k}\right)^*\right|\varepsilon(x_k^*)\tag{1.2}$$

而 A^* 的相对误差限为

$$\varepsilon_r^* = \varepsilon_r(A^*) = \frac{\varepsilon(A^*)}{|A^*|} \approx \sum_{k=1}^{n} \left| \left(\frac{\partial f}{\partial x_k} \right)^* \right| \frac{\varepsilon(x_k^*)}{|A^*|}$$

例 1.2.1. 已测得某场地长 l 的值为 $l^* = 110\,\mathrm{m}$, 宽 d 的值为 $d^* = 80\,\mathrm{m}$, 已知 $|l - l^*| \le 0.2\,\mathrm{m}, |d - d^*| \le 0.1\,\mathrm{m}$, 试求面积 $S = ld$ 的绝对误差限与相对误差限.

解. 因为 $S = ld, \frac{\partial S}{\partial l} = d, \frac{\partial S}{\partial d} = l$, 由式 1.2可知

$$\varepsilon(S^*) \approx \left| \left(\frac{\partial S}{\partial l} \right)^* \right| \varepsilon(l^*) + \left| \left(\frac{\partial S}{\partial d} \right)^* \right| \varepsilon(d^*)$$

其中,

$$\left(\frac{\partial S}{\partial l} \right)^* = d^* = 80\,\mathrm{m}, \left(\frac{\partial S}{\partial d} \right)^* = l^* = 110\,\mathrm{m}$$

而

$$\varepsilon(l^*) = 0.2\,\mathrm{m}, \varepsilon(d^*) = 0.1\,\mathrm{m}$$

于是绝对误差限为

$$\varepsilon(S^*) \approx (80 \times 0.2 + 110 \times 0.1)\mathrm{m}^2 = 27\,\mathrm{m}^2$$

相对误差限为

$$\varepsilon_r(S^*) = \frac{\varepsilon(S^*)}{|S^*|} = \frac{\varepsilon(S^*)}{l^* d^*} \approx \frac{27}{8800} = 0.31\%$$

□

注意: 绝对误差限有量纲, 而相对误差限没有量纲.

1.3 算法数值稳定性

定义 1.3.1 (数值稳定)**.** 一个算法如果初始数值有微小扰动 (即有误差), 而计算过程中舍入误差不增长, 使得结果产生微小误差. 则称该算法为数值稳定的. 反之称为数值不稳定.

例 1.3.1. 计算定积分

$$I_n = \int_0^1 \frac{x^n}{n+5}\,\mathrm{d}x\,, n = 0, 1, 2, \cdots, 8$$

解. 对被积函数变形, 得

$$\begin{aligned} I_n &= \int_0^1 \frac{(x+5)-5}{x+5} x^{n-1}\,\mathrm{d}x \\ &= \int_0^1 x^{n-1}\,\mathrm{d}x - 5\int_0^1 \frac{x^{n-1}}{x+5}\,\mathrm{d}x \\ &= \frac{1}{n} - 5I_{n-1} \end{aligned}$$

其中, $n = 1, 2, \cdots, 8$.

易知, $I_0 = \ln 6 - \ln 5 = \ln 1.2$, 由于机器只能计算小数, 取三位有效数字, 即 $\ln 1.2 \approx 0.182$.

分析上述积分, 可知, $0 < I_n < 0.2$, 且随着 n 增大, I_n 逐渐减小, 当 $n \to \infty$ 时, $I_n \to 0$.

迭代计算上述积分, 可得结果为:

$$I_0 = 0.182, I_1 = 0.09, I_2 = 0.05, I_3 = 0.083, I_4 = -0.17$$
$$I_5 = 1.03, I_6 = -5.0, I_7 = 25.14, I_8 = -125.59$$

可以发现, 该算法数值不稳定.

若对上述积分递推公式进行变形, 可得

$$I_{n-1} = \frac{1}{5n} - \frac{1}{5}I_n, n = 9, 8, \cdots, 1$$

由于当 $n \to \infty$ 时, $I_n \to 0$, 因此当 n 充分大时, 可近似认为 $I_n = I_{n+1}$, 故有 $I_9 \approx I_10$, 将其代入并求解方程, 可得 $I_9 \approx 0.017$.

迭代计算, 可得结果为

$$I_0 = 0.182, I_1 = 0.088, I_2 = 0.058, I_3 = 0.043, I_4 = 0.034$$
$$I_5 = 0.028, I_6 = 0.024, I_7 = 0.021, I_8 = 0.019$$

该算法为数值稳定的.

分析二者的误差, 可得对于第一个算法, 其误差为

$$e_n = |I_n - I_n^*| = 5|e_{n-1}| = 5^n|e_n|$$

而对于第二个算法, 其误差为

$$|e_{n-1}| = \left|I_{n-1} - I_{n-1}^*\right| = \frac{1}{5}|e_n| = \left(\frac{1}{5}\right)^n |e_9|$$

□

通过上述例子, 可以看到对于同一个问题, 使用不同算法, 得到的误差结果可能有很大不同.

扩展: 考虑到数值分析需要结合计算机使用, 故在笔记的适当地方, 将给出代码以供参考 (注: 代码不唯一. 且考虑到算法的设计原则, 如无必要, 不会引入相应的库函数).

本例的运行代码如下所示:

```python
# 验证数值稳定性(例题) Exercise1-1.py
# 方法1(数值不稳定)
def I1(n):
    if n==0:
        return 0.182
    else:
        return 1/n-5*I1(n-1)
# 方法2(数值稳定)
def I2(n):
    if n==9:
        return 0.017
    else:
        return 1/(5*(n+1))-(1/5)*I2(n+1)

for n in range(0,9):
    print(f"I1_{n} = {I1(n)}")

for n in range(0,9):
    print(f"I2_{n} = {I2(n)}")
```

定义 1.3.2 (良态与病态). 对于一个数学问题, 若初始数据有微小扰动 (即误差), 导致计算结果产生较小误差, 则称此问题是良态的, 否则称其为病态的.

注意: 良态和病态是针对于数学问题本身的, 与算法无关.

1.4 数值计算中应该注意的一些原则

1.4.1 避免两相近数相减

使用两相近数相减, 将会导致有效数字损失. 下面的例子将有效说明这一点:

例 1.4.1. *计算函数 $y = \sqrt{x+1} - \sqrt{x}$ 在 $x = 1000$ 处的取值.*
已知 y 的四位有效数字为 0.01580

解. 若选择直接相减, 则有 $y = \sqrt{1001} - \sqrt{1000} \approx 31.64 - 31.62 = 0.02$, 只有两位有效数字.

若选择对其进行变形, 令

$$y = \frac{1}{\sqrt{x+1} + \sqrt{x}}$$

则可得

$$y = \frac{1}{\sqrt{1001} + \sqrt{1000}} \approx \frac{1}{31.64 + 31.62} = 0.01581$$

有三位有效数字. □

注意: 在本例中, 使用第二种方法得到的只有三位有效数字, 这是因为第四位有效数字是 0 而不是 1.

1.4.2 避免除数绝对值远小于被除数绝对值

例如, $\frac{42}{0.01}$ 和 $\frac{42}{0.011}$ 的结果分别是 4200 和 3818.18, 明显可以发现, 除数只变化了 0.001, 结果变化了 381.82

1.4.3 避免大数" 吃" 小数

由于计算机字长是有限的, 在计算过程中需要考虑到对阶, 例如, 计算下面的式子:

$$10^9 + 1$$

在计算前首先需要将其规格化, 即将上式化为

$$0.1 \times 10^{10} + 0.1 \times 10^{1}$$

在计算机计算过程中, 需要进行对阶, 即将指数部分化为相同的. 在这里, 计算机将会做如下处理:

$$0.1 \times 10^{10} + 0.0000000001 \times 10^{10} = 0.1000000001 \times 10^{10}$$

同时, 考虑到计算机内部的小数存储是有长度限制的, 假设以 8 位为例, 则上式中的小数最后一位的 1 将被舍去, 从而得到结果为 0.1×10^{10}, 显然与结果不符.

下面的例子将详细说明这一点:

例 1.4.2. *用单精度 (浮点数保留 8 位小数) 计算*

$$10^9 + 40 + 39 + \cdots + 1$$

解. 假设从左到右计算, 由于

$$10^9 + 40 = 0.1 \times 10^{10} + 0.4 \times 10^2 \approx 0.1 \times 10^{10}$$

会出现大数" 吃" 小数的情况.

假设从右到左计算, 则首先计算 $1 + 2 + \cdots + 40$, 不难得结果为 820, 即有

$$\begin{aligned} \text{原式} &= 820 + 10^9 = 0.82 \times 10^3 + 0.1 \times 10^{10} \\ &= 0.000000082 \times 10^{10} + 0.1 \times 10^{10} \\ &= 0.100000082 \times 10^{10} \qquad \approx 0.10000008 \times 10^{10} = 1000000800 \end{aligned}$$

显然误差较小. □

下面的代码将演示这一点

注意: 由于计算机内部的存储方式和实际计算有些许误差 (计算机采用二进制存储), 因此运行结果可能与理论分析不一样.

```
1 # 演示大数"吃"小数 Exercise1-2.py
2 import numpy as np
3 # 使用从左到右的计算方式, 会有很大误差
4 def example1():
5     result = np.float32(0)
6     result = result + np.float32(1e9)
```

```
    for i in range(1,41):
        result = result + np.float32(i)
    print(f"从左到右计算结果为{result}")
# 使用从右到左的计算方式，误差较小
def example2():
    result = np.float32(0)
    for i in range(1,41):
        result = result + np.float32(i)
    result = result + np.float32(1e9)
    print(f"从右到左计算结果为{result}")
# 运行结果
example1()
example2()
```

1.4.4 简化计算步骤, 避免误差积累

例 1.4.3. *多项式求值: 给定 x, 求下列 n 次多项式的值:*

$$P(x) = a_0 + a_1 x + \cdots + a_n x^n$$

解. 若采用直接求和的方法, 则有

$$P_n(x) = a_0 + a_1 x + a_2 x \cdot x + \cdots + a_n \underbrace{x \cdot x \cdot x \cdots x}_{n\text{个}x}$$

一共需要 $\frac{n(n+1)}{2}$ 次乘法, n 次加法

若使用逐项求和, 即令

$$x^2 = x \cdot x, x^3 = x^2 \cdot x, \cdots x^n = x^{n-1} \cdot x$$

一共需要 $(2n-1)$ 次乘法, n 次加法

若采用秦九韶算法 (Horner 算法), 则可以将上式整理为

$$P_n(x) = a_0 + x(a_1 + x(a_2 + x(\cdots + x(a_{n-1} + a_n x)\cdots)))$$

一共需要 n 次乘法, n 次加法 □

可以明显发现, 使用秦九韶算法的效率明显优于其他两个算法.

对于秦九韶算法, 可以使用如下递推公式:

$$\begin{cases} S_n = a_n \\ S_k = xS_{k+1} + a_k, k = n-1, n-2, \cdots, 0 \\ P_n(x) = S_0 \end{cases}$$

实际上机运行可以参考如下代码：

```
# 演示100000次多项式不同算法时间差异(假设每一项系数a_n都是2)
    Exercise1-3.py
import time
POWER = 100000
# 直接求和
def method1():
    result = 0
    x = 2
    a = []
    for i in range(0,POWER+1):
        a.append(2)
    start_time = time.time()
    for i in range(0,POWER+1):
        result = result + a[i]*x**i
    end_time = time.time()
    # print(result)
    print(end_time-start_time)
# 使用逐项求和
def method2():
    result = 0
    x = [1,2]
    for i in range(2,POWER+1):
        x.append(x[i-1]*2)
    a = []
    for i in range(0,POWER+1):
        a.append(2)
```

```
26      start_time = time.time()
27      for i in range(0,POWER+1):
28          result = result + a[i]*x[i]
29      end_time = time.time()
30      # print(result)
31      print(end_time-start_time)
32  # 秦九韶算法
33  def method3():
34      s = 2
35      x = 2
36      start_time = time.time()
37      for i in range(1,POWER+1):
38          s = s*x+2
39          # s.append(s[i-1]*x+2)
40      end_time = time.time()
41      # print(s)
42      print(end_time-start_time)
43
44  method1()
45  method2()
46  method3()
```

注意: 在本地测试时, 得到运行结果分别为 10.107, 0.264, 0.249(单位”秒”). 这个时间可能在不同计算机上会有所差距, 但一般情况下, 随着多项式次数的增加, 时间差距会逐渐拉大. 同时, 三种算法的时间增长速率也会有明显差距.

Chapter 2

插值法

2.1 引言

定义 2.1.1 (插值法)**.** *设函数 $y = f(x)$ 在区间 $[a, b]$ 上有定义, 且已知在点 $a \le x_0 \le x_1 < \cdots < x_n \le b$ 上的值 $y_0, y_1, \cdots, y_n$, 若存在一简单函数 $P(x)$, 使*

$$P(x_i) = y_i, i = 0, 1, \cdots, n \tag{2.1}$$

成立, 则称 $P(x)$ 为函数 $f(x)$ 的插值函数, 点 $x_0, x_1, \cdots, x_n$ 为插值节点, 包括插值节点的区间 $[a, b]$ 称为 插值区间, 求插值函数 $P(x)$ 的方法称为插值法.

定义 2.1.2 (多项式插值)**.** *若 $P(x)$ 是次数不超过 n 的代数多项式, 即*

$$P(x) = a_0 + a_1 x + \cdots + a_n x^n \tag{2.2}$$

其中 a_i 为实数, 则称 $P(x)$ 为插值多项式, 相应的插值法称为多项式插值.

本章所讨论的主要内容是多项式插值.

在寻找插值多项式之前, 需要对其存在性与唯一性进行讨论[1]. 给出如下定理:

定理 2.1.1. *对于给定互异节点 $x_0, x_1, \cdots, x_n$, 满足插值条件式 (2.1) 的 n 阶插值多项式 (2.2) 存在且唯一.*

[1] 存在性表明插值多项式存在, 唯一性表明无论采用哪种插值方法, 得到的结果是唯一的.

证明. 设所要构造的插值多项式为

$$P_n(x) = a_0 + a_1 x + \cdots + a_n x^n$$

由插值条件

$$P_n(x_i) = y_i, i = 0, 1, \cdots, n$$

得如下线性方程组

$$\begin{cases} 1 \cdot a_0 + x_0 a_1 + \cdots + x_0^n a_n = y_0 \\ 1 \cdot a_0 + x_1 a_1 + \cdots + x_1^n a_n = y_1 \\ \vdots \\ 1 \cdot a_0 + x_n a_1 + \cdots + x_n^n a_n = y_n \end{cases}$$

求解 $a_0, a_1, \cdots, a_n$, 计算系数行列式

$$D = \begin{vmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{vmatrix}$$

该行列式为 Vandermonde 行列式, 其值为

$$D = \prod_{0 \le j < i \le n} (x_i - x_j)$$

当 $x_i \neq x_j$ 时, $D \neq 0$, 即 $P_n(x)$ 由 $a_0, a_1, \cdots, a_n$ 唯一确定 □

在实际计算过程中, 直接求解方程组往往计算量较大, 且方程组可能具有病态性. 例如, 对于 x_1, x_2, x_3, x_4, 若值分别为 0.1, 0.2, 0.3, 0.4, 则行列式 $D = 1.2 \times 10^{-6} \approx 0$.

因此, 通常的做法是在 n 次多项式空间中寻找一组基函数

$$\varphi_0(x), \varphi_1(x), \cdots, \varphi_n(x)$$

使得

$$P_n(x) = a_0\varphi_0(x) + a_1\varphi_1(x) \cdots + a_n\varphi_n(x)$$

不同的基函数对应不同的插值法. 本章重点讨论 Lagrange 插值法与 Newton 插值法.

2.2 Lagrange 插值法

2.2.1 线性插值

例 2.2.1. 对于节点 $(x_0, y_0), (x_1, y_1)$, 求一次多项式

解. 利用直线的两点式, 不难得到其插值多项式为

$$\begin{aligned} P_1 &= \left(\frac{x - x_1}{x_0 - x_1}\right) y_0 + \left(\frac{x - x_0}{x_1 - x_0}\right) y_1 \\ &= l_0(x)y_0 + l_1(x)y_1 = \sum_{i=0}^{1} l_i(x)y_i \end{aligned}$$

□

在这里, 称

$$l_0(x) = \frac{x - x_0}{x_0 - x_1}, l_1(x) = \frac{x - x_0}{x_1 - x_0}$$

为一次 Lagrange 插值基函数.

不难验证, 对于一次 Lagrange 插值基函数而言, 存在如下性质

- $l_0(x), l_1(x)$ 均为一次多项式
- $l_0(x_0) = 1, l_1(x_0) = 0, l_0(x_1) = 0, l_1(x_1) = 1$

2.2.2 抛物插值

与线性插值类似, 对于抛物插值, 设有三个插值点, 分别为 $(x_0, y_0), (x_1, y_1), (x_2, y_2)$, 可得其插值多项式为

$$P_2(x) = y_0 l_0(x) + y_1 l_1(x) + y_2 l_2(x)$$

其中 $l_0(x), l_1(x), l_2(x)$ 均为二次多项式, 且有

$$\begin{aligned} l_0(x_0) = 1, l_1(x_0) = 0, l_2(x_0) = 0 \\ l_0(x_1) = 0, l_1(x_1) = 1, l_2(x_1) = 0 \\ l_0(x_2) = 0, l_1(x_2) = 0, l_2(x_2) = 1 \end{aligned}$$

2.2.3 Lagrange 插值多项式

将上述结论推广至 n 阶情况. 即假设有 $n+1$ 个节点 $x_0, x_1, \cdots, x_n$ 的 n 阶插值多项式 $L_n(x)$, 且满足条件

$$L_n(x_i) = y_i, i = 1, 2, \cdots, n \tag{2.3}$$

类似于线性插值和抛物插值, 我们首先需要定义出基函数.

定义 2.2.1. 若 n 次多项式 $l_j(x), j = 0, 1, \cdots, n$ 在 $n+1$ 个节点 $x_0 < x_1 < \cdots < x_n$ 上满足条件

$$l_j(x_k) = \begin{cases} 1, k = j \\ 0, k \neq j \end{cases}, j, k = 0, 1, \cdots, n$$

则称这 $n+1$ 个 n 次多项式 $l_0(x), l_1(x), \cdots, l_n(x)$ 为节点 $x_0, x_1, \cdots, x_n$ 上的 n 次插值基函数.

利用其性质, 可以得到基函数形式为

$$l_k(x) = \frac{(x-x_0)\cdots(x-x_{k-1})(x-x_{k+1})\cdots(x-x_n)}{(x_k-x_0)\cdots(x_k-x_{k-1})(x_k-x_{k+1})\cdots(x_k-x_n)}, k = 0, 1, \cdots, n \tag{2.4}$$

扩展: 下面将说明如何计算基函数的形式.

利用性质, 可知对于 $l_k(x), k = 0, 1, \cdots, n$, 当 $x \neq x_k$ 时, 其函数值为 *0.* 则可以将其分解为若干因式 $(x - x_j), j = 0, 1, \cdots, n$ 且 $j \neq k$, 即

$$l_k(x) = \lambda(x-x_0)(x-x_1)\cdots(x-x_{k-1})(x-x_{k+1})\cdots(x-x_n), k = 0, 1, \cdots, n$$

同时, 由于当 $x = x_k$ 时, $l_k(x_k) = 1$, 可得待定系数 λ 为

$$\lambda = \frac{1}{(x_k-x_0)(x_k-x_1)\cdots(x_k-x_{k-1})(x_k-x_{k+1})\cdots(x_k-x_n)}, k = 0, 1, \cdots, n$$

代入并整理, 可得基函数的具体形式为

$$l_k(x) = \frac{(x-x_0)\cdots(x-x_{k-1})(x-x_{k+1})\cdots(x-x_n)}{(x_k-x_0)\cdots(x_k-x_{k-1})(x_k-x_{k+1})\cdots(x_k-x_n)}, k = 0, 1, \cdots, n$$

上式因此得证.

下面将试着给出基于 Lagrange 多项式插值的一个程序代码, 仅供参考.

```python
# 使用拉格朗日多项式插值法的实例 Exercise2-1.py
# 假设四个插值点分别为(1,2),(2,3),(3,6),(4,7)
# 实际运行时这些数据可以自行修改，从而观察插值的实际作用.

import numpy as np
import matplotlib.pyplot as plt

def lagrange_interpolation(x, points):
    n = len(points)
    result = 0.0
    for i in range(n):
        xi, yi = points[i]
        term = yi
        for j in range(n):
            if i != j:
                xj, yj = points[j]
                term *= (x - xj) / (xi - xj)
        result += term
    return result

x = [1,2,3,4]
y = [2,3,6,7]
plt.scatter(x,y,color="red")
points = list(zip(x,y))
x = np.arange(1,5,0.01)
result = lagrange_interpolation(x, points)
plt.plot(x,result)
plt.show()
```

使用这段代码运行的结果如图 2.1所示.

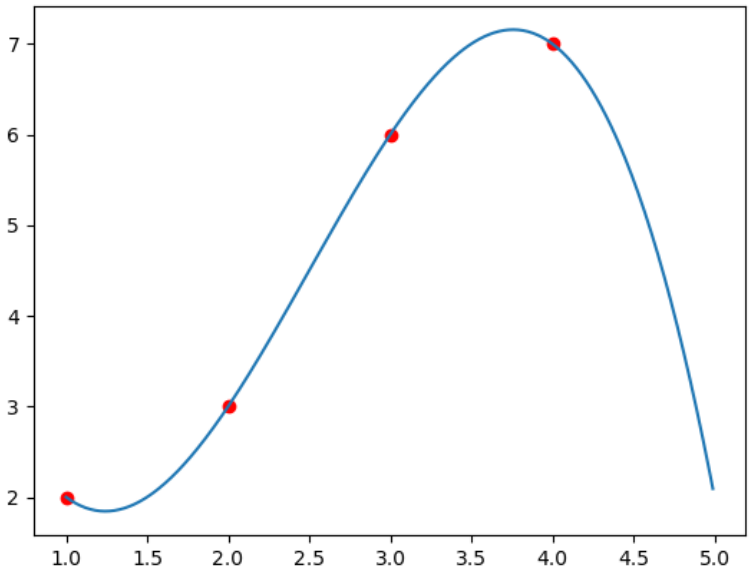

图 2.1: Lagrange 多项式插值 (使用上述代码生成)

2.2.4 插值余项

使用 $L_n(x)$ 近似表示 $f(x)$, 则会引起截断误差. 其截断误差为 $R_n(x) = f(x) - L_n(x)$. 通常会称 $R_n(x)$ 为插值多项式的余项或简称为插值余项.

为估计插值余项, 有如下定理:

定理 2.2.1. *设 $f^{(n)}(x)$ 在 $[a,b]$ 上连续, $f^{(n+1)}(x)$ 在 (a,b) 存在, 节点 $a \le x_0 < x_1 < \cdots < x_n \le b$, $L_n(x)$ 是满足条件式 (2.3) 的插值多项式, 则对于任何 $x \in [a,b]$, 插值余项*

$$R_n(x) = f(x) - L_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^{n} (x - x_i) \tag{2.5}$$

其中, $\xi \in (a,b)$ 且依赖于 x

证明. 由插值条件可知, $R_n(x)$ 在节点 $x_k, k = 0, 1, \cdots, n$ 上为 0, 即可

以做因式分解

$$R_n(x) = K(x)(x-x_0)(x-x_1)\cdots(x-x_n) = K(x)\prod_{i=0}^{n}(x-x_i)$$

其中, $K(x)$ 是与 x 有关的待定系数.

把 x 视作区间 $[a,b]$ 上的一个固定点, 作函数

$$\varphi(t) = f(t) - L_n(t) - K(t)(t-x_0)(t-x_1)\cdots(t-x_n)$$

因此, $\varphi(t)$ 在 $x_0, x_1, \cdots, x_n$ 和 x 处均为 0, 即在区间 $[a,b]$ 上有 $n+2$ 个零点. 根据 Roll 定理可知, $\varphi'(t)$ 在两个零点间至少有一个零点, 即在区间 $[a,b]$ 上, $\varphi'(t)$ 至少有 $n+1$ 个零点. 以此类推, 不难得 $\varphi^{(n+1)}$ 在区间 (a,b) 内至少有一个零点, 将其记为 $\xi \in (a,b)$, 使得

$$\varphi^{(n+1)}(\xi) = f^{(n+1)}(\xi) - (n+1)!K(x) = 0$$

整理可得

$$K(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}, \xi \in (a,b)$$

将其代入上式, 可得余项表达式 (2.5) □

通常, ξ 无法具体确定, 从而实际操作中, 经常估计误差上限. 由

$$\left|f^{(n+1)}(x)\right| \le M_{n+1}$$

对于任意的 $x \in (a,b)$, 将

$$\frac{M_{n+1}}{(n+1)!}\prod_{i=0}^{n}|x-x_i|$$

作为误差估计上限. 通常取

$$M_{n+1} = \max_{a\le x\le b}\left|f^{(n+1)}(x)\right|$$

特别的, 若 $f(x)$ 为任一次数小于等于 n 的多项式, 即 $f(x) \in H_n \in \mathrm{span}\{1, x, x^2, \cdots, x^n\}$, 此时 $f^{(n+1)} \equiv 0$, 即 $R_n(x) \equiv 0$. 因此, 插值多项式对于次数小于等于 n 的多项式总是精确的.

例 2.2.2. *设有 $x_0 \ne x_1 \ne x_2 \ne x_3 \ne x_4$, 且 $l_i(x), i = 0,1,2,3,4$ 为 Lagrange 插值基函数. 求*

$$\sum_{i=0}^{4}\left(3x_i^4 + 4x_i^2 + 2x_i + 1\right)l_i(x)$$

解. 设函数 $f(x) = 3x^4 + 4x^2 + 2x + 1$, 则

$$\text{原式} = \sum_{i=0}^{4} f(x_i) l_i(x) = f(x)$$

□

例 2.2.3. *已知 $\sin\frac{\pi}{6} = \frac{1}{2}, \sin\frac{\pi}{4} = \frac{\sqrt{2}}{2}, \sin\frac{\pi}{3} = \frac{\sqrt{3}}{2}$, 利用 $\sin x$ 的一次, 二次 Lagrange 插值, 计算 $\sin 50^\circ$ 并估计误差*

解. 当 $n = 1$ 时, 利用 x_0, x_1, 有

$$\Rightarrow L_1(x) = \frac{x - \frac{\pi}{4}}{\frac{\pi}{6} - \frac{\pi}{4}} \cdot \frac{1}{2} + \frac{x - \frac{\pi}{6}}{\frac{\pi}{4} - \frac{\pi}{6}} \cdot \frac{\sqrt{2}}{2}$$
$$\Rightarrow L_1(\frac{5}{18}\pi) \approx 0.77614$$

其误差

$$R_1(x) = \frac{f''(\xi)}{2!}\Big|x - \frac{\pi}{6}\Big|\Big|x - \frac{\pi}{4}\Big|$$

其中 $|\sin\xi| \le \frac{\sqrt{2}}{2}$, 因此有

$$\left|R_1(\frac{5}{18}\pi)\right| < 0.01319$$

类似地, 利用 x_1, x_2, 可得 $L_1(x) \approx 0.76008$, 估计误差, 由于 $|\sin\xi| \le \frac{\sqrt{3}}{2}$

$$\left|R_1(\frac{5}{18}\pi)\right| < 0.00660$$

当 $n = 2$ 时, 有 □

2.2.5 Lagrange 插值优缺点

优点: 具有严格的规律性, 便于记忆与理论推导;

缺点: 计算量大, 每次添加 (或删除) 节点都需要重新计算基函数, 不具有承袭性.

为解决上述缺点, 将引出新的插值法, 即 Newton 插值.

2.3 Newton 插值

2.3.1 Newton 插值

与 Lagrange 插值类似, 首先考虑 $n = 1$

例 2.3.1. *已知两个节点 x_0, x_1, 其函数值分别为 y_0, y_1, 试求一次多项式 $P_1(x) = A_0 + A_1 x$, 使得 $P_1(x_0) = y_0, P_1(x_1) = y_1$*

解. 利用直线方程点斜式, 可知

$$P_1(x) = y_0 + \frac{y_1 - y_0}{x_1 - x_0}(x - x_0)$$

此时, 插值节点为 x_0, x_1, 基函数设为 $1, (x - x_0)$, 组合系数为 $A_0 = y_0, A_1 = \frac{y_1 - y_0}{x_1 - x_0}$ □

考虑 $n = 2$ 的情况, 要求具有承袭性. 设 $g(x) = P_2(x) - P_1(x)$, 则 $g(x)$ 为次数不超过 2 的多项式, 且有

$$g(x_i) = P_2(x_i) - P_1(x_i) = y_i - y_i = 0, i = 0, 1$$

因此可对其进行因式分解, 有

$$g(x) = A_2(x - x_0)(x - x_1)$$
$$\Rightarrow P_2(x) = P_1(x) + A_2(x - x_0)(x - x_1)$$

故, 对于 $n = 2$ 而言, 插值节点为 x_0, x_1, x_2, 基函数为 $1, (x - x_0), (x - x_0)(x - x_1)$, 组合系数为 A_0, A_1, A_2. 插值多项式为

$$P_2(x) = A_0 + A_1(x - x_0) + A_2(x - x_0)(x - x_1)$$

类似地, 给定插值条件

$$N_n(x_i) = f(x_i), i = 0, 1, \cdots, n$$

, 插值节点为 $x_i, i = 0, 1, \cdots, n$, 基函数为 $1, (x - x_0), (x - x_0)(x - x_1), \cdots, (x - x_0)(x - x_1) \cdots (x - x_{n-1})$, 组合系数为 $A_i, i = 0, 1, \cdots, n$

下面需要讨论如何求解组合系数.

设 $A_n(x) = A_0 + A_1(x)(x - x_0) + A_2(x - x_0)(x - x_1) + \cdots + A_n(x - x_0)(x - x_1) \cdots (x - x_n)$, 利用插值条件

$$N_n(x_i) = f(x_i), i = 0, 1, \cdots, n$$

代入, 得线性方程组

$$\begin{pmatrix} 1 & 0 & \cdots & 0 \\ 1 & x_1 - x_0 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 1 & x_n - x_0 & \cdots & \prod_{i=0}^{n-1}(x_n - x_i) \end{pmatrix} \begin{pmatrix} A_0 \\ A_1 \\ \vdots \\ A_n \end{pmatrix} = \begin{pmatrix} f(x_0) \\ f(x_1) \\ \vdots \\ f(x_n) \end{pmatrix}$$

求解方程组, 可得

$$\begin{aligned} A_0 &= f(x_0) \\ A_1 &= \frac{f(x_1) - f(x_0)}{x_1 - x_0} \\ A_2 &= \frac{\frac{f(x_2)-f(x_0)}{x_2-x_0} - \frac{f(x_1)-f(x_0)}{x_1-x_0}}{x_2 - x_1} \\ &\vdots \end{aligned}$$

为简化计算, 总结上述规律, 给出下面关于差商的定义

2.3.2 差商

差商的定义

定义 2.3.1 (差商)**.** 称

$$f[x_0, x_k] = \frac{f(x_k) - f(x_0)}{x_k - x_0}$$

为函数 $f(x)$ 关于点 x_0, x_k 的一阶差商, 称

$$f[x_0, x_1, x_k] = \frac{f[x_0, x_k] - f[x_0, x_1]}{x_k - x_1}$$

为 $f(x)$ 关于点 x_0, x_1, x_k 的二阶差商. 一般地, 称

$$f[x_0, x_1, \cdots, x_k] = \frac{f[x_0, x_1, \cdots, x_{k-2}, x_k] - f[x_0, x_1, \cdots, x_{k-1}]}{x_k - x_{k-1}}$$

为 $f(x)$ 的 k 阶差商.

由差商定义可知: 高阶差商是两个低一阶差商的差商.

利用差商定义, 可知组合系数为:

$$\begin{aligned} A_0 &= f(x_0) = f[x_0] \\ A_1 &= f[x_0, x_1] \\ &\vdots \\ A_n &= f[x_0, x_1, \cdots, x_n] \end{aligned}$$

$$\begin{aligned} \Rightarrow N_n(x) =& f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) \\ &+ \cdots + f[x_0, x_1, \cdots, x_n](x - x_0)(x - x_1) \cdots (x - x_{n-1}) \end{aligned}$$

差商性质

差商与函数值有如下关系:

定理 2.3.1. 记 $\omega(x) = (x - x_0)(x - x_1) \cdots (x - x_n)$, 则

$$f[x_0, x_1, \cdots, x_n] = \sum_{i=0}^{n} \frac{f(x_i)}{\omega'(x_i)}$$

证明. 对于 $f(x)$, 使用 Lagrange 插值法, 可得:

$$L_n(x) = \sum_{i=0}^{n} f(x_i) l_i(x)$$

使用 Newton 插值法, 可得:

$$N_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + \cdots + f[x_0, x_1, \cdots, x_n](x - x_0)(x - x_1) \cdots (x - x_{n-1}) \tag{2.6}$$

由于插值多项式具有唯一性, 因此两种插值方法得到的结果相同, 即同次系数相等. 整理可得

$$\sum_{i=0}^{n} f(x_i) = f[x_0, x_1, \cdots, x_n](x - x_0)(x - x_1) \cdots (x - x_{n-1})$$

对 $\omega(x)$ 求导后, 原式得证. □

差商的值与节点的排列顺序无关, 即*差商具有对称性*. 用公式表示为:

$$f[x_0, \cdots, x_i, \cdots, x_j \cdots, x_n] = f[x_0, \cdots, x_j, \cdots, x_i \cdots, x_n]$$

设 $f(x)$ 在 $[a,b]$ 有 n 阶导数, 且 $x_0, x_1, \cdots, x_n \in [a,b]$, 则存在 $\xi \in (a,b)$, 使得

$$f[x_0, x_1, \cdots, x_n] = \frac{f^{(n)}(\xi)}{n!}$$

例 2.3.2. *若 $f(x) = 3x^4 + 4x^2 + 2x + 1$, 计算*

$$f[2^0, 2^1, 2^2, 2^3, 2^4], f[2^0, 2^1, 2^2, 2^3, 2^4, 2^5]$$

解.

$$f[2^0, 2^1, 2^2, 2^3, 2^4] = \frac{f^{(4)}(\xi)}{4!} = 3$$
$$f[2^0, 2^1, 2^2, 2^3, 2^4, 2^5] = \frac{f^{(5)}(\xi)}{5!} = 0$$

□

由前面的性质, 不难得到, 对于差商而言, 有

$$f[x_0.x_1, \cdots, x_n] = \frac{f[x_1, x_2, \cdots, x_n] - f[x_0, x_1, \cdots, x_{n-1}]}{x_n - x_0}$$

该性质表明在实际计算差商过程中, 可以使用列表法计算.

2.3.3 Newton 插值余项

定理 2.3.2. *Newton 插值多项式的余项为:*

$$R_n(x) = f[x_0, x_1, \cdots, x_n]\omega_{n+1}(x)$$

其中,

$$\omega_{n+1}(x) = (x - x_0)(x - x_1)\cdots(x - x_n) = \prod_{i=0}^{n}(x - x_i)$$

2.4 等距节点差商公式

2.4.1 差分定义

定义 2.4.1 (差分)**.** *设函数 $y = f(x)$ 在等距节点 $x_k = x_0 + kh (k = 0, 1, \cdots, n)$ 上的值 $f_k = f(x_k)$ 已知, 其中 h 为常数, 称为步长, 称偏差*

$$\Delta f_k = f_{k+1} - f_k$$
$$\nabla f_k = f_k - f_{k-1}$$
$$\delta f_k = f(x_k + h/2) - f(x_k - h/2) = f_{k+\frac{1}{2}} - f_{k-\frac{1}{2}}$$

分别称为 $f(x)$ 在 x_k 处以 h 为步长的向前差分, 向后差分, 中心差分. 符号 Δ, ∇, δ 分别称为向前差分算子, 向后差分算子, 中心差分算子.

利用一阶差分, 类似可定义二阶差分为

$$\Delta^2 f_k = \Delta f_{k+1} - \Delta f_k = f_{k+2} - 2f_{k+1} + f_k$$

, 一般地, m 阶差分为

$$\Delta^m f_k = \Delta^{m-1} f_{k+1} - \Delta^{m-1} f_k$$

2.4.2 差分的性质

定义不变算子 I 和移位算子 E, 即有

$$If_k = f_k, Ef_k = f_{k+1}$$

由差分定义, 可得 $\Delta = E - I, \nabla = I - E^{-1}, \delta = E^{\frac{1}{2}} - E^{-\frac{1}{2}}$

由不变算子和移位算子, 可得如下性质:

各阶差分均可用函数值表示, 即

$$\Delta^n f_k = (E-1)^n f_k = \sum_{j=0}^{n} (-1)^j \binom{n}{j} E^{n-j} f_k = \sum_{j=0}^{n} (-1)^j \binom{n}{j} f_{n+k-j}$$
$$\nabla^n f_k = (1-E^{-1})^n f_k = \sum_{j=0}^{n} (-1)^{n-j} \binom{n}{j} E^{j-n} f_k = \sum_{j=0}^{n} (-1)^{n-j} \binom{n}{j} f_{k+j-n}$$

其中 $\binom{n}{j} = \frac{n(n-1)\cdots(n-j+1)}{j!}$ 为二项式展开系数

差商与差分之间满足下面的关系. 例如, 对于向前差分, 由定义

$$f[x_k, x_{k+1}] = \frac{f_{k+1} - f_k}{x_{k+1} - x_k} = \frac{\Delta f_k}{h}$$
$$f[x_k, x_{k+1}, x_{k+2}] = \frac{f[x_{k+1}, x_{k+2}] - f[x_k, x_{k+1}]}{x_{k+2} - x_k} = \frac{1}{2h^2}\Delta^2 f_k$$

一般有

$$f[x_k, x_{k+1}, \cdots, x_{k+m}] = \frac{1}{m!}\frac{1}{h^m}\Delta^m f_k, m = 1, 2, \cdots, n \tag{2.7}$$

同理, 对于向后差分, 有

$$f[x_k, x_{k-1}, \cdots, x_{k-m}] = \frac{1}{m!}\frac{1}{h^m}\nabla^m f_k \tag{2.8}$$

利用差商的导数关系, 可得差分与导数的关系为

$$\Delta^n f_k = j^n f^{(n)}(\xi)$$

2.4.3 等距节点插值公式

利用 Newton 插值公式, 将差商用相应的差分替代, 即可得到等距节点插值公式.

若节点 $x_k = x_0 + kh, k = 0, 1, \cdots, n$, 要计算 x_0 附近点 x 的函数 $f(x)$ 的值, 令 $x = x_0 + th$, 其中 $0 \le t \le 1$, 于是有

$$\omega_{k+1}(x) = \prod_{j=0}^{k}(x - x_j) = t(t-1)\cdots(t-k)h^{k+1}$$

将该式与式 (2.7) 代入公式 (2.6), 可得

$$N_n(x_0 + th) = f_0 + t\Delta f_0 + \frac{t(t-1)}{2!}\Delta^2 f_0 + \cdots + \frac{t(t-1)\cdots(t-n+1)}{n!}\Delta^n f_0$$

上式称为 *Newton 前插公式*. 同时, 由于其使用 x_0 附近的点, 故又称为*表初公式*.

不难得到, 上式的余项可由式 (2.5) 得到

$$R_n(x) = \frac{t(t-1)\cdots(t-n)}{(n+1)!}h^{n+1}f^{(n+1)}(\xi), \xi \in (x_0, x_n)$$

类似地, 若要计算 x_n 附近的值 $f(x)$, 则可将 Newton 插值公式 (**??**) 按照倒序排列, 即 $x_n, x_{n-1}, \cdots, x_0$ 的次序. 此时有

$$N_n(x) = f(x_n) + f[x_n, x_{n-1}](x - x_n) + f[x_n, x_{n-1}, x_{n-2}](x - x_n)(x - x_{n-1}) + \cdots + f[x_n, x_{n-1}, \cdots, x_0](x - x_n)\cdots(x - x_1)$$

变换 $x = x_n - th(-1 \le t \le 0)$, 并利用公式 (2.8), 代入可得

$$N_n(x_n + th) = f_n + t\nabla f_n + \frac{t(t+1)}{2!}\nabla^2 f_n + \cdots + \frac{t(t+1)\cdots(t+n-1)}{n!}\nabla^n f_n$$

上式称为 *Newton* 后插公式或表末公式. 其余项为

$$R_n(x) = f(x) - N_n(x_n + th) = \frac{t(t+1)\cdots(t+n)h^{n+1}f^{(n+1)}(\xi)}{(n+1)!}, \xi \in (x_0, x_n)$$

2.5 Hermite 插值

2.5.1 引入, Hermite 插值多项式的存在唯一性

在有些情况下, 不仅要求节点上函数值相等, 同时要求节点上导数值相等, 甚至要求高阶导数值相等. 满足该要求的插值多项式就是 *Hermite* 插值多项式.

仅讨论函数值与导数值个数相等情况. 设在节点 $a \le x_0 < x_1 < \cdots < x_n \le b$ 上, $y_i = f(x_i), m_i = f'(x_i)(i = 0, 1, \cdots, n)$, 要求插值多项式 $H(x)$ 满足条件

$$H(x_i) = y_i, H'(x_i) = m_i, (i = 0, 1, \cdots, n)$$

给出 $(2n+2)$ 个条件, 可唯一确定一个次数不超过 $2n+1$ 的多项式 H_{2n+1}, 其形式为

$$H_{2n+1}(x) = a_0 + a_1 x + \cdots + a_{2n+1}x^{2n+1}$$

2.5.2 Hermite 插值多项式构造

Lagrange 型 Hermite 插值多项式

先求插值基函数 $\alpha_i(x)$ 和 $\beta_i(x), i = 0, 1, \cdots, n$, 共有 $2n+2$ 个, 每一个都是 $2n+1$ 次多项式, 且满足条件:

$$\begin{cases} \alpha_i(x_k) = \delta_{ik} = \begin{cases} 0, j \ne k, \\ 1, j = k, \end{cases} & , \alpha_i'(x_k) = 0 \\ \beta_i(x_k) = 0, \beta_i'(x_k) = \delta_{ik} \end{cases}$$

因此, 满足插值条件的插值多项式 $H(x) = H_{2n+1}(x)$ 可用插值基函数表示为

$$H_{2n+1}(x) = \sum_{i=0}^{n} [y_i \alpha_i(x) + m_i \beta_i(x)]$$

显然有

$$H_{2n+1}(x_k) = y_k, H'_{2n+1}(x_k) = m_k, k = 0, 1, \cdots, n$$

为构造基函数, 使用 Lagrange 插值基函数 $l_i(x)$, 令

$$\alpha_i(x) = (ax + b) l_i^2(x)$$

其中 $l_i(x)$ 是式 (**??**) 所表示的基函数. 由上述条件, 有

$$\begin{aligned} &\alpha_i(x_i) = (ax_i + b) l_i^2(x_i) = 1, \\ &\alpha'_i(x_i) = l_i(x_i) \left[a l_i(x_i) + 2(ax_i + b) l'_i(x_i) \right] = 0 \end{aligned}$$

整理可得

$$\begin{cases} ax_i + b = 1 \\ a + 2l'_i(x_i) = 0 \end{cases}$$

解得

$$a = -2l'_i(x_i), b = 1 + 2x_i l'_i(x_i)$$

由于

$$l_i(x) = \frac{(x - x_0) \cdots (x - x_{i-1})(x - x_{i+1}) \cdots (x - x_n)}{(x_i - x_0) \cdots (x_i - x_{i-1})(x_i - x_{i+1}) \cdots (x_i - x_n)}$$

取对数后求导, 得

$$l'_i(x_i) = \sum_{\substack{k=0 \\ k \neq i}}^{n} \frac{1}{x_i - x_k}$$

于是可得

$$\alpha_i(x) = \left[1 - 2(x - x_i) \sum_{\substack{k=0 \\ k \neq i}}^{n} \frac{1}{x_i - x_k} \right] l_i^2(x) \tag{2.9}$$

同理可得

$$\beta_i(x) = (x - x_i) l_i^2(x) \tag{2.10}$$

扩展: 下面证明满足插值条件得插值多项式是唯一的.

证明. 使用反证法, 设 $H_{2n+1}(x)$ 和 $\overline{H}_{2n+1}(x)$ 均满足条件, 则有

$$\varphi(x) = H_{2n+1}(x) - \overline{H}_{2n+1}(x)$$

其在每个节点上均有二重根, 故 $\varphi(x)$ 有 $2n+2$ 重根, 但 $\varphi(x)$ 是不高于 $2n+1$ 次的多项式, 故 $\varphi \equiv 0$.

唯一性得证. □

利用 Lagrange 插值余项证明方法, 可得若 $f(x)$ 在 (a,b) 内的 $2n+2$ 阶导数存在, 则插值余项为

$$R(x) = f(x) - H_{2n+1}(x) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!}\omega_{n+1}^2(x) \tag{2.11}$$

其中 $\xi \in (a,b)$ 且与 x 有关.

考虑特殊情况 $n=1$, 取节点为 x_k, x_{k+1}, 插值多项式为 $H_3(x)$, 满足条件

$$\begin{cases} H_3(x_k) = y_k, H_3(x_{k+1}) = y_{k+1} \\ H_3'(x_k) = m_k, H_3'(x_{k+1}) = m_{k+1} \end{cases} \tag{2.12}$$

相应的插值基函数为 $\alpha_k(x), \alpha_{k+1}(x), \beta_k(x), \beta_{k+1}(x)$, 且满足条件

$$\begin{gathered} \alpha_k(x_k) = 1, \alpha_k(x_{k+1}) = 0, \alpha_k'(x_k) = \alpha_k'(x_{k+1}) = 0, \\ \alpha_{k+1}(x_k) = 0, \alpha_{k+1}(x_{k+1}) = 1, \\ \alpha_{k+1}'(x_k) = \alpha_{k+1}'(x_{k+1}) = 0, \\ \beta_k(x_k) = \beta_k(x_{k+1}) = 0, \\ \beta_k'(x_k) = 1, \beta_k'(x_{k+1}) = 0, \\ \beta_{k+1}(x_k) = \beta_{k+1}(x_{k+1}) = 0, \\ \beta_{k+1}'(x_k) = 0, \beta_{k+1}'(x_{k+1}) = 1 \end{gathered}$$

根据式 (2.9) 和 (2.10), 可得

$$\begin{cases} \alpha_k(x) = \left(1 + 2\frac{x-x_k}{x_{k+1}-x_k}\right)\left(\frac{x-x_{k+1}}{x_k-x_{k+1}}\right)^2, \\ \alpha_{k+1}(x) = \left(1 + 2\frac{x-x_{k+1}}{x_k-x_{k+1}}\right)\left(\frac{x-x_k}{x_{k+1}-x_k}\right)^2; \end{cases}$$

$$\begin{cases} \beta_k(x) = (x-x_k)\left(\frac{x-x_{k+1}}{x_k-x_{k+1}}\right)^2, \\ \beta_{k+1}(x) = (x-x_{k+1})\left(\frac{x-x_k}{x_{k+1}-x_k}\right)^2 \end{cases}$$

满足式 (2.12) 的插值多项式是

$$H_3(x) = y_k\alpha_k(x) + y_{k+1}\alpha_{k+1}(x) + m_k\beta_k(x) + m_{k+1}\beta_{k+1}(x)$$

由式 (2.11) 可得其余项为

$$R_3(x) = \frac{1}{4!}f^{(4)}(\xi)(x-x_k)^2(x-x_{k+1})^2$$

Newton 型 Hermite 插值多项式

若给定插值条件

$$H(x_0) = f(x_0), H'(x_0) = f'(x_0), \cdots, H^{(m)}(x_0) = f^{(m)}(x_0)$$

利用 Newton 插值法, 其节点为 $x_0, x_0, \cdots, x_0$, 基函数分别为 $1, (x-x_0), (x-x_0)^2, \cdots, (x-x_0)^m$, 组合系数为 $f(x_0), f[x_0, x_0], \cdots, f[x_0, x_0, \cdots, x_0]$

考虑差商与导数的性质, 有

$$f[x_0, x_0, \cdots, x_0] = \frac{f^{(n)}}{n!}$$

故容易得到, Newton 型 Hermite 插值多项式为

$$H(x) = f(x_0) + f'(x_0)(x-x_0) + \cdots + \frac{f^{(m)}}{m!}(x-x_0)^m$$

例 2.5.1. 给定函数表 求插值多项式 $P_4(x)$

x_i	3	4	6
y_i	6	0	2
y_i'	1		-1

解. 利用 Newton 法, 列差商表如下所示 将差商表计算可得

$$P_4 = 6+1(x-3)+(-7)(x-3)^2+\frac{28}{9}(x-3)^2(x-4)+\left(-\frac{38}{27}\right)(x-3)^2(x-4)(x-6)$$

其插值余项为

$$R_4(x) = f[3,3,4,6,6,x](x-3)^2(x-4)(x-6)^2$$

□

表 2.1: 差商表

x_k	$f(x_k)$	一阶差商	二阶差商	三阶差商	四阶差商
3	6				
3	6	$f[3,3]=1$			
4	0	$f[3,4]$	$f[3,3,4]$		
6	2	$f[4,6]$	$f[3,4,6]$	$f[3,3,4,6]$	
6	2	$f[6,6]=-1$	$f[4,6,6]$	$f[3,4,6,6]$	$f[3,3,4,6,6]$

2.6 分段低次插值

2.6.1 多项式插值的 Runge 现象

例 2.6.1. 在 $[-5,5]$ 考察函数

$$f(x)=\frac{1}{1+x^2}$$

的 $L_n(x)$

使用下面的代码:

```
# Runge现象演示 Exercise2-3.py

import numpy as np
import matplotlib.pyplot as plt
from scipy.interpolate import lagrange

# 定义函数
def f(x):
    return 1 / (1 + x ** 2)

# 生成插值节点
n = 11
x = np.linspace(-5, 5, n)
y = f(x)

# 生成插值多项式
```

```
poly = lagrange(x, y)

# 生成等距节点
x_interp = np.linspace(-5, 5, 1000)
y_interp = f(x_interp)

# 生成插值函数
y_poly = poly(x_interp)

# 绘图
plt.plot(x_interp, y_interp)
plt.plot(x_interp, y_poly)
plt.plot(x, y, 'o')
plt.show()
```

生成图像如图 (2.2) 所示

可以看到, 随着节点的增多, 插值多项式在节点处出现振荡. 这就是多项式插值的 *Runge* 现象. 为解决这一问题, 采用分段插值的方法.

2.6.2 分段线性插值

在每个区间 $[x_i, x_{i+1}]$ 上, 用一阶多项式逼近 $f(x)$, 即

$$f(x) = P_1(x) = \frac{x - x_{i+1}}{x_i - x_{i+1}} y_i + \frac{x - x_i}{x_{i+1} - x_i} y_{i+1}, x \in [x_i, x_{i+1}]$$

若用插值基函数表示, 若整个节点在 $[a, b]$ 之间, 则在整个区间的 $P_1(x)$ 可以表示为

$$P_1(x) = \sum_{i=0}^{n} y_i l_i(x)$$

其中 $l_i(x)$ 满足条件 $l_i(x_k) = \delta_{ik}, i, k = 0, 1, \cdots, n$, 其形式为

$$l_i(x) = \begin{cases} \frac{x - x_{i-1}}{x_i - x_{i-1}}, & x_{i-1} \le x \le x_i (i = 0\text{略去}), \\ \frac{x_i - x_{i+1}}{x - x_{i+1}}, & x_i \le x \le x_{i+1} (i = n\text{略去}), \\ 0, & x \in [a, b], x \notin [x_{i-1}, x_{i+1}]. \end{cases}$$

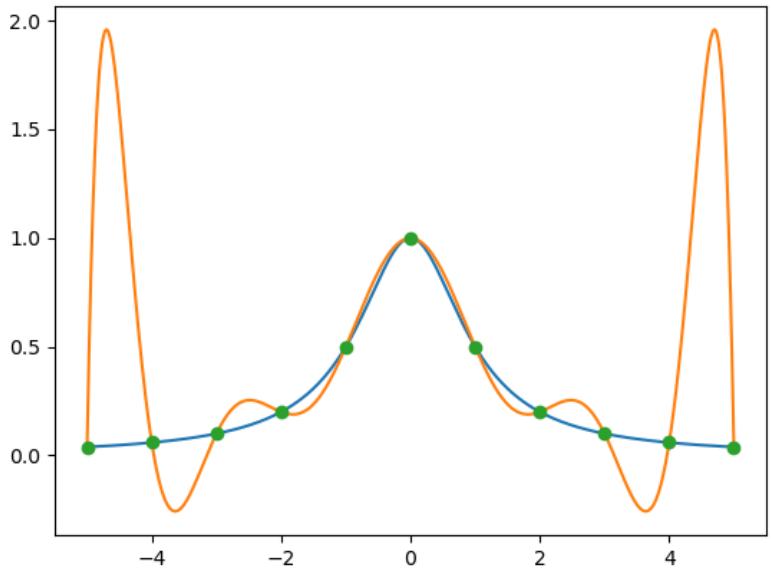

图 2.2: Runge 现象

不难发现, 基函数 $l_i(x)$ 在 x_i 附近不为 0, 其他地方均为零, 这种性质称为局部非零性质.

关于分段线性插值的误差估计, 给出如下定理 (暂不做证明)

定理 2.6.1. *若 $f(x)$ 在 $[a,b]$ 上二阶连续可微, 则分段线性插值 $P(x)$ 余项有如下估计:*

$$|R(x)| = |f(x) - P(x)| \leq \frac{h^2}{8} M$$

其中,

$$h = \max_{0 \leq i \leq n-1} (x_{i+1} - x_i)$$

$$M = \max_{a \leq x \leq b} |f''(x)|$$

下面的程序, 演示了分段线性插值 (图像如图 2.3所示). 可以看到, 分段线性插值在节点处不光滑. 为了改善该问题, 我们可以借助于 Hermite 插值, 即下面的分段三次 *Hermite* 插值.

```python
# 分段线性插值演示 Exercise2-4.py

import numpy as np
import matplotlib.pyplot as plt

# 定义函数
def f(x):
    return np.sin(x)

# 生成插值节点
n = 6
x = np.linspace(0, 2*np.pi, n)
y = f(x)

# 生成分段线性插值函数
x_interp = np.linspace(0, 2*np.pi, 1000)
y_interp = np.zeros_like(x_interp)
for i in range(len(x_interp)):
    if x_interp[i] <= x[0]:
        y_interp[i] = y[0]
    elif x_interp[i] >= x[-1]:
        y_interp[i] = y[-1]
    else:
        j = np.searchsorted(x, x_interp[i])
        x_left = x[j-1]
        x_right = x[j]
        y_left = y[j-1]
        y_right = y[j]
        slope = (y_right - y_left) / (x_right - x_left)
        y_interp[i] = y_left + slope * (x_interp[i] - x_left)

# 绘图
plt.plot(x_interp, f(x_interp))
```

```
34 plt.plot(x_interp, y_interp)
35 plt.plot(x, y, 'o')
36 plt.show()
```

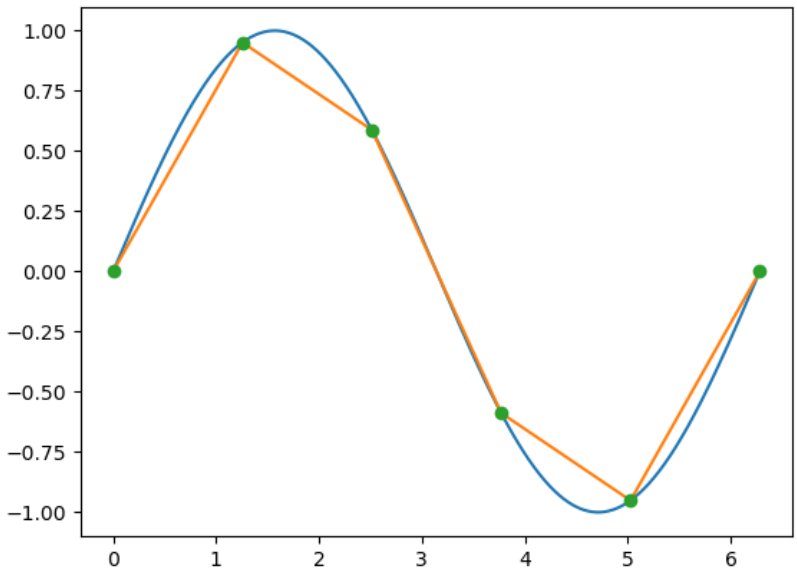

图 2.3: $\sin x$ 的分段线性插值

2.6.3 分段三次 Hermite 插值

给定节点 $a \le x_0 < x_1 < \cdots \le b$, $f(x)$ 在节点 x_i 上的函数值及导数值分别为 y_i, m_i. 在每个子区间 $[x_i, y_i]$ 上作两点三次 Hermite 插值, 插值函数为

$$H(x) = \sum_{i=0}^{n} [y_i \varphi_i(x) + m_i \psi_i(x)] \tag{2.13}$$

其中基函数为

$$\varphi_i(x)=\begin{cases}\left(\frac{x-x_{i-1}}{x_i-x_{i-1}}\right)^2\left(1+2\frac{x-x_i}{x_{i-1}-x_i}\right), & x_{i-1}\le x\le x_i,\\ \left(\frac{x-x_{i+1}}{x_i-x_{i+1}}\right)^2\left(1+2\frac{x-x_i}{x_{i+1}-x_i}\right), & x_i\le x\le x_{i+1},\\ 0, & x\notin[x_{i-1},x_{i+1}]\end{cases},(i=1,2,\cdots,n-1).$$

$$\psi_i(x)=\begin{cases}(x-x_i)\left(\frac{x-x_{i-1}}{x_i-x_{i-1}}\right)^2, & x_{i-1}\le x\le x_i,\\ (x-x_i)\left(\frac{x-x_{i+1}}{x_i-x_{i+1}}\right)^2, & x_i\le x\le x_{i+1},\\ 0, & x\notin[x_{i-1},x_{i+1}]\end{cases}$$

由三次 Hermite 插值的余项可以估计分段 Hermite 插值的余项. 设 $H(x)$ 是给定节点

$$a=x_0<x_1<\cdots<x_n=b$$

上的分段三次 Hermite 插值函数, $f(x)\in C^4[a,b]$, 则 $f(x)$ 与 $H(x)$ 的误差限为

$$|R(x)|\le|f(x)-H(x)|\le\frac{h^4}{384}M_4$$

其中,

$$h=\max_{0\le i\le n-1}|x_{i+1}-x_i|,$$
$$M=\max_{a\le x\le b}\left|f^{(4)}(x)\right|$$

下面的代码演示了分段三次 Hermite 插值, 并绘制了图 2.4. 可以看到, 与线性插值 (图 2.3) 相比, 三次 Hermite 插值具有光滑性.

扩展: 在该代码中使用了 Python 的库函数 PchipInterpolator(), 这个函数会在内部自动计算导数值, 因此与前面所讨论的理论在形式上可能有些许不同.

```
1  # 分段三次Hermite插值演示 Exercise2-5.py
2
3  import numpy as np
4  import matplotlib.pyplot as plt
5  from scipy.interpolate import PchipInterpolator
6
7  # 定义函数
```

```
8  def f(x):
9      return np.sin(x)
10
11 # 生成插值节点
12 n = 5
13 x = np.linspace(0, 2*np.pi, n)
14 y = f(x)
15
16 # 生成分段三次Hermite插值函数
17 x_interp = np.linspace(0, 2*np.pi, 1000)
18 y_interp = PchipInterpolator(x, y)(x_interp)
19
20 # 绘图
21 plt.plot(x_interp, f(x_interp))
22 plt.plot(x_interp, y_interp)
23 plt.plot(x, y, 'o')
24 plt.show()
```

2.7 三次样条插值

2.7.1 三次样条函数

设对 $y = f(x)$ 在区间 $[a, b]$ 上给定一组节点 $a = x_0 < x_1 < \cdots < x_n = b$ 和相应的函数值 $y_0, y_1, \cdots, y_n$, 如果 $s(x)$ 具有如下性质:

1. 在每个子区间 $[x_{i-1}, x_i], i = 1, 2, \cdots, n$ 上 $s(x)$ 是不高于三次的多项式;
2. $s(x), s'(x), s''(x)$ 在 $[a, b]$ 上连续, 则称 $s(x)$ 是三次样条函数. 若再有
3. $s(x_i) = f(x_i), i = 0, 1, \cdots, n$, 则称 $s(x)$ 为 $y = f(x)$ 的三次样条插值函数.

2.7.2 三次样条插值函数构造

首先对三次样条插值的存在性进行证明

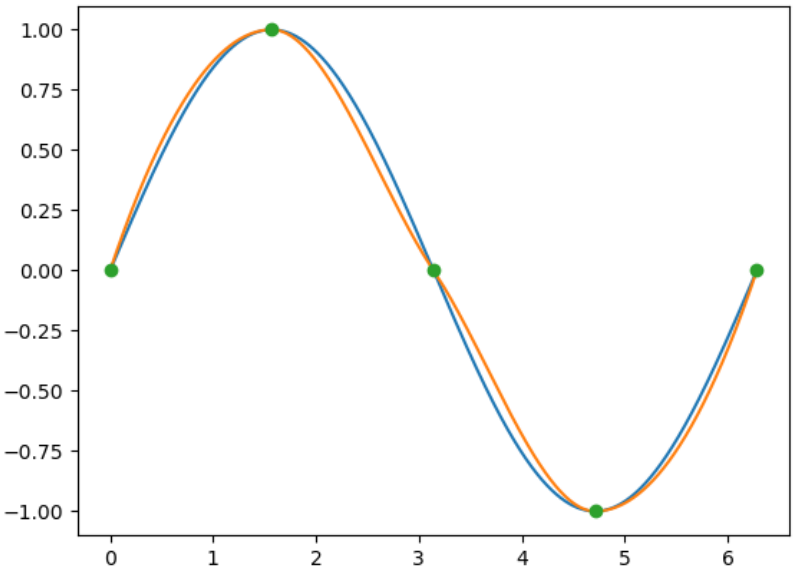

图 2.4: $\sin x$ 的三次 Hermite 插值

证明. 设有 n 个区间, 对于每个区间 S_i, 插值函数为

$$S_i(x) = a_i + b_i x + c_i x^2 + d_i x^3, i = 0, 1, \cdots, n-1$$

对于每一个小区间, 两个端点给定, 总区间共有 $2n$ 个条件.
对于节点 x_i, 其一阶导数连续, 即

$$S'_{i-1}(x_i) = S'_i(x_i)$$

共 $(n-1)$ 个条件.
同理, 其二阶导数连续, 有 $(n-1)$ 个条件.
因此, 给定条件共 $(4n-2)$ 个, 小于 $4n$, 因此解存在但不唯一. □

为保证解的唯一性, 需要补充边界条件. 常见的边界条件有如下四种:
固支边界条件 (D-1 样条):

$$\begin{cases} S'(x_0) = f'(x_0) = m_0 \\ S'(x_n) = f'(x_n) = m_n \end{cases}$$

弯矩边界条件 (D-2 样条):

$$\begin{cases} S''(x_0) = f''(x_0) = M_0 \\ S''(x_n) = f''(x_n) = M_n \end{cases}$$

自然边界条件 (自然样条):

$$\begin{cases} S''(x_0) = 0 \\ S''(x_n) = 0 \end{cases}$$

周期边界条件 (周期样条):

$$\begin{cases} S(x_0) = S(x_n) \\ S'(x_0) = S'(x_n) \\ S''(x_0) = S''(x_n) \end{cases}$$

2.7.3 三转角方程

假定 $S'(x)$ 在节点 x_i 的值为 $S'(x_i) = m_i, i = 0, 1, \cdots, n$, 由式 (2.13) 可得

$$S(x) = \sum_{i=0}^{n} [y_i \varphi_i(x) + m_i \psi_i(x)]$$

显然, 该表达式在 $[a, b]$ 区间连续, 且满足插值条件. 而式中的导数值 m_i 未知, 因此可利用导数的连续条件:

$$S''(x_i - 0) = S''(x_i + 0), i = 1, 2, \cdots, n-1$$

以及边界条件确定.

下面考虑 $S(x)$ 在 $[x_i, x_{i+1}]$ 的表达式

$$\begin{aligned} S(x) = {} & \frac{(x - x_{i+1})^2 [h_i + 2(x - x_i)]}{h_i^3} y_i + \frac{(x - x_i)^2 [h_i + 2(x_{i+1} - x)]}{h_i^3} y_{i+1} \\ & + \frac{(x - x_{i+1})^2 (x - x_i)}{h_i^2} m_i + \frac{(x - x_i)^2 (x - x_{i+1})}{h_i^2} m_{i+1} \end{aligned}$$

这里 $h_i = x_{i+1} - x_i$, 对 $S(x)$ 求二阶导数, 得

$$\begin{aligned} S''(x) = {} & \frac{6x - 2x_i - 4x_{i+1}}{h_i^2} m_i + \frac{6x - 4x_i - 2x_{i+1}}{h_i^2} m_{i+1} \\ & + \frac{6(x_i + x_{i+1} - 2x)}{h_i^3} (y_{i+1} - y_i) \end{aligned}$$

于是

$$S''(x_i+0) = -\frac{4}{h_i}m_i - \frac{2}{h_i}m_{i+1} + \frac{6}{h_i^2}(y_{i+1}-y_i)$$

同理, 可得 $S''(x)$ 在区间 $[x_{i-1}, x_i]$ 得表达式为

$$\begin{aligned} S''(x) = &\frac{6x-2x_{i-1}-4x_i}{h_{i-1}^2}m_{i-1} + \frac{6x-4x_{i-1}-2x_i}{h_{i-1}^2}m_i \\ &+ \frac{6(x_{i-1}+x_i-2x)}{h_{i-1}^2}(y_i-y_{i-1}) \end{aligned}$$

及

$$S''(x_i-0) = \frac{2}{H_{i-1}}m_{i-1} + \frac{4}{h_{i-1}}m_i - \frac{6}{h_{i-1}^2}(y_i-y_{i-1})$$

利用二阶导数连续性, 化简可得结果为

$$\lambda_i m_{i-1} + 2m_i + \mu_i m_{i+1} = g_i, i = 1, 2, \cdots, n-1 \tag{2.14}$$

其中,

$$\begin{aligned} &\lambda_i = \frac{h_i}{h_{i-1}+h_i}, \mu_i = \frac{h_{i-1}}{h_{i-1}+h_i} \\ &g_i = 3(\lambda_i f[x_{i-1}, x_i] + \mu_i f[x_i, x_{i+1}]) \end{aligned}$$

方程是关于未知数 $m_0, m_1, \cdots, m_n$ 的 $n-1$ 个方程, 若加上固支边界条件 $m_0 = f_0', m_n = f_n'$, 则方程为含有 $m_1, \cdots, m_{n-1}$ 的 $(n-1)$ 个方程, 使用矩阵形式可表示为

$$\begin{pmatrix} 2 & \mu_1 & 0 & \cdots & \cdots & 0 \\ \lambda_2 & 2 & \mu_2 & \ddots & & \vdots \\ 0 & \lambda_3 & 2 & \mu_3 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \ddots & 0 \\ 0 & & \ddots & \lambda_{n-2} & 2 & \mu_{n-2} \\ 0 & \cdots & \cdots & 0 & \lambda_{n-1} & 2 \end{pmatrix} \begin{pmatrix} m_1 \\ m_2 \\ m_3 \\ \vdots \\ m_{n-2} \\ m_{n-1} \end{pmatrix} = \begin{pmatrix} g_1 - \lambda_1 f_0' \\ g_2 \\ \vdots \\ g_{n-2} \\ g_{n-1} - \mu_{n-1} f_n' \end{pmatrix}$$

如果边界条件为弯矩边界条件 (或特殊情况下的自然边界条件), 则方程

组为

$$\begin{pmatrix} 2 & 1 & 0 & \cdots & \cdots & 0 \\ \lambda_1 & 2 & \mu_1 & \ddots & & \vdots \\ 0 & \lambda_2 & 2 & \mu_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \ddots & 0 \\ \vdots & & \ddots & \lambda_{n-1} & 2 & \mu_{n-1} \\ 0 & \cdots & \cdots & 0 & 1 & 2 \end{pmatrix} \begin{pmatrix} m_0 \\ m_1 \\ m_2 \\ \vdots \\ m_{n-1} \\ m_n \end{pmatrix} = \begin{pmatrix} g_0 \\ g_1 \\ g_2 \\ \vdots \\ g_{n-1} \\ g_n \end{pmatrix}$$

若采用周期性边界条件, 则

$$m_0 = m_n$$

从而整理得方程组为

$$\begin{pmatrix} 2 & \mu_1 & 0 & \cdots & 0 \\ \lambda_2 & 2 & \mu_2 & \ddots & \vdots \\ 0 & \lambda_3 & \ddots & \ddots & 0 \\ \vdots & \ddots & \ddots & 2 & \mu_{n-1} \\ 0 & \cdots & 0 & \lambda_n & 2 \end{pmatrix} \begin{pmatrix} m_1 \\ m_2 \\ \vdots \\ m_{n-1} \\ m_n \end{pmatrix} = \begin{pmatrix} g_1 \\ g_2 \\ \vdots \\ g_{n-1} \\ g_n \end{pmatrix}$$

上述方程组当中, 每个方程都联系三个 m_i, 故称为*三转角方程*. 同时, 三个方程组的系数矩阵都为严格对角占优矩阵, 故方程有唯一解.

扩展:

定义 2.7.1 (严格对角占优矩阵)**.** *若方阵* $A = (a_{ij}) \in R^{n\times n}$, *满足*

$$|a_{ii}| > \sum_{j=1, j\neq i}^{n} |a_{ij}|, i = 1, 2, \cdots, n$$

称 A *为*严格对角占优矩阵

2.7.4 三弯矩方程

设函数 $f(x)$ 是定义在区间 $[a, b]$ 上的一个二次连续可微函数, 节点 $a = x_0 < x_1 < \cdots < x_n = b$, 令

$$M_i = S''(x_i), i = 0, 1, \cdots, n$$

其中 $S(x)$ 在每一个小区间 $[x_i, x_{i+1}], i = 0, 1, \cdots, n-1$ 上都是三次多项式, 故 $S''(x)$ 在 $[x_i, x_{i+1}]$ 的表达式为:

$$S_i''(x) = M_i \frac{x_{i+1} - x}{h_{i+1}} + M_{i+1} \frac{x - x_i}{h_{i+1}}$$

其中, $h_{i+1} = x_{i+1} - x_i$, 将上式做两次积分, 得

$$\begin{aligned} S_i'(x) &= -M_i \frac{(x_{i+1} - x_i)^2}{2h_{i+1}} + M_{i+1} \frac{(x - x_i)^2}{2h_{i+1}} + A_i \\ S_i(x) &= M_i \frac{(x_{i+1} - x)^3}{6h_{i+1}} + M_{i+1} \frac{(x - x_i)^3}{6h_{i+1}} + A_i(x - x_{i+1}) + B_i \end{aligned}$$

其中, A_i, B_i 为积分常数. 由插值条件并整理可得

$$\begin{cases} A_i = \frac{y_{i+1} - y_i}{h_{i+1}} - \frac{h_{i+1}}{6}(M_{i+1} - M_i) \\ B_i = y_{i+1} - \frac{M_{i+1}}{6} h_{i+1}^2 \end{cases}$$

将其代入, 可得

$$\begin{aligned} S_i(x) = {} & M_i \frac{(x_{i+1} - x)^3}{6h_{i+1}} + M_{i+1} \frac{(x - x_i)^3}{6h_{i+1}} \\ & + \left(y_i - \frac{M_i}{6} h_{i+1}^2 \right) \frac{x_{i+1} - x}{h_{i+1}} + \left(y_{i+1} - \frac{M_{i+1}}{6} h_{i+1}^2 \right) \frac{x - x_i}{h_{i+1}}, i = 0, 1, \cdots, n-1 \end{aligned}$$

对上式进行微分, 有

$$\begin{aligned} S_i'(x) &= -M_i \frac{(x_{i+1} - x)^2}{2h_{i+1}} + M_{i+1} \frac{(x - x_i)^2}{2h_{i+1}} + \frac{y_{i+1} - y_i}{h_{i+1}} - \frac{h_{i+1}}{6}(M_{i+1} - M_i) \\ S_{i-1}'(x) &= -M_{i-1} \frac{(x_i - x)^2}{2h_i} + M_i \frac{(x - x_{i-1})^2}{2h_i} + \frac{y_i - y_{i-1}}{h_i} - \frac{h_i}{6}(M_i - M_{i-1}) \\ & i = 1, 2, \cdots, n-1 \end{aligned}$$

因此有

$$\begin{aligned} S_{i-1}'(x_i) &= \frac{h_i}{3} M_i + \frac{y_i - y_{i-1}}{h_i} + \frac{h_i}{6} M_{i-1} \\ S_i'(x_i) &= \frac{h_{i+1}}{3} M_i + \frac{y_{i+1} - y_i}{h_{i+1}} + \frac{h_{i+1}}{6} M_{i+1} \end{aligned}$$

由于 $S_{i-1}'(x_i) = S_i'(x_i)$, 从而有

$$h_i M_{i-1} + 2(h_i + h_{i+1}) M_i + h_{i+1} M_{i+1} = 6 \left(\frac{y_{i+1} - y_i}{h_{i+1}} - \frac{y_i - y_{i-1}}{h_i} \right), i = 1, 2, \cdots, n-1$$

记

$$\mu_i = \frac{h_{i+1}}{h_i + h_{i+1}}$$
$$\lambda_i = 1 - \lambda_i$$
$$d_i = 6\left[\frac{y_{i+1} - y_i}{h_{i+1}} - \frac{y_i - y_{i-1}}{h_i}\right] / (h_i + h_{i+1}) = 6f[x_{i-1}, x_i, x_{i+1}]$$

可将上式改写为

$$\lambda_i M_{i-1} + 2M_i + \mu_i M_{i+1} = d_i, i = 1, 2, \cdots, n-1$$

可以发现, 上式与式 (2.14) 具有相同的形式, 因此所得到的线性方程组的形式也与上面相同.

对于固支边界条件, 给定两端点导数值 $S'(x_0) = y'_0, S'(x_n) = y'_n$, 有

$$S'_0(x_0) = \frac{y_1 - y_0}{h_1} - \frac{h_1}{3}M_0 - \frac{h_1}{6}M_1 = y'_0 = f[x_0, x_0]$$
$$S'_{n-1}(x_n) = \frac{y_n - y_{n-1}}{h_n} + \frac{h_n}{6}M_{n-1} + \frac{h_n}{3}M_n = y'_n = f[x_n, x_n]$$

于是可得

$$2M_0 + M_1 = \frac{6}{h_1}\left(\frac{y_1 - y_0}{h_1} - y'_0\right) = 6f[x_0, x_0, x_1]$$
$$M_{n-1} + 2M_n = \frac{6}{h_n}\left(y'_n - \frac{y_n - y_{n-1}}{h_n}\right) = 6f[x_{n-1}, x_n, x_n]$$

将其补充为方程组第一个和最后一个方程, 即可得到三弯矩方程为

$$\begin{pmatrix} 2 & 1 & & & & & \\ \lambda_1 & 2 & \mu_1 & & & & \\ & \lambda_2 & 2 & \mu_2 & & & \\ & & & \ddots & & & \\ & & & \lambda_{n-1} & 2 & \mu_{n-1} \\ & & & & 1 & 2 \end{pmatrix} \begin{pmatrix} M_0 \\ M_1 \\ M_2 \\ \vdots \\ M_{n-1} \\ M_n \end{pmatrix} = \begin{pmatrix} d_0 \\ d_1 \\ d_2 \\ \vdots \\ d_{n-1} \\ d_n \end{pmatrix}$$

其中,

$$d_0 = 6f[x_0, x_0, x_1]$$
$$d_n = 6f[x_{n-1}, x_n, x_n]$$
$$d_i = 6f[x_{i-1}, x_i, x_{i+1}], i = 1, 2, \cdots, n-1$$

对于弯矩边界条件, 给定 $M_0 = y_0'', M_n = y_n''$, 方程组可整理为

$$\begin{pmatrix} 2 & \mu_1 & & & & \\ \lambda_2 & 2 & \mu_2 & & & \\ & \lambda_3 & 2 & \mu_3 & & \\ & & & \ddots & & \\ & & & \lambda_{n-2} & 2 & \mu_{n-2} \\ & & & & \lambda_{n-1} & 2 \end{pmatrix} \begin{pmatrix} M_1 \\ M_2 \\ M_3 \\ \vdots \\ M_{n-2} \\ M_{n-1} \end{pmatrix} = \begin{pmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_{n-2} \\ d_{n-1} \end{pmatrix}$$

其中,

$$\begin{aligned} d_1 &= 6f[x_0, x_1, x_2] - \lambda_1 f''(x_0) \\ d_{n-1} &= 6f[x_{n-2}, x_{n-1}, x_n] - \mu_{n-1} f''(x_n) \\ d_i &= 6f[x_{i-1}, x_i, x_{i+1}], i = 2, \cdots, n-2 \end{aligned}$$

将上述方程组当中的 $M_n = M_0 = 0$, 可得自然边界条件, 不再赘述.

对于周期样条, 使用类似的方法, 可得方程组

$$\begin{pmatrix} 2 & \mu_1 & & & & \lambda_1 \\ \lambda_2 & 2 & \mu_2 & & & \\ & \lambda_3 & 2 & \mu_3 & & \\ & & & \ddots & & \\ & & & \lambda_{n-2} & 2 & \mu_{n-2} \\ \mu_n & & & & \lambda_n & 2 \end{pmatrix} \begin{pmatrix} M_1 \\ M_2 \\ M_3 \\ \vdots \\ M_{n-1} \\ M_n \end{pmatrix} = \begin{pmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_{n-1} \\ d_n \end{pmatrix}$$

其中,

$$d_i = 6f[x_{i-1}, x_i, x_{i+1}], i = 1, 2, \cdots, n$$

可以验证, 上述系数矩阵也满足严格对角占优的定义.

2.7.5 三次样条插值函数的收敛性 *

本部分不做证明, 只做介绍.

定义 2.7.2 (一致范数)**.** *设函数 $f(x)$ 是区间 $[a, b]$ 上的连续函数, 则记*

$$\|f\|_\infty = \max_{a \le x \le b} |f(x)|$$

为函数 $f(x)$ 的一致范数

定理 2.7.1. 设被插值函数 $f(x) \in C^4[a,b]$, $S(x)$ 为满足自然边界条件的三次样条插值函数, 则在插值区间 $[a,b]$ 上成立余项估计式

$$\left\|f^{(k)} - S^{(k)}\right\|_\infty \leq c_k h^{4-k}\left\|f^{(4)}\right\|_\infty, k = 0,1,2$$

其中,

$$h = \max_{0\leq i\leq n-1} h_i, h_i = x_{i+1} - x_i,$$
$$c_0 = \frac{1}{16}, c_1 = c_2 = \frac{1}{2}$$

最后, 通过一个三次样条插值的程序结束这一章. 对于 Python 程序而言, 我们调用 `CubicSpline()` 函数进行样条插值. 函数默认是采用自然边界条件, 即得到图 2.5所示:

```python
# 三次样条插值演示(自然边界条件) Exercise2-6.py

import numpy as np
from scipy.interpolate import CubicSpline
import matplotlib.pyplot as plt

# 创建一些数据点
x = np.array([0, 1, 2, 3, 4, 5])
y = np.array([0, 2, 1, 3, 2, 0])

# 使用CubicSpline函数进行样条插值
cs = CubicSpline(x, y)

# 生成插值点
x_interp = np.linspace(0, 5, 100)
y_interp = cs(x_interp)

# 绘制原始数据和插值曲线
plt.plot(x, y, 'o')
plt.plot(x_interp, y_interp)
plt.show()
```

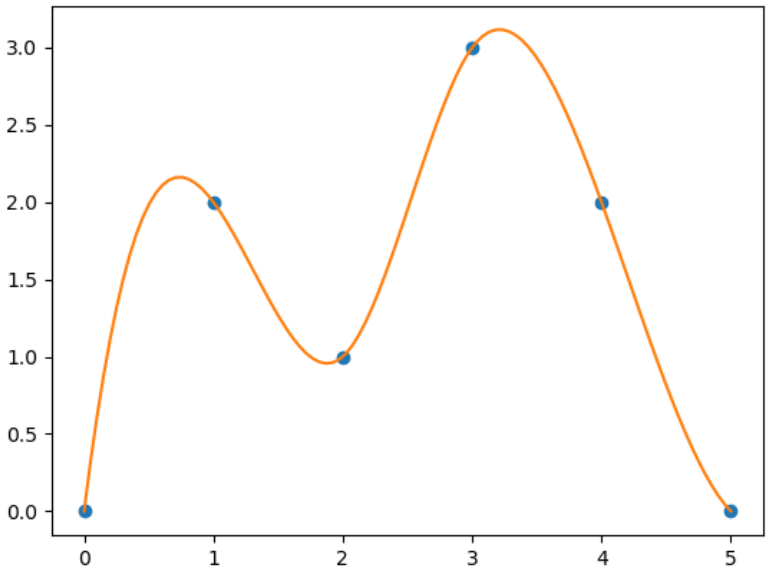

图 2.5: 自然边界条件的三次样条插值

若想采用其他边界条件, 如希望采用固支边界条件, 并令端点一阶导数为 0, 则可以在 Python 当中使用如下代码:

```
# 三次样条插值演示(固支边界条件) Exercise2-7.py

import numpy as np
from scipy.interpolate import CubicSpline
import matplotlib.pyplot as plt

# 创建一些数据点
x = np.array([0, 1, 2, 3, 4, 5])
y = np.array([0, 2, 1, 3, 2, 0])

# 使用CubicSpline函数进行样条插值, 且端点一阶导数值为0
cs = CubicSpline(x, y, bc_type=((1,0),(1,0)))
```

```
13
14  # 生成插值点
15  x_interp = np.linspace(0, 5, 100)
16  y_interp = cs(x_interp)
17
18  # 绘制原始数据和插值曲线
19  plt.plot(x, y, 'o')
20  plt.plot(x_interp, y_interp)
21  plt.show()
```

所得图像如图 2.6所示

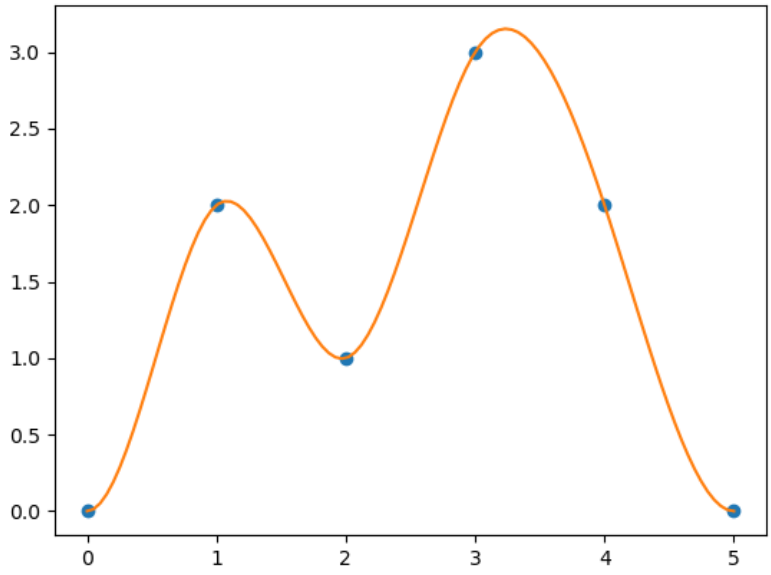

图 2.6: 固支边界条件的三次样条插值

Chapter 3

函数逼近与计算

3.1 引言

3.1.1 函数逼近的问题的一般提法

对于函数类 A 中给定的函数 $f(x)$, 要求在另一类较简单且便于计算的函数类 $B(\subset A)$ 中寻找一个函数 $P(x)$, 使得函数 $P(x)$ 与 $f(x)$ 之差在某种度量意义下最小.

本章所研究的函数类 A 通常为区间 $[a,b]$ 上的连续函数, 记作 $C[a,b]$; 函数类 B 通常为代数多项式或三角多项式.

3.1.2 常用的度量标准

最佳一致逼近

定义 3.1.1 (最佳一致逼近)**.** 若以函数 $f(x)$ 和 $P(x)$ 的最大误差

$$\max_{x\in[a,b]}|f(x)-P(x)|=\|f(x)-P(x)\|_\infty$$

作为度量误差 $f(x)-P(x)$ "大小"的标准, 在这种意义下的函数逼近称为最佳一致逼近或均匀逼近

最佳平方逼近

定义 3.1.2 (最佳平方逼近)**.** *采用*

$$\sqrt{\int_a^b [f(x)-P(x)]^2\,\mathrm{d}x} = \|f(x)-P(x)\|_2$$

*作为度量误差"大小"标准的函数逼近称为*最佳平方逼近或均方逼近*.*

3.2 最佳一致逼近

3.2.1 最佳一致逼近概念

定义 3.2.1. *设函数 $f(x)$ 是区间 $[a,b]$ 上的连续函数, 对于任意给定的 $\varepsilon>0$, 如果存在多项式 $P(x)$, 使不等式*

$$\max_{a\le x\le b}|f(x)-P(x)|<\varepsilon$$

成立, 则称多项式 $P(x)$ 在区间 $[a,b]$ 上一致逼近 (或均匀逼近) 于函数 $f(x)$.

3.2.2 最佳一致逼近多项式的存在性

定理 3.2.1 (Weierstrass 定理)**.** *若 $f(x)$ 是区间 $[a,b]$ 上的连续函数, 则对于任意 $\varepsilon>0$, 总存在多项式 $P(x)$, 使对一切 $a\le x\le b$, 有*

$$\|f(x)-P(x)\|_\infty<\varepsilon$$

定理证明略.

可以证明的是, 多项式 $P(x)$ 形式为:

$$P(x)=\sum_{i=0}^{n(\varepsilon)} f\left(\frac{i}{n}\right)C_n^i x^i(1-x)^{n-i}$$

且

$$\lim_{n\to\infty}P_n(x)\to f(x)$$

3.2.3 $C[a,b]$ 上最佳一致逼近

在次数不超过 n 的多项式当中, 找到一个 $p_n^*(x)$, 使得

$$\|f(x)-p_n^*(x)\|_\infty=\min_{p_n(x)\in H_n}\|f(x)-p_n(x)\|_\infty$$

其中, H_n 表示由所有次数不超过 n 的代数多项式构成的线性空间. 上述问题为 $C[a,b]$ 空间中最佳一致逼近问题.

下面的定理说明了该最佳一致逼近多项式的存在性.

定理 3.2.2 (Borel 定理)**.** *对任意的 $f(x) \in C[a,b]$, 在 H_n 中都存在对 $f(x)$ 的最佳一致逼近多项式, 记为 $p_n^*(x)$, 使得*

$$\|f(x) - p_n^*(x)\|_\infty = \min_{p_n(x) \in H_n} \|f(x) - p_n(x)\|_\infty$$

称 $p_n^*(x)$ 为 $f(x)$ 的 n 次最佳一致逼近多项式. 或简称为最佳逼近多项式.

3.2.4 相关概念

偏差

定义 3.2.2 (偏差)**.** *若 $P_n(x) \in H_n, f(x) \in C[a,b]$, 则称*

$$\Delta(f, P_n) = \|f - P_n\|_\infty = \max_{a \le x \le b} |f(x) - P_n(x)|$$

为 $f(x)$ 与 $P_n(x)$ 在 $[a,b]$ 上的偏差

显然, $\Delta(f, P_n) \le 0$, $\Delta(f, P_n)$ 的全体组成一个集合, 记作 $\Delta(f, H_n)$, 下界为 0.

最小偏差

定义 3.2.3. *若记集合的下确界为*

$$E_n = \inf_{P_n \in H_n} \{\Delta(f, P_n)\} = \inf_{P_n \in H_n} \max_{a \le x \le b} |f(x) - P_n(x)|$$

则称 E_n 为 $f(x)$ 在 $[a,b]$ 上的最小偏差

偏差点

定义 3.2.4 (偏差点)**.** *设 $f(x) \in C[a,b], P(x) \in H_n$, 若在 $x = x_0$ 上有*

$$|P(x_0) - f(x_0)| = \max_{a \le x \le b} |P(x) - f(x)| = \mu$$

则称 x_0 是 $P(x) - f(x)$ 的偏差点.

若 $P(x_0) - f(x_0) = \mu$, 则称 x_0 为正偏差点;

若 $P(x_0) - f(x_0) = -\mu$, 则称 x_0 为负偏差点;

交错点组

定义 3.2.5. *若函数 $f(x)$ 在其定义域内的某一区间 $[a,b]$ 上存在 n 个点 $x_k, k=1,2,\cdots,n$, 使得*

$$|f(x_k)| = \max|f(x)| = \|f(x)\|_\infty, k=1,2,\cdots,n$$
$$-f(x_k) = f(x_{k+1}), k=1,2,\cdots,n-1$$

则称点集 $x_k, k=1,2,\cdots,n$ 为函数 $f(x)$ 在区间 $[a,b]$ 上的一个交错点组, 点 x_k 为交错点.

3.2.5 $C[a,b]$ 上的最佳一致逼近特征

引理 3.2.3. *设 $f(x)$ 是区间 $[a,b]$ 上的连续函数, $P_n^*(x)$ 是 $f(x)$ 的 n 次最佳一致逼近多项式, 则 $f(x)-P_n^*(x)$ 在区间 $[a,b]$ 上必同时存在正负偏差点.*

定理 3.2.4 (Chebyshev 定理)**.** *设 $f(x)$ 是区间 $[a,b]$ 上的连续函数, 则 $P_n^*(x)$ 是 $f(x)$ 的 n 次最佳一致逼近多项式的充要条件是:$f(x)-P_n^*(x)$ 在区间 $[a,b]$ 上存在一个至少由 $n+2$ 个点组成的交错点组.*

例 3.2.1. *求函数 $f(x)=\sin 4x$ 在 $[0,2\pi]$ 上的 6 次最佳一致逼近 $P_6^*(x)$*

解. 令

$$R(x) = f(x) - P_6^*(x)$$

考虑函数 $f(x)=\sin 4x$ 在区间 $[0,2\pi]$ 存在由 8 个点组成的交错点组.

令 $R(x)=\sin 4x$, 则有

$$P_6^*(x) = f(x) - R(x) = 0$$

□

推论 3.2.5. *在 $P_n[a,b]$ 中, 若存在对函数 $f(x)\in C[a,b]$ 的最佳一致逼近元, 则唯一.*

推论 3.2.6. *设 $f(x)$ 是区间 $[a,b]$ 上的连续函数, 则 $f(x)$ 的 n 次最佳一致逼近多项式是 $f(x)$ 的某个 n 次插值多项式.*

推论 3.2.7. 设 $f(x)$ 是区间 $[a,b]$ 上的连续函数, $P_n^*(x)$ 是 $f(x)$ 的 n 次最佳一致逼近多项式, 若 $f^{(n+1)}(x)$ 在 (a,b) 内存在且保号, 则 $f(x)-P_n^*(x)$ 在区间 $[a,b]$ 上恰好存在一个由 $n+2$ 个点组成的交错点组, 且两个端点 a,b 都在交错点组中.

3.2.6 一次最佳逼近多项式 ($n=1$)

推导过程

设 $f(x)\in C^2[a,b]$, 且 $f''(x)$ 在 (a,b) 内不变号, 要求 $f(x)$ 在 $[a,b]$ 上的一次最佳一致逼近多项式 $P_1(x)=a_0+a_1x$. 由上述推论, $f(x)-P_1(x)$ 在 $[a,b]$ 上恰好由 3 个点构成的交错点组, 且区间端点 a,b 属于交错点组. 设另一交错点组为 x_2. 则有

$$\begin{cases} f'(x_2)-P_1'(x_2)=0 \\ f(a)-P_1(a)=f(b)-P_1(b) \\ f(a)-P_1(a)=-\left[f(x_2)-P_1(x_2)\right] \end{cases}$$

即

$$\begin{cases} f'(x_2)=a_1 \\ a_0+a_1a-f(a)=f(x_2)-[a_0+a_1x_2] \\ a_0+a_1a-f(a)=a_0+a_1b-f(b) \end{cases}$$

解得

$$\begin{aligned} a_1&=\frac{f(b)-f(a)}{b-a}=f'(x_2) \\ a_0&=\frac{f(a)+f(x_2)}{2}-\frac{f(b)-f(a)}{b-a}\frac{a+x_2}{2} \end{aligned}$$

即

$$P_1(x)=\frac{f(x_2)+f(a)}{2}+\frac{f(b)-f(a)}{b-a}\left(x-\frac{a+x_2}{2}\right)$$

例 3.2.2. 求 $Rf(x)=\sqrt{1+x^2}$ 在 $[0,1]$ 上的一次最佳一致逼近多项式.

解. 因为

$$\begin{aligned} f'(x)&=\frac{x}{\sqrt{1+x^2}} \\ f''(x)&=\frac{1}{\sqrt[3]{(1+x^2)^2}}>0 \end{aligned}$$

设 $f(x)$ 在 $[0,1]$ 上的一次最佳一致逼近多项式为 $P_1(x)=a_0+a_1x$, 则由

$$a_1=\frac{f(b)-f(a)}{b-a}=f'(x_2)$$

可得

$$a_1=\sqrt{2}-1\approx 0.414$$

再由

$$f'(x_2)=a_1$$

可得

$$\frac{x_2}{\sqrt{1+x_2^2}}=\sqrt{2}-1$$

解得

$$x_2=\sqrt{\frac{\sqrt{2}-1}{2}}\approx 0.4551, f(x_2)=\sqrt{1+x_2^2}\approx 1.0986$$

由

$$a_0=\frac{f(a)+f(x_2)}{2}-\frac{f(b)-f(a)}{b-a}\frac{a+x_2}{2}$$

得

$$a_0=\frac{1+\sqrt{1+x_2^2}}{2}-a_1\frac{x_2}{2}\approx 0.955$$

于是得 $\sqrt{1+x^2}$ 得最佳一次逼近多项式为

$$P_1(x)=0.955+0.414x$$

最小偏差为

$$\|\sqrt{1+x^2}-P_1(x)\|_\infty=\max_{0\le x\le 1}|\sqrt{1+x^2}-P_1(x)|=|\sqrt{1+0^2}-P_1(0)|\le 0.045$$

□

n 次最佳一致逼近多项式 (推广)

设 $f(x)\in C^{n+1}[a,b]$, 且 $f^{(n+1)}(x)$ 在 (a,b) 内不变号吗要求 $f(x)$ 在 $[a,b]$ 上得 n 次最佳一致逼近多项式

$$P_n(x)=a_0+a_1x+\cdots+a_nx^n$$

由推论可知, $f(x)-P_n(x)$ 在 $[a,b]$ 上恰好有 $n+2$ 个点构成得交错点组, 且 a,b 属于交错点组. 设另外 n 个交错点为 $x_1,x_2,\cdots,x_n$, 则有

$$\begin{cases} f'(x_i)-P_n'(x_i)=0, i=1,2,\cdots,n \\ f(a)-P_n(a)=(-1)^i(f(x_i)-P_n(x_i)), i=1,2,\cdots,n \\ f(a)-P_n(a)=(-1)^{n+1}\left[f(b)-P_n(b)\right] \end{cases}$$

3.2.7 Chebyshev 多项式及其应用

定义

定义 3.2.6 (Chebyshev 多项式)**.** *称*

$$T_n=\cos(n\arccos x), |x|\leq 1$$

为 Chebyshev 多项式

注: 令 $\theta=\arccos x$, 则 $\cos\theta=x$. 而

$$\cos n\theta=\cos^n\theta-C_n^2\cos^{n-2}\theta\sin^2\theta+C_n^4\cos^{n-4}\theta\sin^4\theta-\cdots$$

故 T_n 是关于 x 得 n 次代数多项式.

性质

正交性: 由 $T_n(x)$ 所组成的序列 $T_n(x)$ 在区间 $[-1,1]$ 上带权 $\rho(x)=\frac{1}{\sqrt{1-x^2}}$ 的正交多项式序列, 且

$$\int_{-1}^{1}\frac{1}{\sqrt{1-x^2}}T_m(x)T_n(x)\,\mathrm{d}x=\begin{cases}0, & m\neq n\\ \frac{\pi}{2}, & m=n\neq 0\\ \pi, & m=n=0\end{cases}$$

递推关系: 相邻的三个 Chebyshev 多项式具有如下递推关系式:

$$\begin{cases} T_0(x)=1, T_1(x)=x \\ T_{n+1}(x)=2x\cdot T_n(x)-T_{n-1}(x), n=1,2,\cdots \end{cases}$$

奇偶性: Chebyshev 多项式 T_n, 当 n 为奇数时为奇函数, 当 n 为偶数时为偶函数. 即

$$\begin{aligned} T_n(-x) &= \cos[n\arccos(-x)] = \cos(n\pi - n\arccos x) \\ &= (-1)^n \cos(n\arccos x) = (-1)^n T_n(x) \end{aligned}$$

T_n 在区间 $[-1,1]$ 上有 n 个不同的零点

$$x_k = \cos\frac{(2k-1)\pi}{2n}, k = 1, 2, \cdots, n$$

$T_n(x)$ 在 $[-1,1]$ 上有 $n+1$ 个不同的极值点

$$x'_k = \cos k\frac{\pi}{n}, k = 0, 1, \cdots, n$$

使 $T_n(x)$ 轮流取得最大值 1 和最小值-1.

$T_n(x)$ 的最高次项系数为 $2^{n-1}, n = 1, 2, \cdots$

在区间 $[-1,1]$ 上, 在所有首项系数为 1 的 n 次多项式 $p_n(x)$ 中. $\widetilde{T}_n(x) = \frac{1}{2^{n-1}}T_n(x)$ 与零的偏差最小, 且偏差为 $\frac{1}{2^{n-1}}$, 即对于任何 $p(x) \in H_n(x)$, 有

$$\frac{1}{2^{n-1}} = \|\widetilde{T}_n(x) - 0\|_\infty = \min_{p(x)\in H_n} \|p(x) - 0\|_\infty$$

上述性质又被称为 Chebyshev 多项式的最小模性质.

应用

设 $f(x) = b_0 + b_1 x + \cdots + b_{n+1}x^{n+1}(b_{n+1} \neq 0)$ 为 $[-1,1]$ 上的 $n+1$ 次多项式, 要求 $f(x)$ 在 $[-1,1]$ 上的 n 次最佳一致逼近 $P_n^*(x)$.

由于首项系数为 1 的 $n+1$ 次 Chebyshev 多项式 $\widetilde{T}_{n+1}(x)$ 无穷范数最小, 有

$$\frac{f(x) - P_n^*(x)}{b_{n+1}} = \widetilde{T}_{n+1}(x) = \frac{1}{2^n}T_{n+1}(x)$$

于是

$$P_n^*(x) = f(x) - b_{n+1}\widetilde{T}_{n+1}(x)$$

其偏差为

$$\|f(x) - P_n^*(x)\|_\infty = \|\frac{b_{n+1}}{2^n}T_{n+1}(x)\|_\infty = \frac{|b_{n+1}|}{2^n}$$

例 3.2.3. 设 $f(x) = 4x^4 + 2x^3 - 5x^2 + 8x - \frac{5}{2}, |x| \leq 1$, 求 $f(x)$ 在 $[-1,1]$ 上的 3 次最佳一致逼近元 $P_3^*(x)$

解. 由 $f(x)$ 的表达式可知 $b_4 = 4$, 首项系数为 1 的 4 次 Chebyshev 多项式为

$$\widetilde{T}_4(x) = x^4 - x^2 + \frac{1}{8}$$

设 $f(x)$ 在 $[-1,1]$ 上的 3 次最佳一致逼近多项式为 $P_3^*(x)$, 则

$$\frac{f(x) - P_3^*(x)}{4} = \widetilde{T}_4(x)$$

从而

$$P_3^*(x) = f(x) - 4\widetilde{T}_4(x) = 2x^3 - x^2 + 8x - 3$$

其最小偏差为

$$\|f(x) - P_3^*(x)\|_\infty = \|\frac{b_4}{2^3}T_4(x)\|_\infty = \frac{|4|}{2^3} = \frac{1}{2}$$

□

例 3.2.4. *若 $f(x) = 4x^4 - 5x^2 + 8x - \frac{5}{2}, |x| \le 1$, 重求上题*

解. 重复上述步骤, 可得 3 次最佳一致逼近多项式为

$$P_3^*(x) = -x^2 + 8x - 3$$

(注意: 这里的 3 次多项式是次数不超过 3) □

考虑一般区间 $[a,b]$ 上的多项式降阶. 设 $f(x) = b_0 + b_1x + \cdots + b_{n+1}x^{n+1}, b_{n+1} \neq 0$ 为 $[a,b]$ 上的 $n+1$ 次多项式, 要求 $f(x)$ 在 $[a,b]$ 上的 n 次最佳一致逼近 $P_n^*(x)$.

首先做区间变换, 令

$$x = \frac{b-a}{2}t + \frac{b+a}{2}$$

其中 $t \in [-1,1]$, 则

$$f(x) = f\left(\frac{b-a}{2}t + \frac{b+a}{2}\right) = g(t) \in C[-1,1]$$

设 $g(t)$ 在 $[-1,1]$ 的 n 次最佳一致逼近多项式为 $P_n(t)$, 则

$$P_n(t) = g(t) - c_{n+1}\widetilde{T}_{n+1}(t)$$

其中, c_{n+1} 为 $g(t)$ 的最高此项系数.

$$c_{n+1} = b_{n+1}\left(\frac{b-a}{2}\right)^{n+1}$$

于是, $f(x)$ 在 $[a,b]$ 上的 n 次最佳一致逼近多项式为

$$P_n^*(x) = P_n\left(\frac{2x-b-a}{b-a}\right)$$

最小偏差为

$$\|f(x)-P_n(x)\|_\infty = \|g(t)-P_n(t)\|_\infty = \frac{|c_{n+1}|}{2^n}$$

下面再考虑插值多项式的情况. 设 $f(x)\in C[-1,1]$, 且存在 $n+1$ 阶连续导数 $f^{(n+1)}(x)$. 如何在 $[-1,1]$ 上确定互异节点 $x_0,x_1,\cdots,x_n$, 使得 $f(x)$ 的 n 次插值多项式的余项最小.

由插值余项定理, 可知 n 次插值多项式 $L_n(x)$ 的余项为

$$R_n(x) = f(x)-L_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}\omega_{n+1}(x)$$

其中,

$$\omega_{n+1}(x) = \prod_{i=0}^{n}(x-x_i), \xi\in(-1,1)$$

其误差上界为

$$\begin{aligned}|f(x)-L_n(x)| &\le \frac{1}{(n+1)!}\max_{-1\le x\le 1}|f^{(n+1)}(x)|\max_{-1\le x\le 1}|\omega_{n+1}(x)|\\ &= \frac{1}{(n+1)!}\|f^{(n+1)}\|_\infty\|\omega_{n+1}(x)\|_\infty\end{aligned}$$

要使余项达到最小, 即令 $\|\omega_{n+1}(x)\|_\infty$ 尽可能小. 由于是一个首项系数为 1 的 $n+1$ 次多项式. 故有 Chebyshev 多项式, 取

$$\omega_{n+1}(x) = \widetilde{T}_{n+1}(x)$$

同时有

$$\omega_{n+1}(x) = \prod_{i=0}^{n}(x-x_i)$$

故只需令 $x_i, i=0,1,\cdots,n$ 为 $n+1$ 次 Chebyshev 多项式的零点, 即

$$x_i = \cos\frac{(2i+1)\pi}{2(n+1)}, i=0,1,\cdots,n$$

3.3 最佳平方逼近

3.3.1 内积空间

内积空间定义

定义 3.3.1 (内积空间)**.** 设 X 为 *(实)* 线性空间, 在 X 上定义了内积是指对 X 中每一对元素 x, y, 都有一实数, 记为 (x, y) 与之对应, 且这个对应满足*:*

1. $$(x, x) \geq 0, (x, x) = 0 \Leftrightarrow x = 0$$

   ;

2. $$(x, y) = (y, x), x, y \in X$$

   ;

3. $$(\lambda x, y) = \lambda(x, y), x, y \in X; \lambda \in R$$

   ;

4. $$(x + y, z) = (x, z) + (y, z), x, y, z \in X$$

则称 X 为内积空间, 称二元函数 (x, y) 为内积

2-范数定义及其性质

定义 3.3.2. 设 X 为内积空间, 则对任意的 $x \in X$, 称

$$\|x\|_2 = \sqrt{(x, x)}$$

为 x 的 2-范数或欧式范数.

特别的, 对 $f(x) \in C[a, b]$, 称

$$\|f\|_2 = \sqrt{\int_a^b \rho(x) f^2(x)\,\mathrm{d}x} = \sqrt{(f, f)}$$

为函数 $f(x)$ 的 Euclid 范数

设 X 是一内积空间, 则对任意的 $x, y \in X$, 有

1. Cauchy-Schwarz 不等式:

$$(x, y)^2 \leq (x, x)(y, y)$$

2. 三角不等式:

$$\|x + y\|_2 \leq \|x\|_2 + \|y\|_2$$

讨论特殊的两种内积空间,

- n 维欧氏空间 R^n, 内积就是两向量数量积, 即

$$(x, y) = x^T y = \sum x_i y_i$$

- 连续函数空间 $C[a, b]$, 内积定义为积分运算或带权函数积分运算, 即

$$(f(x), g(x)) = \int_a^b f(x)g(x)\,\mathrm{d}x\,, f(x), g(x) \in C[a, b]$$

或者

$$(f(x), g(x)) = \int_a^b \rho(x)f(x)g(x)\,\mathrm{d}x\,, f(x), g(x) \in C[a, b]$$

定义 3.3.3 (权函数)**.** *设 $\rho(x)$ 定义在有限或无限区间 $[a, b]$ 上, 如果具有下列性质:*

1. *对任意 $x \in [a, b], \rho(x) \geq 0$;*
2. *积分 $\int_a^b |x|^n \rho(x)\,\mathrm{d}x$ 存在, $n = 0, 1, 2, \cdots$;*
3. *对非负的连续函数 $g(x)$, 若 $\int_a^b g(x)\rho(x)\,\mathrm{d}x = 0$, 则在 (a, b) 上有 $g(x) \equiv 0$*

称满足上述条件的 $\rho(x)$ 为 $[a, b]$ 上的权函数

3.3.2 相关概念

距离

R^n 中, 两个向量 x, y 之间的距离定义为

$$\mathrm{dist}(x, y) = \|x - y\|_2 = \sqrt{(x - y, x - y)} = \sqrt{\sum_i (x_i - y_i)^2}$$

连续函数空间 $C[a,b]$ 中, 两个函数 $f(x)$ 与 $g(x)$ 的欧式距离为

$$\operatorname{dist}(f(x),g(x))=\|f(x)-g(x)\|_2=\sqrt{\int_a^b\rho(x)\left[f(x)-g(x)\right]^2\mathrm{d}x}$$

正交

在 R^n 中, 若两个向量 x,y 的内积为零, 即

$$(x,y)=0$$

则称向量 x,y 正交.

在连续函数空间 $C[a,b]$ 中, 若函数 $f(x)$ 与 $g(x)$ 满足

$$(f,g)=\int_a^b\rho(x)f(x)g(x)\,\mathrm{d}x=0$$

则称 $f(x)$ 与 $g(x)$ 在 $[a,b]$ 上带权 $\rho(x)$ 正交.

进一步, 设在 $C[a,b]$ 上给定函数系 $\varphi_k(x)$, 若满足条件

$$(\varphi_j(x),\varphi_k(x))=\begin{cases}0, & j\neq k\\ \text{常数}A_k>0, & j=k,j,k=0,1,\cdots\end{cases}$$

则称函数系 $\varphi_k(x)$ 是 $[a,b]$ 上带权 $\rho(x)$ 的正交坐标系.

特别地, 若 $A_k=1$, 则该函数系称为标准正交坐标系.

若上述定义中函数系为多项式系, 则称之为 $C[a,b]$ 上带权 $\rho(x)$ 的正交多项式系, 并称 $\varphi_n(x)$ 为 $[a,b]$ 上带权 $\rho(x)$ 的n 次正交多项式.

3.3.3 内积空间上的最佳平方逼近

函数系的线性关系

定义 3.3.4. 设 $\varphi_0(x),\varphi_1(x),\cdots,\varphi_n(x)$ 为区间 $[a,b]$ 上的连续函数, 若关系式

$$a_0\varphi_0(x)+a_1\varphi_1(x)+\cdots+a_n\varphi_n(x)=0$$

当且仅当 $a_0=a_1=\cdots=a_n=0$ 时成立, 则称函数在 $[a,b]$ 上是线性无关的, 否则称线性相关.

函数系线性无关的判别条件

定理 3.3.1. *连续函数 $\varphi_0(x), \varphi_1(x) \cdots, \varphi_n(x)$ 在 $[a,b]$ 上线性无关的充分必要条件是它们的 Gram 行列式*

$$G_n = \begin{vmatrix} (\varphi_0,\varphi_0) & (\varphi_0,\varphi_1) & \cdots & (\varphi_0,\varphi_n) \\ (\varphi_1,\varphi_0) & (\varphi_1,\varphi_1) & \cdots & (\varphi_1,\varphi_n) \\ \vdots & \vdots & \cdots & \vdots \\ (\varphi_n,\varphi_0) & (\varphi_n,\varphi_1) & \cdots & (\varphi_n,\varphi_n) \end{vmatrix} \neq 0$$

设 $\varphi_0(x), \varphi_1(x), \cdots, \varphi_n(x)$ 是 $[a,b]$ 上线性无关的连续函数, $a_0, a_1, \cdots, a_n$ 是任意实数, 则

$$S(x) = a_0\varphi_0(x) + a_1\varphi_1(x) + \cdots + a_n\varphi_n(x)$$

的全体是 $C[a,b]$ 的一个子集, 记作

$$\Phi = \operatorname{span}\{\varphi_0, \varphi_1, \cdots, \varphi_n\}$$

并称 $\varphi_0(x), \varphi_1(x), \cdots, \varphi_n(x)$ 是生成集合 Φ 的一个基底.

最佳平方逼近元的定义

设 X 为线性内积空间, $\varphi_0, \varphi_1, \cdots, \varphi_n$ 为 X 上 $n+1$ 个线性无关元, 即

$$\Phi = \operatorname{span}\{\varphi_0, \varphi_1, \cdots, \varphi_n\}$$

定义 3.3.5 (最佳平方逼近元)**.** *对任意的 $X \in X$, 在 X 的子空间 Φ 中, 求 g 的在 2-范数意义下的最佳逼近元 S^*, 即求 $S^* \in \Phi$, 使得*

$$\|S^* - g\|_2 = \min_{S\in\Phi} \|S - g\|_2$$

对任意 $S \in \Phi$ 成立. 若满足上式的 $S^* \in \Phi$ 存在, 则称 S^* 为 $g \in X$ 的最佳平方逼近元

最佳平方逼近元的存在性

定理 3.3.2. *设 X 为线性内积空间, 由线性无关组 $\varphi_0, \varphi_1, \cdots, \varphi_n$ 张成的线性空间 Φ 为 X 的子空间, 则对任意的 $g \in X$, 存在 $S^* \in \Phi$ 为 g 的最佳平方逼近元.*

最佳平方逼近元的特征

定理 3.3.3. *$S^* \in \Phi = span\{\varphi_0, \varphi_1, \cdots, \varphi_n\}$ 为 $g \in X$(线性内积空间)的最佳平方逼近元的充要条件是: $g - S^*$ 与一切 $\varphi_j, j = 0, 1, \cdots, n$ 正交. 其中, $\varphi_0, \varphi_1, \cdots, \varphi_n$ 为 X 的 $n+1$ 个线性无关元.*

该定理所说的 $g - S^*$ 与一切 φ_j 正交, 指 $g - S^*$ 与一切 φ_j 的内积为零, 即

$$(g - S^*, \varphi_j) = 0, j = 0, 1, \cdots, n$$

最佳平方逼近元的唯一性

定理 3.3.4. *线性内积空间 X 的子空间 Φ 中若存在对 $g \in X$ 的最佳平方逼近元, 则唯一.*

最佳平方逼近元的求解

由最佳平方逼近元充要条件, 若假定

$$S^* = \sum_{j=0}^{n} c_j^* \varphi_j(x)$$

则可得出

$$\left(g - \sum_{j=0}^{n} c_j^* \varphi_j, \varphi_i \right) = 0, i = 0, 1, \cdots, n$$

移项变形为

$$\left(\sum_{j=0}^{n} c_j^* \varphi_j, \varphi_i \right) = (\varphi_i, g), i = 0, 1, \cdots, n$$

其中, $c_j^*, j = 0, 1, \cdots, n$ 为待定系数. 用矩阵表示方程组为:

$$\begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \cdots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{pmatrix} \begin{pmatrix} c_0^* \\ c_1^* \\ \vdots \\ c_n^* \end{pmatrix} = \begin{pmatrix} (\varphi_0, g) \\ (\varphi_1, g) \\ \vdots \\ (\varphi_n, g) \end{pmatrix}$$

此方程称为法方程组.

若选取的一组基底 $\varphi_0(x), \varphi_1(x), \cdots, \varphi_n(x)$ 满足

$$(\varphi_i, \varphi_j) = \begin{cases} 0, & i \neq j \\ A_i > 0, & i = j \end{cases}$$

则称其为正交基, 此时

$$c_j^* = \frac{(\varphi_j, g)}{(\varphi_j, \varphi_j)}, j = 0, 1, \cdots, n$$

最佳平方逼近元的误差估计

设 $S^* = \sum_{j=0}^n c_j^* \varphi_j \in \Phi = \text{span}\{\varphi_0, \varphi_1, \cdots, \varphi_n\}$ 为 $g \in X$ 的最佳平方逼近元, 则其平方误差为

$$\begin{aligned} \|g - S^*\|_2^2 &= (g - S^*, g - S^*) = (g - S^*, g) - (g - S^*, S^*) \\ &= (g - S^*, g) - (g - S^*, \sum_{j=0}^n c_j^* \varphi_j) \\ &= (g, g) - (S^*, g) - \sum_{j=0}^n c_j^* (g - S^*, \varphi_j) \\ &= (g, g) - (S^*, g) = (g, g) - \sum_{j=1}^n c_j^* (g - \varphi_j) \end{aligned}$$

均方误差为

$$\|g - S^*\|_2 = \sqrt{(g, g) - \sum_{j=0}^n c_j^* (g, \varphi_j)}$$

3.3.4 连续函数的最佳平方逼近

对于给定的函数 $f(x) \in C[a, b]$, 要求函数

$$S^* \in \Phi = \text{span}\{\varphi_0, \varphi_1, \cdots, \varphi_n\}$$

使

$$\int_a^b \rho(x) \left[f(x) - S^*(x)\right]^2 \mathrm{d}x = \min_{S(x) \in \Phi} \int_a^b \rho(x) \left[f(x) - S(x)\right]^2 \mathrm{d}x$$

若这样的 $S^*(x)$ 存在, 则称为 $f(x)$ 在区间 $[a, b]$ 上的最佳平方逼近函数.

特别地, 若取 $\Phi = H_n = \mathrm{span}\{1, x, \cdots, x^n\}$, 则称

$$S^*(x) = a_0 \cdot 1 + a_1 x + \cdots + a_n x^n$$

为 $f(x)$ 在 $[a,b]$ 上的n 次最佳平方逼近多项式.

计算 $C[a,b]$ 上函数 $f(x)$ 的 n 次最佳平方逼近多项式. 取

$$\varphi_0 = 1, \varphi_1 = x, \cdots, \varphi_n = x^n$$

设 $f(x)$ 的 n 次最佳平方逼近多项式为

$$S^*(x) = \sum_{j=0}^{n} a_j \cdot \varphi_j(x) = \sum_{j=0}^{n} a_j \cdot x^j$$

构造法方程组:

$$\begin{pmatrix} (\varphi_0,\varphi_0) & (\varphi_0,\varphi_1) & \cdots & (\varphi_0,\varphi_n) \\ (\varphi_1,\varphi_0) & (\varphi_1,\varphi_1) & \cdots & (\varphi_1,\varphi_n) \\ \vdots & \vdots & & \vdots \\ (\varphi_n,\varphi_0) & (\varphi_n,\varphi_1) & \cdots & (\varphi_n,\varphi_n) \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} (f,\varphi_0) \\ (f,\varphi_1) \\ \vdots \\ (f,\varphi_0) \end{pmatrix}$$

其中,

$$\begin{aligned} (\varphi_i,\varphi_j) &= \int_a^b \varphi_i \cdot \varphi_j \,\mathrm{d}x = \int_a^b x^i \cdot x^j \,\mathrm{d}x \\ &= \frac{b^{i+j+1} - a^{i+j+1}}{i+j+1}, i,j = 0,1,\cdots,n \end{aligned}$$

$$(f,\varphi_j) = \int_a^b f(x) \cdot \varphi_j \,\mathrm{d}x = \int_a^b f(x) \cdot x^j \,\mathrm{d}x\,, j = 0,1,\cdots,n$$

由此可得函数 $f(x)$ 在 H_n 中的 n 次最佳平方逼近多项式:

$$S^*(x) = \sum_{j=0}^{n} a_j^* x^j$$

平方误差为:

$$\|f(x) - S^*(x)\|_2^2 = (f,f) - \sum_{j=0}^{n} a_j^*(f,\varphi_j) = \int_a^b [f(x)]^2 \,\mathrm{d}x - \sum_{j=0}^{n} a_j^*(f,\varphi_j)$$

由于 $\varphi_0, \varphi_1, \cdots, \varphi_n$ 线性无关, 故 $G_n \neq 0$, 上述方程组存在唯一解 $a_k = a_k^*, k = 0,1,\cdots,n$

特别地, 当 $a=0,b=1$ 时, 法方程组系数矩阵为

$$H=\begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+1} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \cdots & \frac{1}{n+2} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \cdots & \frac{1}{n+3} \\ \vdots & \vdots & \vdots & & \vdots \\ \frac{1}{n+1} & \frac{1}{n+2} & \frac{1}{n+3} & \cdots & \frac{1}{2n+1} \end{pmatrix}$$

该矩阵为 Hilbert 矩阵, 为病态矩阵.

例 3.3.1. *求 $g(x)=\sqrt{x}$ 在 $H_1[0,1]$ 中的最佳平方逼近元, 并估计误差*

解. 取 $\varphi_0=1,\varphi_1=x,H_1[0,1]=\operatorname{span}\{1,x\}$, 记

$$S_1^*(x)=a_0+a_1x$$

由

$$(\varphi_0,\varphi_0)=\int_0^1 1\cdot 1\,\mathrm{d}x=1$$
$$(\varphi_0,\varphi_1)=\int_0^1 1\cdot x\,\mathrm{d}x=\frac{1}{2}$$
$$(\varphi_1,\varphi_1)=\int_0^1 x\cdot x\,\mathrm{d}x=\frac{1}{3}$$

同样可求得

$$(\varphi_0,g)=\int_0^1 \sqrt{x}\,\mathrm{d}x=\frac{2}{3}$$
$$(\varphi_1,g)=x\cdot\sqrt{x}\,\mathrm{d}x=\frac{2}{5}$$

所以, 关于 a_0,a_1 的法方程组为

$$\begin{cases} a_0+\frac{1}{2}a_1=\frac{2}{3} \\ \frac{1}{2}a_0+\frac{1}{3}a_1=\frac{2}{5} \end{cases}$$

解得

$$a_0=\frac{4}{15},a_1=\frac{4}{5}$$

即 $S_1^*(x)=\frac{4}{5}x+\frac{4}{155}$ 为 $H_1[0,1]$ 对 $g(x)$ 的最佳平方逼近元. 且误差为

$$\|\delta_n\|_2^2=\|\sqrt{x}-S_1^*(x)\|_2^2=\int_0^1\left(\sqrt{X}\right)^2\mathrm{d}x-\sum_{k=0}^{1}a_k\left(\sqrt{k}.\varphi_k\right)$$
$$=\frac{1}{2}-\frac{4}{15}\times\frac{2}{3}-\frac{4}{5}\times\frac{2}{5}=\frac{1}{255}\approx 0.0044$$

□

3.4 正交多项式

3.4.1 正交化手续

当权函数 $\rho(x)$ 及区间 $[a,b]$ 给定后, 可由幂函数系 $1,x,x^2,\cdots,x^n,\cdots$ 利用 Schmidt 正交化方法构造出和正交多项式系

$$\begin{aligned} &g_0(x)=1,\\ &g_k(x)=x^k-\sum_{i=0}^{k-1}\frac{(x^k,g_i)}{(g_i,g_i)}\cdot g_i, k=1,2,\cdots \end{aligned}$$

3.4.2 正交多项式的性质

1. $g_n(x)$ 是最高次项系数为 1 的 n 次多项式.

2. 任一 n 次多项式 $P_n(x)\in H_n$ 均可表示为 $g_0(x),g_1(x),\cdots,g_n(x)$ 的线性组合.

3. 当 $n\neq m$ 时, $(g_n,g_m)=0$, 且 $g_n(x)$ 与任一次数小于 n 的多项式正交.

4. 递推性,

$$g_{n+1}(x)=(x-\alpha_n)g_n(x)-\beta_n g_{n-1}(x), n=0,1,\cdots$$

其中,

$$\begin{aligned} g_0(x)=1, g_{-1}(x)=0,\\ \alpha_n=\frac{(xg_n,g_n)}{(g_n,g_n)}, n=0,1,\cdots,\\ \beta_n=\frac{(g_n,g_n)}{(g_{n-1},g_{n-1})}, n=1,2,\cdots \end{aligned}$$

这里 $(xg_n,g_n)=\int_a^b xg_n^2(x)\rho(x)\,\mathrm{d}x$

5. 设 $g_0(x),g_1(x),\cdots$ 是在 $[a,b]$ 上带权 $\rho(x)$ 的正交多项式序列, 则 $g_n(x)(n\geq 1)$ 的 n 个根都是单重实根, 且都在区间 (a,b) 内.

3.4.3 常用的正交多项式

第一类 Chebyshev 多项式

定义:

$$T_n = \cos\left(n \arccos x\right), |x| \leq 1$$

性质:

1. 递推关系

$$\begin{cases} T_0(x) = 1, T_1(x) = x \\ T_{n+1}(x) = 2x \cdot T_n(x) - T_{n-1}(x), n = 1, 2, \cdots \end{cases}$$

2. 正交性

由 $T_n(x)$ 所组成的序列 $T_n(x)$ 在区间 $[-1, 1]$ 上带权 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$ 的正交多项式序列, 且

$$(T_m(x), T_n(x)) = \int_{-1}^{1} \frac{1}{\sqrt{1-x^2}} T_m(x) T_n(x) \, \mathrm{d}x = \begin{cases} 0, & m \neq n \\ \frac{\pi}{2}, & m = n \neq 0 \\ \pi, & m = n = 0 \end{cases}$$

Legendre 多项式

定义 3.4.1 (n 次 Legendre 多项式)**.** 多项式

$$P_n(x) = \frac{1}{2^n \cdot n!} \frac{\mathrm{d}^n}{\mathrm{d}x^n} \left[(x^2 - 1)^n\right], n = 0, 1, 2, \cdots$$

称为 n 次 Legendre 多项式

正交性: Legendre 多项式序列 $P_n(x)$ 是 $[-1, 1]$ 上带权 $\rho = 1$ 的正交多项式序列, 且

$$(P_m(x), P_n(x)) = \int_{-1}^{1} P_m(x) P_n(x) \, \mathrm{d}x = \begin{cases} 0, & m \neq n \\ \frac{2}{2n+1}, & m = n \end{cases}$$

相邻的三个 Legendre 多项式具有如下递推关系:

$$\left\{P_0(x) = 1, P_1(x) = x, P_{n+1}(x) = \frac{2x+1}{n+1} x P_n(x) - \frac{n}{n+1} P_{n-1}(x), n = 1, 2, \cdots\right.$$

奇偶性: 当 n 为偶数时, $P_n(x)$ 为偶函数; 当 n 为奇数时, $P_n(x)$ 为奇函数.

$P_n(x)$ 在区间 $[-1,1]$ 内存在 n 个互异实零点. 且最高项系数为 $\frac{(2n)!}{2^n(n!)^2}$

在所有首项系数为 1 的 n 次多项式中, Legendre 多项式 $\widetilde{P}_n(x)$ 在 $[-1,1]$ 上与零的平方误差最小. 即对于任何 $p(x)\in H_n(x)$, 有

$$\|\widetilde{P}_n(x)-0\|_2=\min_{p(x)\in H_n}\|p(x)-0\|_2$$

扩展:

$$\|\widetilde{T}_n(x)-0\|_\infty=\min_{p(x)\in H_n}\|p(x)-0\|_\infty$$

其他常用的正交多项式

定义 3.4.2 (第二类 Chebyshev 多项式)**.** *称*

$$U_n(x)=\frac{\sin\left[(n+1)\arccos x\right]}{\sqrt{1-x^2}}$$

为第二类 Chebyshev 多项式

其中, $U_n(x)$ 是区间 $[-1,1]$ 带权 $\rho(x)=\sqrt{1-x^2}$ 的正交多项式序列,

$$\int_{-1}^{1}\sqrt{1-x^2}U_m(x)U_n(x)\,\mathrm{d}x=\begin{cases}0, & m\neq n\\ \frac{\pi}{2}, & m=n\end{cases}$$

且具有如下递推关系式:

$$\begin{cases}U_0(x)=1, U_1(x)=2x\\ U_{n+1}(x)=2xU_n(x)-U_{n-1}(x), n=1,2,\cdots\end{cases}$$

定义 3.4.3 (Laguerre 多项式)**.** *称多项式*

$$L_n(x)=e^x\frac{\mathrm{d}^n}{\mathrm{d}x^n}\left(x^ne^{-x}\right), 0\le x<+\infty, n=0,1,2,\cdots$$

为 Laguerre 多项式

$L_n(x)$ 是定义在区间 $[0,+\infty)$ 上带权 $\rho(x)=e^{-x}$ 的正交多项式序列.

$$\int_0^\infty e^{-x}\cdot L_m(x)L_n(x)\,\mathrm{d}x=\begin{cases}0, & m\neq n\\ (n!)^2, & m=n\end{cases}$$

递推关系式:

$$\begin{cases} L_0(x) = 1, L_1(x) = 1 - x \\ L_{n+1}(x) = (1 + 2n - x)L_n(x) - n^2 \cdot L_{n-1}(x), n = 1, 2, \cdots \end{cases}$$

定义 3.4.4 (Hermite 多项式)**.** *称多项式*

$$H_n(x) = (-1)^n \cdot e^{x^2} \cdot \frac{\mathrm{d}^n}{\mathrm{d}x^n}\left(e^{-x^2}\right), x \in (-\infty, \infty), n = 0, 1, 2, \cdots$$

为 Hermite 多项式

$H_n(x)$ 是区间 $(-\infty, \infty)$ 上带权 $\rho(x) = e^{-x^2}$ 的正交多项式序列.

$$\int_{-\infty}^{\infty} e^{-x^2} H_m(x) \cdot H_n(x)\,\mathrm{d}x = \begin{cases} 0, & m \neq n \\ 2^n \cdot n! \cdot \sqrt{\pi}, & m = n \end{cases}$$

递推关系式

$$\begin{cases} H_0(x) = 1, H_1(x) = 2x \\ H_{n+1}(x) = 2xH_n(x) - 2nH_{n-1}(x), n = 1, 2, \cdots \end{cases}$$

3.5 函数按正交多项式展开

设 $\Phi = \mathrm{span}\{\varphi_0, \varphi_1, \cdots, \varphi_n\}$, 其中 $\varphi_i (i = 0, 1, \cdots, n)$ 是 $[a, b]$ 上带权 $\rho(x)$ 的正交多项式系, 给定 $f(x) \in C[a, b]$, 若 $S_n^*(x) = a_0\varphi_0(x) + \cdots + a_n\varphi_n(x)$ 为 $f(x)$ 在 $[a, b]$ 上的 n 次最佳平方逼近多项式, 则由正交多项式的性质

$$a_k = \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)}, k = 0, 1, \cdots, n$$

于是

$$S_n^*(x) = \sum_{k=0}^{n} \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)}\varphi_k(x)$$

其均方误差为

$$\|\delta_n\|_2 = \|f(x) - S_n^*(x)\|_2 = \sqrt{(f, f) - \sum_{k=0}^{n} a_k^2(\varphi_k, \varphi_k)}$$

例 3.5.1. *求 $f(x) = e^x$ 在 $[-1, 1]$ 上的三次最佳平方逼近多项式.*

解. 考虑使用 Legendre 多项式, 计算 $(f, P_k), k = 0, 1, 2, 3$, 即

$$
\begin{aligned}
(f, P_0) &= \int_{-1}^{1} e^x \,\mathrm{d}x = e - \frac{1}{e} \approx 2.3504 \\
(f, P_1) &= \int_{-1}^{1} x e^x \,\mathrm{d}x = 2e^{-1} \approx 0.7358 \\
(f, P_2) &= \int_{-1}^{1} \left(\frac{3}{2}x^2 - \frac{1}{2}\right) e^x \,\mathrm{d}x = e - \frac{7}{e} \approx 0.1431 \\
(f, P_3) &= \int_{-1}^{1} \left(\frac{5}{2}x^3 - \frac{3}{2}x\right) e^x \,\mathrm{d}x = \frac{37}{e} - 5e \approx 0.2013
\end{aligned}
$$

所以得

$$
\begin{aligned}
a_0^* &= \frac{(f, P_0)}{2} = 1.1752 \\
a_1^* &= 3\frac{(f, P_1)}{2} = 1.1036 \\
a_2^* &= 5\frac{(f, P_2)}{2} = 0.3578 \\
a_3^* &= 7\frac{(f, P_3)}{2} = 0.07046
\end{aligned}
$$

所以

$$
\begin{aligned}
S_3^*(x) &= 1.1752 + 1.1036x + 0.3578\left(\frac{3}{2}x^2 - \frac{1}{2}\right) + 0.07046\left(\frac{5}{2}x^3 - \frac{3}{2}x\right) \\
&= 0.9963 + 0.9979x + 0.5367x^2 + 0.1761x^3
\end{aligned}
$$

均方误差为

$$
\|\delta_n\|_2 = \|e^x - S_3^*(x)\|_2 = \sqrt{\int_{-1}^{1} e^{2x} \,\mathrm{d}x - \sum_{k=0}^{3} \frac{2}{2k+1} a_k^{*2}} \leq 0.0084
$$

最大误差为

$$
\|\delta_n\|_\infty = \|e^x - S_3^*(x)\|_\infty \leq 0.0112
$$

□

下面使用 Python 代码演示这道题. 注意, 代码当中的系数为 Legendre 多项式的系数.

```python
# 使用Legendre多项式进行平方逼近演示(例题解答) Exercise3-1.py
import numpy as np
from scipy.special import legendre
from scipy.optimize import least_squares

# 计算Legendre多项式的系数
def legendre_coefficients(x, y, degree):
    A = np.zeros((len(x), degree + 1))
    for i in range(degree + 1):
        A[:, i] = legendre(i)(x)
    return np.linalg.lstsq(A, y, rcond=None)[0]
# 定义逼近函数
def approximation_func(x, coefficients):
    result = np.zeros_like(x)
    for i, coeff in enumerate(coefficients):
        result += coeff * legendre(i)(x)
    return result
def legendre_approximation(x, y, degree):
    # 计算逼近函数的系数
    coefficients = legendre_coefficients(x, y, degree)
    # 使用最小二乘法优化逼近函数的系数
    result = least_squares(lambda coefficients:
        approximation_func(x, coefficients) - y, coefficients)
    return result.x

x = np.linspace(-1, 1, 100)
y = np.exp(x)
# 最佳平方逼近
degree = 3
coefficients = legendre_approximation(x, y, degree)
# 计算逼近函数的值
approximation = approximation_func(x, coefficients)
# 打印结果
```

```
33 print("系数:", coefficients)
```

输出结果为:[1.17530022 1.10367036 0.35831431 0.07053157], 与计算结果一致.

3.6 曲线拟合的最小二乘法

3.6.1 问题提出

已知一系列测量数据 (x_i, y_i), 要求简单函数 $f(x)$ 使得 $\rho_i = y_i - f(x_i)$ 在总体上尽可能小. 这里 $y_i \neq f(x_i)$, 称 ρ_i 为*残差*, 这种构造近似函数的方法称为*曲线拟合*, $f(x)$ 为*拟合函数*.

通常, 使 ρ_i 尽可能小的度量准则包括:

- 使 $\max_{1\leq ilem} |P(x_i) - y_i|$ 尽可能小;
- 使 $\sum_{i=1}^{m} |P(x_i) - y_i|$ 尽可能小;
- 使 $\sum_{i=1}^{m} |P(x_i) - y_i|^2$ 尽可能小

3.6.2 曲线拟合的步骤

1. 根据条件画出散点图;
2. 观察分布, 选择适当的函数类构造拟合函数;
3. 根据某一逼近准则确定拟合函数的未知参数.

3.6.3 2-范数度量下的曲线拟合 (最小二乘法)

给定一组数据 $(x_i, y_i), i = 1, 2, \cdots, m$, 确定拟合函数

$$f(x) = c_1\varphi_1(x) + c_2\varphi_2(x) + \cdots + c_n\varphi_n(x)$$

使得

$$\|r\|_2^2 = \sum_{i=1}^{m} \rho_i^2 = \sum_{i=1}^{m} [y_i - f(x_i)]^2 = \sum +i - 1^m \left[y_i - \sum_{j=1}^{n} c_j\varphi_j(x_i) \right]^2$$

达到极小, 这里 $n \leq m$.

若记

$$E(c_1, c_2, \cdots, c_n) = \sum_{i=1}^{m} \left[y_i - \sum_{j=1}^{n} c_j \varphi_j(x_i) \right]^2$$

则 E 是 $c_1, \cdots, c_n$ 的多元函数, 于是问题转化为求多元函数 $E(c_1, c_2, \cdots, c_n)$ 的极小值问题.

由多元函数极值必要条件, 在 E 的极值点处, 有

$$\frac{\partial E}{\partial c_k} = \sum_{i=1}^{m} -2 \left(y_i - \sum_{j=1}^{n} c_j \varphi_k(x_i) \right) \varphi_k(x_i) = 0, k = 1, 2, \cdots, n$$

即

$$\sum_{j=1}^{n} c_j \sum_{i=1}^{m} \varphi_j(x_i) \varphi_k(x_i) = \sum_{i=1}^{m} y_i \varphi_k(x_i), k = 1, 2, \cdots, n$$

若记

$$\Phi_i = \begin{pmatrix} \varphi_i(x_1) \\ \varphi_i(x_2) \\ \vdots \\ \varphi_i(x_m) \end{pmatrix}, i = 1, 2, \cdots, n, b = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

则

$$\sum_{i=1}^{m} \varphi_j(x_i) \varphi_k(x_i) = (\Phi_j, \Phi_k) \sum_{i=1}^{m} y_i \varphi_k(x_i) = (\Phi_k, b)$$

于是上式可写为

$$\sum_{j=1}^{n} c_j (\Phi_j, \Phi_k) = (\Phi_k, b), k = 1, 2, \cdots, n$$

于是有关于 $c_1, c_2, \cdots, c_n$ 的线性方程组

$$\begin{pmatrix} (\Phi_1, \Phi_1) & (\Phi_2, \Phi_1) & \cdots & (\Phi_n, \Phi_1) \\ (\Phi_1, \Phi_2) & (\Phi_2, \Phi_2) & \cdots & (\Phi_n, \Phi_2) \\ \vdots & \vdots & & \vdots \\ (\Phi_1, \Phi_n) & (\Phi_2, \Phi_n) & \cdots & (\Phi_n, \Phi_n) \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix} = \begin{pmatrix} (\Phi_1, b) \\ (\Phi_2, b) \\ \vdots \\ (\Phi_n, b) \end{pmatrix}$$

或等价写作:

$$\begin{pmatrix} \Phi_1^T \Phi_1 & \Phi_2^T \Phi_1 & \cdots & \Phi_n^T \Phi_1 \\ \Phi_1^T \Phi_2 & \Phi_2^T \Phi_2 & \cdots & \Phi_n^T \Phi_2 \\ \vdots & \vdots & & \vdots \\ \Phi_1^T \Phi_n & \Phi_2^T \Phi_n & \cdots & \Phi_n^T \Phi_n \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ v_n \end{pmatrix} = \begin{pmatrix} \Phi_1^T \\ \Phi_2^T \\ \vdots \\ \Phi_n^T \end{pmatrix} b$$

若记

$$A = (\Phi_1, \Phi_2, \cdots, \Phi_n) = \begin{pmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \cdots & \varphi_n(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \cdots & \varphi_n(x_2) \\ \vdots & \vdots & & \vdots \\ \varphi_1(x_m) & \varphi_2(x_m) & \cdots & \varphi_n(x_m) \end{pmatrix}$$

$$x = \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix}$$

则上述方程组可表示为

$$A^T A x = A^T b$$

由于 A 是列满秩矩阵 (列向量线性无关), 故系数矩阵对称正定, 方程组的解存在唯一, 故可得拟合参数 $c_1, c_2, \cdots, c_n$

扩展: 若矩阵 $A \in \mathbb{R}^{m\times n}$, 则 $A^T A \in \mathbb{R}^{n\times n}, AA^T \in \mathbb{R}^{m\times m}$, 它们具有如下共同特点:

- 对称半正定 ($\forall x \in \mathbb{R}^n, x^T(A^T A)x \geq 0$);
- 特征值非负;
- $\operatorname{rank}(A^T A) = \operatorname{rank}(AA^T) = \operatorname{rank}(A)$;
- 非零特征值个数相同, 且非零特征值相同;
- $\operatorname{tr}(AA_T) = \operatorname{tr}\big(A^T A\big)$

若取 $\varphi_0 = 1, \varphi_1(x) = x, \varphi_2(x) = x^2, \cdots, \varphi_n(x) = x^n$, 则拟合函数

$$f(x) = c_0 + c_1 x + c_2 x^2 + \cdots + c_n x^n$$

称为多项式拟合, 此时

$$A = \begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^n \\ 1 & x_2 & x_2^2 & \cdots & x_2^n \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_m & x_m^2 & \cdots & x_m^n \end{pmatrix}$$

$$b = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

$$x = \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{pmatrix}$$

于是

$$A^T Ax = A^T b$$

一些特殊情况下的非线性拟合, 可通过变量代换, 转换为线性拟合. 例如:

1. 双曲拟合
$$\frac{1}{y} = a + b\frac{1}{x} \Rightarrow u = a + bv(u = \frac{1}{y}, v = \frac{1}{x})$$

2. 对数拟合
$$y = a + b\ln x \Rightarrow y = a + bu(u = \ln x)$$

3. 指数拟合
$$y = ae^{bx} \Rightarrow \ln y = \ln a + bx \Rightarrow u = c + bx(u = \ln y, c = \ln a)$$

3.6.4 用正交函数作最小二乘拟合

给定

$$\begin{cases} x_0, \cdots, x_m \\ y_0, \cdots, y_m \end{cases}$$

与正交函数系 $\varphi_0, \varphi_1, \cdots, \varphi_n$, 则最小二乘拟合系数为:

$$P_n(x) = a_0\varphi_0(x) + a_1\varphi_1(x) + \cdots + a_n\varphi_n(x)$$

其中,

$$a_k = \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)} = \frac{\sum_{i=0}^{m} \rho(x_i) y_i \varphi_k(x_i)}{\sum_{i=1}^{m} \rho(x_i)\varphi_k^2(x_i)}$$

最后以一个最小二乘法的例题结束这一章.

例 3.6.1. 给定 (t_i, f_i) 的一组数据

t_i	f_i
0	*81.4*
20	*77.7*
40	*74.2*
60	*72.4*
80	*70.3*
100	*68.8*

求拟合函数 $f(x)$

解. 作图可知点分布在直线附近, 故使用线性函数拟合. 设

$$\varphi_0(t) = 1, \varphi_1(t) = t$$

将数据代入, 可得

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 20 \\ 1 & 40 \\ 1 & 60 \\ 1 & 80 \\ 1 & 100 \end{pmatrix}, x = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}, b = \begin{pmatrix} 81.4 \\ 77.7 \\ 74.2 \\ 72.4 \\ 70.3 \\ 68.8 \end{pmatrix}$$

代入公式

$$A^T A x = A^T b$$

可得拟合函数为

$$f(t) = 80.3 - 0.1t$$

□

下面的代码实现了上面的计算功能:

```
# 演示线性拟合的最小二乘法 Exercise3-2.py
import numpy as np
import matplotlib.pyplot as plt
# 数据
x = np.array([0,20,40,60,80,100])
y = np.array([81.4,77.7,74.2,72.4,70.3,68.8])
# 进行线性拟合
coefficients = np.polyfit(x, y, 1)
slope = coefficients[0]
intercept = coefficients[1]
# 绘制拟合曲线
x_fit= np.arange(0,100,0.01)
y_fit = slope*x_fit+intercept
plt.scatter(x,y)
plt.plot(x_fit,y_fit,c="red")
plt.show()
# 打印拟合结果
print(f"表达式为{slope:.1f}t+{intercept:.1f}")
```

拟合结果图像如图 3.1所示.

最后作为扩展演示, 下面是一个使用 Legendre 多项式进行三次拟合的程序:

```
# 使用Legendre多项式进行三次拟合 Exercise3-3.py
import numpy as np
import matplotlib.pyplot as plt
from scipy.special import legendre
# 示例数据
x = np.array([3.73,5.63,8.67,10.49,13.26,16.74,
19.55,22.19,25.36,28.31,30.83])
y = np.array([21.53,21.43,21.43,21.33,21.22,
20.71,20.20,19.69,18.78,17.76,16.84])
```

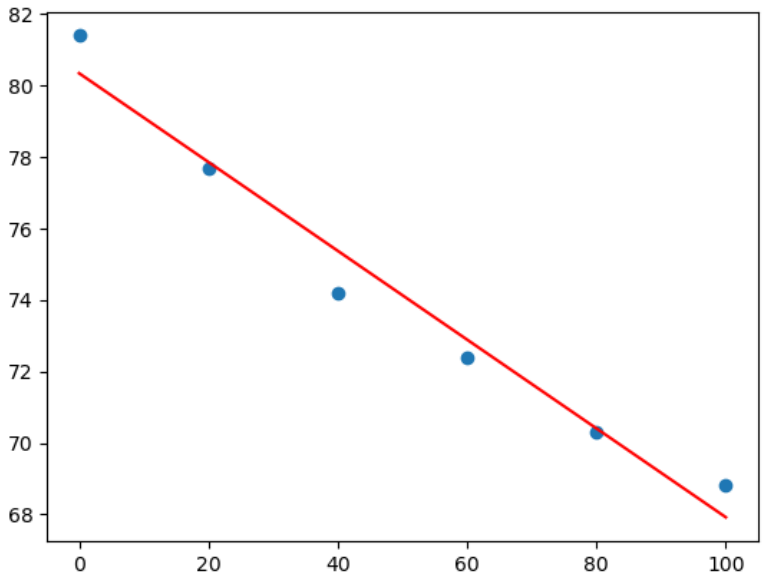

图 3.1: 使用线性拟合结果

```
10 # 进行Legendre拟合
11 coefficients = np.polynomial.legendre.legfit(x, y, 3)
12 # 绘制拟合曲线
13 x_fit = np.arange(3.73,30.83,0.01)
14 y_fit = np.polynomial.legendre.legval(x_fit, coefficients)
15 plt.scatter(x,y)
16 plt.plot(x_fit,y_fit,c="red")
17 plt.show()
```

得到图像如图 3.2所示.

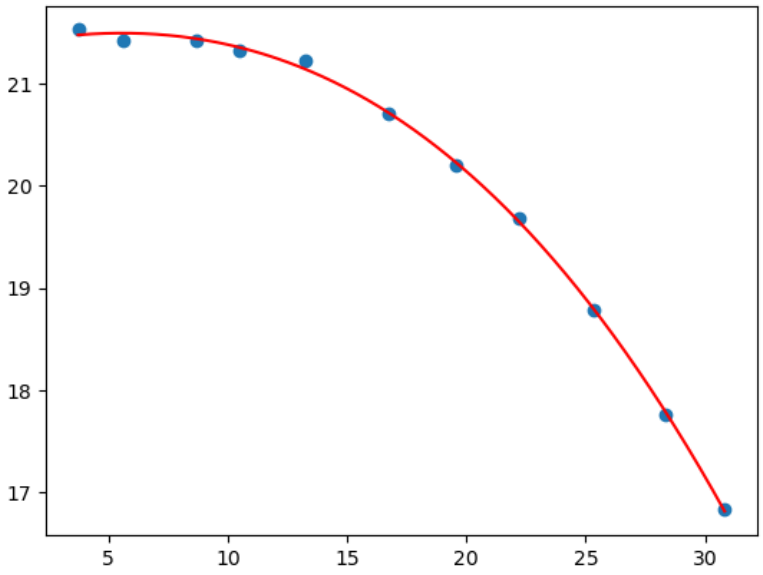

图 3.2: 使用 Legendre 多项式对一组数据进行三次拟合

Chapter 4

数值积分

4.1 引言

4.1.1 数值积分的必要性

本章主要讨论如下形式的一元函数积分

$$I(f) = \int_a^b f(x)\,\mathrm{d}x$$

在微积分里, 按 Newton-Leibniz 公式求定积分

$$I(f) = \int_a^b f(x)\,\mathrm{d}x = F(b) - F(a)$$

要求 $f(x)$ 的原函数 $F(x)$:

- 有解析表达式;
- 为初等函数.

实际上，

1. $f(x)$ 的原函数 $F(x)$ 不能用初等函数表示，如 $\sin x^2, \cos x^2, \frac{\sin x}{x}, \frac{1}{\ln x}$ 等;
2. 被积函数的原函数可以用初等函数表示，但其表达式相当复杂，计算极不方便，如 $x^2\sqrt{2x^2+3}$;

3. $f(x)$ 没有表达式，只有数表形式。

这时就需要积分的数值方法来帮忙了。

4.1.2 数值积分的基本思想

数值积分的理论依据

依据积分中值定理，对于连续函数 $f(x)$，在 $[a,b]$ 内存在一点 ξ，使得

$$I(f)=\int_a^b f(x)\,\mathrm{d}x=(b-a)f(\xi)$$

称 $f(\xi)$ 为 $f(x)$ 在区间 $[a,b]$ 上的平均高度。

求积公式的构造

若简单选取区间端点或中点的函数值作为平均高度，则求积公式 (左矩形公式, 中矩形公式, 右矩形公式) 如下：

$$I(f)\approx f(a)(b-a)$$

$$I(f)\approx f(\frac{a+b}{2})(b-a)$$

$$I(f)\approx f(b)(b-a)$$

定义 4.1.1 (两点求积公式). 若取 a,b 两点，并令 $f(\xi)=\frac{f(a)+f(b)}{2}$，则可得到梯形公式（两点求积公式）

$$I(f)\approx\frac{f(a)+f(b)}{2}(b-a)$$

定义 4.1.2 (三点求积公式/Simpson 公式). 若取三点,$a,b,c=\frac{a+b}{2}$ 并令 $f(\xi)=\frac{[f(a)+4f(c)+f(b)]}{6}$, 则可得 *Simpson* 公式 *(*三点求积公式*)*

$$I(f)\approx(b-a)\frac{[f(a)+4f(c)+f(b)]}{6}$$

定义 4.1.3 (机械求积). 一般地，取区间 $[a,b]$ 内 $n+1$ 个点 $x_i,(i=0,1,2,\cdots,n)$ 处的高度 $f(x_i),(i=0,1,2,\cdots,n)$，通过加权平均的方法近似地得出平均高度 $f(\xi)$。这类求积方法称为机械求积。

$$\int_a^b f(x)\,\mathrm{d}x\approx(b-a)\sum_{i=0}^{n}\lambda_i f(x_i)$$

或写成：

$$\int_a^b f(x)\,\mathrm{d}x \approx \sum_{k=0}^{n} A_k f(x_k)$$

其中 A_k 称为求积系数，x_k 称为求积节点。

记：

数值求积公式：

$$i_n(f) = \sum_{k=0}^{n} A_k f(x_k)$$

求积公式余项（误差）：

$$R(f) = I(f) - I_n(f) = \int_a^b f(x)\,\mathrm{d}x - \sum_{k=0}^{n} A_k f(x_k)$$

构造或确定一个求积公式，要解决的问题包括：

1. 确定求积系数 A_k 和求积节点 x_k;
2. 确定衡量求积公式好坏的标准;
3. 求积公式的误差估计和收敛性分析.

4.1.3 求积公式的代数精度

定义 4.1.4. 称求积公式 $I_n(f) = \sum_{k=0}^{n} A_k f(x_k)$ 具有 m 次代数精度，如果它满足如下两个条件：

1. 对所有 m 次多项式 $P_m(x)$，有

$$R(P_m) = I(P_m) - I_n(P_m) = 0$$

2. 存在 $m+1$ 次多项式 $P_{m+1}(x)$，使得

$$R(P_{m+1}) = I(P_{m+1}) - I_n(P_{m+1}) \neq 0$$

上述定义中的条件等价于：

$$R(x^k) = I(x^k) - I_n(x^k) = 0, (0 \leq k \leq m)$$
$$R(x_{m+1}) \neq 0$$

注意： 梯形公式与中矩形公式都只具有 *1* 次代数精度。

一般的，若要使求积公式 (1) 具有 m 次代数精度, 则只要使求积公式对 $f(x)=1,x,x^2,\cdots,x^m$ 都准确成立，即

$$\begin{cases}\sum_{k=0}^{n}A_k=b-a\\ \sum_{k=0}^{n}A_kx_k=\frac{1}{2}(b^2-a^2)\\ \sum_{k=0}^{n}A_kx_k^m=\frac{1}{m+1}(b^{m+1}-a^{m+1})\end{cases}$$

4.2 插值型求积公式

4.2.1 定义

定义 4.2.1 (拉格朗日插值公式)**.** 在积分区间 $[a,b]$ 上，取 $n+1$ 个节点 $x_i,i=0,1,2,\cdots,n$ 作 $f(x)$ 的 n 次代数插值多项式（拉格朗日插值公式）：

$$L_n(x)=\sum_{k=0}^{n}l_k(x)f(x_k)$$

则有 $f(x)=L_n(x)+R_n(x)$ 其中，$R_n(x)=\frac{f^{(n+1)}(\xi)}{(n+1)!}w_{n+1}(x)$ 为插值余项。$w_{n+1}(x)=\prod_{j=0}^{n}(x-x_j)$

于是有：

$$\begin{aligned}\int_a^b f(x)\,\mathrm{d}x&=\int_a^b L_n(x)\,\mathrm{d}x+\int_a^b R_n(x)\,\mathrm{d}x\\&=\sum_{j=0}^{n}[\int_a^b l_j(x)\,\mathrm{d}x]f(x_j)+\int_a^b R_n(x)\,\mathrm{d}x\end{aligned}$$

取

$$\int_a^b f(x)\,\mathrm{d}x\approx\sum_{j=0}^{n}f(x_j)\int_a^b l_i(x)\,\mathrm{d}x$$

其中 $\int_a^b l_j(x)\,\mathrm{d}x$ 为 A_j。

$A_j=\int_a^b\prod_{i=0,i\neq j}^{n}\frac{(x-x_i)}{(x_j-x_i)}\,\mathrm{d}x$ 由节点决定，与 $f(x)$ 无关。

4.2.2 截断误差与代数精度

截断误差

$$\begin{aligned} R(f) &= \int_a^b f(x)\,\mathrm{d}x - \sum_{k=0}^{n} A_k f(x_k) \\ &= \int_a^b [f(x) - L_n(x)]\,\mathrm{d}x \\ &= \int_a^b \frac{f^{n+1}(\xi_x)}{(n+1)!}\prod_{k=0}^{n}(x-x_k)\,\mathrm{d}x \end{aligned}$$

代数精度

定理 4.2.1. *形如 $\sum_{k=0}^{n} A_k f(x)$ 的求积公式至少有 n 次代数精度 $\Leftrightarrow$ 该公式为插值型（即：$A_k = \int_a^b l_k(x)dx$）*

推论 4.2.2. *求积系数 A_k 满足：*

$$\sum_{k=0}^{n} A_k = b - a$$

4.3 Newton-Cotes 公式

4.3.1 Cotes 系数

取节点为等距分布：$x_i = a + ih, h = \frac{b-a}{n}, i = 0, 1, \cdots, n$ 由此构造的插值型求积公式称为 Newton-Cotes 公式，此时求积系数：

$$\begin{aligned} A_i &= \int_{x_0}^{x_n} \prod_{j\neq i} \frac{(x-x_j)}{x_i - x_j}\,\mathrm{d}x \\ &= \int_0^n \prod_{i\neq j} \frac{(t-j)h}{(i-j)h} \times h\,\mathrm{d}t \\ &= \frac{(b-a)(-1)^{n-i}}{ni!(n-i)!}\int_0^n \prod_{j\neq i}(t-j)\,\mathrm{d}t \\ &= C_i^{(n)}(b-a) \end{aligned}$$

其中，$C_i^{(n)}$ 为 Cotes 系数。

4.3.2 Newton-Cotes 公式

定义

定义 4.3.1 (n 阶闭型 Newton-Cotes 求积公式). 记:

$$C_i^{(n)} = \frac{(-1)^{n-i}}{i!(n-i)!n} \int_0^n [\prod_{k=0,k\neq i}^{n} (t-k)] \,\mathrm{d}t$$

则 $A_i = (b-a)C_i^{(n)}, i = 0, 1, 2, \cdots, n$ 求积公式变为

$$\int_a^b f(x)\,\mathrm{d}x \approx (b-a)\sum_{i=0}^{n} C_i^{(n)} f(x_i)$$

称上式为 n 阶闭型 *Newton-Cotes* 求积公式。

注意: 由式 $C_i^{(n)} = \frac{(-1)^{n-i}}{i!(n-i)!n} \int_0^n [\prod_{k=0,k\neq i}^{n}(t-k)]\,\mathrm{d}t$ 确定的 Cotes 系数只与 i 和 n 有关，与 $f(x)$ 和积分区间 $[a,b]$ 无关，且满足：(1)$C_i^{(n)} = C_{n-i}^{(n)}$ (2)$\sum_{k=0}^{n} C_i^{(n)} = 1$

截断误差

Newton-Cotes 公式的截断误差为:

$$\begin{aligned} R(f) &= \int_a^b \frac{f^{(n+1)}(\xi)}{(n+1)!} w_{(n+1)}(x)\,\mathrm{d}x \\ &= \frac{h^{n+2}}{(n+1)!} \int_0^n f^{(n+1)}(\xi)[\prod_{j=0}^{n}(t-j)]\,\mathrm{d}t\,, \xi \in (a,b) \end{aligned}$$

代数精度

定理 4.3.1. 当阶数 n 为偶数时，*Newton-Cotes* 公式至少具有 $n+1$ 次代数精度。

证明. 只需验证当 n 为偶数时，Newton-Cotes 公式对 $f(x) = x^{n+1}$ 的余项为零。由于 $f(x) = x^{n+1}$，所以 $f^{(n+1)}(x) = (n+1)!$ 即得 $R(f) = h^{n+2}\int_0^n \prod_{j=0}^{n}(t-j)\,\mathrm{d}t$ 引进变换 $t = u + \frac{n}{2}$，因为 n 为偶数，故 $\frac{n}{2}$ 为整数，于是有

$$R(f) = h^{n+2} \int_{-\frac{n}{2}}^{\frac{n}{2}} \prod_{j=0}^{n} (u + \frac{n}{2} - j)\,\mathrm{d}u$$

据此可得 $R(f) = 0$，因为上述被积函数是个奇函数。 □

数值稳定性

现在讨论舍入误差对计算结果产生的影响。设用公式

$$I_n(f) = (b-a)\sum_{j=0}^{n} C_j^{(n)} f(x_j)$$

近似计算积分

$$I(f) = \int_a^b f(x)dx$$

时，其中函数值 $f(x_j)$ 有误差 $\varepsilon_j (j = 0, 1, 2, \cdots, n)$，而计算 $C_j^{(n)}$ 没有误差，中间计算过程中的舍入误差也不考虑，则在 $I_n(f)$ 的计算中，由 ε_j 引起的误差为：

$$\begin{aligned} e_n &= (b-a)\sum_{j=0}^{n} C_j^{(n)} f(x_i) - (b-a)\sum_{j=0}^{n} C_j^{(n)}(f(x_j)+\varepsilon_j) \\ &= -(b-a)\sum_{j=0}^{n} C_j^{(n)}\varepsilon_j \end{aligned}$$

如果 $C_j^{(n)}$ 都是正数，并设 $\varepsilon = \max_{0\le j\le n}|\varepsilon_j|$ 则有

$$|e_n| \le \varepsilon(b-a)\sum_{j=0}^{n}\left|C_j^{(n)}\right| = \varepsilon(b-a)$$

故 e_n 是有界的，即由 ε_j 引起的受到控制，不超过 ε 的 $(b-a)$ 倍，保证了数值计算的稳定性。而当 $n > 7$ 时，$C_j^{(n)}$ 将出现负数，$\sum_{j=0}^{n}|C_j^{(n)}|$ 将随 n 增大，因而不能保证数值稳定性。故高阶公式不宜采用，有实用价值的仅仅是几种低阶的求积公式。

4.3.3 几种常见的低阶求积公式

梯形公式：(代数精度 =1)

$$
\begin{aligned}
n &= 1: \\
C_0^{(1)} &= \frac{1}{2}, C_1^{(1)} = \frac{1}{2} \\
\int_a^b f(x)\,\mathrm{d}x &\approx \frac{b-a}{2}[f(a)+f(b)] \\
R[f] &= \int_a^b \frac{f''(\xi_x)}{2!}(x-a)(x-b)\,\mathrm{d}x \\
&= -\frac{(b-a)^3}{12}f''(\xi), \xi \in [a,b]
\end{aligned}
$$

Simpson 公式:(代数精度 =3)

$$
\begin{aligned}
n &= 2: \\
C_0^{(2)} &= \frac{1}{6}, C_1^{(2)} = \frac{2}{3}, C_2^{(2)} = \frac{1}{6} \\
\int_a^b f(x)\,\mathrm{d}x &\approx \frac{b-a}{6}[f(a)+4f(\frac{a+b}{2})+f(b)] \\
R[f] &= -\frac{(b-a)^5}{2880}f^{(4)}(\xi), \xi \in (a,b)
\end{aligned}
$$

Cotes 公式:(代数精度 =5)

$$
\begin{aligned}
n &= 4: \\
\int_a^b f(x)\,\mathrm{d}x &\approx \frac{b-a}{90}[7f(x_0)+32f(x_1)+12f(x_2)+32f(x_3)+7f(x_4)] \\
x_k &= a+kh, h = \frac{b-a}{4}, k = 0,1,2,3,4 \\
R[f] &= -\frac{8}{945}(\frac{b-a}{4})^7 f^{(6)}(\xi) \\
&= -\frac{2(b-a)}{945}(\frac{b-a}{4})^6 f^{(6)}(\xi), \xi \in [a,b]
\end{aligned}
$$

4.3.4 复化求积公式

定义 4.3.2 (复化梯形公式). $h=\frac{b-a}{h}, x_k=a+kh(k=0,\cdots,n)$ 在每个 $[x_k,x_k+1]$ 上用梯形公式:

$$\int_{x_k}^{x_{k+1}} f(x)\,\mathrm{d}x \approx \frac{x_{k+1}-x_k}{2}[f(x_k)+f(x_{k+1})], k=0,\cdots,n-1$$

$$\int_a^b f(x)\,\mathrm{d}x \approx \sum_{k=0}^{n-1}\frac{h}{2}[f(x_k)+f(x_{k+1})] = \frac{h}{2}[f(a)+2\sum_{k=1}^{n-1}f(x_k)+f(b)] = T_n$$

$$R[f]=\sum_{k=0}^{n-1}[-\frac{h^3}{12}f''(\eta_k)] = -\frac{h^2}{12}(b-a)\frac{\sum_{k=0}^{n-1}f''(\eta_k)}{n} = -\frac{h^2}{12}(b-a)f''(\eta), \eta\in(a,b)$$

定义 4.3.3 (复化 Simpson 公式). $h=\frac{b-a}{n}, x_k=a+kh(k=0,\cdots,n)$ 在每个 $[x_k,x_k+1]$ 上使用 *Simpson* 公式:

$$\int_{x_k}^{x_{k+1}} f(x)\,\mathrm{d}x \approx \frac{h}{6}[f(x_k)+4f(x_{k+\frac12})+f(x_{k+1})]$$

$$\int_a^b f(x)\,\mathrm{d}x \approx \sum_{k=0}^{n-1}\int_{x_k}^{x_{k+1}} f(x)\,\mathrm{d}x \approx \frac{h}{6}[f(a)+4\sum_{k=0}^{n-1}f(x_{k+\frac12})+2\sum_{k=1}^{n-1}f(x_k)+f(b)] = S_n$$

$$R[f]=-\frac{b-a}{2880}h^4f^{(4)}(\xi) = -\frac{b-a}{180}(\frac{h}{2})^4f^{(4)}(\xi), \xi\in(a,b)$$

定义 4.3.4 (复化 Cotes 公式). $h=\frac{b-a}{n}, x_k=a+kh(k=0,\cdots,n)$

$$\int_{x_k}^{x_{k+1}} f(x)\,\mathrm{d}x \approx \frac{h}{90}[7f(x_k)+32f(x_{k+\frac14})+12f(x_{k+\frac12})+32f(_{k+\frac34})+7f(x_{k+1})]$$

$$\int_a^b f(x)\,\mathrm{d}x \approx \sum_{k=0}^{n-1}[7f(x_k)+32f(x_{k+\frac14})+12f(x_{k+\frac12})+32f(_{k+\frac34})+7f(x_{k+1})] = C_n$$

$$R[f]=-\frac{2(b-a)}{945}(\frac{h}{4})^6f^{(6)}(\xi), \xi\in(a,b)$$

例 4.3.1. 利用数据表

复化梯形公式的误差估计

误差先验估计式: 给定精度 ε，如何求 n?

例 4.3.2. 要求 $|I-T_n|<\varepsilon$，如何判断 $n=?$ 由

$$R[f]=I(f)-T_n(f)=-\frac{h^2}{12}(b-a)f''(\xi)$$

若记 $M_2 = \max_{a\le x\le b}|f''(x)|$ 则可令

$$\left|\frac{h^2}{12}(b-a)f''(\xi)\right| \le \frac{h^2}{12}(b-a)M_2 \le \varepsilon$$

其中，$h = \frac{b-a}{n}$，于是，$n \ge \sqrt{\frac{(b-a)^3 M_2}{12\varepsilon}}$

$$\begin{aligned} R[f] &= -\frac{h^2}{12}(b-a)f''(\varepsilon) \\ &= -\frac{h^2}{12}\sum_{k=1}^{n}[f''(\xi_k)\cdot h] \approx -\frac{h^2}{12}\int_a^b f''(x)dx \\ &= -\frac{h^2}{12}[f'(b)-f'(a)] \end{aligned}$$

上例中若要求 $|I - T_n| < 10^{-6}$，则

$$|R_n[f]| \approx \frac{h^2}{12}|f'(1)-f'(0)| = \frac{h^2}{6} < 10^{-6} \Rightarrow h < 0.00244949$$

即取 $n = 409$ 通常采取将区间不断对分的方法，即取 $n = 2^k$ 上例中 $2^k \ge 409 \Rightarrow k = 9$ 时，$T_5 12 = 3.141592502$

误差后验估计式: 注意到区间再次对分时

$$\begin{aligned} R_2 n[f] &\approx -\frac{1}{12}[f'(b)-f'(a)](\frac{h}{2})^2 \\ &\approx \frac{1}{4}R_n[f] \\ \Rightarrow \frac{I-T_{2n}}{I-T_n} &\approx \frac{1}{4} \\ \Rightarrow I - T_{2n} &\approx \frac{1}{3}(T_{2n}-T_n) = \frac{1}{4-1}(T_{2n}-T_n) \end{aligned}$$

可用来判断迭代是否停止。

复化 Simpson 公式的误差估计

误差先验估计式:

$$\begin{aligned} R[f] = I - S_n &= -\frac{b-a}{180}(\frac{h}{4})^4 f^{(4)}(\xi) \\ &\approx -\frac{1}{180}[f^{(3)}(b)-f^{(3)}(a)](\frac{h}{2})^4 \end{aligned}$$

误差后验估计式:

$$I - S_{2n} \approx \frac{1}{15}(S_{2n}-S_n) = \frac{1}{4^2-1}(S_{2n}-S_n)$$

复化 Cotes 公式的误差估计

误差先验估计式:

$$R[f] = I - C_n = -\frac{2(b-a)}{945}(\frac{h}{4})^6 f^{(6)}(\xi), \xi \in (a,b)$$
$$\approx -\frac{2}{945}[f^{(5)}(b) - f^{(5)}(a)](\frac{h}{4})^6$$

误差后验估计式:

$$I - C_{2n} \approx \frac{1}{63}(C_{2n} - C_n) = \frac{1}{4^3 - 1}(C_{2n} - C_n)$$

复化求积公式的收敛速度 (阶)

定义 4.3.5 (p 阶收敛)**.** 若一个复化求积公式的误差满足 $\lim_{h\to 0} \frac{R[f]}{h^p} = C < \infty$ 且 $C \neq 0$，则称该公式是 p 阶收敛的。

注意: 根据上述定义不难验证

$$T_n \sim O(h^2), S_n \sim O(h^4), C_n \sim O(h^6) \tag{4.1}$$

4.4 Romberg 算法

4.4.1 Romberg 求积公式

例 4.4.1. 计算

$$\pi = \int_0^1 \frac{4}{1+x^2}\,\mathrm{d}x$$

若取 $\varepsilon = 10^{-6}$，则利用复化求积公式进行计算时，须将区间对分 9 次，得到 $T_{512} = 3.141592502$

考察 $\frac{I-T_{2n}}{I-T_n} \approx \frac{1}{4}$，若由 $I \approx \frac{4T_{2n}-T_n}{4-1} = \frac{4}{3}T_{2n} - \frac{1}{3}T_n$ 来计算 I 效果是否好些?

$$\frac{4}{3}T_8 - \frac{1}{3}T_4 = 3.141592502 = S_4$$

一般有:

- $\frac{4T_{2n}}{4-1} = S_n$
- $\frac{4^2 S_{2n}-S_n}{4^2-1} = C_n$
- $\frac{4^3 C_{2n}-C_n}{4^3-1} = R_n$(Romberg 求积公式)

4.4.2 理查德森外推加速法

利用低阶公式产生高精度的结果。设对于某一 $h \neq 0$，有公式 $T_0(h)$ 近似计算某一未知值 I。由 Taylor 展开得到：

$$T_0(h) - I = \alpha_1 h + \alpha_2 h^2 + \alpha_3 h^3 + \cdots$$

现将 h 对分，得：

$$T_0(\frac{h}{2}) - I = \alpha_1(\frac{h}{2}) + \alpha_2(\frac{h}{2})^2 + \alpha_3(\frac{h}{2})^3 + \cdots$$

如何将公式精度由 $O(h)$ 提高到 $O(h^2)$?

$$\frac{2T_0(\frac{h}{2}) - T_0(h)}{2-1} - I = -\frac{1}{2}\alpha_2 h^2 - \frac{3}{4}\alpha_3 h^3 - \cdots$$

即：

$$\begin{aligned} T_1(h) &= \frac{2T_0(\frac{h}{2}) - T_0(h)}{2-1} = I + \beta_1 h^2 + \beta_2 h^3 + \cdots \\ T_2(h) &= \frac{2^2 T_1(\frac{h}{2}) - T_1(h)}{2^2-1} = I + \gamma_1 h^3 + \gamma_2 h^4 + \cdots \\ \Rightarrow T_m(h) &= \frac{2^m T_{m-1}(\frac{h}{2}) - T_{m-1}(h)}{2^m - 1} = I + \sigma_1 h^{m+1} + \sigma_2 h^{m+2} + \cdots \end{aligned}$$

4.4.3 复化梯形公式的渐进展开式

定理 4.4.1. 设 $f(x) \in C^\infty[a,b]$，则成立

$$T_n(f) = I + a_1 h^2 + a_2 h^4 + \cdots + a_k h^{2k} + \cdots$$

其中，$h = \frac{b-a}{h}$，系数 $a_k (k = 1, 2, \cdots)$ 与 h 无关。

加速公式：

$$T_m^{(k)} = \frac{4^m T_{m-1}^{(k+1)} - T_{m-1}^{(k)}}{4^m - 1}, k = 1, 2, \cdots; m = 1, 2, \cdots$$

例 4.4.2. 求形如 $\int_{-1}^{1} f(x)dx \approx A_0 f(x_0) + A_1 f(x_1)$ 的两点求积公式。*(1)* 求梯形公式（即以 $x_0 = -1, x_1 = 1$ 为节点的插值型求积公式）立即可得。

$$\int_{-1}^{1} f(x)dx \approx f(-1) + f(1)$$

（只具有 1 次代数精度）(2) 若对求积公式中的四个待定系数 A_0, A_1, x_0, x_1 适当选取，使求积公式对 $f(x) = 1, x, x^2, x^3$ 都准确成立，则 A_0, A_1, x_0, x_1 需满足如下方程组：

$$\begin{cases} A_0 + A_1 = b - a \\ A_0 x_0 + A_1 x_1 = \frac{1}{2}(b^2 - a^2) \\ A_0 x_0^2 + A_1 x_1^2 = \frac{1}{3}(b^3 - a^3) \\ A_0 x_0^3 + A_1 x_1^3 = \frac{1}{4}(b^4 - a^4) \end{cases}$$

4.5 Gauss 型求积公式

定义 4.5.1 (Gauss 型求积公式). 具有 $2n+1$ 次代数精度的插值型求积公式

$$\int_a^b \rho(x) f(x)\,\mathrm{d}x \approx \sum_{k=0}^{n} A_k f(x_k)$$

称为 *Gauss* 型求积公式。

注意: Gauss 型求积公式是代数精度最高的插值型求积公式。

事实上，对于插值型求积公式

$$\int_a^b \rho(x) f(x)\,\mathrm{d}x \approx \sum_{k=0} n A_k f(x_k)$$

其代数精度最高可达 $2n+1$ 次 (Gauss 型求积公式)。考虑 $2n+2$ 次多项式 $w_{n+1}^2(x)$，其中 $w_{n+1}(x) = \prod_{j=0}^{n}(x - x_j)$

$$\int_a^b \rho(x) w_{n+1}^2(x)\,\mathrm{d}x > 0$$

而 $\sum_{k=0}^{n} A_k w_{n+1}^2(x_k) = 0$ 故

$$\int_a^b \rho(x) w_{n+1}^2(x)\,\mathrm{d}x \neq \sum_{k=0}^{n} A_k w_{n+1}^2(x_k) = 0$$

4.5.1 高斯型求积公式的构造

1. 待定系数法将节点 $x_0,\cdots,x_n$ 以及系数 $A_0,\cdots,A_n$ 都作为待定系数。并令求积公式对 $f(x)=1,x,x_2,\cdots,x^{2n-1}$ 精确成立可得非线性方程组：

$$\begin{cases}\sum_{k=0}^{n}A_k=b-a\\ \sum_{k=0}^{n}A_kx_k=\frac{1}{2(b^2-a^2)}\\ \vdots\\ \sum_{k=0}^{n}A_kx_k^{2n+1}=\frac{1}{2n+2}(b^{2n+2}-a^{2n+2})\end{cases}$$

求解该方程组即可得相应的求积节点与求积系数。

例 4.5.1. *求 $\int_0^1\sqrt{x}f(x)dx$ 的 2 点 Gauss 公式。*

解. 设 $\int_0^1\sqrt{x}f(x)dx\approx A_0f(x_0)+A_1f(x_1)$，应有 3 次代数精度。令上述公式 $f(x)=1,x,x^2,x^3$ 精确成立可得

$$\begin{cases}\frac{2}{3}=A_0+A_1\\ \frac{2}{5}=A_0x_0+A_1x_1\\ \frac{2}{7}=A_0x_0^2+A_1x_1^2\\ \frac{2}{9}=A_0x_0^3+A_1x_1^3\end{cases}$$

(不是线性方程组，不易求解。) 解得：

$$\begin{cases}x_0\approx 0.8212\\ x_1\approx 0.2899\\ A_0\approx 0.3891\\ A_1\approx 0.2776\end{cases}$$

□

2. 正交多项式法

定理 4.5.1. *$x_0,\cdots,x_n$ 为 Gauss 点 $\Leftrightarrow w(x)=\prod_{k=0}^{n}(x-x_k)$ 与任意次数不大于 n 的多项式 $P(x)$（带权）正交。*

证明. "⇒": $x_0,\cdots,x_n$ 为 Gauss 点，则公式

$$\int_a^b\rho(x)f(x)\,\mathrm{d}x\approx\sum_{k=0}^{n}A_kf(x_k)$$

具有 $2n+1$ 次代数精度。

对任意次数不大于 n 的多项式 $P_n(x)$，$P_n(x)w(x)$ 的次数不大于 $2n+1$，则代入公式应精确成立：

$$\int_a^b \rho(x)P_m(x)w(x)\,\mathrm{d}x = \sum_{k=0}^{n} A_k P_m(x_k)w(x_k) = 0$$

"⇐": 要证明 $x_0,\cdots,x_n$ 为 Gauss 点，即要证公式对任意次数不大于 $2n+1$ 的多项式 $P_{2n+1}(x)$ 精确成立，即证明：

$$\int_a^b \rho(x)P_m(x)\,\mathrm{d}x = \sum_{k=0}^{n} A_k P_m(x_k)$$

设 $P_{2n+1}(x) = w(x)q(x) + r(x)$

$$\begin{aligned}\int_a^b \rho(x)P_m(x)\,\mathrm{d}x &= \int_a^b \rho(x)w(x)q(x)\,\mathrm{d}x + \int_a^b \rho(x)r(x)\,\mathrm{d}x \\ &= \sum_{k=0}^{n} A_k r(x_k) \\ &= \sum_{k=0}^{n} A_k P_m(x_k)\end{aligned}$$

□

正交多项式族 $\varphi_0,\varphi_1,\cdots,\varphi_n,\cdots$ 有性质：任意次数不大于 n 的多项式 $P(x)$ 必与 φ_{n+1} 正交。⇒ 若取 $w(x)$ 为其中的 φ_{n+1}，则 φ_{n+1} 的根就是 Gauss 点。

例 4.5.2. 使用正交多项式重解上例

解.

$$\int_0^1 \sqrt{x}f(x)\,\mathrm{d}x \approx A_0 f(x_0) + A_1 f(x_1)$$

Step1: 构造正交多项式 φ_2 设 $\varphi_0(x)=1, \varphi_1(x)=x+a, \varphi_2(x)=x^2+bx+c$

1. $(\varphi_0,\varphi_1)=0 \Rightarrow \int_0^1 \sqrt{x}(x+a)\,\mathrm{d}x = 0 \Rightarrow a = -\frac{3}{5}$
2. $(\varphi_0,\varphi_2)=0 \Rightarrow \int_0^1 \sqrt{x}(x^2+bx+c)\,\mathrm{d}x = 0 \Rightarrow b = -\frac{10}{9}$
3. $(\varphi_1,\varphi_2)=0 \Rightarrow \int_0^1 \sqrt{x}(x-\frac{3}{5})(x+bx+c)\,\mathrm{d}x = 0 \Rightarrow c = \frac{5}{21}$

即 $\varphi_2(x) = x^2 - \frac{10}{9}x + \frac{5}{21}$

Step2: 求 $\varphi_2 = 0$ 的 2 个根，即为 Gauss 点 x_o, x_1

$$x_{0;1} = \frac{\frac{10}{9} \pm \sqrt{(\frac{10}{9})^2 - \frac{20}{21}}}{2}$$

Step3: 代入 $f(x) = 1, x$ 以求解 A_0, A_1

结果与前一方法相同：$x_0 \approx 0.8212, x_1 \approx 0.2899, A_0 \approx 0.3891, A_1 \approx 0.2776$ 利用此公式计算 $\int_0^1 \sqrt{x}e^x dx$ 的值

$$\begin{aligned}\int_0^1 \sqrt{x}e^x dx &\approx A_0 e^{x_0} + A_1 e^{x_1} \\ &= 0.3891 \times e^{0.8212} + 0.2776 \times e^{0.2899} \approx 1.2555\end{aligned}$$

□

注意： 构造正交多项式也可以利用 $L - S$ 拟合中介绍过的递推式进行。

4.5.2 几种常见的 Gauss 型求积公式

Gauss-Legendre 求积公式

Legendre 多项式：定义在 $[-1, 1]$，上 $\rho(x) \equiv 1$

$$P_k(x) = \frac{1}{2^k k!} \frac{\mathrm{d}^k}{\mathrm{d}x^k} \left(x^2 - 1\right)^k$$

满足：

$$(P_k, P_l) = \begin{cases} 0 & k \neq l \\ \frac{2}{2k+1} & k = l \end{cases}$$

$P_0 = 1, P_1 = x$, 递推公式：$(k+1)P_{k+1} = (2k+1)xP_k - kP_{k-1}$

Gauss-Legendre 求积公式：

$$\int_{-1}^{1} f(x)\,\mathrm{d}x \approx \sum_{k=0}^{n} A_k f(x_k)$$

其中，求积节点为 P_{n+1} 的根（求积系数通过解线性方程组得到）。

区间 $[a,b]$ 上的 Gauss-Legendre 公式：

$$\begin{aligned}\int_a^b f(x)\,\mathrm{d}x &= \int_{-1}^{1} f(\frac{b-a}{2}t+\frac{b+a}{2})\cdot\frac{b-a}{2}\,\mathrm{d}t \\ &\approx \sum_{k=0}^{n} A_k \frac{b-a}{2} f(\frac{b-a}{2}t_k+\frac{b+a}{2})\end{aligned}$$

其中，t_k 为 n+1 次 Legendre 多项式 P_{n+1} 的根。

Gauss-Chebyshev 求积公式：

Chebyshev 多项式: 定义在 $[-1,1]$ 上，$\rho(x)=\frac{1}{\sqrt{1-x^2}}$

$$T_k(x) = cos(k\times\arccos x)$$

T_{n+1} 的根为：

$$x_k = cos(\frac{2k+1}{2n+2}\pi), k=0,\cdots,n$$

以此为节点构造公式

$$\int_{-1}^{1}\frac{f(x)}{\sqrt{1-x^2}}\,\mathrm{d}x \approx \sum_{k=0}^{n} A_k f(x_k) = \frac{\pi}{n+1}\sum_{k=0}^{n} f(x_l)$$

称为 Gauss-Chebyshev 多项式。**注意：** 到积分端点 $\pm$ 可能是积分的奇点，用普通 Newton-Cotes 公式在端点会出问题。而 Gauss 公式可能避免此问题的发生。

第二类 Gauss-Chebyshev 求积公式

第二类 Chebyshev 多项式：区间 $[-1,1]$ 上，带权 $\rho(x)=\sqrt{1-x^2}$

$$U_n(x) = \frac{\sin[(n+1)\arccos x]}{\sqrt{1-x^2}}\ (n=0,1,2,\cdots)$$

以 U_{n+1} 的零点作为求积节点构造的公式

$$\begin{aligned}\int_{-1}^{1}\sqrt{1-x^2}f(x)\,\mathrm{d}x &\approx \sum_{k=0}^{n} A_k f(x_k) \\ &= \frac{\pi}{n+1}\sum_{k=0}^{n}\sin^2\frac{k\pi}{n+1} f(\cos\frac{k\pi}{n+1})\end{aligned}$$

称为第二类 Gauss-Chebyshev 公式。

Gauss-Laguerre 求积公式

Laguerre 多项式：

$$L_n(x) = e^x \frac{\mathrm{d}^n}{\mathrm{d}x^n}\left(x^n e^{-x}\right), x \in [0, +\infty], n = 0, 1, 2, \cdots$$
$$\rho(x) = e^{-x}$$

以 $n+1$ 次 Laguerre 多项式的零点为求积节点构造的公式

$$\int_0^{+\infty} e^{-x} f(x)\,\mathrm{d}x \approx \sum_{k=0}^{n} A_k f(x_k)$$

称为 Gauss-Laguerre 求积公式。

Gauss-Hermite 求积公式

Hermite 多项式：

$$H_n(x) = (-1)^n \cdot e^{x^2} \cdot \frac{\mathrm{d}^n}{\mathrm{d}x^n}\left(e^{-x^2}\right), x \in (-\infty, +\infty), n = 0, 1, 2, \cdots$$
$$\rho(x) = e^{-x^2}$$

以 $n+1$ 次 Hermite 多项式的零点为求积节点构造的公式

$$\int_{-\infty}^{+\infty} e^{-x^2} f(x)\,\mathrm{d}x \approx \sum_{k=0}^{n} A_k f(x_k)$$

称为 Gauss-Hermite 求积公式。

4.5.3 Gauss 公式的余项

$$\begin{aligned} R[f] &= \int_a^b f(x)\,\mathrm{d}x - \sum_{k=0}^{n} A_k f(x_k) \\ &= \int_a^b f(x)\,\mathrm{d}x - \sum_{k=0}^{n} A_k P(x_k) \\ &= \int_a^b f(x)\,\mathrm{d}x - \int_a^b P(x)\,\mathrm{d}x \\ &= \int_a^b [f(x) - P(x)]\,\mathrm{d}x \end{aligned}$$

4.5.4 Hermite 多项式的余项

Hermite 多项式的插值条件为：$H(x_k) = f(x_k), H'(x_k) = f'(x_k)$ Hermite 插值余项为

$$R(x) = f(x) - H(x) = \frac{f^{(2n+2)}(\xi_x)}{(2n+2)!}\omega^2(x)$$

其中，$\omega(x) = (x - x_0)\cdots(x - x_n)$，$\xi_x$ 与 x 有关。

$$\begin{aligned}\Rightarrow R[f] &= \int_a^b R(x)\,\mathrm{d}x \\ &= \int_a^b \frac{f^{(2n+2)}(\xi_x)}{(2n+2)!}\omega^2(x)\,\mathrm{d}x \\ &= \frac{f^{(2n+2)}(\xi_x)}{(2n+2)!}\int_a^b \omega^2(x)\,\mathrm{d}x\end{aligned}$$

其中, $\xi \in (a, b)$

4.5.5 Gauss 型求积公式的收敛性

定理 4.5.2. *若 $f(x) \in C[a, b]$，则 Gauss 型求积公式所求积分值序列 $I_n(f) = \sum_{k=1}^n A_k f(x_k)$ 收敛于积分值 $I(f)$，即*

$$\lim_{n\to\infty}\sum_{k=1}^n A_k f(x_k) = \int_a^b \rho(x)f(x)\,\mathrm{d}x$$

4.5.6 Gauss 型求积公式的数值稳定性

定理 4.5.3. *Gauss 型求积公式的求积系数都大于零，从而 Gauss 型求积公式是数值稳定的。*

复化 Gauss-Legender 求积公式

$h = \frac{b-a}{n}, x_k = a + kh\ (k = 0, \cdots, n)$

$$\begin{aligned}\int_{x_k}^{x_{k+1}} f(x)\,\mathrm{d}x &= \frac{h}{2}\int_{-1}^1 f(\frac{h}{2}t + a + (k+\frac{1}{2})h)\,\mathrm{d}t \\ &\approx \frac{h}{2}\sum_{k=0}^n A_k f(\frac{h}{2}t_k + a + (k+\frac{1}{2})h)\end{aligned}$$

其中，t_k 为 $n+1$ 次 Legendre 多项式 P_{n+1} 的根。从而

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{b-a}{2n}\sum_{k=0}^{n-1}[\sum_{j=0}^{n} A_j^{(k)} f(\frac{h}{2}t_j^{(k)} + a + (k+\frac{1}{2})h)]$$

4.5.7 复化两点 Gauss-Legender 求积公式

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{b-a}{2n}\sum_{k=0}^{n-1}[F_k(-\frac{1}{\sqrt{3}}) + F_k(\frac{1}{\sqrt{3}})]$$

其中，$F_k(t) = f(\frac{h}{2}t + a + (k+\frac{1}{2})h)$

4.5.8 复化三点 Gauss-Legender 求积公式

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{b-a}{2n}\sum_{k=0}^{n-1}[\frac{5}{9}F_k(-\sqrt{\frac{3}{5}}) + \frac{8}{9}F_k(0) + \frac{5}{9}F_k(\sqrt{\frac{3}{5}})]$$

Chapter 5

线性方程组的直接解法

5.1 Gauss 消去法

5.1.1 三角形方程组回代法

如:

$$\begin{cases} a_{11}x_1 & & & = b_1 \\ a_{21}x_1 + a_{22}x_2 & & & = b_2 \\ \cdots \quad \cdots \quad \cdots & & & \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n & & & = b_n \end{cases}$$

或上三角方程组:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ \qquad\quad a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \qquad\qquad\quad \cdots \\ \qquad\qquad\qquad\quad a_{nn}x_n = b_n \end{cases}$$

5.1.2 顺序 Gauss 消去法

对于一般的线性方程组

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + \cdots + a_{1n}x_n = a_{1,n+1} \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 + \cdots + a_{2n}x_n = a_{2,n+1} \\ \cdots \\ a_{n1}x_1 + a_{n2}x_2 + a_{n3}x_3 + \cdots + a_{nn}x_n = a_{n,n+1} \end{cases}$$

记

$$\overline{A}^{(1)} = (A, b)$$
$$= \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} & a_{1,n+1} \\ a_{21} & a_{22} & \cdots & a_{2n} & a_{2,n+1} \\ \vdots & \vdots & & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} & a_{n,n+1} \end{pmatrix} = \begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ a_{21}^{(1)} & a_{22}^{(1)} & \cdots & a_{2n}^{(1)} & a_{2,n+1}^{(1)} \\ \vdots & \vdots & & \vdots & \vdots \\ a_{n1}^{(1)} & a_{n2}^{(1)} & \cdots & a_{nn}^{(1)} & a_{n,n+1}^{(1)} \end{pmatrix}$$

解 n 阶方程组的顺序 Gauss 消去一般步骤

第一次消元, 设 $a_{11}^{(1)} \neq 0$, 令

$$m_{i1} = \frac{a_{i1}^{(1)}}{a_{11}^{(1)}}$$

称 m_{i1} 为消元因子. 令 $a_{ij}^{(2)} = a_{ij}^{(1)} - m_{i1}a_{1j}^{(1)}, i = 2, \cdots, n, j = 2, \cdots, n+1$, 则得矩阵

$$\begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} \\ 0 & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} \\ \vdots & \vdots & & \vdots \\ 0 & a_{n2}^{(2)} & \cdots & a_{nn}^{(2)} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} a_{1,n+1}^{(1)} \\ a_{2,n+1}^{(2)} \\ \vdots \\ a_{n,n+1}^{(2)} \end{pmatrix}$$

即 $A^{(2)}x = b^{(2)}$

以此类推, 对于第 k 次消元, 若 $a_{kk}^{(k)} \neq 0$, 令

$$m_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$$

令 $a_{ik}^{(k+1)} = a_{ij}^{(k)} - m_{ik}a_{kj}^{(k)}, i = k+1, \cdots, n; j = k+1, \cdots, n+1$ 则

$$A^{(k)} = \begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & \cdots & \cdots & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \cdots & \cdots & \cdots & a_{2n}^{(2)} \\ & & \ddots & \vdots & \vdots & \vdots \\ & & & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} \\ & & & \vdots & & \vdots \\ & & & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} \end{pmatrix}, b^{(k)} = \begin{pmatrix} a_{1,n+1}^{(1)} \\ a_{2,n+1}^{(2)} \\ \vdots \\ a_{k-1,n+1}^{(k-1)} \\ a_{k,n+1}^{(k)} \\ \vdots \\ a_{n,n+1}^{(k)} \end{pmatrix}$$

即 $A^{(k)}x = b^{(k)}$

共进行 $n-1$ 步, 即可得到三角方程组

$$\begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} \\ & & \ddots & \vdots \\ & & & a_{nn}^{(n)} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} a_{1,n+1}^{(1)} \\ a_{2,n+1}^{(2)} \\ \vdots \\ a_{n,n+1}^{(n)} \end{pmatrix}$$

得

$$A^{(n)}x = b^{(n)}$$

利用回代过程, 求解得

$$x_n = \frac{a_{n,n+1}^{(n)}}{a_{nn}^{(n)}}$$

$$x_k = \frac{a_{k,n+1}^{(k)} - \sum_{j=k+1}^{n} a_{kj}^{(k)} x_j}{a_{kk}^{(k)}}, k = n-1, n-2, \cdots, 2, 1$$

称 $a_{kk}^{(k)}$ 为主元素 (或主元).

注: 若第一个主元素为 0, 则可把第一列得非零元素调整至第一行, 此时 Gauss 消去法仍然可用.

一般地, 关于顺序 Gauss 消去法可执行的前提, 有如下引理:

引理 5.1.1. *给定线性方程组 $Ax = b$, 按顺序 Gauss 消去法所形成的各主元素 $a_{kk}^{(k)}(k = 1, 2, \cdots, n)$ 均不为零, 从而 Gauss 消去法可顺利执行的*

充要条件是 n 阶方阵 A 的所有顺序主子式都不为零, 即

$$D_1 = a_{11} \neq 0, \cdots, D_k = \begin{vmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \cdots & a_{kk} \end{vmatrix} \neq 0, k = 2, 3, \cdots, n$$

当线性方程组的系数矩阵为对称正定或严格对角占优时, 按顺序 Gauss 消去法计算是稳定的.

定理 5.1.2. *若矩阵 A 非奇异, 即 A^{-1} 存在, 则可通过逐次消元以及行交换, 将方程组转化为三角形方程组并求出唯一解.*

定理 5.1.3. *若 A 的所有顺序主子式均不为 0, 则 Gauss 消元无需换行即可进行到底并求出唯一解.*

5.1.3 Gauss 主元素消去法

考虑一个方程组:

$$\begin{pmatrix} 0.001 & 2.000 & 3.000 \\ -1.000 & 3.712 & 4.623 \\ -2.000 & 1.072 & 5.643 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1.000 \\ 2.000 \\ 3.000 \end{pmatrix}$$

可以发现, 该方程组在使用四位浮点数运算, 得到的计算解 (近似解) 为 $(-0.4000, -0.09980, 0.4000)^{\mathrm{T}}$, 显然与精确解不符. 出现该问题的原因是, 在消元计算时, 使用了小主元 0.001, 从顺序 Gauss 消去法的角度看, 不为零的主元可以使用, 但从误差的角度看, 使用小主元 (做除数) 会导致数量级增大, 从而引起舍入误差. 因此, 我们需要通过矩阵变换, 以获得合适的主元.

完全主元素法

考虑在每一次消元过程中, 在增广矩阵中选择绝对值最大的一项作为主元素, 并将其移动至对角主元位置, 然后进行消元. 经过一系列的消元, 可将方程组化为

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ & a_{22} & \cdots & a_{2n} \\ & & \ddots & \vdots \\ & & & a_{nn} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

其中, $y_1, y_2, \cdots, y_n$ 为未知数 $x_1, x_2, \cdots, x_n$ 经过选择主元调换后的次序. 这里未知数次序的调换主要是由于列变换导致的 (行变换不会交换未知数的位置)

关于完全主元素法, 有如下特点:

1. 在选择主元时需要花费较多机器时间;

2. 需要实时记录 x 的顺序变化;

列主元消去法

在选择主元时仅考虑按列选取, 然后按行使之变到主元位置上, 再进行消元计算.

为了简单起见, 将通过一个例子实际演示用列主元 Gauss 消去法求解过程.

例 5.1.1. 使用列主元消去法求解方程组

$$\begin{cases} x_1 + x_2 + x_3 = 6 \\ 2x_1 + 2x_2 - x_3 = 3 \\ 3x_1 + x_3 = 6 \end{cases}$$

解. 线性方程组增广矩阵为

$$\begin{pmatrix} 1 & 1 & 1 & 6 \\ 2 & 2 & -1 & 3 \\ 3 & 0 & 1 & 6 \end{pmatrix}$$

对第一列而言, 主元为 3, 故将其作为第一行, 作行变换, 得

$$\begin{pmatrix} 3 & 0 & 1 & 6 \\ 2 & 2 & -1 & 3 \\ 1 & 1 & 1 & 6 \end{pmatrix} \to \begin{pmatrix} 3 & 0 & 1 & 6 \\ 0 & 2 & -5/3 & -1 \\ 0 & 1 & 2/3 & 4 \end{pmatrix}$$

对第二列而言, 2 为主元, 故保持不变, 得

$$\begin{pmatrix} 3 & 0 & 1 & 6 \\ 0 & 2 & -5/3 & -1 \\ 0 & 1 & 2/3 & 4 \end{pmatrix} \to \begin{pmatrix} 3 & 0 & 1 & 6 \\ 0 & 2 & -5/3 & -1 \\ 0 & 0 & 9/6 & 9/2 \end{pmatrix}$$

利用回代法, 得方程组解为 $(1, 2, 3)^{\mathrm{T}}$ □

上述解答用程序语言可以实现如下:

```python
# 使用列主元Gauss消去法求解方程组 Exercise5-1.py

import numpy as np

#使用列主元Gauss消去法求解方程组
def gauss_elimination(A, b):
    n = A.shape[0]
    # 消元
    for j in range(n):
        # 选择最大值作为主元
        max_idx = j + np.argmax(np.abs(A[j:, j]))
        if j != max_idx:
            A[[j, max_idx]] = A[[max_idx, j]]
            b[[j, max_idx]] = b[[max_idx, j]]
        # 计算主元下面的元素
        pivot = A[j, j]
        for i in range(j+1, n):
            factor = A[i, j] / pivot
            A[i, :] -= factor * A[j, :]
            b[i] -= factor * b[j]
    # 回代
    x = np.zeros(n)
    for j in range(n-1, -1, -1):
        x[j] = (b[j] - np.dot(A[j, j+1:], x[j+1:])) / A[j, j]
    return x

# 计算方程组
A = np.array([[1,1,1],[2,2,-1],[3,0,1]], dtype=float)
b = np.array([6,3,6], dtype=float)
x = gauss_elimination(A, b)
print("x=", x)
```

程序计算结果与我们计算结果是一致的.

Gauss-Jordan 消去法

基本思想: 同时消去对角线上方和下方的元素.
特点:

1. 消元和回代同时进行;
2. 乘除法次数比 Gauss 消去法大

下面以一个线性方程组为例, 介绍如何实现 Gauss-Jordan 消去法:

例 5.1.2. 使用 *Gauss-Jordan* 消去法求解方程组

$$\begin{cases} x_1 + x_2 + x_3 = 6 \\ 2x_1 + x_2 - x_3 = 1 \\ 3x_1 + x_3 = 6 \end{cases}$$

解. 对于 Gauss-Jordan 消去法, 我们不考虑主元. 增广矩阵为

$$\begin{pmatrix} 1 & 1 & 1 & 6 \\ 2 & 1 & -1 & 1 \\ 3 & 0 & 1 & 6 \end{pmatrix}$$

首先进行第一次消元, 得到结果为

$$\begin{pmatrix} 1 & 1 & 1 & 6 \\ 2 & 1 & -1 & 1 \\ 3 & 0 & 1 & 6 \end{pmatrix} \to \begin{pmatrix} 1 & 1 & 1 & 6 \\ 0 & -1 & -3 & -11 \\ 0 & -3 & -2 & -12 \end{pmatrix}$$

对第二行进行消元, 对于 Gauss-Jordan 消去法, 我们需要同时考虑对角线上下的元素. 因此, 消元后结果如下:

$$\begin{pmatrix} 1 & 1 & 1 & 6 \\ 0 & -1 & -3 & -11 \\ 0 & -3 & -2 & -12 \end{pmatrix} \to \begin{pmatrix} 1 & 0 & -2 & -5 \\ 0 & 1 & 3 & 11 \\ 0 & 0 & 7 & 21 \end{pmatrix}$$

可以看到, 经过第二步消元后, 第二列除主元素外所有元素都为 0. 同理, 第三步消元得到结果为

$$\begin{pmatrix} 1 & 0 & -2 & -5 \\ 0 & 1 & 3 & 11 \\ 0 & 0 & 7 & 21 \end{pmatrix} \to \begin{pmatrix} 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 2 \\ 0 & 0 & 1 & 3 \end{pmatrix}$$

因此解得方程组解为 $(1,2,3)^{\mathrm{T}}$ □

列主元 Gauss-Jordan 消去法

与列主元 Gauss 消去法类似, 列主元 Gauss-Jordan 消去法步骤为:

第一步, 选择第一列的主元, 并将其换至第一行, 将第一个方程的系数变为 1, 同时从其余 $n-1$ 个方程中消去 x_1;

第二步, 再第二列后 $n-1$ 个元素中选择主元, 将第二个方程 x_2 系数变为 1, 并从其他 $n-1$ 个方程中消去 x_2

$\cdots$

第 k 步, 在第 k 列后 $n-k$ 个元素中选主元并换行, 将第 k 个方程的 x_k 系数变为 1, 并从其他 $n-1$ 个方程中消去变量 x_k

消元公式为

$$\begin{cases} a_{kj}^{(k)} = \frac{a_{kj}^{(k-1)}}{a_{kk}^{(k-1)}}, j = k, k+1, \cdots, n+1 \\ a_{ij}^{(k)} = a_{ij}^{(k-1)} - a_{ik}^{(k-1)} a_{kj}^{(k)} \\ j = k, k+1, \cdots, n+1 \\ i = 1, 2, \cdots, k-1, k+1, \cdots, n \end{cases}$$

对 $k = 1, 2, \cdots$ 进行上述步骤至第 n 步后, 方程组可变为

$$\begin{cases} x_1 = a_{1,n+1}^{(n)} \\ x_2 = a_{2,n+1}^{(n)} \\ \vdots \\ x_n = a_{n,n+1}^{(n)} \end{cases}$$

即为所求的解.

Gauss-Jordan 消去法应用

对于线性方程组系, 如

$$AX = b_1, AX = b_2, \cdots, AX = b_m$$

其中,

$$A = \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{pmatrix}, X = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}, b_i = \begin{pmatrix} a_{1,n+1}^{(i)} \\ a_{2,n+1}^{(i)} \\ \vdots \\ a_{n,n+1}^{(i)} \end{pmatrix}, i = 1, 2, \cdots, n$$

因此上述方程组系可写作

$$AX = B = (b_1, \cdots, b_n)$$

其解为

$$X = A^{-1}B$$

特殊的, 设 $A = (a_{ij})_{n\times n}$ 是非奇异矩阵, $|A| \neq 0$, 令

$$X = A^{-1} = (x_{ij})_{n\times n}$$

由于 $AA^{-1} = AX = I$, 因此求解 X 的过程等价于当 $m = n, B = I$ 的方程组求解, 此时得到 $X = A^{-1}$

例 5.1.3. *用 Gauss-Jordan 消去法求解方程组 $Ax = b$, 并求出 A^{-1}, 其中,*

$$A = \begin{pmatrix} 1 & 3 & 1 \\ 1 & 2 & 4 \\ 5 & 1 & 2 \end{pmatrix}, b = \begin{pmatrix} 10 \\ 17 \\ 13 \end{pmatrix}$$

解. 将系数矩阵, 单位矩阵和 b 组成增广矩阵, 并对其进行 Gauss-Jordan 消元过程, 可得过程为

$$\begin{pmatrix} 1 & 3 & 1 & 1 & & & 10 \\ 1 & 2 & 4 & & 1 & & 17 \\ 5 & 1 & 2 & & & 1 & 13 \end{pmatrix} \to \begin{pmatrix} 1 & 3 & 1 & 1 & & & 10 \\ 0 & -1 & 3 & -1 & 1 & & 7 \\ 0 & -14 & -3 & -5 & & 1 & -37 \end{pmatrix}$$

$$\to \begin{pmatrix} 1 & & 10 & -2 & 3 & & 31 \\ & 1 & -3 & 1 & -1 & 0 & -7 \\ & & -45 & 9 & -14 & 1 & -135 \end{pmatrix} \to \begin{pmatrix} 1 & & & 0 & -0.11 & 0.22 & 1 \\ & 1 & & 0.4 & -0.07 & -0.07 & 2 \\ & & 1 & -0.2 & 0.31 & -0.02 & 3 \end{pmatrix}$$

故方程组的解为 $(1,2,3)^{\mathrm{T}}$, 系数矩阵的逆为

$$A^{-1}=\begin{pmatrix}0 & -0.11 & 0.22\\ 0.4 & -0.07 & -0.07\\ -0.2 & 0.31 & -0.02\end{pmatrix}$$

□

5.2 解三对角方程组的追赶法

求解线性方程组

$$\begin{pmatrix}b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & b_{n-1} & c_{n-1}\\ & & & a_n & b_n\end{pmatrix}\begin{pmatrix}x_1\\ x_2\\ \vdots\\ x_{n-1}\\ x_n\end{pmatrix}=\begin{pmatrix}d_1\\ d_2\\ \vdots\\ d_{n-1}\\ d_n\end{pmatrix}$$

且满足:

$$\begin{cases}|b_1|>|c_1|\\ |b_i|\geq|a_i|+|c_i|, i=2,\cdots,n-1\\ |b_n|>|a_n|\end{cases}$$

消元公式为

$$\begin{cases}r_1=\frac{c_1}{b_1}, y_1=\frac{d_1}{b_1}\\ r_k=\frac{c_k}{b_k-r_{k-1}a_k}, & k=2,3,\cdots,n-1\\ y_k=\frac{d_k-y_{k-1}a_k}{b_k-r_{k-1}a_k}, & k=2,3,\cdots,n\end{cases}$$

回代公式

$$\begin{cases}x_n=y_n\\ x_k=y_k-r_kx_{k+1}, & k=n-1,n-2,\cdots,1\end{cases}$$

5.3 矩阵的三角分解法

5.3.1 Gauss 消元法矩阵形式

对于 Gauss 消元法, 每一步消元过程相当于左乘下三角矩阵 L_k

记

$$A^{(2)} = L_1^{-1}A^{(1)}, b^{(2)} = L_1^{-1}b^{(1)}$$

其中,

$$L_1^{-1} = \begin{pmatrix} 1 & & & & \\ -l_{21} & 1 & & & \\ -l_{31} & 0 & 1 & & \\ \vdots & \vdots & \vdots & \ddots & \\ -l_{n1} & 0 & 0 & \cdots & 1 \end{pmatrix}, l_{i1} = \frac{a_{i1}^{(1)}}{a_{11}^{(1)}}, i = 2, 3, \cdots, n$$

同理, 有

$$A^{(3)} = L_2^{-1}A^{(2)} = L_2^{-1}L_1^{-1}A^{(1)}, b^{(3)} = L_2^{-1}L_1^{-1}b^{(1)}$$

其中,

$$L_2^{-1} = \begin{pmatrix} 1 & & & & \\ 0 & 1 & & & \\ 0 & -l_{32} & 1 & & \\ \vdots & \vdots & \vdots & \ddots & \\ 0 & -l_{n2} & 0 & \cdots & 1 \end{pmatrix}, l_{i2} = \frac{a_{i2}^{(2)}}{a_{22}^{(2)}}, i = 3, 4, \cdots, n$$

一般地, 对 $i = 1, 2, \cdots, n-1$, 令

$$L_i^{-1} = \begin{pmatrix} 1 & & & & & \\ 0 & 1 & & & & \\ \vdots & & 1 & & & \\ 0 & \cdots & -l_{i+1,i} & 1 & & \\ \vdots & & \vdots & \vdots & \ddots & \\ 0 & & -l_{ni} & & & 1 \end{pmatrix}, L_i = \begin{pmatrix} 1 & & & & & \\ 0 & 1 & & & & \\ \vdots & & \ddots & & & \\ \vdots & & & 1 & & \\ 0 & & & l_{i+1,i} & 1 & \\ \vdots & & & \vdots & & \ddots \\ 0 & & & l_{ni} & & 1 \end{pmatrix}$$

$$l_{ki} = \frac{a_{ki}^{(i)}}{a_{ii}^{(i)}}, k = i+1, \cdots, n$$

则

$$A^{(n)} = L_{n-1}^{-1}L_{n-2}^{-1}\cdots L_1^{-1}A^{(1)}$$

$$b^{(n)} = L_{n-1}^{-1}L_{n-2}^{-1}\cdots L_1^{-1}b^{(1)}$$

于是有

$$A^{(1)} = L_1 L_2 \cdots L_{n-1} A^{(n)} = L A^{(n)} = LU$$

将上式分解方式, 称为矩阵 A 的 LU 分解.

5.3.2 矩阵三角分解的定义

定义 5.3.1. 设 A 是 $n \times n$ 实矩阵, 如果存在下三角矩阵 L 与上三角矩阵 U, 使得 $A = LU$, 则称为矩阵 A 的三角分解, 若存在单位下三角矩阵 L, 对角矩阵 D 以及单位上三角矩阵 R, 使得 $A = LDR$, 则称为矩阵 A 的 LDR 分解.

若 L 为单位下三角矩阵而 U 是一般上三角矩阵, 则称该分解为 *Doolittle* 分解; 若 L 为一般下三角矩阵而 U 是单位上三角矩阵, 则称该分解为 *Crout* 分解.

5.3.3 矩阵三角分解的存在性

定理 5.3.1. 设 A 为 $n \times n$ 实矩阵, 若求解 $AX = b$ 用顺序 *Gauss* 消去法能够完成, 即 $a_{kk}^{(k)} \neq 0, k = 1, 2, \cdots, n$, 则矩阵 A 可分解为单位下三角矩阵 L 与上三角矩阵 U 的乘积, 即

$$A = LU$$

且这种分解唯一.

若 A 已经实现了 LU 分解, 则将方程组 $Ax = b$ 转化为 $(LU)x = b$, 从而计算得

$$Ly = b$$
$$Ux = y$$

若直接从矩阵 A 的元素得到计算 L, U 的递推公式, 而不需要中间步骤, 则称这种分解方法为直接三角分解法

直接三角分解法

例 5.3.1. 使用三角分解法解方程组

$$\begin{cases} x_1 + x_2 + x_3 = 6 \\ 4x_2 - x_3 = 5 \\ 2x_1 - 2x_2 + x_3 = 1 \end{cases}$$

解. 系数矩阵为

$$A = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 4 & -1 \\ 2 & -2 & 1 \end{pmatrix}$$

计算消元因子, 有

$$m_{21} = 0/1 = 0$$
$$m_{31} = 2/1 = 2$$

得行变换后矩阵为

$$A \to \begin{pmatrix} 1 & 1 & 1 \\ 0 & 4 & -1 \\ 0 & -4 & -1 \end{pmatrix}$$

类似地, 消元因子

$$m_{32} = -4/4 = -1$$

矩阵变换

$$\begin{pmatrix} 1 & 1 & 1 \\ 0 & 4 & -1 \\ 0 & 0 & -2 \end{pmatrix}$$

因此, 由 Gauss 消去法得矩阵分解

$$A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 1 \\ 0 & 4 & -1 \\ 0 & 0 & -2 \end{pmatrix}$$

解方程组

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2 & -1 & 1 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} = \begin{pmatrix} 6 \\ 5 \\ 1 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 1 & 1 \\ 0 & 4 & -1 \\ 0 & 0 & -2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix}$$

解得

$$\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

□

Doolittle 三角分解法

对于矩阵三角分解, 也可以直接使用待定系数法, 称为 Doolittle 分解法.

例 5.3.2. 利用 *Doolittle* 三角分解法重解上题

解. 待定系数法, 设

$$L = \begin{pmatrix} 1 & 0 & 0 \\ l_{21} & 1 & 0 \\ l_{31} & l_{32} & 1 \end{pmatrix}, U = \begin{pmatrix} u_{11} & u_{12} & u_{13} \\ 0 & u_{22} & u_{23} \\ 0 & 0 & u_{33} \end{pmatrix}$$

利用矩阵分解表达式, 有

$$\begin{pmatrix} 1 & 1 & 1 \\ 0 & 4 & -1 \\ 2 & -2 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ l_{21} & 1 & 0 \\ l_{31} & l_{32} & 1 \end{pmatrix} \begin{pmatrix} u_{11} & u_{12} & u_{13} \\ 0 & u_{22} & u_{23} \\ 0 & 0 & u_{33} \end{pmatrix}$$

得

$$u_{11} = 1, u_{12} = 1, u_{13} = 1$$
$$l_{21} = 0, u_{22} = 4, u_{23} = -1$$
$$l_{31} = 2, l_{32} = -1, u_{33} = -2$$

故将矩阵分解为

$$A=\begin{pmatrix}1&0&0\\0&1&0\\2&-1&1\end{pmatrix}\begin{pmatrix}1&1&1\\0&4&-1\\0&0&-2\end{pmatrix}$$

□

例 5.3.3. 用矩阵三角分解法求解方程组

$$\begin{pmatrix}1&2&3\\2&5&2\\3&1&5\end{pmatrix}\begin{pmatrix}x_1\\x_2\\x_3\end{pmatrix}=\begin{pmatrix}14\\18\\20\end{pmatrix}$$

解. 待定系数法,

$$\begin{pmatrix}1&2&3\\2&5&2\\3&1&5\end{pmatrix}=\begin{pmatrix}1&0&0\\l_{21}&1&0\\l_{31}&l_{32}&1\end{pmatrix}\begin{pmatrix}u_{11}&u_{12}&u_{13}\\0&u_{22}&u_{23}\\0&0&u_{33}\end{pmatrix}$$

解得

$$u_{11}=1,u_{12}=2,u_{13}=3$$
$$l_{21}=2,u_{22}=1,u_{23}=-4$$
$$l_{31}=3,l_{32}=-5,u_{33}=-24$$

即

$$L=\begin{pmatrix}1&0&0\\2&1&0\\3&-5&1\end{pmatrix},U=\begin{pmatrix}1&2&3\\0&1&-4\\0&0&-24\end{pmatrix}$$

解方程组

$$Ly=b$$
$$Ux=y$$

可得

$$x=(1,2,3)^{\mathrm{T}}$$

□

紧凑格式的 Doolittle 三角分解法

考虑增广矩阵 $(A;b)$, 将消元因子作为矩阵变换过程中的元素, 从而在变换过程中一次性得到 L,U,y, 将这种过程称为紧凑格式的 *Doolittle* 三角分解法.

例 5.3.4. 使用紧凑格式的 *Doolittle* 三角分解法重解上题

解. 考虑增广矩阵

$$\begin{pmatrix} 1 & 2 & 3 & 14 \\ 2 & 5 & 2 & 18 \\ 3 & 1 & 5 & 20 \end{pmatrix}$$

消元因子 $m_{21}=2, m_{31}=3$, 变换得

$$\begin{pmatrix} 1 & 2 & 3 & 14 \\ 2 & 1 & -4 & -10 \\ 3 & -5 & -4 & -22 \end{pmatrix}$$

类似地, 消元因子 $m_{32}=-5$, 故得变换后矩阵为

$$\begin{pmatrix} 1 & 2 & 3 & 14 \\ 2 & 1 & -4 & -10 \\ 3 & -5 & -24 & -72 \end{pmatrix}$$

因此直接解得

$$L=\begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 3 & -5 & 1 \end{pmatrix}, U=\begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & -4 \\ 0 & 0 & -24 \end{pmatrix}, y=\begin{pmatrix} 14 \\ -10 \\ -72 \end{pmatrix}$$

解方程组 $Ux=y$, 可得

$$x=(1,2,3)^{\mathrm{T}}$$

□

上述例题可使用下述程序代码求解:

```
1 # 使用紧凑格式的Doolittle三角分解法求解线性方程组 Exercise5-2.py
2
```

```python
import numpy as np

def doolittle_triangular_decomposition(A):
    """
    Doolittle三角分解法
    """
    n = A.shape[0]
    L = np.zeros((n, n))
    U = np.zeros((n, n))
    for i in range(n):
        L[i, i] = 1
        for j in range(i, n):
            U[i, j] = A[i, j] - sum(L[i, k] * U[k, j] for k in
                range(i))
            if i != j:
                L[j, i] = (A[j, i] - sum(L[j, k] * U[k, i] for k
                    in range(i))) / U[i, i]
    return L, U

def forward_substitution(L, b):
    """
    前向替代
    """
    n = L.shape[0]
    x = np.zeros(n)
    for i in range(n):
        x[i] = b[i] / L[i, i]
        for j in range(i):
            x[i] -= x[j] * L[i, j] / L[i, i]
    return x

def backward_substitution(U, b):
    """
```

```
    回代
    """
    n = U.shape[0]
    x = np.zeros(n)
    for i in reversed(range(n)):
        x[i] = (b[i] - sum(U[i, j] * x[j] for j in range(i+1, n
            ))) / U[i, i]
    return x

def doolittle_solver(A, b):
    """
    使用Doolittle三角分解法求解线性方程组
    """
    L, U = doolittle_triangular_decomposition(A)
    y = forward_substitution(L, b)
    x = backward_substitution(U, y)
    return x

A = np.array([[1,2,3],[2,5,2],[3,1,5]], dtype=float)
b = np.array([14,18,20], dtype=float)
x = doolittle_solver(A, b)
print("x=", x)
```

类似地, 还有紧凑格式的列主元 Doolittle 三角分解法, 不做详细说明. 需要特别注意的是, 在变换矩阵过程中所得到的消元因子, 不参与行变换的计算, 但需要参与行交换.

5.4 Gauss 消去法变形

5.4.1 矩阵 LDR 分解

定理 5.4.1. *若 n 阶矩阵 A 的所有顺序主子式均不为 0, 则矩阵 A 存在唯一分解式 $A = LDR$, 其中 L, R 分别为 n 阶单位下三角矩阵和单位上三角矩阵, D 为对角元素不为 0 的 n 阶对角矩阵. 上述分解方法称为 A 的*

LDR 分解.

推论 5.4.2. 设 A 为 n 阶对称矩阵, 且 A 的所有顺序主子式均不为 *0*, 则 A 可唯一分解为

$$A + LDL^T$$

其中, L 为单位下三角矩阵, D 为对角矩阵

特殊地, 考虑对称正定矩阵, 其定义为

定义 5.4.1. 设 $A \in R^{n\times n}$, 若 A 满足

1.

$$A^T = A$$

2. $\forall x \in R^n$, 且 $x \neq 0$, 有

$$x^T Ax > 0$$

则称 A 为对称正定矩阵.

关于对称正定矩阵, 有如下性质

1. A 是非奇异矩阵, 且 A^{-1} 是对称正定矩阵;

2. A 地顺序主子式均大于 0, 即

$$\det(A_k) > 0, k = 1, 2, \cdots, n$$

3. A 的特征值

$$\lambda_i(A) > 0, i = 1, 2, \cdots, n$$

对于对称正定矩阵, 矩阵有特殊的分解, 即平方根法

5.4.2 平方根法

定理 5.4.3. 若 A 为对称正定矩阵, 则存在一个实的非奇异下三角矩阵, 使得 $A = LL^T$, 且当限定的对角元素为正时, 这种分解是唯一的, 称为矩阵 A 的 *Cholesky* 分解.

对于平方根法, 其数值是稳定的, 即在计算过程中不需要选择主元, 但在计算过程中会引入平方根计算, 因此计算难度会较大 (但计算量较一般的 LU 分解小)

5.4.3 改进平方根法

为避免开方运算, 我们改进平方根法, 即考虑将矩阵 A 分解为 LDL^{T}, 其中 L 为单位下三角矩阵, D 为对角矩阵.

通过分解, 将方程组转换为 $LDL^{\mathrm{T}}x = b$, 求解下列方程组

$$Ly = bL^{\mathrm{T}}x = D^{-1}y$$

下面将通过一个例子实际演示使用改进的平方根法求解方程组

例 5.4.1. 用改进平方根法求解方程组

$$\begin{pmatrix} 1 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 4 \\ 6 \\ 4 \end{pmatrix}$$

解. 系数矩阵为对称矩阵, 则可以将其分解为

$$\begin{pmatrix} 1 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ l_{21} & 1 & 0 \\ l_{31} & l_{32} & 1 \end{pmatrix} \begin{pmatrix} d_1 & & \\ & d_2 & \\ & & d_3 \end{pmatrix} \begin{pmatrix} 1 & l_{21} & l_{31} \\ 0 & 1 & l_{32} \\ 0 & 0 & 1 \end{pmatrix}$$

解得

$$L = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 1 & 1 & 1 \end{pmatrix}, D = \begin{pmatrix} 1 & & \\ & -1 & \\ & & 2 \end{pmatrix}$$

解方程

$$Ly = b$$

得

$$y = (4, -2, 2)^{\mathrm{T}}$$

解方程

$$L^{\mathrm{T}}x = D^{-1}y$$

其中

$$D^{-1} = \begin{pmatrix} 1 & & \\ & -1 & \\ & & \frac{1}{2} \end{pmatrix}$$

得

$$x = (1, 1, 1)^{\mathrm{T}}$$

□

使用改进平方根法有如下优点:

1. 计算量小, 是目前计算对称正定矩阵方程组得有效方法;
2. 计算简单, 没有开方计算;
3. 精度较高;
4. 可以推广至非正定方程组的求解

5.5 线性方程组的性态和解的误差估计

在求解线性方程 $Ax = b$ 时, 系数 A 和 b 的误差对解 x 有影响.

当 A 精确时, 设 b 有误差 δb, 设得到的解为 $x + \delta x$, 即

$$A(x + \delta x) = b + \delta b$$

有

$$\delta x = A^{-1}\delta b$$

由范数的性质可知,

$$\|\delta x\| \leq \|A^{-1}\| \, \|\delta b\|$$

又因为

$$\|b\| = \|Ax\| \leq \|A\| \, \|x\| \Rightarrow \frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|}$$

即

$$\frac{\|\delta x\|}{\|x\|} \leq \|A\| \, \|A^{-1}\| \, \frac{\|\delta b\|}{\|b\|}$$

同理, 设 b 精确, A 有误差 δA, 解为 $x + \delta x$, 即

$$(A + \delta A)(x + \delta x) = b$$

可得

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A\| \, \|A^{-1}\| \, \frac{\|\delta A\|}{\|A\|}}{1 - \|A\| \, \|A^{-1}\| \, \frac{\|\delta A\|}{\|A\|}}$$

可以发现, $\|A\| \, \|A^{-1}\|$ 是衡量误差放大的重要因素, 称为条件数, 记作 $\mathrm{cond}(A)$.

定义 5.5.1. 设线性方程组的系数矩阵是非奇异的, 若 $cond(A)$ 越大, 则称这个方程组越病态, 反之, 若 $cond(A)$ 越小, 则称方程组越良态.

通常来说, 判断一个矩阵是否病态, 可采用如下方法:

1. 行列式很大或很小;
2. 元素之间相差较大数量级;
3. 主元消去过程中出现小主元;
4. 特征值相差较大数量级

Chapter 6

线性方程组的迭代解法

6.1 一般迭代法

将线性方程组 $Ax = b$ 改写为等价形式 $x = Bx + g$, 建立某一种迭代格式

$$x_{k+1} = BX_k + g$$

从而从初始值 x_0 出发, 得到序列 x_k

6.1.1 迭代格式构造

将矩阵 A 分裂为

$$A = Q - C, |Q| \neq 0$$

则

$$\begin{aligned} Ax = b &\Leftrightarrow (Q - C)x = b \\ &\Leftrightarrow (I - Q^{-1}C)x = Q^{-1}b \\ &\Leftrightarrow x = Bx + g \end{aligned}$$

其中,

$$\begin{aligned} B &= Q^{-1}C \\ g &= Q^{-1}b \end{aligned}$$

将上式改写为迭代过程

$$x_{k+1} = BX_k + g$$

称这种迭代过程为逐次逼近法, B 为迭代矩阵. 对于给定的初值 x_0, 可得到向量序列

$$x_0, x_1, \cdots, x_n, \cdots$$

定义 6.1.1. 若

$$\lim_{n\to\infty} x_n = x^*$$

则称逐次逼近法收敛, 否则称逐次逼近法不收敛或发散

下面的定理保证了, 收敛值 x^* 为方程组的解

定理 6.1.1. 对于任意给定的初始向量 x_0, 如果经过逐次逼近法产生的向量序列收敛于向量 x^*, 则 x^* 是方程组 $x = Bx + g$ 的解

证明.

$$\lim_{k\to\infty} x_{k+1} = \lim_{k\to\infty} (Bx_k + g)$$

由极限的收敛性可知,

$$x^* = Bx^* + g$$

□

6.1.2 迭代法收敛条件

引理 6.1.2. 当 $k \to \infty$ 时, $B^k \to 0$ 的充要条件是:

$$\rho(B) < 1$$

定理 6.1.3. 设线性方程组 $x = Bx + g$ 有唯一解, 那么逐次逼近法对任意初始向量 x_0 收敛的充要条件是迭代矩阵 B 的谱半径 $\rho(B) < 1$

证明.

$$\begin{cases} x^* = Bx^* + g \\ x_{k+1} = Bx_k + g \end{cases}$$

$$\Rightarrow x_{k+1} - x^* = B(x_k - x^*) = \cdots = B^{k+1}(x_0 - x^*)$$

因此,

$$\lim_{k\to\infty}(x_{k+1}-x^*)=0 \Leftrightarrow \lim_{k\to\infty}B^{k+1}=0$$

由上述引理可知, 其充要条件为 $\rho(B)<1$ □

事实上, 在实际验证收敛性的时候, 我们可以使用谱半径, 但更简单的, 可以使用下面的定理 (这个定理是充分条件而不是充要条件)

定理 6.1.4. *若逐次逼近法的迭代矩阵满足 $\|B\|<1$, 则逐次逼近法收敛. 其中, $\|\cdot\|$ 为矩阵 B 的某种范数.*

由于我们在计算范数的时候, 矩阵的 1-范数与 ∞-范数都可以直接用矩阵元素计算, 因此更容易判断收敛性.

6.1.3 迭代法的误差估计

定理 6.1.5. *若存在一个矩阵范数使得 $\|B\|<1$, 则迭代收敛, 且有误差估计*

$$\|x^*-x_k+1\|\le\frac{\|B\|^{k+1}}{1-\|B\|}\|x_1-x_0\|$$
$$\|x^*-x_{k+1}\|\le\frac{\|B\|}{1-\|B\|}\|x_{k+1}-x_k\|$$

其中, 第一个式子用于判断误差表达式与收敛速度, 第二个式子用于判断终止条件 (即停机准则).

6.2 Jacobi 迭代法

设有 n 阶方程组

$$\begin{cases}a_{11}x_1+a_{12}x_2+\cdots+a_{1n}x_n=b_1\\ a_{21}x_1+a_{22}x_2+\cdots+a_{2n}x_n=b_2\\ \vdots\\ a_{n1}x_1+a_{n2}x_2+\cdots+a_{nn}x_n=b_n\end{cases}$$

若系数矩阵非奇异, 且 $a_{ii} \neq 0 (i = 1, 2, \cdots, n)$, 将方程组改写为

$$\begin{cases} x_1 = \frac{1}{a_{11}}(b_1 - a_{12}x_2 - a_{13}x_3 - \cdots - a_{1n}x_n) \\ x_2 = \frac{1}{a_{22}}(b_2 - a_{21}x_1 - a_{23}x_3 - \cdots - a_{2n}x_n) \\ \vdots \\ x_n = \frac{1}{a_{nn}}(b_n - a_{n1}x_1 - a_{n2}x_2 - \cdots - a_{n,n-1}x_{n-1}) \end{cases}$$

写成迭代格式

$$\begin{cases} x_1^{(k+1)} = \frac{1}{a_{11}}(b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)}) \\ x_2^{(k+1)} = \frac{1}{a_{22}}(b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)}) \\ \vdots \\ x_n^{(k+1)} = \frac{1}{a_{nn}}(b_n - a_{n1}x_1^{(k)} - a_{n2}x_2^{(k)} - \cdots - a_{n,n-1}x_{n-1}^{(k)}) \end{cases}$$

也可以简单写作

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^{n} a_{ij} x_j^{(k)} \right), i = 1, 2, \cdots, n$$

写成矩阵形式,

$$\begin{aligned} Ax = b &\Leftrightarrow (D - L - U)x = b \\ &\Leftrightarrow Dx = (L + U)x + b \\ &\Leftrightarrow x = D^{-1}(L + U)x + D^{-1}b \end{aligned}$$

定义

$$B_J = D^{-1}(L + U), f = D^{-1}b$$

其中 B_J 为 Jacobi 迭代阵, 则迭代格式可以写作

$$x^{(k+1)} = B_J x^{(k)} + f$$

注意: 矩阵 D 是对角矩阵, L 和 U 分别为严格下三角矩阵和严格上三角矩阵, 且 L 和 U 的元素为 A 的相反数

不难验证, B_J 满足下面的形式

$$B_J = \begin{pmatrix} 0 & -\frac{a_{12}}{a_{11}} & -\frac{a_{13}}{a_{11}} & \cdots & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & -\frac{a_{23}}{a_{22}} & \cdots & -\frac{a_{2n}}{a_{22}} \\ -\frac{a_{31}}{a_{33}} & -\frac{a_{32}}{a_{33}} & 0 & \cdots & -\frac{a_{3n}}{a_{33}} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -\frac{a_{n1}}{a_{nn}} & -\frac{a_{n2}}{a_{nn}} & -\frac{a_{n3}}{a_{nn}} & \cdots & 0 \end{pmatrix}$$

1. 在迭代过程中, 矩阵 A 的元素不会改变, 故可以事先调整好 A 的值, 使得对角元素 $a_{ii} \neq 0$, 否则 A 不可逆;

2. 在计算的时候, 需要计算完 $x^{(k)}$ 之后才能继续计算 $x^{(k+1)}$, 因此需要两组向量存储. 从计算机的角度看, 占用了内存空间.

为了解决空间占用问题, 需要给出另一种迭代方法

6.3 Gauss-Seidel 迭代法

若使用下面的形式计算

$$\begin{aligned}
x_1^{(k+1)} &= \frac{1}{a_{11}}(-a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - a_{14}x_4^{(k)} - \cdots - a_{1n}x_n^{(k)} + b_1) \\
x_2^{(k+1)} &= \frac{1}{a_{22}}(-a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - a_{24}x_4^{(k)} - \cdots - a_{2n}x_n^{(k)} + b_2) \\
x_3^{(k+1)} &= \frac{1}{a_{33}}(-a_{31}x_1^{(k+1)} - a_{32}x_2^{(k+1)} - a_{34}x_4^{(k)} - \cdots - a_{3n}x_n^{(k)} + b_3) \\
&\vdots \\
x_n^{(k+1)} &= \frac{1}{a_{nn}}(-a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - a_{n3}x_3^{(k+1)} - \cdots - a_{n,n-1}x_{n-1}^{(k+1)} + b_n)
\end{aligned}$$

用矩阵形式写作

$$\begin{aligned}
& x^{(k+1)} = D^{-1}(Lx^{(k+1)} + Ux^{(k)}) + D^{-1}b \\
& \Leftrightarrow (D-L)x^{(k+1)} = Ux^{(k)} + b \\
& \Leftrightarrow x^{(k+1)} = (D-L)^{-1}Ux^{(k)} + (D-L)^{-1}b
\end{aligned}$$

定义

$$B_{G-S} = (D-L)^{-1}U, g = (D-L)^{-1}$$

称 B_{G-S} 为 Gauss-Seidel 迭代阵.

上式可以理解为将系数矩阵 A 作另一个分裂

$$A = (D - L) - U$$

此时有

$$\begin{aligned} Ax = b &\Leftrightarrow ((D-L)-U)x = b \\ &\Leftrightarrow (D-L)x = Ux + b \\ &\Leftrightarrow x = (D-L)^{-1}Ux + (D-L)^{-1}b \\ &\Leftrightarrow x_{k+1} = (D-L)^{-1}Ux_k + (D-L)^{-1}b \\ &\Leftrightarrow x_{k+1} = B_{G-S}x_k + g \end{aligned}$$

6.4 Jacobi 迭代法和 Gauss-Seidel 迭代法收敛性

定理 6.4.1. *n 阶矩阵 A 是按行严格对角占优矩阵的充分必要条件是 Jacobi 迭代法的迭代矩阵满足 $\|B_J\|_\infty < 1$*

按行严格对角占优矩阵, 指的是对于矩阵 $A = (a_{ij})_{n\times n}$, 有

$$|a_{ii}| > \sum_{j=1, j\neq i}^{n} |a_{ij}|$$

定理 6.4.2. *如果 A 是严格对角占优矩阵, 则 Jacobi 和 Gauss-Seidel 迭代法都收敛*

定理 6.4.3. *若 A 是不可约对角占优矩阵, 则 Jacobi 迭代法与 Gauss-Seidel 迭代法都收敛*

定义 6.4.1 (可约矩阵与不可约矩阵)**.** *设 $A = (a_{ij})_{n\times n}$, 当 $n \geq 2$ 时, 如果存在 n 阶置换阵 P, 使得*

$$P^T AP = \begin{pmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{pmatrix}$$

其中 A_{11} 为 r 阶子矩阵, A_{22} 为 $n-r$ 阶子矩阵, 且 $1 \leq r \leq n$, 则称矩阵 A 为可约矩阵, 否则, 若不存在置换阵 P 使上式成立, 则称矩阵 A 为不可约矩阵.

定理 6.4.4. 若 A 使 n 阶正定矩阵, 则 *Gauss-Seidel* 迭代法收敛.

定理 6.4.5. 若 A 使有正对角元的 n 阶对称矩阵, 则 *Jacobi* 迭代法收敛的充要条件使 A 和 $2D-A$ 同为正定矩阵

对于 Jacobi 迭代, 其特征方程为

$$\begin{aligned}|\lambda I - B_J| = 0 &\Leftrightarrow |\lambda I - D^{-1}(L+U)| = 0\\ &\Leftrightarrow |\lambda D - (L+U)| = 0\\ &\Leftrightarrow \begin{vmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n}\\ a_{21} & \lambda a_{22} & \cdots & a_{2n}\\ \vdots & \vdots & \ddots & \vdots\\ a_{n1} & a_{n2} & \cdots & \lambda a_{nn}\end{vmatrix} = 0\end{aligned}$$

同理, 对于 Gauss-Seidel 迭代

$$\begin{aligned}|\lambda I - B_{G-S}| = 0 &\Leftrightarrow |\lambda I - (D-L)^{-1}U| = 0\\ &\Leftrightarrow |\lambda(D-L) - U| = 0\\ &\Leftrightarrow \begin{vmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n}\\ \lambda a_{21} & \lambda a_{22} & \cdots & a_{2n}\\ \vdots & \vdots & \ddots & \vdots\\ \lambda a_{n1} & \lambda a_{n2} & \cdots & \lambda a_{nn}\end{vmatrix} = 0\end{aligned}$$

例 6.4.1. 分析线性方程组

$$\begin{cases} 2x_1 - x_2 + x_3 = 1\\ x_1 + x_2 + x_3 = 1\\ x_1 + x_2 - 2x_3 = 1\end{cases}$$

使用 *Jacobi* 迭代和 *Gauss-Seidel* 迭代的收敛性

解. 对于 Jacobi 迭代, 其特征方程为

$$\begin{vmatrix} 2\lambda & -1 & 1\\ 1 & \lambda & 1\\ 1 & 1 & -2\lambda\end{vmatrix} = 0$$

解得其特征值为 $0, \pm\frac{\sqrt{5}}{2}i$, 因此谱半径大于 1, Jacobi 迭代法不收敛.

对于 Gauss-Seidel 迭代, 特征方程为

$$\begin{vmatrix} 2\lambda & -1 & 1 \\ \lambda & \lambda & 1 \\ \lambda & \lambda & -2\lambda \end{vmatrix} = 0$$

其特征值为 $0, -\frac{1}{2}$, 因此谱半径小于 1, Gauss-Seidel 迭代法收敛. □

例 6.4.2. 分析线性方程组

$$\begin{cases} x_1 + x_2 = 1 \\ x_1 + 2x_2 - 2x_3 = 1 \\ -2x_2 + 5x_3 = 1 \end{cases}$$

的 *Jacobi* 迭代和 *Gauss-Seidel* 迭代收敛性

解. 系数矩阵 A 是正定矩阵, 因此 Gauss-Seidel 迭代法收敛. 又因为矩阵

$$2D - A = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 2 & 2 \\ 0 & 2 & 5 \end{pmatrix}$$

也是正定矩阵, 因此 Jacobi 迭代法也收敛. □

例 6.4.3. 分析线性方程组

$$\begin{cases} 10x_1 + x_3 - 5x_4 = -7 \\ x_1 + 8x_2 - 3x_3 = 11 \\ 3x_1 + 2x_2 - 8x_3 + x_4 = 23 \\ x_1 - 2x_2 + 2x_3 + 7x_4 = 17 \end{cases}$$

的 *Jacobi* 迭代和 *Gauss-Seidel* 迭代的收敛性

解. 方程系数矩阵为

$$A = \begin{pmatrix} 10 & 0 & 1 & -5 \\ 1 & 8 & -3 & 0 \\ 3 & 2 & -8 & 1 \\ 1 & -2 & 2 & 7 \end{pmatrix}$$

为严格对角占优矩阵, 因此 Jacobi 迭代和 Gauss-Seidel 迭代均收敛. □

6.5 超松弛法

对于超松弛法而言, 每一次迭代分为如下两个步骤:

1. 迭代, 即

$$\widetilde{x}_i^{(k+1)} = \frac{1}{a_{ii}}\left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij}x_j^{(k)}\right)$$

2. 加速, 令

$$x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \omega\widetilde{x}_i^{k+1}, i = 1, 2, \cdots, n$$

即

$$x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \frac{\omega}{a_{ii}}\left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij}x_j^{(k)}\right)$$

用矩阵形式表示为

$$\begin{aligned} & x^{(k+1)} = (1-\omega)x^{(k)} + \omega D^{-1}\left(b - Lx^{(k+1)} + Ux^{(k)}\right) \\ \Leftrightarrow & (D-\omega L)x^{(k+1)} = [(1-\omega)D + \omega U]x^{(k)} + \omega b \\ \Leftrightarrow & x^{(k+1)} = (D-\omega L)^{-1}[(1-\omega)D + \omega U]x^{(k)} + \omega(D-\omega L)^{-1}b \end{aligned}$$

对于超松弛法, 其收敛的充要条件为 $\rho(L_\omega) < 1$, 其中,

$$L_\omega = (D-\omega L)^{-1}[(1-\omega)D + \omega U]$$

定理 6.5.1. *超松弛法收敛的必要条件是松弛因子*

$$0 < \omega < 2$$

定理 6.5.2. *给定线性方程组 $Ax = b$, 如果 A 是对称正定矩阵, 且 $0 < \omega < 2$, 则超松弛法收敛.*

其中, 当 $\omega = 1$ 时, 超松弛法过渡为 Gauss-Seidel 迭代.
最后以课本的一道课后练习题结束

例 6.5.1. 设方程组

$$\begin{cases} x_1 - \frac{1}{4}x_2 - \frac{1}{4}x_4 = \frac{1}{2} \\ x_2 - \frac{1}{4}x_3 - \frac{1}{4}x_4 = \frac{1}{2} \\ -\frac{1}{4}x_1 - \frac{1}{4}x_2 + x_3 = \frac{1}{2} \\ -\frac{1}{4}x_1 - \frac{1}{4}x_2 + x_4 = \frac{1}{2} \end{cases}$$

求解该方程组对 *Jacobi* 迭代和 *Gauss-Seidel* 迭代法的迭代矩阵谱半径, 并判断其收敛性.

解. 由题意可知, 其系数矩阵为

$$A = \begin{pmatrix} 1 & 0 & -\frac{1}{4} & -\frac{1}{4} \\ 0 & 1 & -\frac{1}{4} & -\frac{1}{4} \\ -\frac{1}{4} & -\frac{1}{4} & 1 & 0 \\ -\frac{1}{4} & -\frac{1}{4} & 0 & 1 \end{pmatrix}$$

将其分解为对角矩阵 D, 严格下三角矩阵 L 和严格上三角矩阵 U, 使其满足 $A = D - L - U$, 得

$$D = \begin{pmatrix} 1 & & & \\ & 1 & & \\ & & 1 & \\ & & & 1 \end{pmatrix}$$

$$L = \begin{pmatrix} 0 & & & \\ 0 & 0 & & \\ \frac{1}{4} & \frac{1}{4} & 0 & \\ \frac{1}{4} & \frac{1}{4} & 0 & 0 \end{pmatrix}$$

$$U = \begin{pmatrix} 0 & 0 & \frac{1}{4} & \frac{1}{4} \\ & 0 & \frac{1}{4} & \frac{1}{4} \\ & & 0 & 0 \\ & & & 0 \end{pmatrix}$$

对于 Jacobi 迭代, 其迭代矩阵为

$$B_J = D^{-1}(L + U) = \begin{pmatrix} 0 & 0 & \frac{1}{4} & \frac{1}{4} \\ 0 & 0 & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{4} & 0 & 0 \\ \frac{1}{4} & \frac{1}{4} & 0 & 0 \end{pmatrix}$$

其谱半径为特征值模得最大值, 计算可得

$$\rho(B_J) = 0.5$$

同理, 对于 Gauss-Seidel 迭代, 其迭代矩阵为

$$B_{G-S} = (D-L)^{-1}U = \begin{pmatrix} 0 & 0 & \frac{1}{4} & \frac{1}{4} \\ 0 & 0 & \frac{1}{4} & \frac{1}{4} \\ 0 & 0 & \frac{1}{8} & \frac{1}{8} \\ 0 & 0 & \frac{1}{8} & \frac{1}{8} \end{pmatrix}$$

谱半径

$$\rho(B_{G-S}) = 0.25$$

由于其谱半径均小于 1, 因此 Jacobi 迭代和 Gauss-Seidel 迭代法均收敛. □

关于收敛性, 也可以使用系数矩阵的正定性来判断, 即由于系数矩阵 A 为正定矩阵, 则 Gauss-Seidel 迭代法收敛. 又由于系数矩阵为对称矩阵, 且 $2D - A$ 为正定矩阵, 因此 Jacobi 迭代法收敛.

可以发现, 使用两种方法得到的收敛性结果是一致的.

Chapter 7

非线性方程求根

学习思路

$$f(x) = 0 \tag{7.1}$$

1. 根的存在性；
2. 根的搜索；
3. 根的精确化。

7.0.1 根的存在性

定义 7.0.1. 如果存在 x^* 使得 $f(x^*) = 0$, 则称 x^* 为方程 *(7.1)* 的根或函数 $f(x)$ 的零点。

定理 7.0.1. 设函数 $f(x)$ 在区间 $[a, b]$ 上连续，如果

$$f(a) \cdots f(b) < 0$$

则方程 $f(x) = 0$ 在 $[a, b]$ 内至少有一实根 x^*。

定义 7.0.2 (m 重根)**.** 若

$$f(x) = (x - x^*)^m g(x)$$

其中，$g(x^*) \neq 0, m$ 为正整数，则当 $m = 1$ 时，称 x^* 为方程 *(7.1)* 的单根或函数 $f(x)$ 的单零点。当 $m \geq 2$ 时，称 x^* 为方程 *(7.1)* 的 m 重根或函数 $f(x)$ 的 m 重零点。

7.0.2 根的搜索

1. 图解法
2. 解析法
3. 近似方程法
4. 定步长搜索法 $\surd$

定义 7.0.3 (定步长搜索法). *1.* 画出 $f(x)$ 的略图，从而看出曲线与 x 轴交点的位置。*2.* 从左端点 $x = a$ 出发，按某个预先选定的步长 h 一步一步地向右跨，每跨一步都检验每步起点 x_0 和终点 $x_0 + h$ 的函数值，若 $f(x_0) \cdot f(x_0 + h) \leq 0$，那么所求的根 x^* 必在 x_0 与 $x_0 + h$ 之间，这里可取 x_0 或 $x_0 + h$ 作为根的初始近似。

例 7.0.1. 考察方程

$$f(x) = x^3 - x - 1 = 0$$

7.1 二分法

$|x_{k+1} - x_k < \varepsilon_1$ 或 $|f(x)| < \varepsilon_2$ 后者不能保证 x 的精度。

1. 计算 $f(x)$ 在有界区间 $[a, b]$ 端点处的值 $f(a), f(b)$。
2. 计算区间中点 x_1 及 $f(x)$ 在区间中点处的函数值 $f(x_1)$。
3. 判断若 $f(x_1) = 0$，则 x_1 即是根，否则检验：
   (a) 若 $f(x_1)$ 与 $f(a)$ 异号，则知解位于区间 $[a, x_1]$，$b_1 = x_1, a_1 = a$；
   (b) 若 $f(x_1)$ 与 $f(a)$ 同号，则知解位于区间 $[x_1, b]$，$a_1 = x_1, b_1 = b$；

   反复执行步骤 2、3，便可得到一系列有根区间：

$$[a, b] \supset [a_1, b_1] \supset [a_2, b_2] \supset \cdots \supset [a_n, b_n] \supset \cdots$$

4. 当 $|b_{k+1}-a_{k+1}|<\varepsilon$ 时，停止；$x_{k+1}=\frac{1}{2}(a_k+b_k)$ 即为根的近似。

注 7.1.1. 当 $n\to\infty$ 时，$b_n-a_n\to 0$，即这些区间必将收缩于一点，也就是方程的根。在实际计算中，只要 $[a_n,b_n]$ 的区间长度小于预定容许误差 ε 就可以停止搜索，即

$$\frac{b-a}{2^n}<\varepsilon$$

然后取其中点 x_n 作为方程的一个根的近似值。

例 7.1.1. 证明方程 $e^x+10x-2=0$ 存在唯一的实根 $x^*\in(0,1)$。用二分法求出此根，要求误差不超过 0.5×10^{-2}。

解. 解：记 $f(x)=e^x+10x-2$ 则对任意 $x\in R$，

$$f'(x)=e^x+10>0$$

因而，$f(x)$ 是严格单调的，$f(x)=0$ 最多有一个根，又因为 $f(0)=-1<0, f(1)=e+8>0$ 所以，$f(x)=0$，有唯一实根 $x^*\in(0,1)$ 用二分法求解，要使 $|x_k-x^*|\le 0.5\times 10^{-2}$，只要

$$\frac{1-0}{2^{k+1}}\le 0.5\times 10^{-2}$$

解得 $k\ge\frac{2}{\lg 2}=6.64$，取 $k=7$。所以只要二等分 7 次，即可求得满足精度要求的根。计算过程如表 8.2.1 所示。所以，$x^*\approx 0.5\times(0.0859375+0.09375)\approx 0.09$ □

扩展: [二分法的优缺点] 优点：

1. 简单；

2. 对 $f(x)$ 要求不高（只要连续即可）。

缺点：

1. 无法求复根及偶重根；

2. 收敛慢。

7.2 迭代法

使用迭代法求解非线性代数方程的步骤为：

1. 迭代格式的构造；
2. 迭代格式的收敛性分析；
3. 迭代格式的收敛速度与误差分析。

7.2.1 简单迭代法

迭代格式的构造

$$f(x)=0 \Longleftrightarrow x=\varphi(x)$$

方程 (8.3.1) 称为不动点方程，$\varphi(x)$ 称为迭代函数。满足 (8.3.1) 式的点称为不动点。这样就将求 $f(x)$ 的零点问题转化为求 $\varphi(x)$ 的不动点问题。以不动点方程为原型构造迭代格式

$$x_{k+1}=\varphi(x_k),(k=0,1,\cdots)$$

称这种迭代格式为不动点迭代。

例 7.2.1. *求代数方程 $2x^3-x-1=0$ 的根。*

解. 解：显然，1 是方程的一个根，位于区间 $[0,1.5]$ 内。

迭代格式 1：将方程等价变换为：$x=2x^3-1$ 构造迭代格式：$x_{k+1}=2x_k^3-1$ 取迭代初始值：$x_0=0$ 迭代过程：

$$\begin{cases} x_0=0 \\ x_1=2x_0^3-1=-1 \\ x_2=2x_1^3-1=-3 \\ x_3=2x_2^3-1=-55 \\ \quad\cdots \end{cases}$$

上式显然迭代发散。

迭代格式 2：将方程等价变换为：$x=\sqrt[3]{\frac{x+1}{2}}$ 取初值：$x_0=0$ 迭代过程：

$$\begin{cases} x_0=0 \\ x_1=\sqrt[3]{\dfrac{x_0+1}{2}}=\sqrt[3]{\dfrac{1}{2}}\approx 0.7937 \\ x_2=\sqrt[3]{\dfrac{x_1+1}{2}}=\sqrt[3]{\dfrac{1.7937}{2}}\approx 0.9644 \end{cases}$$

以此类推，收敛于 1。 □

注意： 同样的方程，不同的迭代公式，不同的收敛性。

注 7.2.1. *1.* 简单迭代法的迭代函数不唯一，迭代函数不同，收敛性不同；

2. 非线性方程的根不唯一，迭代点列收敛与否不仅与迭代函数有关，还与初始点有关。

迭代过程的收敛性

定理 7.2.1. 如果 $\varphi(x)$ 满足下列条件

1. 当 $x\in[a,b]$，$\varphi(x)\in[a,b]$

2. 对任意 $x\in[a,b]$，存在 $0<L<1$，使

$$|\varphi'(x)|\le L<1$$

则方程 $x=\varphi(x)$ 在 $[a,b]$ 上有唯一的根 x^*，且对任意初值 $x_0\in[a,b]$，迭代序列 $x_{k+1}=\varphi(x_k)(k=0,1,\cdots)$ 收敛于 x^*。

注 7.2.2. 此处 L 可以看成是 $|\varphi'(x)|$ 在区间 $[a,b]$ 内的最大值。

迭代法的误差估计

在定理 8.1 的条件下，简单迭代法产生的迭代点列有如下误差估计式：

$$|x_k-x^*|\le\frac{L^k}{1-L}|x_1-x_0| \tag{7.2}$$

$$|x_k-x^*|\le\frac{1}{1-L}|x_{k+1}-x_k| \tag{7.3}$$

$$|x_k-x^*|\le\frac{L}{1-L}|x_k-x_{k-1}| \tag{7.4}$$

例 7.2.2. *求方程* $f(x) = x^3 + 4x^2 - 10 = 0$ *在* $[1, 1.5]$ *内的根* x^*。

解. 解：原方程可以等价变形为下列三个迭代格式：

$$x_{k+1} = 10 + x_k - 4x_k^2 - x_k^3 (k = 0, 1, 2, \cdots) \tag{7.5}$$

$$x_{k+1} \frac{1}{2}\sqrt{10 - x_k^3} (k = 0, 1, 2, \cdots) \tag{7.6}$$

$$x_{k+1} = \sqrt{\frac{10}{x_k + 4}} (k = 0, 1, 2, \cdots) \tag{7.7}$$

由迭代格式 (7.5) 取初值 $x_0 = 1.25$ 得：

$$x_1 = 3.046875$$

$$x_2 = -26.04005$$

注意： 结果是发散的。

由迭代格式 (7.6) 取初值 $x_0 = 1.25$ 得：

$$\begin{aligned}
x_1 &= \varphi(x_0) = 1.41835, \\
x_2 &= \varphi(x_1) = 1.33666, \\
x_3 &= \varphi(x_2) = 1.37948, \\
x_4 &= \varphi(x_3) = 1.35786, \\
x_5 &= \varphi(x_4) = 1.36898, \\
x_6 &= \varphi(x_5) = 1.36331, \\
x_7 &= \varphi(x_6) = 1.36621, \\
x_8 &= \varphi(x_7) = 1.36473, \\
x_9 &= \varphi(x_8) = 1.36549, \\
x_{10} &= \varphi(x_9) = 1.36510
\end{aligned}$$

结果精确到四位有效数字，迭代到 x_{10} 得到收敛结果。**注意：** 迭代 10 步才能得到收敛的结果。

由迭代格式 (7.7) 取初值 $x_0 = 1.25$ 得：

$$x_1 = \varphi(x_0) = 1.38013, \tag{7.8}$$

$$x_2 = \varphi(x_1) = 1.36334, \tag{7.9}$$

$$x_3 = \varphi(x_2) = 1.36547, \tag{7.10}$$

$$x_4 = \varphi(x_3) = 1.36512 \tag{7.11}$$

结果精确到四位有效数字，迭代到 x_4 得到收敛结果。**注意：** 四步就能得到收敛的结果。 □

扩展： 分析：迭代格式 *(1)* 的迭代函数为：

$$\varphi(x) = 10 + x - 4x^2 - x^3$$

求导得

$$\varphi'(x) = 1 - 8x - 3x^2$$

当 $x \in [1, 1.5]$ 时，

$$|\varphi'(x)| = 3x^2 + 8x - 1 \geq 10 > 1$$

故迭代格式 *(1)* 是发散的。

迭代格式 *(2)* 的迭代函数为：

$$\varphi(x) = \frac{1}{2}\sqrt{10 - x^3}$$

当 $x \in [1, 1.5]$ 时，

$$\begin{aligned}\varphi(x) \in [\varphi(1.5), \varphi(1)] &= [\frac{1}{2}\sqrt{10 - 1.5^3}, \frac{1}{2}\sqrt{10 - 1^3}] \\ &= [1.287, 1.5] \in [1, 1.5]\end{aligned}$$

由

$$\begin{aligned}\varphi'(x) &= -\frac{3x^2}{4\sqrt{10 - x^3}} < 0 \\ \varphi''(x) &= -\frac{3}{8}x(10 - x^3)(10 - x^3)^{-\frac{3}{2}} < 0\end{aligned}$$

知，当 $x \in [1, 1.5]$ 时，

$$|\varphi'(x)| \leq |\varphi'(1.5)| = \frac{3}{4}\frac{1.5^2}{\sqrt{1. - 1.5^2}} = 0.6556 < 1$$

所以迭代格式 *(2)* 是收敛的。

迭代格式 *(3)* 的迭代函数为：

$$\varphi(x) = \sqrt{\frac{10}{x + 4}}$$

当 $x \in [1, 1.5]$ 时，

$$\varphi(x) = [\varphi(1.5), \varphi(1)] = \left[\sqrt{\frac{10}{1.5+4}}, \sqrt{\frac{10}{1+4}}\right]$$
$$= [1.348, 1.414] \subset [1, 1.5]$$

由

$$\varphi'(x) = -\frac{1}{2}\sqrt{10}(x+4)^{-\frac{3}{2}} < 0,$$
$$\varphi''(x) = -\frac{3}{4}\sqrt{10}(x+4)^{\frac{5}{2}} > 0$$

知，当 $x \in [1, 1.5]$ 时，

$$|\varphi'(x)| \leq |\varphi'(1)| = \frac{1}{2}\sqrt{10}(1+4)^{-\frac{3}{2}} = \frac{\sqrt{2}}{10} = 0.1414$$

所以迭代格式 *(3)* 也是收敛的。

通过以上算例可以看出，对迭代函数 $\varphi(x)$ 求导，所得到的 $|\varphi'(x)|$ 的霞姐若是大于 *1*，则迭代格式发散；若上界小于 *1*，则收敛；且上界越小收敛速度越快。

迭代过程的局部收敛性

定义 7.2.1. 若存在 x^* 的某个邻域 N: $|x - x^*| \leq \delta$ 使迭代过程 $x_{k+1} = \varphi(x_k)$ 对任意初值 $x_0 \in N$ 均收敛，则称迭代过程 $x_{k+1} = \varphi(x_k)$ 在 x^* 邻近具有局部收敛性。

定理 7.2.2. 设 x^* 为方程 $x = \varphi(x)$ 的根，$\varphi'(x)$ 在 x^* 的邻近连续且 $|\varphi'(x^*)| < 1$，则迭代过程 $x^{k+1} = \varphi(x_k)$ 在 x^* 邻近具有局部收敛性。

迭代过程的收敛速度

定义 7.2.2. 设由某方法确定的序列 x_k 收敛于方程的根 x^*，如果存在正实数 p，使得

$$\lim_{k\to\infty} \frac{|x^* - x_{k+1}|}{|x^* - x_k|} = C(C\text{为非零常数})$$

则称序列 x_k 收敛于 x^* 的收敛速度是 p 阶的，或称该方法具有 p 阶收敛速度。当 $p = 1$ 时，称该方法为线性（一次）收敛；当 $p = 2$ 时，称该方法为平方（二次）收敛；当 $1 < p < 2$ 或 $C = 0, p = 1$ 时，称该方法为超线性收敛。

加速收敛技术

L 越小迭代法的收敛速度越快，因此，可以从寻找较小的 L 来改进迭代格式以加快收敛速度。

(1) 松弛法引入待定参数 $\lambda \neq -1$，将 $x = \varphi(x)$ 作等价变形为

$$x = \frac{\lambda}{1+\lambda}x + \frac{1}{1+\lambda}\varphi(x) \tag{7.12}$$

将方程右端记为 $\Psi(x)$, 则得到新的迭代格式

$$x_{k+1} = \Psi(x_k)$$

由定理 8.1 知

$$|\varphi'(x)| \leq L < 1$$

为了使新的迭代格式比原来迭代格式收敛得更快，只要满足

$$|\Psi'(x)| < |\varphi'(x)|$$

且 $|\Psi'(x)| = |\frac{1}{1+\lambda}(\lambda + \varphi'(x))|$ 越小，所获取的 L 就越小，迭代法收敛的就越快，因此我们希望 $\Psi'(x) \to 0$。可取 $\lambda_k = \varphi'(x_k) \neq -1$，若记 $\omega_k = \frac{1}{1+\lambda_k}$，则 (8.3.4) 式可改写为

$$x_{k+1} = (1-\omega_k)x_k + \omega_k\varphi(x_k)$$

ω_k 称为松弛因子，这种方法称为松弛法。为使迭代速度加快，需要边计算边调整松弛因子。由于计算松弛因子需要用到微商，在实际应用中不便使用，具有一定局限性。若迭代法是线性收敛的，当计算 $\varphi'(x)$ 不方便时，可以采用埃特金加速公式。

(2) 埃特金加速公式设迭代法是线性收敛的，由定义知

$$\lim_{k\to\infty} \frac{x_{k+1} - x^*}{x_k - x^*} = c \neq 0$$

成立，故当 $k \to \infty$ 时有

$$\frac{x_{k+1} - x^*}{x_k - x^*} \approx \frac{x_{k+2} - x^*}{x_{k+1} - x^*}$$

由此可得 x^* 的近似值

$$x^* \approx x_k - \frac{(x_{k+1} - x_k)^2}{x_{k+2} - 2x_{k+1} = x_k} = \overline{x_k} \tag{7.13}$$

由此获得比 x_k，x_{k+1} 和 x_{k+2} 更好的近似值 $\bar{x}_k$。该式称为埃特金加速公式。

(3)Steffensen 加速法：将埃特金加速公式与不动点迭代相结合，可得

$$\begin{cases} x_{k+1}^{(1)} = \boldsymbol{\varphi}(x_k), \quad x_{k+1}^{(2)} = \boldsymbol{\varphi}(x_{k+1}^{(1)}) \\ x_{k+1} = x_k - \frac{\left(x_{k+1}^{(1)} - x_k\right)^2}{x_{k+1}^{(2)} - 2x_{k+1}^{(1)} + x_k}, \quad k = 0, 1, \cdots \end{cases}$$

利用 (8.3.6) 式构造序列 x_k 的方法称为 Steffensen 加速法。即每进行两次不动点迭代，就执行一次 Aitken 加速。

例 7.2.3. 试用简单迭代法和 *Steffensen* 加速法求方程

$$x = e^{-x}$$

在 $x = 0.5$ 附近的根，精确至四位有效数。

解. 记 $\varphi(x) = e^{-x}$，简单迭代法公式为:

$$x_{k+1} = \varphi(x_k), k = 0, 1, 2, \cdots$$

计算得

k	x_k	k	x_k	k	x_k
0	0.5	7	0.5584380	14	0.5671188
1	0.6065306	8	0.5664094	15	0.5671571
2	0.5452392	9	0.5675596	16	0.5671354
3	0.5797031	10	0.5669072	17	0.5671477
4	0.5600646	11	0.5672772	18	0.5671407
5	0.5711721	12	0.5670673		
6	0.5648629	13	0.5671863		

Aitken 加速公式：

$$x_{k+1} = x_k - \frac{\left(x_{k+1}^{(1)} - x_k\right)^2}{x_{k+1}^{(2)} - 2x_{k+1}^{(1)} + x_k}$$

计算得所以，$x^* \approx 0.5671$ □

7.3 牛顿法

7.3.1 牛顿迭代公式

考虑非线性方程：

$$f(x) = 0$$

取 $x_0 \approx x^*$，将 $f(x)$ 在 x_0 做一阶 Taylor 展开：

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(\xi)}{2!}(x - x_0)^2$$

ξ 在 x_0 和 x 之间。

将 $(x^* - x_0)^2$ 看成高阶小量，则有：

$$0 = f(x^*) \approx f(x_0) + f'(x_0)(x^* - x_0) \Rightarrow x^* \approx x_0 - \frac{f(x_0)}{f'(x_0)}$$

记

$$x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}$$

再将 $f(x)$ 在 x_1 做一阶 Taylor 展开，并忽略二阶项得

$$0 = f(x) \approx f(x_1) + f'(x_1)(x - x_1) \Longrightarrow x^* \approx x_2 = x_1 - \frac{f(x_1)}{f'(x_1)}$$

依此类推，可构造迭代公式

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \tag{7.14}$$

公式 (6.4.1) 称为牛顿迭代公式。

只要 $f \in C^1$，且每步迭代都有 $f'(x_k) \neq 0$，且 $\lim_{k\to\infty} x_k = x^*$，则

$$x^* = \lim_{k\to\infty} x_{k+1} = \lim_{k\to\infty} \left[x_k - \frac{f(x_k)}{f'(x_k)} \right] = x^* - \frac{f(x*)}{f'(x*)}$$

从而

$$f(x^*) = 0$$

即 x^* 就是 $f(x)$ 的根。故只要牛顿迭代格式收敛，则必收敛到 $f(x)$ 的根。

7.3.2 牛顿法的几何意义

7.3.3 牛顿法的收敛性

牛顿法收敛的条件

定理 7.3.1. 设 $f(x)$ 在 $[a,b]$ 上二阶连续可导且满足下列条件。

1.

$$f(a)\cdot f(b)<0;$$

2.

$$f'(x)\neq 0;$$

3. $f''(x)$ 在区间 $[a,b]$ 上不变号；

4. 取 $x_0\in[a,b]$，使得 $f''(x)\cdot f(x_0)>0$

则由 *(6.4.1)* 确定的牛顿迭代序列 x_k 二阶收敛于 $f(x)$ 在 $[a,b]$ 上的唯一单根 x^*。

注 7.3.1. *Newton* 法的收敛性依赖于 x_0 的选取。

注意: Newton 法是局部收敛的算法！且是条件最为严格的。

迭代法收敛阶的判别

定理 7.3.2. 如果 $\varphi(x)$ 在 x^* 附近的某个邻域内有 $p(p\geq 1)$ 阶连续导数，且

$$\begin{aligned}&\varphi^{(j)}(x^*)=0\quad (j=1,2,\ldots,p-1)\\&\varphi^{(p)}(x^*)\neq 0\end{aligned}$$

则迭代格式 $x_{k+1}=\varphi(x_k)$ 在 x^* 附近是 p 阶局部收敛的，且有

$$\lim_{k\to\infty}\frac{(x_{k+1}-x^*)}{(x_k-x^*)^p}=\frac{\varphi^{(p)}(x^*)}{p!}$$

牛顿迭代法的局部收敛性和收敛速度

若 x^* 是 $f(x^*)$ 的一个单根，即 $f(x^*)=0, f'(x)\neq 0$，且 f 在包含 x^* 的一个区间二阶连续可导，则 Newton 迭代法至少二阶收敛，即 $\varphi'(x^*)=0$。且

$$\lim_{k\to\infty}\frac{x_{k+1}-x^*}{(x_k-x^*)^2}=\frac{f''(x^*)}{2f'(x^*)}\varphi'(x)=\frac{f(x)f''(x)}{[f'(x)]^2}$$

其中，$\varphi(x)=x-\frac{f(x)}{f'(x)}$ 为牛顿迭代函数。值得注意的是，当 $f(x)$ 充分光滑且 x^* 是 $f(x)=0$ 的重根时，牛顿法在 x^* 的附近是线性收敛的。即

$$\varphi'(x^*)\neq 0$$

例 7.3.1. 用牛顿法求方程的根：$xe^x-1=0$

解. 解：由牛顿迭代公式 $x_{k+1}=x_k-\frac{f(x_k)}{f'(x_k)}$ 得：

$$x_{k+1}=x_k-\frac{x_k-e^{-x_k}}{1+x_k}$$

取初值 $x_0=0.5$ □

例 7.3.2. *Leonardo* 与 *1225* 年研究了方程

$$x^3+2x^2+10x-20=0$$

并得出该方程的一个近似根 $x=1.368808107$。试用牛顿法求出此结果。

解. 解：记

$$f(x)=x^3+2x^2+10x-20$$

则

$$f'(x)=3x^2+4x+10=3(x+\frac{2}{3})^2+\frac{26}{3}$$

当 $x\in R$ 时，$f'(x)>0$ 即 $f(x)$ 为单调函数，又

$$f(1)=-7<0, f(2)=16>0$$

所以 $f(x)=0$ 有唯一实根 $x^*\in(1,2)$。改写：

$$f(x)=((x+2)x+10)x-20$$
$$f'(x)=(3x+4)x+10$$

用牛顿迭代格式：

$$\begin{cases} x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}, k = 0, 1, 2, \cdot \\ x_0 = 1.5 \end{cases}$$

所以，$x^* \approx 1.368808107$ □

注 7.3.2. 牛顿法只用了 *3* 步就得到具有 *10* 位有效数字的近似解。

牛顿法的计算步骤

1. 准备：$x_0, f_0 = f(x_0), f_0' = f'(x_0)$
2. 迭代：$x_1 = x_0 - \frac{f_0}{f_0'}, f_1 = f(x_1), f_1' = f'(x_1)$
3. 控制：若 $|f_1| < \varepsilon_1$ 或 $|\delta| < \varepsilon_2$，停 $x^* = x_1$；否则转 4 步

$$\delta = \begin{cases} |x_1 - x_0| & \text{if} |x_1| < c \\ \frac{|x_1 - x_0|}{|x_1|} & \text{if} |x_1| \geq c \end{cases}$$

4. 修改：若迭代次数 $> N$，或 $f_1' = 0$，则方法失败，否则继续。

注 7.3.3 (牛顿迭代法的优缺点)**.** 优点：公式简单，使用方便，易于编程，收敛速度快，易于求解；缺点：计算量大，每次迭代都要计算函数值与导数值。

牛顿法应用举例

1. 求正数平方根设 $C > 0$，求 $x = \sqrt{C}$

解. 解：令 $f(x) = x^2 - C$ 则 $f'(x) = 2x$ 于是，牛顿迭代公式为

$$x_{k+1} = x_k - \frac{x_k^2 - C}{2x_k} \Rightarrow x_{k+1} = \frac{1}{2}[x_k + \frac{C}{x_k}]$$

收敛性分析：

$$\begin{aligned} x_{k+1} - \sqrt{c} &= \frac{1}{2}[x_k + \frac{c}{x_k}] - \sqrt{c} \\ &= \frac{1}{2x_k}[x_k^2 - 2x_k\sqrt{c} + c] \\ &= \frac{1}{2x_k}(x_k - \sqrt{c})^2 \end{aligned}$$

同理可得：

$$x_{k+1}+\sqrt{c}=\frac{1}{2}[x_k+\frac{c}{x_k}]=\frac{1}{2x_k}(x_k+\sqrt{c})^2$$

从而有

$$\frac{x_{k+1}-\sqrt{c}}{x_{k+1}+\sqrt{c}}=\left(\frac{x_k-\sqrt{c}}{x_k-\sqrt{c}}\right)^2$$
$$=\left(\frac{x_{k-1}-\sqrt{c}}{x_{k-1}-\sqrt{c}}\right)^{2^2}=\left(\frac{x_0-\sqrt{c}}{x_0-\sqrt{c}}\right)^{2^{k+1}}$$

要使 $\lim_{k\to\infty}=\sqrt{c}$，则需 $(\frac{x_0-\sqrt{c}}{x-\sqrt{c}})^{2^{k+1}}\to 0, k\to\infty$ 令 $r=\frac{x_0-\sqrt{c}}{x-\sqrt{c}}$，则 $|r|<1$
故要使平方根的牛顿迭代格式收敛，只需取初值

$$x_0>0$$

且当迭代格式收敛时，有

$$\lim_{k\to\infty}\frac{|e_{k+1}|}{|e_k|^2}=\frac{1}{2\sqrt{c}}$$

即求正数平方根的牛顿迭代格式二阶收敛。

$$x_{k+1}=\frac{1}{2[x_k+\frac{c}{x_k}]}$$

□

注 7.3.4. *求正数平方根的牛顿法是局部收敛的，要求初值 >0。*

例 7.3.3. *用牛顿法求* $\sqrt{115}$

解. 取 $x_0=10, c=115$ 迭代结果如下：所以 $\sqrt{115}\approx 10.73805$ □

2. 求倒数算法用牛顿法求非零数 a 的倒数，不用除法。

解. 解：考虑方程

$$\frac{1}{x}-a=0$$

令

$$f(x)=\frac{1}{x}-a$$

则牛顿迭代格式为

$$x_{k+1}=x_k-\frac{\frac{1}{x_k}-a}{-\frac{1}{x_k^2}}$$

即

$$x_{k+1} = x_k(2 - ax_k)$$

收敛性分析：

$$\begin{aligned} x_{k+1} - \frac{1}{a} &= x_k(2 - ax_k) \\ &= -a(x_k - \frac{1}{a})^2 \end{aligned}$$

将上式等价变形得

$$ax_{k+1} - 1 = -(ax_k - 1)^2$$

即

$$1 - ax_{k+1} = (1 - ax_k)^2$$

令 $r_k = 1 - ax_k$，有

$$r_{k+1} = r_k^2 = r_{k-1}^{2^2} = \cdots = r_0^{2^k}$$

要使 $r_k \to 0$，需 $|r_0| = |1 - ax_0| < 1$，即 $0 < x_0 < \frac{2}{a}$

注 7.3.5. *求倒数算法要求初值 x_0 满足 $0 < x_0 < \frac{2}{a}$*

此时有

$$\lim_{k\to\infty} \frac{|e_{k+1}|}{|e_k|^2} = a$$

即求倒数的牛顿算法二阶收敛。 □

7.3.4 求 m 重根的牛顿法-修正牛顿法

设

$$\begin{aligned} f(x^*) = f'(x^*) = \cdots = f^{(m-1)}(x^*) = 0 \\ f^{(m)}(x^*) \neq 0, (m \geq 2) \end{aligned}$$

修正格式一：构造迭代格式

$$x_{k+1} = x_k - m\frac{f(x_k)}{f'(x_k)} \tag{7.15}$$

则迭代格式 (6.4.2) 至少 2 阶收敛。

注 7.3.6. 重数 m 的确定：令

$$\Psi(x)=\frac{[f'(x)]^2}{[f'(x)]^2-f(x)f''(x)}$$

则

$$m=\lim_{x\to x^*}\Psi(x)$$

修正格式二：令

$$u(x)=\frac{f(x)}{f'(x)}$$

则 x^* 是 $u(x)$ 的单根，即 $u(x^*)=0,u'(x^*)\neq 0$ 构造迭代格式

$$x_{k+1}=x_k-\frac{u(x_k)}{u'(x_k)} \tag{7.16}$$

则迭代格式 (6.4.3) 至少 2 阶收敛。

7.3.5 牛顿法的变形

牛顿下山法的基本思想

由于 Newton 迭代法的收敛性依赖于初值 x_0 的选取，如果 x_0 离方程的根 x^* 较远，则 Newton 迭代法可能发散。为了防止迭代发散，可以将 Newton 迭代法与下山法结合起来，放宽初值 x_0 的选取范围，为此，将 (6.4.1) 式修改为：

$$x_{k+1}=x_k-\lambda\frac{f(x_k)}{f'(x_k)},(k=0,1,2,\cdots)$$

其中，$0<\lambda\leq 1$ 称为下山因子，选择下山因子时，希望 $f(x_k)$ 满足下山法具有的单调性，即

$$|f(x_{k+1})|<|f(x_k)|,(k=0,1,2,\cdots)$$

这种算法称为 Newton 下山法。

在实际应用中，可选择 $\lambda=\lambda_k,0<\lambda_k\leq 1$

牛顿下山法的计算步骤

1. 选取初始近似值 x_0；
2. 取下山因子 $\lambda=1$；

3. 计算 $x_{k+1} = x_k - \lambda \frac{f(x_k)}{f'(x_k)}$

4. 计算 $f(x_{k+1})$，并比较 $|f(x_{k+1})|$ 与 $|f(x_k)|$ 的大小，分一下二种情况

   (a) 若 $|f(x_{k+1})| < |f(x_k)|$，则当 $|x_{k+1} - x_k| < \varepsilon_2$ 时，取 $x^* \approx x_{k+1}$，计算过程结束；当 $|x_{k+1} - x_k| \geq \varepsilon_2$ 时，则把 x_{k+1} 作为新的近似值，并返回到第 2 步中。

   (b) 若 $|f(x_{k+1})| \geq |f(x_k)|$，则当 $\lambda \leq \varepsilon_\lambda$ 时，取 $x^* \approx x_k$，计算过程结束；否则，若 $\lambda \leq \varepsilon_\lambda$，而 $|f(x_{k+1})| \geq \varepsilon_1$ 时，则把 x_{k+1} 加上一个适当选定的小正数，即取 $x_{k+1} + \delta$ 作为新的 x_k 值，并转向第 3 步重复计算；当 $\lambda > \varepsilon_\lambda$ 且 $|f(x_{k+1})| \geq \varepsilon_1$ 时，则将下山因子缩小一半，取 $\frac{\lambda}{2}$ 代入，并转向第 3 步重复计算。

例 7.3.4. *求方程* $f(x) = x^3 - x - 1 = 0$ *的根。* $x_0 = 0.6$

解. 牛顿下山法的计算结果： □

Chapter 8

常微分方程数值解法

8.1 引言

常微分方程的数值解法分为

1. 初值问题的数值解法
2. 边值问题的数值解法

8.1.1 初值问题的数值解法

一阶常微分方程初值问题一般形式

一阶常微分方程初值问题的一般形式为

$$\begin{cases} y'(x) = f(x, y(x)), a \leq x \leq b \\ y(a) = y_0 \end{cases}$$

求解方法主要是构造迭代格式, 即将连续的微分方程及初值条件离散化, 并使用不同的数值方法进行求解. 常见的构造方法为离散点函数值的集合 + 线性组合结构 = 近似公式.

进行微分方程数值解法时, 主要解决如下问题:

1. 如何将方程离散化, 并建立迭代公式;
2. 如何估计迭代公式局部截断误差与整体误差;
3. 如何保证迭代公式稳定性与收敛性.

相关定义

记

$$D = (x, y)|a \leq x \leq b, y(x) - \delta \leq y \leq y(x) + \delta$$

为 $f(x, y)$ 在 D 上对 y 满足 Lipschitz 条件指: 存在 $L > 0$, 使得对于任意的 $x \in [a, b], y_1, y_2 \in [y(x) - \delta, y(x) + \delta]$, 有

$$|f(x, y_1) - f(x, y_2)| \leq L|y_1 - y_2|$$

8.1.2 初值问题解存在唯一性

对于一阶常微分方程初值问题

$$\begin{cases} \frac{\mathrm{d}y}{\mathrm{d}x} = f(x, y), x \in [a, b] \\ y(a) = y_0 \end{cases}$$

只要 $f(x, y)$ 在 $[a, b] \times R^1$ 上连续, 且关于 y 满足 Lipschitz 条件, 即存在与 x, y 无关常数 L, 使得

$$|f(x, y_1) - f(x, y_2)| \leq L|y_1 - y_2|$$

对任意定义在 $[a, b]$ 上的 $y_1(x), y_2(x)$ 成立, 则上述微分方程初值问题存在唯一解.

求函数 $y(x)$ 在一系列节点处的近似值

$$y_i \approx y(x_i), i = 1, 2, \cdots, n$$

的方法称为微分方程的*数值解法*, $y_1, \cdots, y_n$ 为微分方程的*数值解*.

称节点间距 $h_i = x_{i+1} - x_i, i = 0, 1, \cdots, n - 1$ 为步长, 通常采用等距节点, 即 $h_i = h =$ 常数

8.1.3 初值问题的离散化方法

按照某一递推公式, 按节点从左至右顺序依次求出 $y(x_i)$ 的近似值 $y_i, i = 1, 2, \cdots, n$, 取 $y_0 = \eta$, 若计算 y_{i+1} 只用到前一步的值 y_i, 则称该方法为*单步方法*; 若用到前 r 步的值 $y_i, y_{i-1}, \cdots, y_{i-r+1}$, 则称该方法为$r$ *步方法*.

8.2 Euler 方法

8.2.1 Euler 公式

采用向前差商

$$y'(x_0) \approx \frac{y(x_1) - y(x_0)}{h}$$

近似导数, 则

$$y(x_1) \approx y(x_0) + hy'(x_0) = y_0 + hf(x_0, y_0)$$

并将该结果记为 y_1

类似地, 可以推导得到迭代格式为

$$y_{i+1} = y_i + hf(x_i, y_i), i = 0, 1, \cdots, n-1$$

定义 8.2.1 (局部截断误差)**.** *在假设 $y_i = y(x_i)$, 即第 i 步计算精确前提下, 考虑的截断误差*

$$R_i = y(x_{i+1}) - y_{i+1}$$

称为局部截断误差

定义 8.2.2. *若某算法局部截断误差为 $O(h^{p+1})$, 则称该算法有 p 阶精度.*

对于 Euler 法, 可以分析

$$\begin{aligned} R_i &= y(x_{i+1}) - y_{i+1} \\ &= \left[y(x_i) + hy'(x_i) + \frac{h^2}{2} y''(x_i) + O(h^3) \right] - [y_i + hf(x_i, y_i)] \\ &= \frac{h^2}{2} y''(x_i) + O(h^3) \\ &= O(h^2) \end{aligned}$$

称

$$\frac{h^2}{2} y''(x_i)$$

为 R_i 的主项. 由定义可知, Euler 法具有一阶精度.

例 8.2.1. 用 *Euler* 公式求解初值问题

$$\begin{cases} y' = -2xy^2, 0 \le x \le 1.2 \\ y(0) = 1 \end{cases}$$

要求取步长为 $h = 0.1$

解. 应用 Euler 公式

$$\begin{cases} y_{i+1} = y_i - 2hx_i y_i^2, i = 0, 1, \cdots, 11 \\ y(0) = 1 \end{cases}$$

其中 $x_i = 0.1i$, 可直接进行迭代计算. 在此不再赘述. □

8.2.2 隐式 Euler 法 (向后 Euler 法)

使用向后差商近似导数, 即

$$y'(x_1) \approx \frac{y(x_1) - y(x_0)}{h}$$

有

$$y(x_1) \approx y_0 + hf(x_1, y(x_1))$$

以此可得迭代格式为

$$y_{i+1} = y_i + hf(x_{i+1}, y_{i+1}), i = 0, 1, \cdots, n-1$$

注意到未知数 y_{i+1} 同时出现在等式两边, 因此在实际应用时不能直接得到, 称为隐式 *Euler* 公式.

与显式 Euler 公式类似, 隐式 Euler 公式的局部截断误差为

$$R_i = y(x_{i+1}) - y_{i+1} = -\frac{h^2}{2}y''(x_i) + O(h^3)$$

即具有 1 阶精度.

8.2.3 梯形公式

计算显式 Euler 公式和隐式 Euler 公式的平均值, 可得

$$y_{i+1} = y_i + \frac{h}{2}[f(x_i, y_i) + f(x_{i+1}, y_{i+1})], i = 0, 1, \cdots, n-1$$

注意: 梯形公式的局部截断误差为

$$R_i = O(h^3)$$

即具有 2 阶精度. 但该公式仍然为隐式公式.

8.2.4 中点 Euler 公式

使用中心差商近似导数

$$y'(x_1) \approx \frac{y(x_2) - y(x_0)}{2h}$$

即

$$y(x_2) \approx y(x_0) + 2hf(x_1, y(x_1))$$

可得迭代格式为

$$y_{i+1} = y_{i-1} + 2hf(x_i, y_i), i = 1, 2, \cdots, n-1$$

假设 $y_{i-1} = y(x_{i-1}), y_i = y(x_i)$, 则可以导出

$$R_i = O(h^3)$$

即中点 Euler 公式具有 2 阶精度

注意: 中点 Euler 公式是显式公式, 且精度相较显式 Euler 公式有所提高. 但中点 Euler 公式多一个初值, 可能在此影响精度.

为解决上述问题, 我们尝试改进梯形公式, 给出下面的方法

8.2.5 预测校正法

先使用显式 Euler 公式进行预测, 算出

$$\overline{y_{i+1}} = y_i + hf(x_i, y_i)$$

并将预测值 $\overline{y_{i+1}}$ 代入梯形公式右侧进行校正, 使得

$$y_{i+1} = y_i + \frac{h}{2}\left[f(x_i, y_i) + f\left(x_{i+1}, \overline{y_{i+1}}\right)\right]$$

迭代格式为

$$y_{i+1} = y_i + \frac{h}{2}\left[f(x_i, y_i) + f(x_{i+1}, y_i + hf(x_i, y_i))\right], i = 0, 1, \cdots, n-1$$

可以验证的是, 该算法具有 *2* 阶精度. 且是单步递推, 求解过程较简单.

注意: 实际计算中, 可先计算向前 Euler 公式, 再将计算结果代入向后 Euler 公式, 再将两个结果取算术平均值.

例 8.2.2. *用改进 Euler 公式重解上述初值问题, 步长* $h = 0.1$

解. 其迭代形式为

$$y_0 = 1$$

$$\begin{cases} y_{i+1}^{(p)} = y_i + 2hx_i y_i^2 \\ y_{i+1}^{(c)} = y_i - 2hx_{i+1}(y_{i+1}^{(p)})^2 \\ y_{i+1} = \frac{1}{2}\left(y_{i+1}^{(p)} + y_{i+1}^{(c)}\right) \end{cases}$$

□

8.3 Runge-Kutta 方法

对于改进的 Euler 法, 将其改写为

$$\begin{cases} y_{i+1} = y_i + h\left[\frac{1}{2}K_1 + \frac{1}{2}K_2\right] \\ K_1 = f(x_i, y_i) \\ K_2 = f(x_i + h, y_i + hK_1) \end{cases}$$

考察上式中 K_1, K_2 的系数和步长 h, 试着调整它们的值, 将改进 Euler 法进行推广:

$$\begin{cases} y_{i+1} = y_i + h[\lambda K_1 + \lambda_2 K_2] \\ K_1 = f(x_i, y_i) \\ K_2 = f(x_i + ph, y_i + phK_1) \end{cases}$$

首先考虑确定系数 λ_1, λ_2, p 使其具有 2 阶精度, 即

$$R_i = y(x_{i+1}) - y_{i+1} = O(h^3)$$

将 K_2 在 (x_i, y_i) 处作 Taylor 展开

$$\begin{aligned} K_2 &= f(x_i + ph, y_i + phK_1) \\ &= f(x_i, y_i) + phf_x(x_i, y_i) + phK_1 f_y(x_i, y_i) + O(h^2) \\ &= y'(x_i) + phy''(x_i) + O(h^2) \end{aligned}$$

将其代入推广 Euler 法公式, 得

$$\begin{aligned} y_{i+1} &= y_i + h\left\{\lambda_1 y'(x_i) + \lambda_2[y'(x_i) + phy''(x_i) + O(h^2)]\right\} \\ &= y_i + (\lambda_1 + \lambda_2)hy'(x_i) + \lambda_2 ph^2 y''(x_i) + O(h^3) \end{aligned}$$

将二者进行比较, 若要求 $R_i = O(h^3)$, 则必有

$$\begin{aligned} \lambda_1 + \lambda_2 &= 1 \\ \lambda_2 p &= \frac{1}{2} \end{aligned}$$

上式存在无穷多解, 所有满足上式得格式统称为 *2* 阶 *Runge-Kutta* 格式. 特别地, 当 $p = 1, \lambda_1 = \lambda_2 = 1/2$ 时, 上式化为改进的 Euler 法.

除此之外, 还有若干方法 (如二阶中点方法, 二阶 Heun 方法等), 在此不赘述.

8.3.1 二阶 Runge-Kutta 格式精度

令

$$\begin{aligned} F &= f_x + f_y f \\ G &= f_{xx} + 2f_{xy}f + f_{yy}f^2 \end{aligned}$$

则

$$k_2 = f + phF + \frac{1}{2}p^2h^2G + O(h^3)$$

即

$$\begin{aligned} y_{i+1} &= y_i + (\lambda_1 + \lambda_2)hf + \lambda_2 ph^2 F + \frac{1}{2}\lambda_2 p^2 h^3 G + O(h^4) \\ &= y_i + hf + \frac{1}{2}h^2 F + \frac{1}{4}ph^3 G + O(h^4) \end{aligned}$$

同时得

$$\begin{aligned} y(x_{i+1}) &= y(x_i) + hy'(x_i) + \frac{h^2}{2!}y''(x_i) + \frac{h^3}{3!}y'''(x_i) + O(h^4) \\ &= y_i + hf + \frac{h^2}{2}F + \frac{h^3}{6}(G + f_y F) + O(h^4) \end{aligned}$$

因此对于二阶 Runge-Kutta 方法而言, 其精度不超过二阶.

对于高精度而言, 可以取更多的点, 即做如下推广:

$$\begin{cases} y_{i+1} = y_i + h[\lambda_1 K_1 + \lambda_2 K_2 + \cdots + \lambda_m K_m] \\ K_1 = f(x_i, y_i) \\ K_2 = f(x_i + \alpha_2 h, y_i + \beta_{21} h K_1) \\ \vdots \\ K_m = f(x_i + \alpha_m h, y + \beta_{m1} h K_1 + \beta_{m2} h K_2 + \cdots + \beta_{m,m-1} h K_{m-1}) \end{cases}$$

其中 $\lambda_i (i = 1, 2, \cdots, m), \alpha_i (i = 2, \cdots, m), \beta_{ij} (i = 1, 2, \cdots, m; j = 1, 2, \cdots, i-1)$ 均为待定系数.

对于 n 阶显式 Runge-Kutta 公式:

$$\begin{cases} y_{i+1} = y_i + h \sum_{j=1}^{n} \lambda_j k_j \\ k_1 = f(x_i, y_i) \\ k_j = f\left(x_i + c_j h, y_i + h \sum_{m=1}^{j-1} a_{jm} k_m\right), j = 2, 3, \cdots, n \end{cases}$$

其中

$$\sum_{m=1}^{j-1} a_{jm} = c_j$$

当 $n = 3$ 时, 得

$$\begin{cases} y_{i+1} = y_i + h(\lambda_1 k_1 + \lambda_2 k_2 + \lambda_3 k_3) \\ k_1 = f(x_i, y_i) \\ k_2 = f(x_i + c_2 h, y_i + c_2 h k_1) \\ k_3 = f(x_i + c_3 h, y_i + a_{31} h k_1 + a_{32} h k_2) \\ c_3 = a_{31} + a_{32} \end{cases}$$

记

$$F = f_x + f_y x, G = f_{xx} + 2 f f_{xy} + f^2 f_{yy}$$

则可得

$$\begin{aligned} & a_{31} k_1 + a_{32} k_2 \\ =& c_3 f + c_2 a_{32} h F + \frac{1}{2} c_2^2 a_{32} h^2 G + O(h^3) \\ & k_3 = f + c_3 h F + h^2 (c_2 a_{32} F f_y + \frac{1}{2} c_3^2 G) + O(h^3) \end{aligned}$$

整理, 若要使局部截断误差为 $O(h^4)$, 则必须有

$$\begin{cases} \lambda_1 + \lambda_2 + \lambda_3 = 1 \\ \lambda_2 c_2 + \lambda_3 c_3 = \frac{1}{2} \\ \lambda_2 c_2^2 + \lambda_3 c_3^2 = \frac{1}{3} \\ \lambda_3 c_2 a_{32} = \frac{1}{6} \end{cases}$$

对于不同的取值得到不同的方法. 具体公式详见书后附录.

类似地, 也可以得到四阶 Runge-Kutta 方法, 这里以四阶经典 Runge-Kutta 方法为例 (公式见书后附录), 演示一道例题.

例 8.3.1. *用四阶 Runge-Kutta 方法求初值问题*

$$f(x, y) = -\frac{1}{2+y}, y(0) = 1$$

取步长 $h = 1$, 求 $y(1)$ 的值

解. 取 $x_0 = 0, y_0 = 1, x_1 = x_0 + h = 1$, 计算 k_1, k_2, k_3, k_4 有

$$\begin{cases} k_1 = f(x_n, y_n) \\ k_2 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2} k_1) \\ k_3 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2} k_2) \\ k_4 = f(x_n + h, y_n + h k_3) \end{cases}$$

将其代入

$$y_{n+1} = y_n + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4)$$

得

$$y_1 = 1 + \frac{1}{6} \times (-0.3333 - 2 \times 0.3529 - 2 \times 0.3542 - 0.3780) \approx 0.645744444$$

即使用四阶 Runge-Kutta 方法在 $x = 1$ 处得估计值为 0.645744444. □

对于上例而言, 不难验证该问题有精确解析解

$$y(x) = \sqrt{9 - 2x} - 2$$

即对于 $x = 1$ 而言, 可得其精确值为

$$y(1) = \sqrt{7} - 2 \approx 0.645751311$$

截断误差为

$$R_1 = y(1) - y_1 = 0.0000068666$$

注意: 对于二阶 Runge-Kutta 方法, 其局部截断误差为 $O(h^3)$, 对于三阶 Runge-Kutta 方法, 局部截断误差为 $O(h^4)$, 对于四阶 Runge-Kutta 方法, 局部截断误差为 $O(h^5)$.

可以看出, 随着计算 K_i 的值越多, 其精度越高. 但根据 Butcher 给出得计算量与可达最高精度阶数关系, 当 K_i 的个数达到 $n(n \geq 8)$ 时, 可达到最高精度反而降低至 $O(h^{n-2})$. 因此在实际应用时, 常采用低阶算法而将步长 h 取小.

附录 A

矩阵分析基础

A.1 向量范数

A.1.1 向量范数的定义

定义 A.1.1. 设 $X \in R^n$, $\|X\|$ 表示定义在 R^n 上的一个实函数, 称之为 X 的范数, 其具有如下性质:

1. 非负性, 即对一切 $X \in R^n, X \neq 0, \|X\| > 0$;
2. 齐次性, 即对任何实数 $a \in R, x \in R^n$, 有 $\|aX\| = \|a\| \cdot \|X\|$;
3. 三角不等式, 即对任意两个向量 $X, Y \in R^n$, 有 $\|X + Y\| \leq \|X\| + \|Y\|$

A.1.2 常用的向量范数

设向量 $X = (x_1, x_2, \cdots, x_n)^{\mathrm{T}} \in R^n$, 则定义三种常用范数为

$$\|X\|_{\infty} = \max_{1 \leq i \leq n} |x_i|$$

$$\|X\|_1 = \sum_{i=1}^{n} |x_i|$$

$$\|X\|_2 = \left(\sum_{i=1}^{n} |x_i|^2 \right)^{1/2}$$

分别称为∞-范数, 1-范数和 2-范数

例 A.1.1. 计算向量 $X = (1, 2, -3)^T$ 的范数

解.

$$\|X\|_1 = \sum_{i=1}^{n} |x_i| = 6$$

$$\|X\|_2 = \left(\sum_{i=1}^{n} x_i^2 \right)^{1/2} = \sqrt{14}$$

$$\|X\|_\infty = \max_{1 \le i \le n} |x_i| = 3$$

□

A.1.3 向量范数性质

定义 A.1.2. 如果 R^n 中有两个范数 $\|X\|_s$ 与 $\|X\|_t$, 存在常数 $m, M > 0$, 使得对任意 n 维向量 X, 有

$$m\|X\|_s \le \|X\|_t \le M\|X\|_s$$

则称这两个范数等价

可以验证, 向量范数有如下不等式关系:

$$\frac{1}{n}\|X\|_1 \le \|X\|_\infty \le \|X\|_1$$

$$\|X\|_\infty \le \|X\|_1 \le n\|X\|_\infty$$

$$\|X\|_\infty \le \|X\|_2 \le \sqrt{n}\|X\|_\infty$$

定义 A.1.3. 设给定 R^n 中的向量序列 X_k, 即

$$X_0, X_1, \cdots, X_k, \cdots$$

若对任何 $i (i = 1, 2, \cdots, n)$ 都有

$$\lim_{k \to \infty} x_i^{(k)} = x_i^*$$

则向量

$$X^* = (x_1^*, x_2^*, \cdots, x_n^*)^T$$

称为向量序列 X_k 的极限, 或者说向量序列 X_k 依坐标收敛于向量 X^*, 记为

$$\lim_{k \to \infty} X_k = X^*$$

定理 A.1.1. 向量序列 X_k 依坐标收敛于 X^* 的充要条件是

$$\lim_{k\to\infty}\|X_k - X^*\| = 0$$

注: 若某向量序列在某一范数意义下收敛时, 根据向量范数的等价性, 则在其他范数意义下也收敛.

A.2 矩阵范数

A.2.1 矩阵范数的定义

定义 A.2.1. 设对任意矩阵 $A \in R^{n\times n}$, 按一定的规则有一实数与之对应, 记作 $\|A\|$, 若 $\|A\|$ 满足

1. 正定性: $\|A\| \geq 0$, 当且仅当 $A = 0$ 时有 $\|A\| = 0$;
2. 齐次性: $\|cA\| = |c|\,\|A\|, \forall c \in R$;
3. 三角不等式: $\|A+B\| \leq \|A\| + \|B\|$;
4. 相容性: $\|AB\| \leq \|A\|\,\|B\|$

则称 $\|A\|$ 时矩阵 A 的范数

定义 A.2.2 (矩阵的算子范数)**.** 设 $x \in R^n, A \in R^{n\times n}, \|X\|_v$ 是向量范数 $(v = 1, 2, \infty)$, 则

$$\|A\|_v = \sup_{X\neq\theta}\frac{\|AX\|_v}{\|X\|_v}$$

是矩阵的非负函数, 称为矩阵 A 的算子范数

注:

$$\|A\|_v = \sup_{X\neq\theta}\frac{\|AX\|_v}{\|X\|_v} = \sup_{X\neq\theta}\|A\frac{X}{\|X\|}\|$$

令

$$y = \frac{X}{\|X\|_v}$$

则

$$\|A\|_v = \max_{\|y\|_v=1}\|Ay\|_v$$

定理 A.2.1. 设 $\|\cdot\|_v$ 是 R^n 中的向量范数, 则 $\|A\|_v$ 为 $R^{n\times n}$ 上的矩阵范数, 且满足

$$\|Ax\|_v \leq \|A\|_v\|x\|_v$$

A.2.2 常用的矩阵范数

定理 A.2.2. 设 n 阶方阵 $A=(a_{ij})_{n\times n}$, 则

1. 与 $\|x\|_1$ 相容的矩阵范数是

$$\|A\|_1=\max_j\sum_{i=1}^{n}|a_{ij}|$$

2. 与 $\|x\|_\infty$ 相容的矩阵范数是

$$\|A\|_\infty=\max_i\sum_{j=1}^{n}|a_{ij}|$$

3. 与 $\|x\|_2$ 相容的矩阵范数是

$$\|A\|_2=\sqrt{\lambda_{max}(A^TA)}$$

其中 $\lambda_{max}(A^TA)$ 为矩阵 A^TA 的最大特征值.

上述三种范数又分别称为矩阵的 *1*-范数, ∞-范数, *2*-范数. 根据求和方式, 又分别称为列和范数, 行和范数, 谱范数

特殊的, 定义 Frobenius 范数为:

$$\|A\|_F=\sqrt{\sum_{i=1}^{n}\sum_{j=1}^{n}|a_{ij}|^2}$$

可将该范数看作对向量范数 $\|\cdot\|_2$ 的直接推广.

可以证明, 对于方阵 $A\in R^{n\times n}$ 和 $x\in R^n$, 有

$$\|Ax\|_2\le\|A\|_F\cdot\|x\|_2$$

注意, F-范数不是算子范数, 但有如下性质:

$$\|A\|_F=\sqrt{\mathrm{tr}(A^{\mathrm{T}}A)}=\sqrt{\mathrm{tr}(AA^{\mathrm{T}})}$$

例 A.2.1. 计算矩阵

$$A=\begin{pmatrix}1&-2\\-3&4\end{pmatrix}$$

的各种范数

解.

$$\|A\|_\infty = \max_{1\le i\le n}\sum_{j=1}^{n}|a_{ij}| = \max\{1+2, 3+4\} = 7$$

$$\|A\|_1 = \max_{1\le j\le n}\sum_{i=1}^{n}|a_{ij}| = \max\{1+3, 2+4\} = 6$$

$$\|A\|_F = \left(\sum_{i,j=1}^{n} a_{ij}^2\right)^{1/2} = \sqrt{1+2+9+16} \approx 5.477$$

下面计算 2-范数

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^{\mathrm{T}}A)}$$

$$A^{\mathrm{T}}A = \begin{pmatrix} 1 & -3 \\ -2 & 4 \end{pmatrix}\begin{pmatrix} 1 & -2 \\ -3 & 4 \end{pmatrix} = \begin{pmatrix} 10 & -14 \\ -14 & 20 \end{pmatrix}$$

令

$$\begin{vmatrix} \lambda - 10 & -14 \\ -14 & \lambda - 20 \end{vmatrix} = 0$$

解得

$$\lambda_{1,2} = 15 \pm \sqrt{221}$$

故最大特征值为

$$\lambda_{\max} = 15 + \sqrt{221}$$

所以得 2-范数

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^{\mathrm{T}}A)} = \sqrt{15+\sqrt{221}}$$

□

A.2.3 矩阵范数与特征值之间的关系

定义 A.2.3. 矩阵 A 的所有特征值的最大模称为 A 的谱半径, 记作

$$\rho(A) = \max_{1\le i\le n}|\lambda_i|$$

定理 A.2.3. 矩阵 A 谱半径不超过 A 的任一矩阵范数, 即

$$\rho(A) = \max_{1\le i\le n}|\lambda_i| \le \|A\|$$

证明. 设 λ 是矩阵 A 的任一特征值, x 为对应特征向量, 则特征方程

$$Ax = \lambda x$$

由矩阵范数的相容性可知,

$$|\lambda| \|x\| = \|\lambda x\| = \|Ax\| \leq \|A\| \|x\|$$

即

$$|\lambda| \leq \|A\|$$

□

推论 A.2.4. *若 A 为对称矩阵, 则*

$$\rho(A) = \|A\|_2$$

注: $R^{n\times n}$ 中任意两个矩阵范数也是等价的.

定义 A.2.4. *设 $\|\cdot\|$ 为 $R^{n\times n}$ 上的矩阵范数, $A, B \in R^{n\times n}$, 称 $\|A-B\|$ 为 A 与 B 之间的距离*

定义 A.2.5. *设给定 $R^{n\times n}$ 中的矩阵序列 A_k, 若*

$$\lim_{k\to\infty} \|A_k - A\| = 0$$

则称矩阵序列 A_k 收敛于矩阵 A, 记作

$$\lim_{k\to\infty} A_k = A$$

定理 A.2.5. *若 $\|B\| < 1$, 则 $I \pm B$ 为非奇异矩阵, 且*

$$\|(I \pm B)^{-1}\| \leq \frac{1}{1 - \|B\|}$$

其中, $\|\cdot\|$ 为矩阵的算子范数.

证明. 反证法, 假设 $\det\{(I \pm B)\} = 0$, 则线性方程组 $(I \pm B)x = 0$ 有非零解, 即存在 $x_0 \neq 0$ 使得

$$Bx_0 = x_0, \frac{\|Bx_0\|}{\|x_0\|} = 1$$

因此有

$$\|B\| \geq 1$$

与假设矛盾.

又因为

$$(I \pm B)(I \pm B)^{-1} = I$$

有

$$(I \pm B)^{-1} = I \mp B(I - B)^{-1}$$

从而

$$\|(I \pm B)^{-1}\| \leq \|I\| + \|B\| \, \|(I \pm B)^{-1}\|$$

即

$$\|(I \pm B)^{-1}\| \leq \frac{1}{1 - \|B\|}$$

□

定理 A.2.6. 设 $B \in R^{n \times n}$, 则由 B 的各幂次得到的矩阵序列 $B^k, k = 0, 1, 2, \cdots$ 收敛于零矩阵, 即

$$\lim_{k \to \infty} B^k = 0$$

的充要条件是

$$\rho(B) < 1$$

A.2.4 矩阵的条件数

定义 A.2.6. 设矩阵 A 为非奇异矩阵, 则称

$$cond(A) = \|A^{-1}\| \, \|A\|$$

为矩阵 A 的条件数, 其中 $\|\cdot\|$ 为矩阵的算子范数.

对矩阵 A 的任意一个算子范数 $\|\cdot\|$, 有

1. $\text{cond}(A) = \|A^{-1}\| \, \|A\| \geq \|A^{-1} \cdot A\| = \|I\| = 1$;
2. $\text{cond}(kA) = \text{cond}(A)$, k 为非零常数;
3. 若 $\|A\| = 1$, 则 $\text{cond}(A) = \|A^{-1}\|$

注: $\mathrm{cond}(A)$ 与所取范数有关. 常用的条件数有:

$$\begin{aligned}\mathrm{cond}(A)_1 &= \|A^{-1}\|_1\|A\|_1\\ \mathrm{cond}(A)_\infty &= \|A^{-1}\|_\infty\|A\|_\infty\\ \mathrm{cond}(A)_2 &= \sqrt{\lambda_{\max}(A^{\mathrm{T}}A)/\lambda_{\min}(A^{\mathrm{T}}A)}\end{aligned}$$

特别地, 当 A 对称时, 则

$$\mathrm{cond}(A)_2 = \frac{\max|\lambda_i|}{\min|\lambda_i|}$$

A.3 初等矩阵

A.3.1 初等矩阵

定义 A.3.1. *设向量 $u, v \in R^n, \sigma \in R$, 则形如*

$$E(u, v, \sigma) = I - \sigma uv^T$$

的矩阵叫做实初等矩阵, 其中 I 为 n 阶单位矩阵

A.3.2 初等下三角矩阵

定义 A.3.2. *令向量 $u = l_i = (0, \cdots, 0, l_{i+1,i}, \cdots, l_{ni})^T$, 向量 $v = e_i, \sigma = 1$, 则称矩阵*

$$L_i = L_i(l_i) = E(l_i, e_i; 1) = I - l_i e_i^T = \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -l_{i+1,i} & 1 & \\ & & \vdots & & \ddots \\ & & -l_{ni} & & 1 \end{pmatrix}$$

为初等下三角阵

定理 A.3.1. *初等下三角阵 L_i 具有如下性质:*

1. $L_i^{-1}(l_i) = L_i(-l_i), |L_i| = 1$;

2.

$$L = L_1(l_1)L_2l_2\cdots L_{n-1}(l_{n-1}) = \begin{pmatrix} 1 & & & \\ -l_{21} & 1 & & \\ \vdots & \vdots & \ddots & \\ -l_{n1} & -l_{n2} & \cdots & 1 \end{pmatrix}$$

为单位下三角阵*;*

3. 任何一个单位下三角阵 $L \in R^n$ 都可分裂成

$$L = I - l_1e_1^T - l_2e_2^T - \cdots - l_{n-1}e_{n-1}^T$$

因此, 对任一非奇异下三角阵 L, 都可分裂成一个非奇异对角阵和若干个下三角阵的乘积*;*

4. L_i 左乘矩阵 A 的结果是从 A 的各行中减去第 i 行乘一个因子.

附录 B

常见 Runge-Kutta 公式

正如前文所说, Runge-Kutta 公式具有无穷多种格式, 这里给出一些常见的 RUnge-Kutta 公式

B.1 二阶 Runge-Kutta 方法

$$\begin{cases} y_{i+1} = y_i + h[\lambda_1 K_1 + \lambda_2 K_2] \\ K_1 = f(x_i, y_i) \\ K_2 = f(x_i + ph, y_i + phK_1) \end{cases}$$

其中

$$\lambda_1 + \lambda_2 = 1, \lambda_2 p = \frac{1}{2}$$

B.1.1 二阶中点方法

取 $\lambda_1 = 0, \lambda_2 = 1, p = 1/2$

$$\begin{cases} y_{i+1} = y_i + hk_2 \\ k_1 = f(x_i, y_i) \\ k_2 = f(x_i + \frac{h}{2}, y_i + \frac{h}{2}k_1) \end{cases}$$

B.1.2 二阶 Hune 方法

取 $\lambda_1 = 1/4, \lambda_2 = 3/4.p = 2/3$

$$\begin{cases} y_{i+1} = y_i + h\left(\frac{1}{4}k_1 + \frac{3}{4}k_2\right) \\ k_1 = f(x_i, y_i) \\ k_2 = f(x_1 + \frac{2h}{3}, y_i + \frac{2h}{3}k_1) \end{cases}$$

B.2 三阶 Runge-Kutta 方法

$$\begin{cases} y_{i+1} = y_i + h(\lambda_1 k_1 + \lambda_2 k_2 + \lambda_3 k_3) \\ k_1 = f(x_i, y_i) \\ k_2 = f(x_i + c_2 h, y_i + c_2 h k_1) \\ k_3 = f(x_i + c_3 h, y_i + a_{31} h k_1 + a_{32} h k_2) \\ c_3 = a_{31} + a_{32} \end{cases}$$

其中

$$\begin{cases} \lambda_1 + \lambda_2 + \lambda_3 = 1 \\ \lambda_2 c_2 + \lambda_3 c_3 = \frac{1}{2} \\ \lambda_2 c_2^2 + \lambda_3 c_3^2 = \frac{1}{3} \\ \lambda_3 c_2 a_{32} = \frac{1}{6} \end{cases}$$

B.2.1 三阶 Kutta 方法

取 $\lambda_1 = 1/6, \lambda_2 = 2/3, \lambda_3 = 1/6, c_2 = 1/2, c_3 = 1, a_{32} = 2, a_{31} = -1$

$$\begin{cases} y_{i+1} = y_i + h\left(\frac{1}{6}k_1 + \frac{2}{3}k_2 + \frac{1}{6}k_3\right) \\ k_1 = f(x_i, y_i) \\ k_2 = f(x_i + \frac{1}{2}h, y_i + \frac{1}{2}hk_1) \\ k_3 = f(x_i + h, y_i - hk_1 + 2hk_2) \end{cases}$$

B.2.2 三阶 Hune 方法

取 $\lambda_1 = 1/4, \lambda_2 = 0, \lambda_3 = 3/4, c_2 = 1/3, c_3 = 2/3, a_{32} = 2/3, a_{31} = 0$

$$\begin{cases} y_{i+1} = y_i + h\left(\frac{1}{4}k_1 + \frac{3}{4}k_3\right) \\ k_1 = f(x_i, y_i) \\ k_2 = f(x_i + \frac{1}{3}h, y_i + \frac{1}{3}hk_1) \\ k_3 = f(x_i + \frac{2}{3}h, y_i + \frac{2}{3}hk_2) \end{cases}$$

B.3 四阶 Runge-Kutta 方法

$$\begin{cases} y_{i+1} = y_i + h(\lambda_1 k_1 + \lambda_2 k_2 + \lambda_3 k_3 + \lambda_4 k_4) \\ k_1 = f(x_i, y_i) \\ k_2 = f(x_i + c_2 h, y_i + c_2 h k_1) \\ k_3 = f(x_i + c_3 h, y_i + a_{31} h k_1 + a_{32} h k_2) \\ k_4 = f(x_i + c_4 h, y_i + a_{41} h k_1 + a_{42} h k_2 + a_{43} h k_3) \\ c_3 = a_{31} + a_{32}, c_4 = a_{41} + a_{42} + a_{43} \end{cases}$$

其中

$$\begin{cases} a_{31} + a_{32} = c_3 \\ a_{41} + a_{42} + a_{43} = c_4 \\ \lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 = 1 \\ \lambda_2 c_2 + \lambda_3 c_3 + \lambda_4 c_4 = \frac{1}{2} \\ \lambda_2 c_2^2 + \lambda_3 c_3^2 + \lambda_4 c_4^2 = \frac{1}{3} \\ \lambda_2 c_2^3 + \lambda_3 c_3^3 + \lambda_4 c_4^3 = \frac{1}{4} \\ \lambda_3 c_2 a_{32} + \lambda_4(c_2 a_{42} + c_3 a_{43}) = \frac{1}{6} \\ \lambda_3 c_2^2 a_{32} + \lambda_4(c_2^2 a_{42} + c_3^2 a_{43}) = \frac{1}{12} \\ \lambda_3 c_2 c_3 a_{32} + \lambda_4 c_4(c_2 a_{42} + c_3 a_{43}) = \frac{1}{8} \\ \lambda_4 c_2 a_{32} a_{43} = \frac{1}{24} \end{cases}$$

B.3.1 四阶经典 Runge-Kutta 方法

$$\begin{cases} y_{i+1} = y_i + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4) \\ k_1 = f(x_i, y_i) \\ k_2 = f(x_i + \frac{h}{2}, y_i + \frac{h}{2}k_1) \\ k_3 = f(x_i + \frac{h}{2}, y_i + \frac{h}{2}k_2) \\ k_4 = f(x_i + h, y_i + hk_3) \end{cases}$$