

# 数值分析笔记

## Python version

Jiaqi Z.<sup>1</sup>

2023 年 11 月 8 日

<sup>1</sup>Copyright ©2023 Jiaqi Z. All rights reserved.



# 目录

关于本笔记的版权与使用说明	v
<b>1 绪论</b>	<b>1</b>
1.1 误差	1
1.1.1 误差来源与分类	1
1.1.2 误差概念	2
1.1.3 相对误差限和有效数字的关系	5
1.2 数值运算的误差估计	6
1.2.1 四则运算误差估计	6
1.2.2 函数值误差估计	7
1.3 算法数值稳定性	8
1.4 数值计算中应该注意的一些原则	11
1.4.1 避免两相近数相减	11
1.4.2 避免除数绝对值远小于被除数绝对值	11
1.4.3 避免大数“吃”小数	11
1.4.4 简化计算步骤, 避免误差积累	13
<b>2 插值法</b>	<b>17</b>
2.1 引言	17
2.2 Lagrange 插值法	19
2.2.1 线性插值	19
2.2.2 抛物插值	19
2.2.3 Lagrange 插值多项式	20
2.2.4 插值余项	22

2.2.5	Lagrange 插值优缺点 . . . . .	24
2.3	Newton 插值 . . . . .	25
2.3.1	Newton 插值 . . . . .	25
2.3.2	差商 . . . . .	26
2.3.3	Newton 插值余项 . . . . .	28
2.4	等距节点差商公式 . . . . .	28
2.4.1	差分定义 . . . . .	28
2.4.2	差分的性质 . . . . .	29
2.4.3	等距节点插值公式 . . . . .	30
2.5	Hermite 插值 . . . . .	31
2.5.1	引入, Hermite 插值多项式的存在唯一性 . . . . .	31
2.5.2	Hermite 插值多项式构造 . . . . .	31
2.6	分段低次插值 . . . . .	35
2.6.1	多项式插值的 Runge 现象 . . . . .	35
2.6.2	分段线性插值 . . . . .	36
2.6.3	分段三次 Hermite 插值 . . . . .	39
2.7	三次样条插值 . . . . .	41
2.7.1	三次样条函数 . . . . .	41
2.7.2	三次样条插值函数构造 . . . . .	41
2.7.3	三转角方程 . . . . .	43
2.7.4	三弯矩方程 . . . . .	45
2.7.5	三次样条插值函数的收敛性 * . . . . .	48
<b>3</b>	<b>函数逼近与计算</b>	<b>53</b>
3.1	引言 . . . . .	53
3.1.1	函数逼近的问题的一般提法 . . . . .	53
3.1.2	常用的度量标准 . . . . .	53
3.2	最佳一致逼近 . . . . .	54
3.2.1	最佳一致逼近概念 . . . . .	54
3.2.2	最佳一致逼近多项式的存在性 . . . . .	54
3.2.3	$C[a, b]$ 上最佳一致逼近 . . . . .	54
3.2.4	相关概念 . . . . .	55
3.2.5	$C[a, b]$ 上的最佳一致逼近特征 . . . . .	56
3.2.6	一次最佳逼近多项式 ( $n = 1$ ) . . . . .	57

3.2.7	Chebyshev 多项式及其应用 . . . . .	59
3.3	最佳平方逼近 . . . . .	63
3.3.1	内积空间 . . . . .	63
3.3.2	相关概念 . . . . .	64
3.3.3	内积空间上的最佳平方逼近 . . . . .	65
3.3.4	连续函数的最佳平方逼近 . . . . .	68
3.4	正交多项式 . . . . .	71
3.4.1	正交化手续 . . . . .	71
3.4.2	正交多项式的性质 . . . . .	71
3.4.3	常用的正交多项式 . . . . .	72
3.5	函数按正交多项式展开 . . . . .	74
3.6	曲线拟合的最小二乘法 . . . . .	77
3.6.1	问题提出 . . . . .	77
3.6.2	曲线拟合的步骤 . . . . .	77
3.6.3	2-范数度量下的曲线拟合 (最小二乘法) . . . . .	77
3.6.4	用正交函数作最小二乘拟合 . . . . .	80
<b>A</b>	<b>矩阵分析基础</b> . . . . .	<b>85</b>
A.1	向量范数 . . . . .	85
A.1.1	向量范数的定义 . . . . .	85
A.1.2	常用的向量范数 . . . . .	85
A.1.3	向量范数性质 . . . . .	86
A.2	矩阵范数 . . . . .	87
A.2.1	矩阵范数的定义 . . . . .	87
A.2.2	常用的矩阵范数 . . . . .	88
A.2.3	矩阵范数与特征值之间的关系 . . . . .	89
A.2.4	矩阵的条件数 . . . . .	91
A.3	初等矩阵 . . . . .	92
A.3.1	初等矩阵 . . . . .	92
A.3.2	初等下三角矩阵 . . . . .	92



# 关于本笔记的版权与使用说明

- 本笔记可免费用于学习, 科研等非商业活动;
- 可以以非商业目的进行传播, 但在传播过程中必须保证笔记内容的完整性 (截止到 GitHub 仓库<sup>1</sup>最新发布时, ”笔记” 包括但不限于仓库内笔记 Latex 源码, pdf 文件, 演示程序代码等. 下同), 需保证作者信息完整, 不得进行修改;
- 本笔记不可用于任何商业用途 (如确有需要, 需联系作者);
- 除在 GitHub 仓库以 pull request 形式进行编辑修改外, 不允许对笔记进行修改并公开传播私自修改版本 (以 GitHub 仓库版本为标准版本);
- 本笔记著作权归作者 (Jiaqi Z.) 所有, 对本笔记进行创作的人员也可获得著作权, 其他著作权所有者不得违反上述版权说明;
- 本笔记如因违反上述说明传播而造成不良影响, 与作者和其他创作者无关, 特此声明;

以上说明解释权归 Jiaqi Z. 所有, 且如有后续更新, 以 GitHub 仓库最新版说明为准.

---

<sup>1</sup>GitHub 仓库地址:<https://github.com/JackyZhang00/numerical-analysis-notes>





# Chapter 1

## 绪论

### 1.1 误差

#### 1.1.1 误差来源与分类

1. (模型误差): 从实际模型中抽象出数学模型;

例如, 一个质量为  $m$  的小球做自由落体运动, 则位置  $s$  与时间  $t$  的关系式满足:

$$m \frac{d^2 s}{dt^2} = mg$$

不难想见, 该式仅在不考虑阻力时成立.

2. (观测误差): 通过测量得到模型中参数的值;
3. (方法误差 (或称截断误差)): 求近似解时所引入的误差;

**例 1.1.1.** 考虑函数  $f(x)$  做 *Taylor* 多项式展开所导致的截断误差.

**解.** 对函数  $f(x)$  计算 *Taylor* 多项式, 有

$$P_n(x) = f(0) + \frac{f'(0)}{1!}x + \frac{f''(0)}{2!}x^2 + \cdots + \frac{f^{(n)}(0)}{n!}x^n$$

由于有限项, 因此多项式有截断误差

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}x^{n+1}$$

其中,  $\xi \in (x, 0)$

□

4. (舍入误差): 机器字长有限所引起的误差

其中, 方法误差和舍入误差是数值分析所重点考虑的误差, 同时, 方法误差是可以避免的.

### 1.1.2 误差概念

#### 绝对误差与绝对误差限

**定义 1.1.1** (绝对误差与绝对误差限). 设  $x$  是准确值,  $x^*$  是  $x$  的一个近似值, 则称

$$e(x^*) = x^* - x$$

为  $x^*$  的绝对误差, 简称误差.

同时, 误差的绝对值的上限  $\varepsilon(x^*)$ , 即有

$$|e(x^*)| = |x^* - x| \leq \varepsilon(x^*)$$

$\varepsilon(x^*)$  称为绝对误差限.

**注意:** 误差有正有负, 而误差限恒为正值.

习惯上, 我们把精确值和测量值的关系表示为

$$x = x^* \pm \varepsilon$$

#### 相对误差与相对误差限

**定义 1.1.2** (相对误差与相对误差限). 设  $x$  为准确值,  $x^*$  为近似值, 称

$$e_r^* = e_r^*(x^*) = \frac{e(x^*)}{x} = \frac{x^* - x}{x}$$

为近似值  $x^*$  的相对误差.

同时, 其绝对值的上限  $\varepsilon_r^*$ , 即有

$$\left| \frac{x - x^*}{x} \right| \leq \varepsilon_r^*$$

$\varepsilon_r^*$  称为相对误差限.

可以证明, 当  $e_r^*$  较小时, 有

$$e_r^* \approx \frac{x^* - x}{x^*}$$

同时易得

$$\varepsilon_r^* = \frac{\varepsilon^*}{|x^*|}$$

## 有效数字

定义 1.1.3 (有效数字, 有效位数, 有效数). 若近似值  $x^*$  误差满足

$$|x - x^*| \leq \frac{1}{2} \times 10^{-n}$$

则称  $x^*$  近似表示  $x$  准确到小数点后第  $n$  位, 并从第  $n$  位起一直到最左边非零数字之间的一切数字称为有效数字, 位数为有效位数.

若所有数字均为有效数字, 则称为有效数

例 1.1.2. 考虑圆周率  $\pi$ , 且有近似值  $\pi_1 = 3.14, \pi_2 = 3.1415, \pi_3 = 3.1416, \pi_4 = 3.14159$ . 考虑它们的有效数字, 且判断是否为有效数.

解. 对于  $\pi_1 = 3.14$ , 有  $|\pi - \pi_1| \approx 0.00159 \leq 0.5 \times 10^{-2}$ , 即  $\pi_1$  精确到小数点后 2 位, 有效数字是 3 位, 是有效数.

同理, 有  $|\pi - \pi_2| \approx 0.0000926 \leq 0.5 \times 10^{-3}$ , 即  $\pi_2$  精确到小数点后 3 位, 有效数字是 4 位, 不是有效数.

$|\pi - \pi_3| \approx 0.0000073 \leq 0.5 \times 10^{-4}$ , 即  $\pi_3$  精确到小数点后 4 位, 有效数字是 5 位, 是有效数.

$|\pi - \pi_4| \approx 0.0000026 \leq 0.5 \times 10^{-5}$ , 即  $\pi_4$  精确到小数点后 5 位, 有效数字是 6 位, 是有效数.  $\square$

从上例中不难看出, 有效数通常是采取四舍五入所得到的近似值.

扩展: 我们可以简单给出关于四舍五入的证明.

证明. 设准确值为  $x$ , 其近似值为  $x^*$ , 考虑近似值精确到小数点后  $n$  位, 即

$$|x - x^*| \leq 5 \times 10^{-(n+1)}$$

若其为有效数, 则  $x^*$  为小数点后  $n$  位, 不妨设

$$x^* = a + b \cdot 10^{-n}$$

其中  $b \in [1, 10)$

特别地, 分两种情况讨论.

若  $x > x^*$ , 即真实值大于近似值, 此时有

$$x \leq x^* + 5 \times 10^{-(n+1)} = a + b \cdot 10^{-n} + 5 \times 10^{-(n+1)}$$

即当小数点后第  $n+1$  位小于等于 5 时, 舍去后面的数字可以得到有效数.

若  $x < x^*$ , 即真实值小于近似值, 此时有

$$\begin{aligned} x &\geq x^* - 5 \times 10^{-(n+1)} = a + b \cdot 10^{-n} - 5 \times 10^{-(n+1)} \\ &= a + (b - 1) \cdot 10^{-n} + 5 \times 10^{-(n+1)} \end{aligned}$$

即当小数点后第  $n + 1$  位大于等于 5 时, 进位可以得到有效数.  $\square$

### 十进制浮点表示法

**定义 1.1.4.** 设  $x^*$  为任一十进制数, 则  $x^*$  可表示为

$$x^* = \pm 0.a_1 a_2 \cdots a_n \cdots \times 10^m$$

其中,  $a_1$  为 1 到 9 之间的一个数字,  $a_2 \cdots a_n$  为 0 到 9 之间的一个数字,  $m$  为整数. 这样表示的  $x^*$  称为十进制浮点数 (规格化浮点数).

### 有效数字的等价定义 (基于浮点表示法)

**定义 1.1.5.** 若近似值  $x^* = \pm 0.a_1 a_2 \cdots a_n a_{n+1} \cdots a_{n+p} \times 10^m (a_1 \neq 0)$  的误差限是某一位上的半个单位, 即

$$|x - x^*| \leq \frac{1}{2} \times 10^{m-n} \quad (1.1)$$

则称  $x^*$  有  $n$  位有效数字.

**例 1.1.3.** 设  $x_1^* = 0.0051, x_2^* = 5.100$ , 两数均为四舍五入得到, 求两个数字的有效位数.

**解.** 由于有

$$\begin{aligned} \varepsilon(x_1^*) &= 0.5 \times 10^{-4}, x_1^* = 0.51 \times 10^{-2} \\ \varepsilon(x_2^*) &= 0.5 \times 10^{-3}, x_2^* = 0.51 \times 10^1 \end{aligned}$$

可得

$$\begin{aligned} \varepsilon(x_1^*) &= 0.5 \times 10^{-2-2} \\ \varepsilon(x_2^*) &= 0.5 \times 10^{1-4} \end{aligned}$$

即,  $x_1^*$  有两位有效数字,  $x_2^*$  有四位有效数字.  $\square$

**例 1.1.4.** 设  $x_1^* = 2.180, x_2^* = 10.210$ , 均具有四位有效数字, 求绝对误差限和相对误差限.

**解.** 对  $x_1^*$ , 有

$$x_1^* = 0.2180 \times 10^1$$

即  $m = 1$ , 且具有四位有效数字, 即  $n = 4$ , 则根据公式 (1.1), 有

$$\varepsilon(x_1^*) = 0.5 \times 10^{1-4} = 0.5 \times 10^{-3}$$

其相对误差限为

$$\varepsilon_r(x_1^*) = \frac{\varepsilon(x_1^*)}{|x_1^*|} = 0.023\%$$

同理可得, 对于  $x_2^*$ , 有

$$\varepsilon(x_2^*) = 0.5 \times 10^{-2}, \varepsilon_r(x_2^*) = 0.049\%$$

□

### 1.1.3 相对误差限和有效数字的关系

关于有效数字和相对误差限之间的关系, 有如下定理.

**定理 1.1.1.** 对于用式 (1.1.4) 表示的近似数  $x^*$ , 若  $x^*$  具有  $n$  位有效数字, 则其相对误差限为

$$\varepsilon_r^* \leq \frac{1}{2a_1} \times 10^{-n}$$

**证明.** 由式 1.1.4 可得

$$a_1 \times 10^m \leq |x^*| \leq (a_1 + 1) \times 10^m$$

当  $x^*$  有  $n$  位有效数字时, 有

$$|x - x^*| = |x^*| \varepsilon_r^* \leq (a_1 + 1) \times 10^m \times \frac{1}{2(a_1 + 1)} \times 10^{-n} = 0.5 \times 10^{m-n}$$

故  $x^*$  有  $n$  位有效数字.

□

上述定理表明: 有效位数越多, 相对误差限越小.

**例 1.1.5.** 令  $\sqrt{20}$  的近似值相对误差限小于  $0.1\%$ , 则需要取多少位有效数字?

解. 由定理 1.1.1 可知

$$\varepsilon_r^* \leq \frac{1}{2a_1} \times 10^{-n}$$

由于  $\sqrt{20} \approx 4.4$ , 故  $a_1 = 4$ , 只需要取  $n = 4$ , 有

$$\varepsilon_r^* \leq 0.125 \times 10^{-3} < 10^{-3} = 0.1\%$$

即只需要对  $\sqrt{20}$  的近似值取 4 位有效数字, 其相对误差限就可以小于 0.1%, 此时有

$$\sqrt{20} \approx 4.472.$$

□

## 1.2 数值运算的误差估计

### 1.2.1 四则运算误差估计

两个近似数分别为  $x_1^*$  和  $x_2^*$ , 误差限分别为  $\varepsilon(x_1^*), \varepsilon(x_2^*)$ , 进行四则运算的误差限分别为:

$$\begin{aligned}\varepsilon(x_1^* \pm x_2^*) &= \varepsilon(x_1^*) + \varepsilon(x_2^*) \\ \varepsilon(x_1^* x_2^*) &\approx |x_1^*| \varepsilon(x_2^*) + |x_2^*| \varepsilon(x_1^*) \\ \varepsilon(x_1^* / x_2^*) &\approx \frac{|x_1^*| \varepsilon(x_2^*) + |x_2^*| \varepsilon(x_1^*)}{|x_2^*|^2}\end{aligned}$$

下面试着给出加减法误差的证明, 对于乘法和除法的证明, 将在后面给出.

证明.

$$\begin{aligned}|e(x_1^* \pm x_2^*)| &= |(x_1^* \pm x_2^*) - (x_1 \pm x_2)| \\ &= |(x_1^* - x_1) \pm (x_2^* - x_2)| \\ &\leq |x_1^* - x_1| + |x_2^* - x_2| \\ &\leq \varepsilon(x_1^*) + \varepsilon(x_2^*)\end{aligned}$$

□

### 1.2.2 函数值误差估计

#### 一元函数误差估计

设  $f(x)$  是一元函数,  $x$  的近似值为  $x^*$ , 以  $f(x^*)$  近似  $f(x)$ , 其误差限记作  $\varepsilon(f(x^*))$ , 可用 Taylor 展开

$$f(x) - f(x^*) = f'(x^*)(x - x^*) + \frac{f''(\xi)}{2}\varepsilon^2(x^*)$$

其中,  $\xi$  介于  $x, x^*$  之间, 取绝对值有

$$|f(x) - f(x^*)| \leq |f'(x^*)|\varepsilon(x^*) + \frac{|f''(\xi)|}{2}\varepsilon^2(x^*)$$

假定  $f'(x^*)$  与  $f''(x^*)$  的比值不大, 可忽略  $\varepsilon(x^*)$  的高阶项, 于是可得误差限为

$$\varepsilon(f(x^*)) \approx |f'(x^*)|\varepsilon(x^*)$$

相对误差限为

$$\varepsilon_r(f(x^*)) \approx \frac{|f'(x^*)|\varepsilon(x^*)}{|f(x^*)|} = C_p(f, x^*)\varepsilon_r(x^*)$$

其中,

$$C_p(f, x^*) = \frac{|x^* f'(x^*)|}{|f(x^*)|}$$

称为  $f(x^*)$  的条件数.

#### 多元函数误差估计

当  $f$  为多元函数时计算  $A = f(x_1, x_2, \dots, x_n)$ , 如果  $x_1, x_2, \dots, x_n$  的近似值为  $x_1^*, x_2^*, \dots, x_n^*$ , 则  $A$  的近似值为  $A^* = f(x_1^*, x_2^*, \dots, x_n^*)$ , 于是函数值  $A^*$  的误差  $e(A^*)$  由 Taylor 展开, 得

$$\begin{aligned} e(A^*) &= A^* - A = f(x_1^*, x_2^*, \dots, x_n^*) - f(x_1, x_2, \dots, x_n) \\ &\approx \sum_{k=1}^n \left( \frac{\partial f(x_1^*, x_2^*, \dots, x_n^*)}{\partial x_k} \right) (x_k^* - x_k) = \sum_{k=1}^n \left( \frac{\partial f}{\partial x_k} \right)^* e_k^* \end{aligned}$$

于是误差限为

$$\varepsilon(A^*) \approx \sum_{k=1}^n \left| \left( \frac{\partial f}{\partial x_k} \right)^* \right| \varepsilon(x_k^*) \quad (1.2)$$

而  $A^*$  的相对误差限为

$$\varepsilon_r^* = \varepsilon_r(A^*) = \frac{\varepsilon(A^*)}{|A^*|} \approx \sum_{k=1}^n \left| \left( \frac{\partial f}{\partial x_k} \right)^* \right| \frac{\varepsilon(x_k^*)}{|A^*|}$$

**例 1.2.1.** 已测得某场地长  $l$  的值为  $l^* = 110 \text{ m}$ , 宽  $d$  的值为  $d^* = 80 \text{ m}$ , 已知  $|l - l^*| \leq 0.2 \text{ m}$ ,  $|d - d^*| \leq 0.1 \text{ m}$ , 试求面积  $S = ld$  的绝对误差限与相对误差限.

**解.** 因为  $S = ld$ ,  $\frac{\partial S}{\partial l} = d$ ,  $\frac{\partial S}{\partial d} = l$ , 由式 1.2 可知

$$\varepsilon(S^*) \approx \left| \left( \frac{\partial S}{\partial l} \right)^* \right| \varepsilon(l^*) + \left| \left( \frac{\partial S}{\partial d} \right)^* \right| \varepsilon(d^*)$$

其中,

$$\left( \frac{\partial S}{\partial l} \right)^* = d^* = 80 \text{ m}, \left( \frac{\partial S}{\partial d} \right)^* = l^* = 110 \text{ m}$$

而

$$\varepsilon(l^*) = 0.2 \text{ m}, \varepsilon(d^*) = 0.1 \text{ m}$$

于是绝对误差限为

$$\varepsilon(S^*) \approx (80 \times 0.2 + 110 \times 0.1) \text{ m}^2 = 27 \text{ m}^2$$

相对误差限为

$$\varepsilon_r(S^*) = \frac{\varepsilon(S^*)}{|S^*|} = \frac{\varepsilon(S^*)}{l^* d^*} \approx \frac{27}{8800} = 0.31\%$$

□

**注意:** 绝对误差限有量纲, 而相对误差限没有量纲.

### 1.3 算法数值稳定性

**定义 1.3.1** (数值稳定). 一个算法如果初始数值有微小扰动 (即有误差), 而计算过程中舍入误差不增长, 使得结果产生微小误差. 则称该算法为数值稳定的. 反之称为数值不稳定.

**例 1.3.1.** 计算定积分

$$I_n = \int_0^1 \frac{x^n}{n+5} dx, n = 0, 1, 2, \dots, 8$$



解. 对被积函数变形, 得

$$\begin{aligned} I_n &= \int_0^1 \frac{(x+5)-5}{x+5} x^{n-1} dx \\ &= \int_0^1 x^{n-1} dx - 5 \int_0^1 \frac{x^{n-1}}{x+5} dx \\ &= \frac{1}{n} - 5I_{n-1} \end{aligned}$$

其中,  $n = 1, 2, \dots, 8$ .

易知,  $I_0 = \ln 6 - \ln 5 = \ln 1.2$ , 由于机器只能计算小数, 取三位有效数字, 即  $\ln 1.2 \approx 0.182$ .

分析上述积分, 可知,  $0 < I_n < 0.2$ , 且随着  $n$  增大,  $I_n$  逐渐减小, 当  $n \rightarrow \infty$  时,  $I_n \rightarrow 0$ .

迭代计算上述积分, 可得结果为:

$$\begin{aligned} I_0 &= 0.182, I_1 = 0.09, I_2 = 0.05, I_3 = 0.083, I_4 = -0.17 \\ I_5 &= 1.03, I_6 = -5.0, I_7 = 25.14, I_8 = -125.59 \end{aligned}$$

可以发现, 该算法数值不稳定.

若对上述积分递推公式进行变形, 可得

$$I_{n-1} = \frac{1}{5n} - \frac{1}{5}I_n, n = 9, 8, \dots, 1$$

由于当  $n \rightarrow \infty$  时,  $I_n \rightarrow 0$ , 因此当  $n$  充分大时, 可近似认为  $I_n = I_{n+1}$ , 故有  $I_9 \approx I_0$ , 将其代入并求解方程, 可得  $I_9 \approx 0.017$ .

迭代计算, 可得结果为

$$\begin{aligned} I_0 &= 0.182, I_1 = 0.088, I_2 = 0.058, I_3 = 0.043, I_4 = 0.034 \\ I_5 &= 0.028, I_6 = 0.024, I_7 = 0.021, I_8 = 0.019 \end{aligned}$$

该算法为数值稳定的.

分析二者的误差, 可得对于第一个算法, 其误差为

$$e_n = |I_n - I_n^*| = 5|e_{n-1}| = 5^n |e_0|$$

而对于第二个算法, 其误差为

$$|e_{n-1}| = |I_{n-1} - I_{n-1}^*| = \frac{1}{5}|e_n| = \left(\frac{1}{5}\right)^n |e_0|$$

□

通过上述例子, 可以看到对于同一个问题, 使用不同算法, 得到的误差结果可能有很大不同.

扩展: 考虑到数值分析需要结合计算机使用, 故在笔记的适当地方, 将给出代码以供参考 (注: 代码不唯一. 且考虑到算法的设计原则, 如无必要, 不会引入相应的库函数).

本例的运行代码如下所示:

```
1  # 验证数值稳定性(例题) Exercise1-1.py
2  # 方法1(数值不稳定)
3  def I1(n):
4      if n==0:
5          return 0.182
6      else:
7          return 1/n-5*I1(n-1)
8  # 方法2(数值稳定)
9  def I2(n):
10     if n==9:
11         return 0.017
12     else:
13         return 1/(5*(n+1))-(1/5)*I2(n+1)
14
15 for n in range(0,9):
16     print(f"I1_{n}={I1(n)}")
17
18 for n in range(0,9):
19     print(f"I2_{n}={I2(n)}")
```

**定义 1.3.2** (良态与病态). 对于一个数学问题, 若初始数据有微小扰动 (即误差), 导致计算结果产生较小误差, 则称此问题是良态的, 否则称其为病态的.

注意: 良态和病态是针对数学问题本身的, 与算法无关.

## 1.4 数值计算中应该注意的一些原则

### 1.4.1 避免两相近数相减

使用两相近数相减, 将会导致有效数字损失. 下面的例子将有效说明这一点:

**例 1.4.1.** 计算函数  $y = \sqrt{x+1} - \sqrt{x}$  在  $x = 1000$  处的取值.

已知  $y$  的四位有效数字为 0.01580

**解.** 若选择直接相减, 则有  $y = \sqrt{1001} - \sqrt{1000} \approx 31.64 - 31.62 = 0.02$ , 只有两位有效数字.

若选择对其进行变形, 令

$$y = \frac{1}{\sqrt{x+1} + \sqrt{x}}$$

则可得

$$y = \frac{1}{\sqrt{1001} + \sqrt{1000}} \approx \frac{1}{31.64 + 31.62} = 0.01581$$

有三位有效数字. □

**注意:** 在本例中, 使用第二种方法得到的只有三位有效数字, 这是因为第四位有效数字是 0 而不是 1.

### 1.4.2 避免除数绝对值远小于被除数绝对值

例如,  $\frac{42}{0.01}$  和  $\frac{42}{0.011}$  的结果分别是 4200 和 3818.18, 明显可以发现, 除数只变化了 0.001, 结果变化了 381.82

### 1.4.3 避免大数”吃”小数

由于计算机字长是有限的, 在计算过程中需要考虑到对阶, 例如, 计算下面的式子:

$$10^9 + 1$$

在计算前首先需要将其规格化, 即将上式化为

$$0.1 \times 10^{10} + 0.1 \times 10^1$$

在计算机计算过程中, 需要进行对阶, 即将指数部分化为相同的. 在这里, 计算机将会做如下处理:

$$0.1 \times 10^{10} + 0.0000000001 \times 10^{10} = 0.1000000001 \times 10^{10}$$

同时, 考虑到计算机内部的小数存储是有长度限制的, 假设以 8 位为例, 则上式中的小数最后一位的 1 将被舍去, 从而得到结果为  $0.1 \times 10^{10}$ , 显然与结果不符.

下面的例子将详细说明这一点:

**例 1.4.2.** 用单精度 (浮点数保留 8 位小数) 计算

$$10^9 + 40 + 39 + \cdots + 1$$

**解.** 假设从左到右计算, 由于

$$10^9 + 40 = 0.1 \times 10^{10} + 0.4 \times 10^2 \approx 0.1 \times 10^{10}$$

会出现大数”吃”小数的情况.

假设从右到左计算, 则首先计算  $1 + 2 + \cdots + 40$ , 不难得结果为 820, 即有

$$\begin{aligned} \text{原式} &= 820 + 10^9 = 0.82 \times 10^3 + 0.1 \times 10^{10} \\ &= 0.000000082 \times 10^{10} + 0.1 \times 10^{10} \\ &= 0.100000082 \times 10^{10} \approx 0.10000008 \times 10^{10} = 1000000800 \end{aligned}$$

显然误差较小. □

下面的代码将演示这一点

**注意:** 由于计算机内部的存储方式和实际计算有些许误差 (计算机采用二进制存储), 因此运行结果可能与理论分析不一样.

```

1 # 演示大数"吃"小数 Exercise1-2.py
2 import numpy as np
3 # 使用从左到右的计算方式, 会有很大误差
4 def example1():
5     result = np.float32(0)
6     result = result + np.float32(1e9)

```

```

7     for i in range(1,41):
8         result = result + np.float32(i)
9         print(f"从左到右计算结果为{result}")
10    # 使用从右到左的计算方式, 误差较小
11    def example2():
12        result = np.float32(0)
13        for i in range(1,41):
14            result = result + np.float32(i)
15            result = result + np.float32(1e9)
16        print(f"从右到左计算结果为{result}")
17    # 运行结果
18    example1()
19    example2()

```

#### 1.4.4 简化计算步骤, 避免误差积累

例 1.4.3. 多项式求值: 给定  $x$ , 求下列  $n$  次多项式的值:

$$P(x) = a_0 + a_1x + \cdots + a_nx^n$$

解. 若采用直接求和的方法, 则有

$$P_n(x) = a_0 + a_1x + a_2x \cdot x + \cdots + a_n \underbrace{x \cdot x \cdot x \cdots x}_{n \uparrow x}$$

一共需要  $\frac{n(n+1)}{2}$  次乘法,  $n$  次加法

若使用逐项求和, 即令

$$x^2 = x \cdot x, x^3 = x^2 \cdot x, \cdots x^n = x^{n-1} \cdot x$$

一共需要  $(2n-1)$  次乘法,  $n$  次加法

若采用秦九韶算法 (Horner 算法), 则可以将上式整理为

$$P_n(x) = a_0 + x(a_1 + x(a_2 + x(\cdots + x(a_{n-1} + a_nx) \cdots)))$$

一共需要  $n$  次乘法,  $n$  次加法

□

可以明显发现, 使用秦九韶算法的效率明显优于其他两个算法.  
对于秦九韶算法, 可以使用如下递推公式:

$$\begin{cases} S_n = a_n \\ S_k = xS_{k+1} + a_k, k = n-1, n-2, \dots, 0 \\ P_n(x) = S_0 \end{cases}$$

实际上机运行可以参考如下代码:

```

1  # 演示100000次多项式不同算法时间差异(假设每一项系数a_n都是2)
   Exercise1-3.py
2  import time
3  POWER = 100000
4  # 直接求和
5  def method1():
6      result = 0
7      x = 2
8      a = []
9      for i in range(0, POWER+1):
10         a.append(2)
11         start_time = time.time()
12         for i in range(0, POWER+1):
13             result = result + a[i]*x**i
14         end_time = time.time()
15         # print(result)
16         print(end_time-start_time)
17  # 使用逐项求和
18  def method2():
19      result = 0
20      x = [1, 2]
21      for i in range(2, POWER+1):
22         x.append(x[i-1]*2)
23      a = []
24      for i in range(0, POWER+1):
25         a.append(2)

```

```
26     start_time = time.time()
27     for i in range(0,POWER+1):
28         result = result + a[i]*x[i]
29     end_time = time.time()
30     # print(result)
31     print(end_time-start_time)
32 # 秦九韶算法
33 def method3():
34     s = 2
35     x = 2
36     start_time = time.time()
37     for i in range(1,POWER+1):
38         s = s*x+2
39         # s.append(s[i-1]*x+2)
40     end_time = time.time()
41     # print(s)
42     print(end_time-start_time)
43
44 method1()
45 method2()
46 method3()
```

**注意：** 在本地测试时，得到运行结果分别为 10.107, 0.264, 0.249(单位“秒”)。这个时间可能在不同计算机上会有所差距，但一般情况下，随着多项式次数的增加，时间差距会逐渐拉大。同时，三种算法的时间增长速率也会有明显差距。





## Chapter 2

# 插值法

### 2.1 引言

**定义 2.1.1** (插值法). 设函数  $y = f(x)$  在区间  $[a, b]$  上有定义, 且已知在点  $a \leq x_0 \leq x_1 < \cdots < x_n \leq b$  上的值  $y_0, y_1, \cdots, y_n$ , 若存在一简单函数  $P(x)$ , 使

$$P(x_i) = y_i, i = 0, 1, \cdots, n \quad (2.1)$$

成立, 则称  $P(x)$  为函数  $f(x)$  的插值函数, 点  $x_0, x_1, \cdots, x_n$  为插值节点, 包括插值节点的区间  $[a, b]$  称为插值区间, 求插值函数  $P(x)$  的方法称为插值法.

**定义 2.1.2** (多项式插值). 若  $P(x)$  是次数不超过  $n$  的代数多项式, 即

$$P(x) = a_0 + a_1x + \cdots + a_nx^n \quad (2.2)$$

其中  $a_i$  为实数, 则称  $P(x)$  为插值多项式, 相应的插值法称为多项式插值.

本章所讨论的主要内容是多项式插值.

在寻找插值多项式之前, 需要对其存在性与唯一性进行讨论<sup>1</sup>. 给出如下定理:

**定理 2.1.1.** 对于给定互异节点  $x_0, x_1, \cdots, x_n$ , 满足插值条件式 (2.1) 的  $n$  阶插值多项式 (2.2) 存在且唯一.

---

<sup>1</sup> 存在性表明插值多项式存在, 唯一性表明无论采用哪种插值方法, 得到的结果是唯一的.

证明. 设所要构造的插值多项式为

$$P_n(x) = a_0 + a_1x + \cdots + a_nx^n$$

由插值条件

$$P_n(x_i) = y_i, i = 0, 1, \cdots, n$$

得如下线性方程组

$$\begin{cases} 1 \cdot a_0 + x_0a_1 + \cdots + x_0^na_n = y_0 \\ 1 \cdot a_0 + x_1a_1 + \cdots + x_1^na_n = y_1 \\ \vdots \\ 1 \cdot a_0 + x_na_1 + \cdots + x_n^na_n = y_n \end{cases}$$

求解  $a_0, a_1, \cdots, a_n$ , 计算系数行列式

$$D = \begin{vmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{vmatrix}$$

该行列式为 Vandermonde 行列式, 其值为

$$D = \prod_{0 \leq j < i \leq n} (x_i - x_j)$$

当  $x_i \neq x_j$  时,  $D \neq 0$ , 即  $P_n(x)$  由  $a_0, a_1, \cdots, a_n$  唯一确定 □

在实际计算过程中, 直接求解方程组往往计算量较大, 且方程组可能具有病态性. 例如, 对于  $x_1, x_2, x_3, x_4$ , 若值分别为 0.1, 0.2, 0.3, 0.4, 则行列式  $D = 1.2 \times 10^{-6} \approx 0$ .

因此, 通常的做法是在  $n$  次多项式空间中寻找一组基函数

$$\varphi_0(x), \varphi_1(x), \cdots, \varphi_n(x)$$

使得

$$P_n(x) = a_0\varphi_0(x) + a_1\varphi_1(x) + \cdots + a_n\varphi_n(x)$$

不同的基函数对应不同的插值法. 本章重点讨论 Lagrange 插值法与 Newton 插值法.

## 2.2 Lagrange 插值法

### 2.2.1 线性插值

例 2.2.1. 对于节点  $(x_0, y_0), (x_1, y_1)$ , 求一次多项式

解. 利用直线的两点式, 不难得到其插值多项式为

$$\begin{aligned} P_1 &= \left( \frac{x - x_1}{x_0 - x_1} \right) y_0 + \left( \frac{x - x_0}{x_1 - x_0} \right) y_1 \\ &= l_0(x)y_0 + l_1(x)y_1 = \sum_{i=0}^1 l_i(x)y_i \end{aligned}$$

□

在这里, 称

$$l_0(x) = \frac{x - x_1}{x_0 - x_1}, l_1(x) = \frac{x - x_0}{x_1 - x_0}$$

为一次 Lagrange 插值基函数.

不难验证, 对于一次 Lagrange 插值基函数而言, 存在如下性质

- $l_0(x), l_1(x)$  均为一次多项式
- $l_0(x_0) = 1, l_1(x_0) = 0, l_0(x_1) = 0, l_1(x_1) = 1$

### 2.2.2 抛物插值

与线性插值类似, 对于抛物插值, 设有三个插值点, 分别为  $(x_0, y_0), (x_1, y_1), (x_2, y_2)$ , 可得其插值多项式为

$$P_2(x) = y_0 l_0(x) + y_1 l_1(x) + y_2 l_2(x)$$

其中  $l_0(x), l_1(x), l_2(x)$  均为二次多项式, 且有

$$l_0(x_0) = 1, l_1(x_0) = 0, l_2(x_0) = 0$$

$$l_0(x_1) = 0, l_1(x_1) = 1, l_2(x_1) = 0$$

$$l_0(x_2) = 0, l_1(x_2) = 0, l_2(x_2) = 1$$

### 2.2.3 Lagrange 插值多项式

将上述结论推广至  $n$  阶情况. 即假设有  $n+1$  个节点  $x_0, x_1, \dots, x_n$  的  $n$  阶插值多项式  $L_n(x)$ , 且满足条件

$$L_n(x_i) = y_i, i = 1, 2, \dots, n \quad (2.3)$$

类似于线性插值和抛物插值, 我们首先需要定义出基函数.

**定义 2.2.1.** 若  $n$  次多项式  $l_j(x), j = 0, 1, \dots, n$  在  $n+1$  个节点  $x_0 < x_1 < \dots < x_n$  上满足条件

$$l_j(x_k) = \begin{cases} 1, & k = j \\ 0, & k \neq j \end{cases}, j, k = 0, 1, \dots, n$$

则称这  $n+1$  个  $n$  次多项式  $l_0(x), l_1(x), \dots, l_n(x)$  为节点  $x_0, x_1, \dots, x_n$  上的  $n$  次插值基函数.

利用其性质, 可以得到基函数形式为

$$l_k(x) = \frac{(x-x_0) \cdots (x-x_{k-1})(x-x_{k+1}) \cdots (x-x_n)}{(x_k-x_0) \cdots (x_k-x_{k-1})(x_k-x_{k+1}) \cdots (x_k-x_n)}, k = 0, 1, \dots, n \quad (2.4)$$

扩展: 下面将说明如何计算基函数的形式.

利用性质, 可知对于  $l_k(x), k = 0, 1, \dots, n$ , 当  $x \neq x_k$  时, 其函数值为 0. 则可以将其分解为若干因式  $(x-x_j), j = 0, 1, \dots, n$  且  $j \neq k$ , 即

$$l_k(x) = \lambda(x-x_0)(x-x_1) \cdots (x-x_{k-1})(x-x_{k+1}) \cdots (x-x_n), k = 0, 1, \dots, n$$

同时, 由于当  $x = x_k$  时,  $l_k(x_k) = 1$ , 可得待定系数  $\lambda$  为

$$\lambda = \frac{1}{(x_k-x_0)(x_k-x_1) \cdots (x_k-x_{k-1})(x_k-x_{k+1}) \cdots (x_k-x_n)}, k = 0, 1, \dots, n$$

代入并整理, 可得基函数的具体形式为

$$l_k(x) = \frac{(x-x_0) \cdots (x-x_{k-1})(x-x_{k+1}) \cdots (x-x_n)}{(x_k-x_0) \cdots (x_k-x_{k-1})(x_k-x_{k+1}) \cdots (x_k-x_n)}, k = 0, 1, \dots, n$$

上式因此得证.

下面将试着给出基于 Lagrange 多项式插值的一个程序代码, 仅供参考.

```
1  # 使用拉格朗日多项式插值法的实例 Exercise2-1.py
2  # 假设四个插值点分别为 (1,2), (2,3), (3,6), (4,7)
3  # 实际运行时这些数据可以自行修改, 从而观察插值的实际作用.
4
5  import numpy as np
6  import matplotlib.pyplot as plt
7
8  def lagrange_interpolation(x, points):
9      n = len(points)
10     result = 0.0
11     for i in range(n):
12         xi, yi = points[i]
13         term = yi
14         for j in range(n):
15             if i != j:
16                 xj, yj = points[j]
17                 term *= (x - xj) / (xi - xj)
18         result += term
19     return result
20
21 x = [1,2,3,4]
22 y = [2,3,6,7]
23 plt.scatter(x,y,color="red")
24 points = list(zip(x,y))
25 x = np.arange(1,5,0.01)
26 result = lagrange_interpolation(x, points)
27 plt.plot(x,result)
28 plt.show()
```

使用这段代码运行的结果如图 2.1所示.




图 2.1: Lagrange 多项式插值 (使用上述代码生成)

### 2.2.4 插值余项

使用  $L_n(x)$  近似表示  $f(x)$ , 则会引起截断误差. 其截断误差为  $R_n(x) = f(x) - L_n(x)$ . 通常会称  $R_n(x)$  为插值多项式的余项或简称为插值余项.

为估计插值余项, 有如下定理:

**定理 2.2.1.** 设  $f^{(n)}(x)$  在  $[a, b]$  上连续,  $f^{(n+1)}(x)$  在  $(a, b)$  存在, 节点  $a \leq x_0 < x_1 < \cdots < x_n \leq b$ ,  $L_n(x)$  是满足条件式 (2.3) 的插值多项式, 则对于任何  $x \in [a, b]$ , 插值余项

$$R_n(x) = f(x) - L_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^n (x - x_i) \quad (2.5)$$

其中,  $\xi \in (a, b)$  且依赖于  $x$

**证明.** 由插值条件可知,  $R_n(x)$  在节点  $x_k, k = 0, 1, \dots, n$  上为 0, 即可

以做因式分解

$$R_n(x) = K(x)(x - x_0)(x - x_1) \cdots (x - x_n) = K(x) \prod_{i=0}^n (x - x_i)$$

其中,  $K(x)$  是与  $x$  有关的待定系数.

把  $x$  视作区间  $[a, b]$  上的一个固定点, 作函数

$$\varphi(t) = f(t) - L_n(t) - K(t)(t - x_0)(t - x_1) \cdots (t - x_n)$$

因此,  $\varphi(t)$  在  $x_0, x_1, \dots, x_n$  和  $x$  处均为 0, 即在区间  $[a, b]$  上有  $n+2$  个零点. 根据 Roll 定理可知,  $\varphi'(t)$  在两个零点间至少有一个零点, 即在区间  $[a, b]$  上,  $\varphi'(t)$  至少有  $n+1$  个零点. 以此类推, 不难得出  $\varphi^{(n+1)}$  在区间  $(a, b)$  内至少有一个零点, 将其记为  $\xi \in (a, b)$ , 使得

$$\varphi^{(n+1)}(\xi) = f^{(n+1)}(\xi) - (n+1)!K(x) = 0$$

整理可得

$$K(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}, \xi \in (a, b)$$

将其代入上式, 可得余项表达式 (2.5)

□

通常,  $\xi$  无法具体确定, 从而实际操作中, 经常估计误差上限. 由

$$|f^{(n+1)}(x)| \leq M_{n+1}$$

对于任意的  $x \in (a, b)$ , 将

$$\frac{M_{n+1}}{(n+1)!} \prod_{i=0}^n |x - x_i|$$

作为误差估计上限. 通常取

$$M_{n+1} = \max_{a \leq x \leq b} |f^{(n+1)}(x)|$$

特别的, 若  $f(x)$  为任一次数小于等于  $n$  的多项式, 即  $f(x) \in H_n \in \text{span}\{1, x, x^2, \dots, x^n\}$ , 此时  $f^{(n+1)} \equiv 0$ , 即  $R_n(x) \equiv 0$ . 因此, 插值多项式对于次数小于等于  $n$  的多项式总是精确的.

**例 2.2.2.** 设有  $x_0 \neq x_1 \neq x_2 \neq x_3 \neq x_4$ , 且  $l_i(x), i = 0, 1, 2, 3, 4$  为 Lagrange 插值基函数. 求

$$\sum_{i=0}^4 (3x_i^4 + 4x_i^2 + 2x_i + 1) l_i(x)$$

解. 设函数  $f(x) = 3x^4 + 4x^2 + 2x + 1$ , 则

$$\text{原式} = \sum_{i=0}^4 f(x_i)l_i(x) = f(x)$$

□

例 2.2.3. 已知  $\sin \frac{\pi}{6} = \frac{1}{2}$ ,  $\sin \frac{\pi}{4} = \frac{\sqrt{2}}{2}$ ,  $\sin \frac{\pi}{3} = \frac{\sqrt{3}}{2}$ , 利用  $\sin x$  的一次, 二次 Lagrange 插值, 计算  $\sin 50^\circ$  并估计误差

解. 当  $n = 1$  时, 利用  $x_0, x_1$ , 有

$$\begin{aligned}\Rightarrow L_1(x) &= \frac{x - \frac{\pi}{4}}{\frac{\pi}{6} - \frac{\pi}{4}} \cdot \frac{1}{2} + \frac{x - \frac{\pi}{6}}{\frac{\pi}{4} - \frac{\pi}{6}} \cdot \frac{\sqrt{2}}{2} \\ \Rightarrow L_1\left(\frac{5}{18}\pi\right) &\approx 0.77614\end{aligned}$$

其误差

$$R_1(x) = \frac{f''(\xi)}{2!} \left| x - \frac{\pi}{6} \right| \left| x - \frac{\pi}{4} \right|$$

其中  $|\sin \xi| \leq \frac{\sqrt{2}}{2}$ , 因此有

$$\left| R_1\left(\frac{5}{18}\pi\right) \right| < 0.01319$$

类似地, 利用  $x_1, x_2$ , 可得  $L_1(x) \approx 0.76008$ , 估计误差, 由于  $|\sin \xi| \leq \frac{\sqrt{3}}{2}$

$$\left| R_1\left(\frac{5}{18}\pi\right) \right| < 0.00660$$

当  $n = 2$  时, 有

□

### 2.2.5 Lagrange 插值优缺点

优点: 具有严格的规律性, 便于记忆与理论推导;

缺点: 计算量大, 每次添加 (或删除) 节点都需要重新计算基函数, 不具有承袭性.

为解决上述缺点, 将引出新的插值法, 即 Newton 插值.



## 2.3 Newton 插值

### 2.3.1 Newton 插值

与 Lagrange 插值类似, 首先考虑  $n = 1$

**例 2.3.1.** 已知两个节点  $x_0, x_1$ , 其函数值分别为  $y_0, y_1$ , 试求一次多项式  $P_1(x) = A_0 + A_1x$ , 使得  $P_1(x_0) = y_0, P_1(x_1) = y_1$

**解.** 利用直线方程点斜式, 可知

$$P_1(x) = y_0 + \frac{y_1 - y_0}{x_1 - x_0}(x - x_0)$$

此时, 插值节点为  $x_0, x_1$ , 基函数设为  $1, (x - x_0)$ , 组合系数为  $A_0 = y_0, A_1 = \frac{y_1 - y_0}{x_1 - x_0}$  □

考虑  $n = 2$  的情况, 要求具有承袭性. 设  $g(x) = P_2(x) - P_1(x)$ , 则  $g(x)$  为次数不超过 2 的多项式, 且有

$$g(x_i) = P_2(x_i) - P_1(x_i) = y_i - y_i = 0, i = 0, 1$$

因此可对其进行因式分解, 有

$$g(x) = A_2(x - x_0)(x - x_1)$$

$$\Rightarrow P_2(x) = P_1(x) + A_2(x - x_0)(x - x_1)$$

故, 对于  $n = 2$  而言, 插值节点为  $x_0, x_1, x_2$ , 基函数为  $1, (x - x_0), (x - x_0)(x - x_1)$ , 组合系数为  $A_0, A_1, A_2$ . 插值多项式为

$$P_2(x) = A_0 + A_1(x - x_0) + A_2(x - x_0)(x - x_1)$$

类似地, 给定插值条件

$$N_n(x_i) = f(x_i), i = 0, 1, \dots, n$$

, 插值节点为  $x_i, i = 0, 1, \dots, n$ , 基函数为  $1, (x - x_0), (x - x_0)(x - x_1), \dots, (x - x_0)(x - x_1) \cdots (x - x_{n-1})$ , 组合系数为  $A_i, i = 0, 1, \dots, n$

下面需要讨论如何求解组合系数.

设  $A_n(x) = A_0 + A_1(x - x_0) + A_2(x - x_0)(x - x_1) + \cdots + A_n(x - x_0)(x - x_1) \cdots (x - x_{n-1})$ , 利用插值条件

$$N_n(x_i) = f(x_i), i = 0, 1, \dots, n$$

代入, 得线性方程组

$$\begin{pmatrix} 1 & 0 & \cdots & 0 \\ 1 & x_1 - x_0 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 1 & x_n - x_0 & \cdots & \prod_{i=0}^{n-1} (x_n - x_i) \end{pmatrix} \begin{pmatrix} A_0 \\ A_1 \\ \vdots \\ A_n \end{pmatrix} = \begin{pmatrix} f(x_0) \\ f(x_1) \\ \vdots \\ f(x_n) \end{pmatrix}$$

求解方程组, 可得

$$\begin{aligned} A_0 &= f(x_0) \\ A_1 &= \frac{f(x_1) - f(x_0)}{x_1 - x_0} \\ A_2 &= \frac{\frac{f(x_2) - f(x_0)}{x_2 - x_0} - \frac{f(x_1) - f(x_0)}{x_1 - x_0}}{x_2 - x_1} \\ &\vdots \end{aligned}$$

为简化计算, 总结上述规律, 给出下面关于差商的定义

### 2.3.2 差商

差商的定义

**定义 2.3.1** (差商). 称

$$f[x_0, x_k] = \frac{f(x_k) - f(x_0)}{x_k - x_0}$$

为函数  $f(x)$  关于点  $x_0, x_k$  的一阶差商, 称

$$f[x_0, x_1, x_k] = \frac{f[x_0, x_k] - f[x_0, x_1]}{x_k - x_1}$$

为  $f(x)$  关于点  $x_0, x_1, x_k$  的二阶差商. 一般地, 称

$$f[x_0, x_1, \dots, x_k] = \frac{f[x_0, x_1, \dots, x_{k-2}, x_k] - f[x_0, x_1, \dots, x_{k-1}]}{x_k - x_{k-1}}$$

为  $f(x)$  的  $k$  阶差商.

由差商定义可知: 高阶差商是两个低一阶差商的差商.

利用差商定义, 可知组合系数为:

$$\begin{aligned} A_0 &= f(x_0) = f[x_0] \\ A_1 &= f[x_0, x_1] \\ &\vdots \\ A_n &= f[x_0, x_1, \dots, x_n] \end{aligned}$$

$$\begin{aligned} \Rightarrow N_n(x) &= f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) \\ &\quad + \dots + f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \dots (x - x_{n-1}) \end{aligned}$$

### 差商性质

差商与函数值有如下关系:

**定理 2.3.1.** 记  $\omega(x) = (x - x_0)(x - x_1) \dots (x - x_n)$ , 则

$$f[x_0, x_1, \dots, x_n] = \sum_{i=0}^n \frac{f(x_i)}{\omega'(x_i)}$$

**证明.** 对于  $f(x)$ , 使用 Lagrange 插值法, 可得:

$$L_n(x) = \sum_{i=0}^n f(x_i) l_i(x)$$

使用 Newton 插值法, 可得:

$$N_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + \dots + f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \dots (x - x_{n-1}) \quad (2.6)$$

由于插值多项式具有唯一性, 因此两种插值方法得到的结果相同, 即同次系数相等. 整理可得

$$\sum_{i=0}^n f(x_i) = f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \dots (x - x_{n-1})$$

对  $\omega(x)$  求导后, 原式得证. □

差商的值与节点的排列顺序无关, 即差商具有对称性. 用公式表示为:

$$f[x_0, \dots, x_i, \dots, x_j, \dots, x_n] = f[x_0, \dots, x_j, \dots, x_i, \dots, x_n]$$

设  $f(x)$  在  $[a, b]$  有  $n$  阶导数, 且  $x_0, x_1, \dots, x_n \in [a, b]$ , 则存在  $\xi \in (a, b)$ , 使得

$$f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(\xi)}{n!}$$

**例 2.3.2.** 若  $f(x) = 3x^4 + 4x^2 + 2x + 1$ , 计算

$$f[2^0, 2^1, 2^2, 2^3, 2^4], f[2^0, 2^1, 2^2, 2^3, 2^4, 2^5]$$

解.

$$\begin{aligned} f[2^0, 2^1, 2^2, 2^3, 2^4] &= \frac{f^{(4)}(\xi)}{4!} = 3 \\ f[2^0, 2^1, 2^2, 2^3, 2^4, 2^5] &= \frac{f^{(5)}(\xi)}{5!} = 0 \end{aligned}$$

□

由前面的性质, 不难得到, 对于差商而言, 有

$$f[x_0, x_1, \dots, x_n] = \frac{f[x_1, x_2, \dots, x_n] - f[x_0, x_1, \dots, x_{n-1}]}{x_n - x_0}$$

该性质表明在实际计算差商过程中, 可以使用列表法计算.

### 2.3.3 Newton 插值余项

**定理 2.3.2.** *Newton* 插值多项式的余项为:

$$R_n(x) = f[x_0, x_1, \dots, x_n] \omega_{n+1}(x)$$

其中,

$$\omega_{n+1}(x) = (x - x_0)(x - x_1) \cdots (x - x_n) = \prod_{i=0}^n (x - x_i)$$

## 2.4 等距节点差商公式

### 2.4.1 差分定义

**定义 2.4.1** (差分). 设函数  $y = f(x)$  在等距节点  $x_k = x_0 + kh$  ( $k = 0, 1, \dots, n$ ) 上的值  $f_k = f(x_k)$  已知, 其中  $h$  为常数, 称为步长, 称偏差

$$\begin{aligned}\Delta f_k &= f_{k+1} - f_k \\ \nabla f_k &= f_k - f_{k-1} \\ \delta f_k &= f(x_k + h/2) - f(x_k - h/2) = f_{k+\frac{1}{2}} - f_{k-\frac{1}{2}}\end{aligned}$$

分别称为  $f(x)$  在  $x_k$  处以  $h$  为步长的向前差分, 向后差分, 中心差分. 符号  $\Delta, \nabla, \delta$  分别称为向前差分算子, 向后差分算子, 中心差分算子.

利用一阶差分, 类似可定义二阶差分为

$$\Delta^2 f_k = \Delta f_{k+1} - \Delta f_k = f_{k+2} - 2f_{k+1} + f_k$$

, 一般地,  $m$  阶差分为

$$\Delta^m f_k = \Delta^{m-1} f_{k+1} - \Delta^{m-1} f_k$$

### 2.4.2 差分的性质

定义不变算子  $I$  和移位算子  $E$ , 即有

$$If_k = f_k, Ef_k = f_{k+1}$$

由差分定义, 可得  $\Delta = E - I, \nabla = I - E^{-1}, \delta = E^{\frac{1}{2}} - E^{-\frac{1}{2}}$

由不变算子和移位算子, 可得如下性质:

各阶差分均可用函数值表示, 即

$$\begin{aligned}\Delta^n f_k &= (E - I)^n f_k = \sum_{j=0}^n (-1)^j \binom{n}{j} E^{n-j} f_k = \sum_{j=0}^n (-1)^j \binom{n}{j} f_{k+n-j} \\ \nabla^n f_k &= (1 - E^{-1})^n f_k = \sum_{j=0}^n (-1)^{n-j} \binom{n}{j} E^{j-n} f_k = \sum_{j=0}^n (-1)^{n-j} \binom{n}{j} f_{k+j-n}\end{aligned}$$

其中  $\binom{n}{j} = \frac{n(n-1)\cdots(n-j+1)}{j!}$  为二项式展开系数

差商与差分之间满足下面的关系. 例如, 对于向前差分, 由定义

$$\begin{aligned} f[x_k, x_{k+1}] &= \frac{f_{k+1} - f_k}{x_{k+1} - x_k} = \frac{\Delta f_k}{h} \\ f[x_k, x_{k+1}, x_{k+2}] &= \frac{f[x_{k+1}, x_{k+2}] - f[x_k, x_{k+1}]}{x_{k+2} - x_k} = \frac{1}{2h^2} \Delta^2 f_k \end{aligned}$$

一般有

$$f[x_k, x_{k+1}, \dots, x_{k+m}] = \frac{1}{m!} \frac{1}{h^m} \Delta^m f_k, m = 1, 2, \dots, n \quad (2.7)$$

同理, 对于向后差分, 有

$$f[x_k, x_{k-1}, \dots, x_{k-m}] = \frac{1}{m!} \frac{1}{h^m} \nabla^m f_k \quad (2.8)$$

利用差商的导数关系, 可得差分与导数的关系为

$$\Delta^n f_k = j^n f^{(n)}(\xi)$$

### 2.4.3 等距节点插值公式

利用 Newton 插值公式, 将差商用相应的差分替代, 即可得到等距节点插值公式.

若节点  $x_k = x_0 + kh, k = 0, 1, \dots, n$ , 要计算  $x_0$  附近点  $x$  的函数  $f(x)$  的值, 令  $x = x_0 + th$ , 其中  $0 \leq t \leq 1$ , 于是有

$$\omega_{k+1}(x) = \prod_{j=0}^k (x - x_j) = t(t-1) \cdots (t-k) h^{k+1}$$

将该式与式 (2.7) 代入公式 (2.6), 可得

$$N_n(x_0 + th) = f_0 + t\Delta f_0 + \frac{t(t-1)}{2!} \Delta^2 f_0 + \cdots + \frac{t(t-1) \cdots (t-n+1)}{n!} \Delta^n f_0$$

上式称为 Newton 前插公式. 同时, 由于其使用  $x_0$  附近的点, 故又称为表初公式.

不难得到, 上式的余项可由式 (2.5) 得到

$$R_n(x) = \frac{t(t-1) \cdots (t-n)}{(n+1)!} h^{n+1} f^{(n+1)}(\xi), \xi \in (x_0, x_n)$$

类似地, 若要计算  $x_n$  附近的值  $f(x)$ , 则可将 Newton 插值公式 (??) 按照倒序排列, 即  $x_n, x_{n-1}, \dots, x_0$  的次序. 此时有

$$N_n(x) = f(x_n) + f[x_n, x_{n-1}](x - x_n) + f[x_n, x_{n-1}, x_{n-2}](x - x_n)(x - x_{n-1}) \\ + \cdots + f[x_n, x_{n-1}, \cdots, x_0](x - x_n) \cdots (x - x_1)$$

变换  $x = x_n - th$  ( $-1 \leq t \leq 0$ ), 并利用公式 (2.8), 代入可得

$$N_n(x_n + th) = f_n + t\nabla f_n + \frac{t(t+1)}{2!}\nabla^2 f_n + \cdots + \frac{t(t+1)\cdots(t+n-1)}{n!}\nabla^n f_n$$

上式称为 *Newton* 后插公式或表末公式. 其余项为

$$R_n(x) = f(x) - N_n(x_n + th) = \frac{t(t+1)\cdots(t+n)h^{n+1}f^{(n+1)}(\xi)}{(n+1)!}, \xi \in (x_0, x_n)$$

## 2.5 Hermite 插值

### 2.5.1 引入, Hermite 插值多项式的存在唯一性

在有些情况下, 不仅要求节点上函数值相等, 同时要求节点上导数值相等, 甚至要求高阶导数值相等. 满足该要求的插值多项式就是 *Hermite* 插值多项式.

仅讨论函数值与导数值个数相等情况. 设在节点  $a \leq x_0 < x_1 < \cdots < x_n \leq b$  上,  $y_i = f(x_i)$ ,  $m_i = f'(x_i)$  ( $i = 0, 1, \cdots, n$ ), 要求插值多项式  $H(x)$  满足条件

$$H(x_i) = y_i, H'(x_i) = m_i, (i = 0, 1, \cdots, n)$$

给出  $(2n+2)$  个条件, 可唯一确定一个次数不超过  $2n+1$  的多项式  $H_{2n+1}$ , 其形式为

$$H_{2n+1}(x) = a_0 + a_1x + \cdots + a_{2n+1}x^{2n+1}$$

### 2.5.2 Hermite 插值多项式构造

#### Lagrange 型 Hermite 插值多项式

先求插值基函数  $\alpha_i(x)$  和  $\beta_i(x)$ ,  $i = 0, 1, \cdots, n$ , 共有  $2n+2$  个, 每一个都是  $2n+1$  次多项式, 且满足条件:

$$\begin{cases} \alpha_i(x_k) = \delta_{ik} = \begin{cases} 0, j \neq k, \\ 1, j = k, \end{cases} & , \alpha'_i(x_k) = 0 \\ \beta_i(x_k) = 0, \beta'_i(x_k) = \delta_{ik} \end{cases}$$

因此, 满足插值条件的插值多项式  $H(x) = H_{2n+1}(x)$  可用插值基函数表示为

$$H_{2n+1}(x) = \sum_{i=0}^n [y_i \alpha_i(x) + m_i \beta_i(x)]$$

显然有

$$H_{2n+1}(x_k) = y_k, H'_{2n+1}(x_k) = m_k, k = 0, 1, \dots, n$$

为构造基函数, 使用 Lagrange 插值基函数  $l_i(x)$ , 令

$$\alpha_i(x) = (ax + b)l_i^2(x)$$

其中  $l_i(x)$  是式 (??) 所表示的基函数. 由上述条件, 有

$$\alpha_i(x_i) = (ax_i + b)l_i^2(x_i) = 1,$$

$$\alpha'_i(x_i) = l_i(x_i) [al_i(x_i) + 2(ax_i + b)l'_i(x_i)] = 0$$

整理可得

$$\begin{cases} ax_i + b = 1 \\ a + 2l'_i(x_i) = 0 \end{cases}$$

解得

$$a = -2l'_i(x_i), b = 1 + 2x_i l'_i(x_i)$$

由于

$$l_i(x) = \frac{(x - x_0) \cdots (x - x_{i-1})(x - x_{i+1}) \cdots (x - x_n)}{(x_i - x_0) \cdots (x_i - x_{i-1})(x_i - x_{i+1}) \cdots (x_i - x_n)}$$

取对数后求导, 得

$$l'_i(x_i) = \sum_{\substack{k=0 \\ k \neq i}}^n \frac{1}{x_i - x_k}$$

于是可得

$$\alpha_i(x) = \left[ 1 - 2(x - x_i) \sum_{\substack{k=0 \\ k \neq i}}^n \frac{1}{x_i - x_k} \right] l_i^2(x) \quad (2.9)$$

同理可得

$$\beta_i(x) = (x - x_i)l_i^2(x) \quad (2.10)$$

扩展: 下面证明满足插值条件得插值多项式是唯一的.



证明. 使用反证法, 设  $H_{2n+1}(x)$  和  $\overline{H}_{2n+1}(x)$  均满足条件, 则有

$$\varphi(x) = H_{2n+1}(x) - \overline{H}_{2n+1}(x)$$

其在每个节点上均有二重根, 故  $\varphi(x)$  有  $2n+2$  重根, 但  $\varphi(x)$  是不高于  $2n+1$  次的多项式, 故  $\varphi \equiv 0$ .

唯一性得证.  $\square$

利用 Lagrange 插值余项证明方法, 可得若  $f(x)$  在  $(a, b)$  内的  $2n+2$  阶导数存在, 则插值余项为

$$R(x) = f(x) - H_{2n+1}(x) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \omega_{n+1}^2(x) \quad (2.11)$$

其中  $\xi \in (a, b)$  且与  $x$  有关.

考虑特殊情况  $n = 1$ , 取节点为  $x_k, x_{k+1}$ , 插值多项式为  $H_3(x)$ , 满足条件

$$\begin{cases} H_3(x_k) = y_k, H_3(x_{k+1}) = y_{k+1} \\ H'_3(x_k) = m_k, H'_3(x_{k+1}) = m_{k+1} \end{cases} \quad (2.12)$$

相应的插值基函数为  $\alpha_k(x), \alpha_{k+1}(x), \beta_k(x), \beta_{k+1}(x)$ , 且满足条件

$$\begin{aligned} \alpha_k(x_k) &= 1, \alpha_k(x_{k+1}) = 0, \alpha'_k(x_k) = \alpha'_k(x_{k+1}) = 0, \\ \alpha_{k+1}(x_k) &= 0, \alpha_{k+1}(x_{k+1}) = 1, \\ \alpha'_{k+1}(x_k) &= \alpha'_{k+1}(x_{k+1}) = 0, \\ \beta_k(x_k) &= \beta_k(x_{k+1}) = 0, \\ \beta'_k(x_k) &= 1, \beta'_k(x_{k+1}) = 0, \\ \beta_{k+1}(x_k) &= \beta_{k+1}(x_{k+1}) = 0, \\ \beta'_{k+1}(x_k) &= 0, \beta'_{k+1}(x_{k+1}) = 1 \end{aligned}$$

根据式 (2.9) 和 (2.10), 可得

$$\begin{cases} \alpha_k(x) = \left(1 + 2 \frac{x-x_k}{x_{k+1}-x_k}\right) \left(\frac{x-x_{k+1}}{x_k-x_{k+1}}\right)^2, \\ \alpha_{k+1}(x) = \left(1 + 2 \frac{x-x_{k+1}}{x_k-x_{k+1}}\right) \left(\frac{x-x_k}{x_{k+1}-x_k}\right)^2; \\ \beta_k(x) = (x-x_k) \left(\frac{x-x_{k+1}}{x_k-x_{k+1}}\right)^2, \\ \beta_{k+1}(x) = (x-x_{k+1}) \left(\frac{x-x_k}{x_{k+1}-x_k}\right)^2 \end{cases}$$

满足式 (2.12) 的插值多项式是

$$H_3(x) = y_k \alpha_k(x) + y_{k+1} \alpha_{k+1}(x) + m_k \beta_k(x) + m_{k+1} \beta_{k+1}(x)$$

由式 (2.11) 可得其余项为

$$R_3(x) = \frac{1}{4!} f^{(4)}(\xi)(x - x_k)^2(x - x_{k+1})^2$$

### Newton 型 Hermite 插值多项式

若给定插值条件

$$H(x_0) = f(x_0), H'(x_0) = f'(x_0), \dots, H^{(m)}(x_0) = f^{(m)}(x_0)$$

利用 Newton 插值法, 其节点为  $x_0, x_0, \dots, x_0$ , 基函数分别为  $1, (x - x_0), (x - x_0)^2, \dots, (x - x_0)^m$ , 组合系数为  $f(x_0), f[x_0, x_0], \dots, f[x_0, x_0, \dots, x_0]$  考虑差商与导数的性质, 有

$$f[x_0, x_0, \dots, x_0] = \frac{f^{(n)}}{n!}$$

故容易得到, Newton 型 Hermite 插值多项式为

$$H(x) = f(x_0) + f'(x_0)(x - x_0) + \dots + \frac{f^{(m)}}{m!}(x - x_0)^m$$

**例 2.5.1.** 给定函数表 求插值多项式  $P_4(x)$

$x_i$	3	4	6
$y_i$	6	0	2
$y'_i$	1		-1

**解.** 利用 Newton 法, 列差商表如下所示 将差商表计算可得

$$P_4 = 6 + 1(x-3) + (-7)(x-3)^2 + \frac{28}{9}(x-3)^2(x-4) + \left(-\frac{38}{27}\right)(x-3)^2(x-4)(x-6)$$

其插值余项为

$$R_4(x) = f[3, 3, 4, 6, 6, x](x-3)^2(x-4)(x-6)^2$$

□

表 2.1: 差商表

$x_k$	$f(x_k)$	一阶差商	二阶差商	三阶差商	四阶差商
3	6				
3	6	$f[3, 3] = 1$			
4	0	$f[3, 4]$	$f[3, 3, 4]$		
6	2	$f[4, 6]$	$f[3, 4, 6]$	$f[3, 3, 4, 6]$	
6	2	$f[6, 6] = -1$	$f[4, 6, 6]$	$f[3, 4, 6, 6]$	$f[3, 3, 4, 6, 6]$

## 2.6 分段低次插值

### 2.6.1 多项式插值的 Runge 现象

例 2.6.1. 在  $[-5, 5]$  考察函数

$$f(x) = \frac{1}{1+x^2}$$

的  $L_n(x)$

使用下面的代码:

```

1  # Runge现象演示 Exercise2-3.py
2
3  import numpy as np
4  import matplotlib.pyplot as plt
5  from scipy.interpolate import lagrange
6
7  # 定义函数
8  def f(x):
9      return 1 / (1 + x ** 2)
10
11 # 生成插值节点
12 n = 11
13 x = np.linspace(-5, 5, n)
14 y = f(x)
15
16 # 生成插值多项式

```

```

17 poly = lagrange(x, y)
18
19 # 生成等距节点
20 x_interp = np.linspace(-5, 5, 1000)
21 y_interp = f(x_interp)
22
23 # 生成插值函数
24 y_poly = poly(x_interp)
25
26 # 绘图
27 plt.plot(x_interp, y_interp)
28 plt.plot(x_interp, y_poly)
29 plt.plot(x, y, 'o')
30 plt.show()

```

生成图像如图 (2.2) 所示

可以看到, 随着节点的增多, 插值多项式在节点处出现振荡. 这就是多项式插值的 *Runge* 现象. 为解决这一问题, 采用分段插值的方法.

### 2.6.2 分段线性插值

在每个区间  $[x_i, x_{i+1}]$  上, 用一阶多项式逼近  $f(x)$ , 即

$$f(x) = P_1(x) = \frac{x - x_{i+1}}{x_i - x_{i+1}}y_i + \frac{x - x_i}{x_{i+1} - x_i}y_{i+1}, x \in [x_i, x_{i+1}]$$

若用插值基函数表示, 若整个节点在  $[a, b]$  之间, 则在整个区间的  $P_1(x)$  可以表示为

$$P_1(x) = \sum_{i=0}^n y_i l_i(x)$$

其中  $l_i(x)$  满足条件  $l_i(x_k) = \delta_{ik}, i, k = 0, 1, \dots, n$ , 其形式为

$$l_i(x) = \begin{cases} \frac{x - x_{i-1}}{x_i - x_{i-1}}, & x_{i-1} \leq x \leq x_i (i=0 \text{ 略去}), \\ \frac{x_i - x_{i+1}}{x - x_{i+1}}, & x_i \leq x \leq x_{i+1} (i=n \text{ 略去}), \\ 0, & x \in [a, b], x \notin [x_{i-1}, x_{i+1}]. \end{cases}$$




图 2.2: Runge 现象

不难发现, 基函数  $l_i(x)$  在  $x_i$  附近不为 0, 其他地方均为零, 这种性质称为局部非零性质.

关于分段线性插值的误差估计, 给出如下定理 (暂不做证明)

**定理 2.6.1.** 若  $f(x)$  在  $[a, b]$  上二阶连续可微, 则分段线性插值  $P(x)$  余项有如下估计:

$$|R(x)| = |f(x) - P(x)| \leq \frac{h^2}{8} M$$

其中,

$$h = \max_{0 \leq i \leq n-1} (x_{i+1} - x_i)$$

$$M = \max_{a \leq x \leq b} |f''(x)|$$


下面的程序, 演示了分段线性插值 (图像如图 2.3所示). 可以看到, 分段线性插值在节点处不光滑. 为了改善该问题, 我们可以借助于 Hermite 插值, 即下面的分段三次 Hermite 插值.

```
1  # 分段线性插值演示 Exercise2-4.py
2
3  import numpy as np
4  import matplotlib.pyplot as plt
5
6  # 定义函数
7  def f(x):
8      return np.sin(x)
9
10 # 生成插值节点
11 n = 6
12 x = np.linspace(0, 2*np.pi, n)
13 y = f(x)
14
15 # 生成分段线性插值函数
16 x_interp = np.linspace(0, 2*np.pi, 1000)
17 y_interp = np.zeros_like(x_interp)
18 for i in range(len(x_interp)):
19     if x_interp[i] <= x[0]:
20         y_interp[i] = y[0]
21     elif x_interp[i] >= x[-1]:
22         y_interp[i] = y[-1]
23     else:
24         j = np.searchsorted(x, x_interp[i])
25         x_left = x[j-1]
26         x_right = x[j]
27         y_left = y[j-1]
28         y_right = y[j]
29         slope = (y_right - y_left) / (x_right - x_left)
30         y_interp[i] = y_left + slope * (x_interp[i] - x_left)
31
32 # 绘图
33 plt.plot(x_interp, f(x_interp))
```

```

34 plt.plot(x_interp, y_interp)
35 plt.plot(x, y, 'o')
36 plt.show()

```

图 2.3:  $\sin x$  的分段线性插值

### 2.6.3 分段三次 Hermite 插值

给定节点  $a \leq x_0 < x_1 < \cdots \leq b$ ,  $f(x)$  在节点  $x_i$  上的函数值及导数值分别为  $y_i, m_i$ . 在每个子区间  $[x_i, x_{i+1}]$  上作两点三次 Hermite 插值, 插值函数为

$$H(x) = \sum_{i=0}^n [y_i \varphi_i(x) + m_i \psi_i(x)] \quad (2.13)$$

其中基函数为

$$\varphi_i(x) = \begin{cases} \left(\frac{x-x_{i-1}}{x_i-x_{i-1}}\right)^2 \left(1 + 2\frac{x-x_i}{x_{i-1}-x_i}\right), & x_{i-1} \leq x \leq x_i, \\ \left(\frac{x-x_{i+1}}{x_i-x_{i+1}}\right)^2 \left(1 + 2\frac{x-x_i}{x_{i+1}-x_i}\right), & x_i \leq x \leq x_{i+1}, \\ 0, & x \notin [x_{i-1}, x_{i+1}] \end{cases}, (i = 1, 2, \dots, n-1).$$

$$\psi_i(x) = \begin{cases} (x-x_i) \left(\frac{x-x_{i-1}}{x_i-x_{i-1}}\right)^2, & x_{i-1} \leq x \leq x_i, \\ (x-x_i) \left(\frac{x-x_{i+1}}{x_i-x_{i+1}}\right)^2, & x_i \leq x \leq x_{i+1}, \\ 0, & x \notin [x_{i-1}, x_{i+1}] \end{cases}$$

由三次 Hermite 插值的余项可以估计分段 Hermite 插值的余项. 设  $H(x)$  是给定节点

$$a = x_0 < x_1 < \dots < x_n = b$$

上的分段三次 Hermite 插值函数,  $f(x) \in C^4[a, b]$ , 则  $f(x)$  与  $H(x)$  的误差限为

$$|R(x)| \leq |f(x) - H(x)| \leq \frac{h^4}{384} M_4$$

其中,

$$h = \max_{0 \leq i \leq n-1} |x_{i+1} - x_i|,$$

$$M = \max_{a \leq x \leq b} |f^{(4)}(x)|$$

下面的代码演示了分段三次 Hermite 插值, 并绘制了图 2.4. 可以看到, 与线性插值 (图 2.3) 相比, 三次 Hermite 插值具有光滑性.

扩展: 在该代码中使用了 *Python* 的库函数 *PchipInterpolator()*, 这个函数会在内部自动计算导数值, 因此与前面所讨论的理论在形式上可能有些许不同.

```

1 # 分段三次Hermite插值演示 Exercise2-5.py
2
3 import numpy as np
4 import matplotlib.pyplot as plt
5 from scipy.interpolate import PchipInterpolator
6
7 # 定义函数

```



```
8 def f(x):
9     return np.sin(x)
10
11 # 生成插值节点
12 n = 5
13 x = np.linspace(0, 2*np.pi, n)
14 y = f(x)
15
16 # 生成分段三次Hermite插值函数
17 x_interp = np.linspace(0, 2*np.pi, 1000)
18 y_interp = PchipInterpolator(x, y)(x_interp)
19
20 # 绘图
21 plt.plot(x_interp, f(x_interp))
22 plt.plot(x_interp, y_interp)
23 plt.plot(x, y, 'o')
24 plt.show()
```

## 2.7 三次样条插值


### 2.7.1 三次样条函数

设对  $y = f(x)$  在区间  $[a, b]$  上给定一组节点  $a = x_0 < x_1 < \cdots < x_n = b$  和相应的函数值  $y_0, y_1, \cdots, y_n$ , 如果  $s(x)$  具有如下性质:

1. 在每个子区间  $[x_{i-1}, x_i], i = 1, 2, \cdots, n$  上  $s(x)$  是不高于三次的多项式;
2.  $s(x), s'(x), s''(x)$  在  $[a, b]$  上连续, 则称  $s(x)$  是三次样条函数. 若再有
3.  $s(x_i) = f(x_i), i = 0, 1, \cdots, n$ , 则称  $s(x)$  为  $y = f(x)$  的三次样条插值函数.

### 2.7.2 三次样条插值函数构造

首先对三次样条插值的存在性进行证明

图 2.4:  $\sin x$  的三次 Hermite 插值

**证明.** 设有  $n$  个区间, 对于每个区间  $S_i$ , 插值函数为

$$S_i(x) = a_i + b_i x + c_i x^2 + d_i x^3, i = 0, 1, \dots, n-1$$

对于每一个小区间, 两个端点给定, 总区间共有  $2n$  个条件.

对于节点  $x_i$ , 其一阶导数连续, 即

$$S'_{i-1}(x_i) = S'_i(x_i)$$

共  $(n-1)$  个条件.

同理, 其二阶导数连续, 有  $(n-1)$  个条件.

因此, 给定条件共  $(4n-2)$  个, 小于  $4n$ , 因此解存在但不唯一.  $\square$

为保证解的唯一性, 需要补充边界条件. 常见的边界条件有如下四种:

固支边界条件 (D-1 样条):

$$\begin{cases} S'(x_0) = f'(x_0) = m_0 \\ S'(x_n) = f'(x_n) = m_n \end{cases}$$

弯矩边界条件 (D-2 样条):

$$\begin{cases} S'''(x_0) = f''(x_0) = M_0 \\ S'''(x_n) = f''(x_n) = M_n \end{cases}$$

自然边界条件 (自然样条):

$$\begin{cases} S''(x_0) = 0 \\ S''(x_n) = 0 \end{cases}$$

周期边界条件 (周期样条):

$$\begin{cases} S(x_0) = S(x_n) \\ S'(x_0) = S'(x_n) \\ S''(x_0) = S''(x_n) \end{cases}$$

### 2.7.3 三转角方程

假定  $S'(x)$  在节点  $x_i$  的值为  $S'(x_i) = m_i, i = 0, 1, \dots, n$ , 由式 (2.13) 可得

$$S(x) = \sum_{i=0}^n [y_i \varphi_i(x) + m_i \psi_i(x)]$$

显然, 该表达式在  $[a, b]$  区间连续, 且满足插值条件. 而式中的导数值  $m_i$  未知, 因此可利用导数的连续条件:

$$S''(x_i - 0) = S''(x_i + 0), i = 1, 2, \dots, n-1$$

以及边界条件确定.

下面考虑  $S(x)$  在  $[x_i, x_{i+1}]$  的表达式

$$\begin{aligned} S(x) = & \frac{(x - x_{i+1})^2 [h_i + 2(x - x_i)]}{h_i^3} y_i + \frac{(x - x_i)^2 [h_i + 2(x_{i+1} - x)]}{h_i^3} y_{i+1} \\ & + \frac{(x - x_{i+1})^2 (x - x_i)}{h_i^2} m_i + \frac{(x - x_i)^2 (x - x_{i+1})}{h_i^2} m_{i+1} \end{aligned}$$

这里  $h_i = x_{i+1} - x_i$ , 对  $S(x)$  求二阶导数, 得

$$\begin{aligned} S''(x) = & \frac{6x - 2x_i - 4x_{i+1}}{h_i^2} m_i + \frac{6x - 4x_i - 2x_{i+1}}{h_i^2} m_{i+1} \\ & + \frac{6(x_i + x_{i+1} - 2x)}{h_i^3} (y_{i+1} - y_i) \end{aligned}$$

于是

$$S''(x_i + 0) = -\frac{4}{h_i}m_i - \frac{2}{h_i}m_{i+1} + \frac{6}{h_i^2}(y_{i+1} - y_i)$$

同理, 可得  $S''(x)$  在区间  $[x_{i-1}, x_i]$  得表达式为

$$\begin{aligned} S''(x) &= \frac{6x - 2x_{i-1} - 4x_i}{h_{i-1}^2}m_{i-1} + \frac{6x - 4x_{i-1} - 2x_i}{h_{i-1}^2}m_i \\ &\quad + \frac{6(x_{i-1} + x_i - 2x)}{h_{i-1}^2}(y_i - y_{i-1}) \end{aligned}$$

及

$$S''(x_i - 0) = \frac{2}{h_{i-1}}m_{i-1} + \frac{4}{h_{i-1}}m_i - \frac{6}{h_{i-1}^2}(y_i - y_{i-1})$$

利用二阶导数连续性, 化简可得结果为

$$\lambda_i m_{i-1} + 2m_i + \mu_i m_{i+1} = g_i, i = 1, 2, \dots, n-1 \quad (2.14)$$

其中,

$$\begin{aligned} \lambda_i &= \frac{h_i}{h_{i-1} + h_i}, \mu_i = \frac{h_{i-1}}{h_{i-1} + h_i} \\ g_i &= 3(\lambda_i f[x_{i-1}, x_i] + \mu_i f[x_i, x_{i+1}]) \end{aligned}$$

方程是关于未知数  $m_0, m_1, \dots, m_n$  的  $n-1$  个方程, 若加上固支边界条件  $m_0 = f'_0, m_n = f'_n$ , 则方程为含有  $m_1, \dots, m_{n-1}$  的  $(n-1)$  个方程, 使用矩阵形式可表示为

$$\begin{pmatrix} 2 & \mu_1 & 0 & \cdots & \cdots & 0 \\ \lambda_2 & 2 & \mu_2 & \ddots & & \vdots \\ 0 & \lambda_3 & 2 & \mu_3 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \ddots & 0 \\ 0 & & \ddots & \lambda_{n-2} & 2 & \mu_{n-2} \\ 0 & \cdots & \cdots & 0 & \lambda_{n-1} & 2 \end{pmatrix} \begin{pmatrix} m_1 \\ m_2 \\ m_3 \\ \vdots \\ m_{n-2} \\ m_{n-1} \end{pmatrix} = \begin{pmatrix} g_1 - \lambda_1 f'_0 \\ g_2 \\ \vdots \\ g_{n-2} \\ g_{n-1} - \mu_{n-1} f'_n \end{pmatrix}$$

如果边界条件为弯矩边界条件 (或特殊情况下的自然边界条件), 则方程

组为

$$\begin{pmatrix} 2 & 1 & 0 & \cdots & \cdots & 0 \\ \lambda_1 & 2 & \mu_1 & \ddots & & \vdots \\ 0 & \lambda_2 & 2 & \mu_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \ddots & 0 \\ \vdots & & \ddots & \lambda_{n-1} & 2 & \mu_{n-1} \\ 0 & \cdots & \cdots & 0 & 1 & 2 \end{pmatrix} \begin{pmatrix} m_0 \\ m_1 \\ m_2 \\ \vdots \\ m_{n-1} \\ m_n \end{pmatrix} = \begin{pmatrix} g_0 \\ g_1 \\ g_2 \\ \vdots \\ g_{n-1} \\ g_n \end{pmatrix}$$

若采用周期性边界条件, 则

$$m_0 = m_n$$

从而整理得方程组为

$$\begin{pmatrix} 2 & \mu_1 & 0 & \cdots & 0 \\ \lambda_2 & 2 & \mu_2 & \ddots & \vdots \\ 0 & \lambda_3 & \ddots & \ddots & 0 \\ \vdots & \ddots & \ddots & 2 & \mu_{n-1} \\ 0 & \cdots & 0 & \lambda_n & 2 \end{pmatrix} \begin{pmatrix} m_1 \\ m_2 \\ \vdots \\ m_{n-1} \\ m_n \end{pmatrix} = \begin{pmatrix} g_1 \\ g_2 \\ \vdots \\ g_{n-1} \\ g_n \end{pmatrix}$$

上述方程组当中, 每个方程都联系三个  $m_i$ , 故称为三转角方程. 同时, 三个方程组的系数矩阵都为严格对角占优矩阵, 故方程有唯一解.

扩展:

**定义 2.7.1** (严格对角占优矩阵). 若方阵  $A = (a_{ij}) \in R^{n \times n}$ , 满足

$$|a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|, i = 1, 2, \cdots, n$$

称  $A$  为严格对角占优矩阵

#### 2.7.4 三弯矩方程

设函数  $f(x)$  是定义在区间  $[a, b]$  上的一个二次连续可微函数, 节点  $a = x_0 < x_1 < \cdots < x_n = b$ , 令

$$M_i = S''(x_i), i = 0, 1, \cdots, n$$

其中  $S(x)$  在每一个小区间  $[x_i, x_{i+1}]$ ,  $i = 0, 1, \dots, n-1$  上都是三次多项式, 故  $S''(x)$  在  $[x_i, x_{i+1}]$  的表达式为:

$$S''_i(x) = M_i \frac{x_{i+1} - x}{h_{i+1}} + M_{i+1} \frac{x - x_i}{h_{i+1}}$$

其中,  $h_{i+1} = x_{i+1} - x_i$ , 将上式做两次积分, 得

$$\begin{aligned} S'_i(x) &= -M_i \frac{(x_{i+1} - x)^2}{2h_{i+1}} + M_{i+1} \frac{(x - x_i)^2}{2h_{i+1}} + A_i \\ S_i(x) &= M_i \frac{(x_{i+1} - x)^3}{6h_{i+1}} + M_{i+1} \frac{(x - x_i)^3}{6h_{i+1}} + A_i(x - x_{i+1}) + B_i \end{aligned}$$

其中,  $A_i, B_i$  为积分常数. 由插值条件并整理可得

$$\begin{cases} A_i = \frac{y_{i+1} - y_i}{h_{i+1}} - \frac{h_{i+1}}{6}(M_{i+1} - M_i) \\ B_i = y_{i+1} - \frac{M_{i+1}}{6}h_{i+1}^2 \end{cases}$$

将其代入, 可得

$$\begin{aligned} S_i(x) &= M_i \frac{(x_{i+1} - x)^3}{6h_{i+1}} + M_{i+1} \frac{(x - x_i)^3}{6h_{i+1}} \\ &\quad + \left( y_i - \frac{M_i}{6}h_{i+1}^2 \right) \frac{x_{i+1} - x}{h_{i+1}} + \left( y_{i+1} - \frac{M_{i+1}}{6}h_{i+1}^2 \right) \frac{x - x_i}{h_{i+1}}, i = 0, 1, \dots, n-1 \end{aligned}$$

对上式进行微分, 有

$$\begin{aligned} S'_i(x) &= -M_i \frac{(x_{i+1} - x)^2}{2h_{i+1}} + M_{i+1} \frac{(x - x_i)^2}{2h_{i+1}} + \frac{y_{i+1} - y_i}{h_{i+1}} - \frac{h_{i+1}}{6}(M_{i+1} - M_i) \\ S'_{i-1}(x) &= -M_{i-1} \frac{(x_i - x)^2}{2h_i} + M_i \frac{(x - x_{i-1})^2}{2h_i} + \frac{y_i - y_{i-1}}{h_i} - \frac{h_i}{6}(M_i - M_{i-1}) \\ i &= 1, 2, \dots, n-1 \end{aligned}$$

因此有

$$\begin{aligned} S'_{i-1}(x_i) &= \frac{h_i}{3}M_i + \frac{y_i - y_{i-1}}{h_i} + \frac{h_i}{6}M_{i-1} \\ S'_i(x_i) &= \frac{h_{i+1}}{3}M_i + \frac{y_{i+1} - y_i}{h_{i+1}} + \frac{h_{i+1}}{6}M_{i+1} \end{aligned}$$

由于  $S'_{i-1}(x_i) = S'_i(x_i)$ , 从而有

$$h_i M_{i-1} + 2(h_i + h_{i+1})M_i + h_{i+1}M_{i+1} = 6 \left( \frac{y_{i+1} - y_i}{h_{i+1}} - \frac{y_i - y_{i-1}}{h_i} \right), i = 1, 2, \dots, n-1$$

记

$$\begin{aligned}\mu_i &= \frac{h_{i+1}}{h_i + h_{i+1}} \\ \lambda_i &= 1 - \mu_i \\ d_i &= 6 \left[ \frac{y_{i+1} - y_i}{h_{i+1}} - \frac{y_i - y_{i-1}}{h_i} \right] / (h_i + h_{i+1}) = 6f[x_{i-1}, x_i, x_{i+1}]\end{aligned}$$

可将上式改写为

$$\lambda_i M_{i-1} + 2M_i + \mu_i M_{i+1} = d_i, i = 1, 2, \dots, n-1$$

可以发现, 上式与式 (2.14) 具有相同的形式, 因此所得到的线性方程组的形式也与上面相同.

对于固支边界条件, 给定两端点导数值  $S'(x_0) = y'_0, S'(x_n) = y'_n$ , 有

$$\begin{aligned}S'_0(x_0) &= \frac{y_1 - y_0}{h_1} - \frac{h_1}{3}M_0 - \frac{h_1}{6}M_1 = y'_0 = f[x_0, x_0] \\ S'_{n-1}(x_n) &= \frac{y_n - y_{n-1}}{h_n} + \frac{h_n}{6}M_{n-1} + \frac{h_n}{3}M_n = y'_n = f[x_n, x_n]\end{aligned}$$

于是可得

$$\begin{aligned}2M_0 + M_1 &= \frac{6}{h_1} \left( \frac{y_1 - y_0}{h_1} - y'_0 \right) = 6f[x_0, x_0, x_1] \\ M_{n-1} + 2M_n &= \frac{6}{h_n} \left( y'_n - \frac{y_n - y_{n-1}}{h_n} \right) = 6f[x_{n-1}, x_n, x_n]\end{aligned}$$

将其补充为方程组第一个和最后一个方程, 即可得到三弯矩方程为

$$\begin{pmatrix} 2 & 1 & & & & \\ \lambda_1 & 2 & \mu_1 & & & \\ & \lambda_2 & 2 & \mu_2 & & \\ & & & \ddots & & \\ & & & & \lambda_{n-1} & 2 & \mu_{n-1} \\ & & & & & 1 & 2 \end{pmatrix} \begin{pmatrix} M_0 \\ M_1 \\ M_2 \\ \vdots \\ M_{n-1} \\ M_n \end{pmatrix} = \begin{pmatrix} d_0 \\ d_1 \\ d_2 \\ \vdots \\ d_{n-1} \\ d_n \end{pmatrix}$$

其中,

$$\begin{aligned}d_0 &= 6f[x_0, x_0, x_1] \\ d_n &= 6f[x_{n-1}, x_n, x_n] \\ d_i &= 6f[x_{i-1}, x_i, x_{i+1}], i = 1, 2, \dots, n-1\end{aligned}$$

对于弯矩边界条件, 给定  $M_0 = y_0'', M_n = y_n''$ , 方程组可整理为

$$\begin{pmatrix} 2 & \mu_1 & & & \\ \lambda_2 & 2 & \mu_2 & & \\ & \lambda_3 & 2 & \mu_3 & \\ & & & \ddots & \\ & & & \lambda_{n-2} & 2 & \mu_{n-2} \\ & & & & \lambda_{n-1} & 2 \end{pmatrix} \begin{pmatrix} M_1 \\ M_2 \\ M_3 \\ \vdots \\ M_{n-2} \\ M_{n-1} \end{pmatrix} = \begin{pmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_{n-2} \\ d_{n-1} \end{pmatrix}$$

其中,

$$\begin{aligned} d_1 &= 6f[x_0, x_1, x_2] - \lambda_1 f''(x_0) \\ d_{n-1} &= 6f[x_{n-2}, x_{n-1}, x_n] - \mu_{n-1} f''(x_n) \\ d_i &= 6f[x_{i-1}, x_i, x_{i+1}], i = 2, \dots, n-2 \end{aligned}$$

将上述方程组当中的  $M_n = M_0 = 0$ , 可得自然边界条件, 不再赘述.

对于周期样条, 使用类似的方法, 可得方程组

$$\begin{pmatrix} 2 & \mu_1 & & & \lambda_1 \\ \lambda_2 & 2 & \mu_2 & & \\ & \lambda_3 & 2 & \mu_3 & \\ & & & \ddots & \\ & & & \lambda_{n-2} & 2 & \mu_{n-2} \\ \mu_n & & & & \lambda_n & 2 \end{pmatrix} \begin{pmatrix} M_1 \\ M_2 \\ M_3 \\ \vdots \\ M_{n-1} \\ M_n \end{pmatrix} = \begin{pmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_{n-1} \\ d_n \end{pmatrix}$$

其中,

$$d_i = 6f[x_{i-1}, x_i, x_{i+1}], i = 1, 2, \dots, n$$

可以验证, 上述系数矩阵也满足严格对角占优的定义.

### 2.7.5 三次样条插值函数的收敛性 \*

本部分不做证明, 只做介绍.

**定义 2.7.2** (一致范数). 设函数  $f(x)$  是区间  $[a, b]$  上的连续函数, 则记

$$\|f\|_\infty = \max_{a \leq x \leq b} |f(x)|$$

为函数  $f(x)$  的一致范数



**定理 2.7.1.** 设被插值函数  $f(x) \in C^4[a, b]$ ,  $S(x)$  为满足自然边界条件的三次样条插值函数, 则在插值区间  $[a, b]$  上成立余项估计式

$$\|f^{(k)} - S^{(k)}\|_{\infty} \leq c_k h^{4-k} \|f^{(4)}\|_{\infty}, k = 0, 1, 2$$

其中,

$$h = \max_{0 \leq i \leq n-1} h_i, h_i = x_{i+1} - x_i,$$

$$c_0 = \frac{1}{16}, c_1 = c_2 = \frac{1}{2}$$

最后, 通过一个三次样条插值的程序结束这一章. 对于 Python 程序而言, 我们调用 `CubicSpline()` 函数进行样条插值. 函数默认是采用自然边界条件, 即得到图 2.5所示:

```

1  # 三次样条插值演示(自然边界条件) Exercise2-6.py
2
3  import numpy as np
4  from scipy.interpolate import CubicSpline
5  import matplotlib.pyplot as plt
6
7  # 创建一些数据点
8  x = np.array([0, 1, 2, 3, 4, 5])
9  y = np.array([0, 2, 1, 3, 2, 0])
10
11 # 使用 CubicSpline 函数进行样条插值
12 cs = CubicSpline(x, y)
13
14 # 生成插值点
15 x_interp = np.linspace(0, 5, 100)
16 y_interp = cs(x_interp)
17
18 # 绘制原始数据和插值曲线
19 plt.plot(x, y, 'o')
20 plt.plot(x_interp, y_interp)
21 plt.show()

```




图 2.5: 自然边界条件的三次样条插值

若想采用其他边界条件, 如希望采用固支边界条件, 并令端点一阶导数为 0, 则可以在 Python 当中使用如下代码:

```
1  # 三次样条插值演示(固支边界条件) Exercise2-7.py
2
3  import numpy as np
4  from scipy.interpolate import CubicSpline
5  import matplotlib.pyplot as plt
6
7  # 创建一些数据点
8  x = np.array([0, 1, 2, 3, 4, 5])
9  y = np.array([0, 2, 1, 3, 2, 0])
10
11 # 使用CubicSpline函数进行样条插值, 且端点一阶导数值为0
12 cs = CubicSpline(x, y, bc_type=((1,0),(1,0)))
```

```
13  
14 # 生成插值点  
15 x_interp = np.linspace(0, 5, 100)  
16 y_interp = cs(x_interp)  
17  
18 # 绘制原始数据和插值曲线  
19 plt.plot(x, y, 'o')  
20 plt.plot(x_interp, y_interp)  
21 plt.show()
```

所得图像如图 2.6所示




图 2.6: 固支边界条件的三次样条插值



## Chapter 3

# 函数逼近与计算

### 3.1 引言

#### 3.1.1 函数逼近的问题的一般提法

对于函数类  $A$  中给定的函数  $f(x)$ , 要求在另一类较简单且便于计算的函数类  $B(\subset A)$  中寻找一个函数  $P(x)$ , 使得函数  $P(x)$  与  $f(x)$  之差在某种度量意义下最小.

本章所研究的函数类  $A$  通常为区间  $[a, b]$  上的连续函数, 记作  $C[a, b]$ ; 函数类  $B$  通常为代数多项式或三角多项式.

#### 3.1.2 常用的度量标准

##### 最佳一致逼近

定义 3.1.1 (最佳一致逼近). 若以函数  $f(x)$  和  $P(x)$  的最大误差

$$\max_{x \in [a, b]} |f(x) - P(x)| = \|f(x) - P(x)\|_{\infty}$$

作为度量误差  $f(x) - P(x)$  ”大小”的标准, 在这种意义下的函数逼近称为最佳一致逼近或均匀逼近

### 最佳平方逼近

定义 3.1.2 (最佳平方逼近). 采用

$$\sqrt{\int_a^b [f(x) - P(x)]^2 dx} = \|f(x) - P(x)\|_2$$

作为度量误差“大小”标准的函数逼近称为最佳平方逼近或均方逼近.

## 3.2 最佳一致逼近

### 3.2.1 最佳一致逼近概念

定义 3.2.1. 设函数  $f(x)$  是区间  $[a, b]$  上的连续函数, 对于任意给定的  $\varepsilon > 0$ , 如果存在多项式  $P(x)$ , 使不等式

$$\max_{a \leq x \leq b} |f(x) - P(x)| < \varepsilon$$

成立, 则称多项式  $P(x)$  在区间  $[a, b]$  上一致逼近 (或均匀逼近) 于函数  $f(x)$ .

### 3.2.2 最佳一致逼近多项式的存在性

定理 3.2.1 (Weierstrass 定理). 若  $f(x)$  是区间  $[a, b]$  上的连续函数, 则对于任意  $\varepsilon > 0$ , 总存在多项式  $P(x)$ , 使对一切  $a \leq x \leq b$ , 有

$$\|f(x) - P(x)\|_\infty < \varepsilon$$

定理证明略.

可以证明的是, 多项式  $P(x)$  形式为:

$$P(x) = \sum_{i=0}^{n(\varepsilon)} f\left(\frac{i}{n}\right) C_n^i x^i (1-x)^{n-i}$$

且

$$\lim_{n \rightarrow \infty} P_n(x) \rightarrow f(x)$$

### 3.2.3 $C[a, b]$ 上最佳一致逼近

在次数不超过  $n$  的多项式当中, 找到一个  $p_n^*(x)$ , 使得

$$\|f(x) - p_n^*(x)\|_\infty = \min_{p_n(x) \in H_n} \|f(x) - p_n(x)\|_\infty$$

其中,  $H_n$  表示由所有次数不超过  $n$  的代数多项式构成的线性空间. 上述问题为  $C[a, b]$  空间中最佳一致逼近问题.

下面的定理说明了该最佳一致逼近多项式的存在性.

**定理 3.2.2** (Borel 定理). 对任意的  $f(x) \in C[a, b]$ , 在  $H_n$  中都存在对  $f(x)$  的最佳一致逼近多项式, 记为  $p_n^*(x)$ , 使得

$$\|f(x) - p_n^*(x)\|_\infty = \min_{p_n(x) \in H_n} \|f(x) - p_n(x)\|_\infty$$

称  $p_n^*(x)$  为  $f(x)$  的  $n$  次最佳一致逼近多项式. 或简称为最佳逼近多项式.

### 3.2.4 相关概念

#### 偏差

**定义 3.2.2** (偏差). 若  $P_n(x) \in H_n, f(x) \in C[a, b]$ , 则称

$$\Delta(f, P_n) = \|f - P_n\|_\infty = \max_{a \leq x \leq b} |f(x) - P_n(x)|$$

为  $f(x)$  与  $P_n(x)$  在  $[a, b]$  上的偏差

显然,  $\Delta(f, P_n) \geq 0$ ,  $\Delta(f, P_n)$  的全体组成一个集合, 记作  $\Delta(f, H_n)$ , 下界为 0.

#### 最小偏差

**定义 3.2.3.** 若记集合的下确界为

$$E_n = \inf_{P_n \in H_n} \{\Delta(f, P_n)\} = \inf_{P_n \in H_n} \max_{a \leq x \leq b} |f(x) - P_n(x)|$$

则称  $E_n$  为  $f(x)$  在  $[a, b]$  上的最小偏差

#### 偏差点

**定义 3.2.4** (偏差点). 设  $f(x) \in C[a, b], P(x) \in H_n$ , 若在  $x = x_0$  上有

$$|P(x_0) - f(x_0)| = \max_{a \leq x \leq b} |P(x) - f(x)| = \mu$$

则称  $x_0$  是  $P(x) - f(x)$  的偏差点.

若  $P(x_0) - f(x_0) = \mu$ , 则称  $x_0$  为正偏差点;

若  $P(x_0) - f(x_0) = -\mu$ , 则称  $x_0$  为负偏差点;

## 交错点组

**定义 3.2.5.** 若函数  $f(x)$  在其定义域内的某一区间  $[a, b]$  上存在  $n$  个点  $x_k, k = 1, 2, \dots, n$ , 使得

$$\begin{aligned} |f(x_k)| &= \max |f(x)| = \|f(x)\|_{\infty}, k = 1, 2, \dots, n \\ -f(x_k) &= f(x_{k+1}), k = 1, 2, \dots, n-1 \end{aligned}$$

则称点集  $x_k, k = 1, 2, \dots, n$  为函数  $f(x)$  在区间  $[a, b]$  上的一个交错点组, 点  $x_k$  为交错点.

3.2.5  $C[a, b]$  上的最佳一致逼近特征

**引理 3.2.3.** 设  $f(x)$  是区间  $[a, b]$  上的连续函数,  $P_n^*(x)$  是  $f(x)$  的  $n$  次最佳一致逼近多项式, 则  $f(x) - P_n^*(x)$  在区间  $[a, b]$  上必同时存在正负偏差点.

**定理 3.2.4** (Chebyshev 定理). 设  $f(x)$  是区间  $[a, b]$  上的连续函数, 则  $P_n^*(x)$  是  $f(x)$  的  $n$  次最佳一致逼近多项式的充要条件是:  $f(x) - P_n^*(x)$  在区间  $[a, b]$  上存在一个至少由  $n+2$  个点组成的交错点组.

**例 3.2.1.** 求函数  $f(x) = \sin 4x$  在  $[0, 2\pi]$  上的 6 次最佳一致逼近  $P_6^*(x)$

**解.** 令

$$R(x) = f(x) - P_6^*(x)$$

考虑函数  $f(x) = \sin 4x$  在区间  $[0, 2\pi]$  存在由 8 个点组成的交错点组.

令  $R(x) = \sin 4x$ , 则有

$$P_6^*(x) = f(x) - R(x) = 0$$

□

**推论 3.2.5.** 在  $P_n[a, b]$  中, 若存在对函数  $f(x) \in C[a, b]$  的最佳一致逼近元, 则唯一.

**推论 3.2.6.** 设  $f(x)$  是区间  $[a, b]$  上的连续函数, 则  $f(x)$  的  $n$  次最佳一致逼近多项式是  $f(x)$  的某个  $n$  次插值多项式.



**推论 3.2.7.** 设  $f(x)$  是区间  $[a, b]$  上的连续函数,  $P_n^*(x)$  是  $f(x)$  的  $n$  次最佳一致逼近多项式, 若  $f^{(n+1)}(x)$  在  $(a, b)$  内存在且保号, 则  $f(x) - P_n^*(x)$  在区间  $[a, b]$  上恰好存在一个由  $n+2$  个点组成的交错点组, 且两个端点  $a, b$  都在交错点组中.

### 3.2.6 一次最佳逼近多项式 ( $n = 1$ )

推导过程

设  $f(x) \in C^2[a, b]$ , 且  $f''(x)$  在  $(a, b)$  内不变号, 要求  $f(x)$  在  $[a, b]$  上的一次最佳一致逼近多项式  $P_1(x) = a_0 + a_1x$ . 由上述推论,  $f(x) - P_1(x)$  在  $[a, b]$  上恰好由 3 个点构成的交错点组, 且区间端点  $a, b$  属于交错点组. 设另一交错点组为  $x_2$ . 则有

$$\begin{cases} f'(x_2) - P_1'(x_2) = 0 \\ f(a) - P_1(a) = f(b) - P_1(b) \\ f(a) - P_1(a) = -[f(x_2) - P_1(x_2)] \end{cases}$$

即

$$\begin{cases} f'(x_2) = a_1 \\ a_0 + a_1a - f(a) = f(x_2) - [a_0 + a_1x_2] \\ a_0 + a_1a - f(a) = a_0 + a_1b - f(b) \end{cases}$$

解得

$$\begin{aligned} a_1 &= \frac{f(b) - f(a)}{b - a} = f'(x_2) \\ a_0 &= \frac{f(a) + f(x_2)}{2} - \frac{f(b) - f(a)}{b - a} \frac{a + x_2}{2} \end{aligned}$$

即

$$P_1(x) = \frac{f(x_2) + f(a)}{2} + \frac{f(b) - f(a)}{b - a} \left( x - \frac{a + x_2}{2} \right)$$

**例 3.2.2.** 求  $Rf(x) = \sqrt{1+x^2}$  在  $[0, 1]$  上的一次最佳一致逼近多项式.

**解.** 因为

$$\begin{aligned} f'(x) &= \frac{x}{\sqrt{1+x^2}} \\ f''(x) &= \frac{1}{\sqrt[3]{(1+x^2)^2}} > 0 \end{aligned}$$

设  $f(x)$  在  $[0, 1]$  上的一次最佳一致逼近多项式为  $P_1(x) = a_0 + a_1x$ , 则由

$$a_1 = \frac{f(b) - f(a)}{b - a} = f'(x_2)$$

可得

$$a_1 = \sqrt{2} - 1 \approx 0.414$$

再由

$$f'(x_2) = a_1$$

可得

$$\frac{x_2}{\sqrt{1+x_2^2}} = \sqrt{2} - 1$$

解得

$$x_2 = \sqrt{\frac{\sqrt{2}-1}{2}} \approx 0.4551, f(x_2) = \sqrt{1+x_2^2} \approx 1.0986$$

由

$$a_0 = \frac{f(a) + f(x_2)}{2} - \frac{f(b) - f(a)}{b - a} \frac{a + x_2}{2}$$

得

$$a_0 = \frac{1 + \sqrt{1+x_2^2}}{2} - a_1 \frac{x_2}{2} \approx 0.955$$

于是得  $\sqrt{1+x^2}$  得最佳一次逼近多项式为

$$P_1(x) = 0.955 + 0.414x$$

最小偏差为

$$\|\sqrt{1+x^2} - P_1(x)\|_\infty = \max_{0 \leq x \leq 1} |\sqrt{1+x^2} - P_1(x)| = |\sqrt{1+0^2} - P_1(0)| \leq 0.045$$

□

$n$  次最佳一致逼近多项式 (推广)

设  $f(x) \in C^{n+1}[a, b]$ , 且  $f^{(n+1)}(x)$  在  $(a, b)$  内不变号吗要求  $f(x)$  在  $[a, b]$  上得  $n$  次最佳一致逼近多项式

$$P_n(x) = a_0 + a_1x + \cdots + a_nx^n$$

由推论可知,  $f(x) - P_n(x)$  在  $[a, b]$  上恰好有  $n + 2$  个点构成得交错点组, 且  $a, b$  属于交错点组. 设另外  $n$  个交错点为  $x_1, x_2, \dots, x_n$ , 则有

$$\begin{cases} f'(x_i) - P'_n(x_i) = 0, i = 1, 2, \dots, n \\ f(a) - P_n(a) = (-1)^i (f(x_i) - P_n(x_i)), i = 1, 2, \dots, n \\ f(a) - P_n(a) = (-1)^{n+1} [f(b) - P_n(b)] \end{cases}$$

### 3.2.7 Chebyshev 多项式及其应用

定义

定义 3.2.6 (Chebyshev 多项式). 称

$$T_n = \cos(n \arccos x), |x| \leq 1$$

为 Chebyshev 多项式

注: 令  $\theta = \arccos x$ , 则  $\cos \theta = x$ . 而

$$\cos n\theta = \cos^n \theta - C_n^2 \cos^{n-2} \theta \sin^2 \theta + C_n^4 \cos^{n-4} \theta \sin^4 \theta - \dots$$

故  $T_n$  是关于  $x$  得  $n$  次代数多项式.

性质

正交性: 由  $T_n(x)$  所组成的序列  $T_n(x)$  在区间  $[-1, 1]$  上带权  $\rho(x) = \frac{1}{\sqrt{1-x^2}}$  的正交多项式序列, 且

$$\int_{-1}^1 \frac{1}{\sqrt{1-x^2}} T_m(x) T_n(x) dx = \begin{cases} 0, & m \neq n \\ \frac{\pi}{2}, & m = n \neq 0 \\ \pi, & m = n = 0 \end{cases}$$

递推关系: 相邻的三个 Chebyshev 多项式具有如下递推关系式:

$$\begin{cases} T_0(x) = 1, T_1(x) = x \\ T_{n+1}(x) = 2x \cdot T_n(x) - T_{n-1}(x), n = 1, 2, \dots \end{cases}$$

奇偶性: Chebyshev 多项式  $T_n$ , 当  $n$  为奇数时为奇函数, 当  $n$  为偶数时为偶函数. 即

$$\begin{aligned} T_n(-x) &= \cos[n \arccos(-x)] = \cos(n\pi - n \arccos x) \\ &= (-1)^n \cos(n \arccos x) = (-1)^n T_n(x) \end{aligned}$$

$T_n$  在区间  $[-1, 1]$  上有  $n$  个不同的零点

$$x_k = \cos \frac{(2k-1)\pi}{2n}, k = 1, 2, \dots, n$$

$T_n(x)$  在  $[-1, 1]$  上有  $n+1$  个不同的极值点

$$x'_k = \cos k \frac{\pi}{n}, k = 0, 1, \dots, n$$

使  $T_n(x)$  轮流取得最大值 1 和最小值 -1.

$T_n(x)$  的最高次项系数为  $2^{n-1}, n = 1, 2, \dots$

在区间  $[-1, 1]$  上, 在所有首项系数为 1 的  $n$  次多项式  $p_n(x)$  中.  $\tilde{T}_n(x) = \frac{1}{2^{n-1}} T_n(x)$  与零的偏差最小, 且偏差为  $\frac{1}{2^{n-1}}$ , 即对于任何  $p(x) \in H_n(x)$ , 有

$$\frac{1}{2^{n-1}} = \|\tilde{T}_n(x) - 0\|_{\infty} = \min_{p(x) \in H_n} \|p(x) - 0\|_{\infty}$$

上述性质又被称为 Chebyshev 多项式的最小模性质.

### 应用

设  $f(x) = b_0 + b_1 x + \dots + b_{n+1} x^{n+1} (b_{n+1} \neq 0)$  为  $[-1, 1]$  上的  $n+1$  次多项式, 要求  $f(x)$  在  $[-1, 1]$  上的  $n$  次最佳一致逼近  $P_n^*(x)$ .

由于首项系数为 1 的  $n+1$  次 Chebyshev 多项式  $\tilde{T}_{n+1}(x)$  无穷范数最小, 有

$$\frac{f(x) - P_n^*(x)}{b_{n+1}} = \tilde{T}_{n+1}(x) = \frac{1}{2^n} T_{n+1}(x)$$

于是

$$P_n^*(x) = f(x) - b_{n+1} \tilde{T}_{n+1}(x)$$

其偏差为

$$\|f(x) - P_n^*(x)\|_{\infty} = \left\| \frac{b_{n+1}}{2^n} T_{n+1}(x) \right\|_{\infty} = \frac{|b_{n+1}|}{2^n}$$

**例 3.2.3.** 设  $f(x) = 4x^4 + 2x^3 - 5x^2 + 8x - \frac{5}{2}, |x| \leq 1$ , 求  $f(x)$  在  $[-1, 1]$  上的 3 次最佳一致逼近元  $P_3^*(x)$

**解.** 由  $f(x)$  的表达式可知  $b_4 = 4$ , 首项系数为 1 的 4 次 Chebyshev 多项式为

$$\tilde{T}_4(x) = x^4 - x^2 + \frac{1}{8}$$

设  $f(x)$  在  $[-1, 1]$  上的 3 次最佳一致逼近多项式为  $P_3^*(x)$ , 则

$$\frac{f(x) - P_3^*(x)}{4} = \tilde{T}_4(x)$$

从而

$$P_3^*(x) = f(x) - 4\tilde{T}_4(x) = 2x^3 - x^2 + 8x - 3$$

其最小偏差为

$$\|f(x) - P_3^*(x)\|_{\infty} = \left\| \frac{b_4}{2^3} T_4(x) \right\|_{\infty} = \frac{|4|}{2^3} = \frac{1}{2}$$

□

**例 3.2.4.** 若  $f(x) = 4x^4 - 5x^2 + 8x - \frac{5}{2}$ ,  $|x| \leq 1$ , 重求上题

**解.** 重复上述步骤, 可得 3 次最佳一致逼近多项式为

$$P_3^*(x) = -x^2 + 8x - 3$$

(注意: 这里的 3 次多项式是次数不超过 3)

□

考虑一般区间  $[a, b]$  上的多项式降阶. 设  $f(x) = b_0 + b_1x + \cdots + b_{n+1}x^{n+1}$ ,  $b_{n+1} \neq 0$  为  $[a, b]$  上的  $n+1$  次多项式, 要求  $f(x)$  在  $[a, b]$  上的  $n$  次最佳一致逼近  $P_n^*(x)$ .

首先做区间变换, 令

$$x = \frac{b-a}{2}t + \frac{b+a}{2}$$

其中  $t \in [-1, 1]$ , 则

$$f(x) = f\left(\frac{b-a}{2}t + \frac{b+a}{2}\right) = g(t) \in C[-1, 1]$$

设  $g(t)$  在  $[-1, 1]$  的  $n$  次最佳一致逼近多项式为  $P_n(t)$ , 则

$$P_n(t) = g(t) - c_{n+1}\tilde{T}_{n+1}(t)$$

其中,  $c_{n+1}$  为  $g(t)$  的最高此项系数.

$$c_{n+1} = b_{n+1} \left( \frac{b-a}{2} \right)^{n+1}$$

于是,  $f(x)$  在  $[a, b]$  上的  $n$  次最佳一致逼近多项式为

$$P_n^*(x) = P_n \left( \frac{2x - b - a}{b - a} \right)$$

最小偏差为

$$\|f(x) - P_n(x)\|_\infty = \|g(t) - P_n(t)\|_\infty = \frac{|c_{n+1}|}{2^n}$$

下面再考虑插值多项式的情况. 设  $f(x) \in C[-1, 1]$ , 且存在  $n+1$  阶连续导数  $f^{(n+1)}(x)$ . 如何在  $[-1, 1]$  上确定互异节点  $x_0, x_1, \dots, x_n$ , 使得  $f(x)$  的  $n$  次插值多项式的余项最小.

由插值余项定理, 可知  $n$  次插值多项式  $L_n(x)$  的余项为

$$R_n(x) = f(x) - L_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x)$$

其中,

$$\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i), \xi \in (-1, 1)$$

其误差上界为

$$\begin{aligned} |f(x) - L_n(x)| &\leq \frac{1}{(n+1)!} \max_{-1 \leq x \leq 1} |f^{(n+1)}(x)| \max_{-1 \leq x \leq 1} |\omega_{n+1}(x)| \\ &= \frac{1}{(n+1)!} \|f^{(n+1)}\|_\infty \|\omega_{n+1}(x)\|_\infty \end{aligned}$$

要使余项达到最小, 即令  $\|\omega_{n+1}(x)\|_\infty$  尽可能小. 由于是一个首项系数为 1 的  $n+1$  次多项式. 故有 Chebyshev 多项式, 取

$$\omega_{n+1}(x) = \tilde{T}_{n+1}(x)$$

同时有

$$\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i)$$

故只需令  $x_i, i = 0, 1, \dots, n$  为  $n+1$  次 Chebyshev 多项式的零点, 即

$$x_i = \cos \frac{(2i+1)\pi}{2(n+1)}, i = 0, 1, \dots, n$$

### 3.3 最佳平方逼近

#### 3.3.1 内积空间

内积空间定义

**定义 3.3.1** (内积空间). 设  $X$  为 (实) 线性空间, 在  $X$  上定义了内积是指对  $X$  中每一对元素  $x, y$ , 都有一实数, 记为  $(x, y)$  与之对应, 且这个对应满足:

1.

$$(x, x) \geq 0, (x, x) = 0 \Leftrightarrow x = 0$$

;

2.

$$(x, y) = (y, x), x, y \in X$$

;

3.

$$(\lambda x, y) = \lambda(x, y), x, y \in X; \lambda \in R$$

;

4.

$$(x + y, z) = (x, z) + (y, z), x, y, z \in X$$

则称  $X$  为内积空间, 称二元函数  $(x, y)$  为内积

#### 2-范数定义及其性质

**定义 3.3.2.** 设  $X$  为内积空间, 则对任意的  $x \in X$ , 称

$$\|x\|_2 = \sqrt{(x, x)}$$

为  $x$  的 2-范数或欧式范数.

特别的, 对  $f(x) \in C[a, b]$ , 称

$$\|f\|_2 = \sqrt{\int_a^b \rho(x) f^2(x) dx} = \sqrt{(f, f)}$$

为函数  $f(x)$  的 Euclid 范数

设  $X$  是一内积空间, 则对任意的  $x, y \in X$ , 有

1. Cauchy-Schwarz 不等式:

$$(x, y)^2 \leq (x, x)(y, y)$$

2. 三角不等式:

$$\|x + y\|_2 \leq \|x\|_2 + \|y\|_2$$

讨论特殊的两种内积空间,

- $n$  维欧氏空间  $R^n$ , 内积就是两向量数量积, 即

$$(x, y) = x^T y = \sum x_i y_i$$

- 连续函数空间  $C[a, b]$ , 内积定义为积分运算或带权函数积分运算, 即

$$(f(x), g(x)) = \int_a^b f(x)g(x) dx, f(x), g(x) \in C[a, b]$$

或者

$$(f(x), g(x)) = \int_a^b \rho(x)f(x)g(x) dx, f(x), g(x) \in C[a, b]$$

**定义 3.3.3 (权函数).** 设  $\rho(x)$  定义在有限或无限区间  $[a, b]$  上, 如果具有下列性质:

1. 对任意  $x \in [a, b], \rho(x) \geq 0$ ;
2. 积分  $\int_a^b |x|^n \rho(x) dx$  存在,  $n = 0, 1, 2, \dots$ ;
3. 对非负连续函数  $g(x)$ , 若  $\int_a^b g(x)\rho(x) dx = 0$ , 则在  $(a, b)$  上有  $g(x) \equiv 0$

称满足上述条件的  $\rho(x)$  为  $[a, b]$  上的权函数

### 3.3.2 相关概念

距离

$R^n$  中, 两个向量  $x, y$  之间的距离定义为

$$\text{dist}(x, y) = \|x - y\|_2 = \sqrt{(x - y, x - y)} = \sqrt{\sum_i (x_i - y_i)^2}$$



连续函数空间  $C[a, b]$  中, 两个函数  $f(x)$  与  $g(x)$  的欧式距离为

$$\text{dist}(f(x), g(x)) = \|f(x) - g(x)\|_2 = \sqrt{\int_a^b \rho(x) [f(x) - g(x)]^2 dx}$$

### 正交

在  $R^n$  中, 若两个向量  $x, y$  的内积为零, 即

$$(x, y) = 0$$

则称向量  $x, y$  正交.

在连续函数空间  $C[a, b]$  中, 若函数  $f(x)$  与  $g(x)$  满足

$$(f, g) = \int_a^b \rho(x) f(x) g(x) dx = 0$$

则称  $f(x)$  与  $g(x)$  在  $[a, b]$  上带权  $\rho(x)$  正交.

进一步, 设在  $C[a, b]$  上给定函数系  $\varphi_k(x)$ , 若满足条件

$$(\varphi_j(x), \varphi_k(x)) = \begin{cases} 0, & j \neq k \\ \text{常数 } A_k > 0, & j = k, j, k = 0, 1, \dots \end{cases}$$

则称函数系  $\varphi_k(x)$  是  $[a, b]$  上带权  $\rho(x)$  的正交坐标系.

特别地, 若  $A_k = 1$ , 则该函数系称为标准正交坐标系.

若上述定义中函数系为多项式系, 则称之为  $C[a, b]$  上带权  $\rho(x)$  的正交多项式系, 并称  $\varphi_n(x)$  为  $[a, b]$  上带权  $\rho(x)$  的  $n$  次正交多项式.

### 3.3.3 内积空间上的最佳平方逼近

#### 函数系的线性关系

**定义 3.3.4.** 设  $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$  为区间  $[a, b]$  上的连续函数, 若关系式

$$a_0 \varphi_0(x) + a_1 \varphi_1(x) + \dots + a_n \varphi_n(x) = 0$$

当且仅当  $a_0 = a_1 = \dots = a_n = 0$  时成立, 则称函数在  $[a, b]$  上是线性无关的, 否则称线性相关.

### 函数系线性无关的判别条件

**定理 3.3.1.** 连续函数  $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$  在  $[a, b]$  上线性无关的充分必要条件是它们的 Gram 行列式

$$G_n = \begin{vmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \cdots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{vmatrix} \neq 0$$

设  $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$  是  $[a, b]$  上线性无关的连续函数,  $a_0, a_1, \dots, a_n$  是任意实数, 则

$$S(x) = a_0\varphi_0(x) + a_1\varphi_1(x) + \cdots + a_n\varphi_n(x)$$

的全体是  $C[a, b]$  的一个子集, 记作

$$\Phi = \text{span}\{\varphi_0, \varphi_1, \dots, \varphi_n\}$$

并称  $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$  是生成集合  $\Phi$  的一个基底.

### 最佳平方逼近元的定义

设  $X$  为线性内积空间,  $\varphi_0, \varphi_1, \dots, \varphi_n$  为  $X$  上  $n+1$  个线性无关元, 即

$$\Phi = \text{span}\{\varphi_0, \varphi_1, \dots, \varphi_n\}$$

**定义 3.3.5** (最佳平方逼近元). 对任意的  $g \in X$ , 在  $X$  的子空间  $\Phi$  中, 求  $g$  的在 2-范数意义下的最佳逼近元  $S^*$ , 即求  $S^* \in \Phi$ , 使得

$$\|S^* - g\|_2 = \min_{S \in \Phi} \|S - g\|_2$$

对任意  $S \in \Phi$  成立. 若满足上式的  $S^* \in \Phi$  存在, 则称  $S^*$  为  $g \in X$  的最佳平方逼近元

### 最佳平方逼近元的存在性

**定理 3.3.2.** 设  $X$  为线性内积空间, 由线性无关组  $\varphi_0, \varphi_1, \dots, \varphi_n$  张成的线性空间  $\Phi$  为  $X$  的子空间, 则对任意的  $g \in X$ , 存在  $S^* \in \Phi$  为  $g$  的最佳平方逼近元.

## 最佳平方逼近元的特征

**定理 3.3.3.**  $S^* \in \Phi = \text{span}\{\varphi_0, \varphi_1, \dots, \varphi_n\}$  为  $g \in X$  (线性内积空间) 的最佳平方逼近元的充要条件是:  $g - S^*$  与一切  $\varphi_j, j = 0, 1, \dots, n$  正交. 其中,  $\varphi_0, \varphi_1, \dots, \varphi_n$  为  $X$  的  $n+1$  个线性无关元.

该定理所说的  $g - S^*$  与一切  $\varphi_j$  正交, 指  $g - S^*$  与一切  $\varphi_j$  的内积为零, 即

$$(g - S^*, \varphi_j) = 0, j = 0, 1, \dots, n$$

## 最佳平方逼近元的唯一性

**定理 3.3.4.** 线性内积空间  $X$  的子空间  $\Phi$  中若存在对  $g \in X$  的最佳平方逼近元, 则唯一.

## 最佳平方逼近元的求解

由最佳平方逼近元充要条件, 若假定

$$S^* = \sum_{j=0}^n c_j^* \varphi_j(x)$$

则可得出

$$\left( g - \sum_{j=0}^n c_j^* \varphi_j, \varphi_i \right) = 0, i = 0, 1, \dots, n$$

移项变形为

$$\left( \sum_{j=0}^n c_j^* \varphi_j, \varphi_i \right) = (\varphi_i, g), i = 0, 1, \dots, n$$

其中,  $c_j^*, j = 0, 1, \dots, n$  为待定系数. 用矩阵表示方程组为:

$$\begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \cdots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{pmatrix} \begin{pmatrix} c_0^* \\ c_1^* \\ \vdots \\ c_n^* \end{pmatrix} = \begin{pmatrix} (\varphi_0, g) \\ (\varphi_1, g) \\ \vdots \\ (\varphi_n, g) \end{pmatrix}$$

此方程称为法方程组.

若选取的一组基底  $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$  满足

$$(\varphi_i, \varphi_j) = \begin{cases} 0, & i \neq j \\ A_i > 0, & i = j \end{cases}$$

则称其为正交基, 此时

$$c_j^* = \frac{(\varphi_j, g)}{(\varphi_j, \varphi_j)}, j = 0, 1, \dots, n$$

**最佳平方逼近元的误差估计**

设  $S^* = \sum_{j=0}^n c_j^* \varphi_j \in \Phi = \text{span}\{\varphi_0, \varphi_1, \dots, \varphi_n\}$  为  $g \in X$  的最佳平方逼近元, 则其平方误差为

$$\begin{aligned} \|g - S^*\|_2^2 &= (g - S^*, g - S^*) = (g - S^*, g) - (g - S^*, S^*) \\ &= (g - S^*, g) - (g - S^*, \sum_{j=0}^n c_j^* \varphi_j) \\ &= (g, g) - (S^*, g) - \sum_{j=0}^n c_j^* (g - S^*, \varphi_j) \\ &= (g, g) - (S^*, g) = (g, g) - \sum_{j=1}^n c_j^* (g - \varphi_j) \end{aligned}$$

均方误差为

$$\|g - S^*\|_2 = \sqrt{(g, g) - \sum_{j=0}^n c_j^* (g, \varphi_j)}$$

### 3.3.4 连续函数的最佳平方逼近

对于给定的函数  $f(x) \in C[a, b]$ , 要求函数

$$S^* \in \Phi = \text{span}\{\varphi_0, \varphi_1, \dots, \varphi_n\}$$

使

$$\int_a^b \rho(x) [f(x) - S^*(x)]^2 dx = \min_{S(x) \in \Phi} \int_a^b \rho(x) [f(x) - S(x)]^2 dx$$

若这样的  $S^*(x)$  存在, 则称为  $f(x)$  在区间  $[a, b]$  上的最佳平方逼近函数.

特别地, 若取  $\Phi = H_n = \text{span}\{1, x, \dots, x^n\}$ , 则称

$$S^*(x) = a_0 \cdot 1 + a_1 x + \dots + a_n x^n$$

为  $f(x)$  在  $[a, b]$  上的  $n$  次最佳平方逼近多项式.

计算  $C[a, b]$  上函数  $f(x)$  的  $n$  次最佳平方逼近多项式. 取

$$\varphi_0 = 1, \varphi_1 = x, \dots, \varphi_n = x^n$$

设  $f(x)$  的  $n$  次最佳平方逼近多项式为

$$S^*(x) = \sum_{j=0}^n a_j \cdot \varphi_j(x) = \sum_{j=0}^n a_j \cdot x^j$$

构造法方程组:

$$\begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ \vdots \\ (f, \varphi_n) \end{pmatrix}$$

其中,

$$\begin{aligned} (\varphi_i, \varphi_j) &= \int_a^b \varphi_i \cdot \varphi_j \, dx = \int_a^b x^i \cdot x^j \, dx \\ &= \frac{b^{i+j+1} - a^{i+j+1}}{i+j+1}, i, j = 0, 1, \dots, n \end{aligned}$$

$$(f, \varphi_j) = \int_a^b f(x) \cdot \varphi_j \, dx = \int_a^b f(x) \cdot x^j \, dx, j = 0, 1, \dots, n$$

由此可得函数  $f(x)$  在  $H_n$  中的  $n$  次最佳平方逼近多项式:

$$S^*(x) = \sum_{j=0}^n a_j^* x^j$$

平方误差为:

$$\|f(x) - S^*(x)\|_2^2 = (f, f) - \sum_{j=0}^n a_j^* (f, \varphi_j) = \int_a^b [f(x)]^2 \, dx - \sum_{j=0}^n a_j^* (f, \varphi_j)$$

由于  $\varphi_0, \varphi_1, \dots, \varphi_n$  线性无关, 故  $G_n \neq 0$ , 上述方程组存在唯一解  $a_k = a_k^*, k = 0, 1, \dots, n$

特别地, 当  $a = 0, b = 1$  时, 法方程组系数矩阵为

$$H = \begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+1} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \cdots & \frac{1}{n+2} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \cdots & \frac{1}{n+3} \\ \vdots & \vdots & \vdots & & \vdots \\ \frac{1}{n+1} & \frac{1}{n+2} & \frac{1}{n+3} & \cdots & \frac{1}{2n+1} \end{pmatrix}$$

该矩阵为 Hilbert 矩阵, 为病态矩阵.

**例 3.3.1.** 求  $g(x) = \sqrt{x}$  在  $H_1[0, 1]$  中的最佳平方逼近元, 并估计误差

**解.** 取  $\varphi_0 = 1, \varphi_1 = x, H_1[0, 1] = \text{span}\{1, x\}$ , 记

$$S_1^*(x) = a_0 + a_1 x$$

由

$$\begin{aligned} (\varphi_0, \varphi_0) &= \int_0^1 1 \cdot 1 \, dx = 1 \\ (\varphi_0, \varphi_1) &= \int_0^1 1 \cdot x \, dx = \frac{1}{2} \\ (\varphi_1, \varphi_1) &= \int_0^1 x \cdot x \, dx = \frac{1}{3} \end{aligned}$$

同样可求得

$$\begin{aligned} (\varphi_0, g) &= \int_0^1 \sqrt{x} \, dx = \frac{2}{3} \\ (\varphi_1, g) &= \int_0^1 x \cdot \sqrt{x} \, dx = \frac{2}{5} \end{aligned}$$

所以, 关于  $a_0, a_1$  的法方程组为

$$\begin{cases} a_0 + \frac{1}{2}a_1 = \frac{2}{3} \\ \frac{1}{2}a_0 + \frac{1}{3}a_1 = \frac{2}{5} \end{cases}$$

解得

$$a_0 = \frac{4}{15}, a_1 = \frac{4}{5}$$

即  $S_1^*(x) = \frac{4}{5}x + \frac{4}{15}$  为  $H_1[0, 1]$  对  $g(x)$  的最佳平方逼近元. 且误差为

$$\begin{aligned} \|\delta_n\|_2^2 &= \|\sqrt{x} - S_1^*(x)\|_2^2 = \int_0^1 (\sqrt{x})^2 \, dx - \sum_{k=0}^1 a_k (\sqrt{x}, \varphi_k) \\ &= \frac{1}{2} - \frac{4}{15} \times \frac{2}{3} - \frac{4}{5} \times \frac{2}{5} = \frac{1}{255} \approx 0.0044 \end{aligned}$$

□

## 3.4 正交多项式

### 3.4.1 正交化手续

当权函数  $\rho(x)$  及区间  $[a, b]$  给定后, 可由幂函数系  $1, x, x^2, \dots, x^n, \dots$  利用 Schmidt 正交化方法构造出和正交多项式系

$$g_0(x) = 1,$$

$$g_k(x) = x^k - \sum_{i=0}^{k-1} \frac{(x^k, g_i)}{(g_i, g_i)} \cdot g_i, k = 1, 2, \dots$$

### 3.4.2 正交多项式的性质

1.  $g_n(x)$  是最高次项系数为 1 的  $n$  次多项式.
2. 任一  $n$  次多项式  $P_n(x) \in H_n$  均可表示为  $g_0(x), g_1(x), \dots, g_n(x)$  的线性组合.
3. 当  $n \neq m$  时,  $(g_n, g_m) = 0$ , 且  $g_n(x)$  与任一次数小于  $n$  的多项式正交.
4. 递推性,

$$g_{n+1}(x) = (x - \alpha_n)g_n(x) - \beta_n g_{n-1}(x), n = 0, 1, \dots$$

其中,

$$g_0(x) = 1, g_{-1}(x) = 0,$$

$$\alpha_n = \frac{(xg_n, g_n)}{(g_n, g_n)}, n = 0, 1, \dots,$$

$$\beta_n = \frac{(g_n, g_n)}{(g_{n-1}, g_{n-1})}, n = 1, 2, \dots$$

这里  $(xg_n, g_n) = \int_a^b xg_n^2(x)\rho(x) dx$

5. 设  $g_0(x), g_1(x), \dots$  是在  $[a, b]$  上带权  $\rho(x)$  的正交多项式序列, 则  $g_n(x) (n \geq 1)$  的  $n$  个根都是单重实根, 且都在区间  $(a, b)$  内.

### 3.4.3 常用的正交多项式

#### 第一类 Chebyshev 多项式

定义:

$$T_n = \cos(n \arccos x), |x| \leq 1$$

性质:

##### 1. 递推关系

$$\begin{cases} T_0(x) = 1, T_1(x) = x \\ T_{n+1}(x) = 2x \cdot T_n(x) - T_{n-1}(x), n = 1, 2, \dots \end{cases}$$

##### 2. 正交性

由  $T_n(x)$  所组成的序列  $T_n(x)$  在区间  $[-1, 1]$  上带权  $\rho(x) = \frac{1}{\sqrt{1-x^2}}$  的正交多项式序列, 且

$$(T_m(x), T_n(x)) = \int_{-1}^1 \frac{1}{\sqrt{1-x^2}} T_m(x) T_n(x) dx = \begin{cases} 0, & m \neq n \\ \frac{\pi}{2}, & m = n \neq 0 \\ \pi, & m = n = 0 \end{cases}$$

#### Legendre 多项式

定义 3.4.1 ( $n$  次 Legendre 多项式). 多项式

$$P_n(x) = \frac{1}{2^n \cdot n!} \frac{d^n}{dx^n} [(x^2 - 1)^n], n = 0, 1, 2, \dots$$

称为  $n$  次 Legendre 多项式

正交性: Legendre 多项式序列  $P_n(x)$  是  $[-1, 1]$  上带权  $\rho = 1$  的正交多项式序列, 且

$$(P_m(x), P_n(x)) = \int_{-1}^1 P_m(x) P_n(x) dx = \begin{cases} 0, & m \neq n \\ \frac{2}{2n+1}, & m = n \end{cases}$$

相邻的三个 Legendre 多项式具有如下递推关系:

$$\begin{cases} P_0(x) = 1, P_1(x) = x, P_{n+1}(x) = \frac{2x+1}{n+1} x P_n(x) - \frac{n}{n+1} P_{n-1}(x), n = 1, 2, \dots \end{cases}$$



奇偶性: 当  $n$  为偶数时,  $P_n(x)$  为偶函数; 当  $n$  为奇数时,  $P_n(x)$  为奇函数.

$P_n(x)$  在区间  $[-1, 1]$  内存在  $n$  个互异实零点. 且最高项系数为  $\frac{(2n)!}{2^n(n!)^2}$

在所有首项系数为 1 的  $n$  次多项式中, Legendre 多项式  $\tilde{P}_n(x)$  在  $[-1, 1]$  上与零的平方误差最小. 即对于任何  $p(x) \in H_n(x)$ , 有

$$\|\tilde{P}_n(x) - 0\|_2 = \min_{p(x) \in H_n} \|p(x) - 0\|_2$$

扩展:

$$\|\tilde{T}_n(x) - 0\|_\infty = \min_{p(x) \in H_n} \|p(x) - 0\|_\infty$$

其他常用的正交多项式

定义 3.4.2 (第二类 Chebyshev 多项式). 称

$$U_n(x) = \frac{\sin[(n+1)\arccos x]}{\sqrt{1-x^2}}$$

为第二类 Chebyshev 多项式

其中,  $U_n(x)$  是区间  $[-1, 1]$  带权  $\rho(x) = \sqrt{1-x^2}$  的正交多项式序列,

$$\int_{-1}^1 \sqrt{1-x^2} U_m(x) U_n(x) dx = \begin{cases} 0, & m \neq n \\ \frac{\pi}{2}, & m = n \end{cases}$$

且具有如下递推关系式:

$$\begin{cases} U_0(x) = 1, U_1(x) = 2x \\ U_{n+1}(x) = 2xU_n(x) - U_{n-1}(x), n = 1, 2, \dots \end{cases}$$

定义 3.4.3 (Laguerre 多项式). 称多项式

$$L_n(x) = e^x \frac{d^n}{dx^n} (x^n e^{-x}), 0 \leq x < +\infty, n = 0, 1, 2, \dots$$

为 Laguerre 多项式

$L_n(x)$  是定义在区间  $[0, +\infty)$  上带权  $\rho(x) = e^{-x}$  的正交多项式序列.

$$\int_0^\infty e^{-x} \cdot L_m(x) L_n(x) dx = \begin{cases} 0, & m \neq n \\ (n!)^2, & m = n \end{cases}$$

递推关系式:

$$\begin{cases} L_0(x) = 1, L_1(x) = 1 - x \\ L_{n+1}(x) = (1 + 2n - x)L_n(x) - n^2 \cdot L_{n-1}(x), n = 1, 2, \dots \end{cases}$$

定义 3.4.4 (Hermite 多项式). 称多项式

$$H_n(x) = (-1)^n \cdot e^{x^2} \cdot \frac{d^n}{dx^n} (e^{-x^2}), x \in (-\infty, \infty), n = 0, 1, 2, \dots$$

为 Hermite 多项式

$H_n(x)$  是区间  $(-\infty, \infty)$  上带权  $\rho(x) = e^{-x^2}$  的正交多项式序列.

$$\int_{-\infty}^{\infty} e^{-x^2} H_m(x) \cdot H_n(x) dx = \begin{cases} 0, & m \neq n \\ 2^n \cdot n! \cdot \sqrt{\pi}, & m = n \end{cases}$$

递推关系式

$$\begin{cases} H_0(x) = 1, H_1(x) = 2x \\ H_{n+1}(x) = 2xH_n(x) - 2nH_{n-1}(x), n = 1, 2, \dots \end{cases}$$

### 3.5 函数按正交多项式展开

设  $\Phi = \text{span}\{\varphi_0, \varphi_1, \dots, \varphi_n\}$ , 其中  $\varphi_i (i = 0, 1, \dots, n)$  是  $[a, b]$  上带权  $\rho(x)$  的正交多项式系, 给定  $f(x) \in C[a, b]$ , 若  $S_n^*(x) = a_0\varphi_0(x) + \dots + a_n\varphi_n(x)$  为  $f(x)$  在  $[a, b]$  上的  $n$  次最佳平方逼近多项式, 则由正交多项式的性质

$$a_k = \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)}, k = 0, 1, \dots, n$$

于是

$$S_n^*(x) = \sum_{k=0}^n \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)} \varphi_k(x)$$

其均方误差为

$$\|\delta_n\|_2 = \|f(x) - S_n^*(x)\|_2 = \sqrt{(f, f) - \sum_{k=0}^n a_k^2 (\varphi_k, \varphi_k)}$$

例 3.5.1. 求  $f(x) = e^x$  在  $[-1, 1]$  上的三次最佳平方逼近多项式.

**解.** 考虑使用 Legendre 多项式, 计算  $(f, P_k), k = 0, 1, 2, 3$ , 即

$$(f, P_0) = \int_{-1}^1 e^x dx = e - \frac{1}{e} \approx 2.3504$$

$$(f, P_1) = \int_{-1}^1 x e^x dx = 2e^{-1} \approx 0.7358$$

$$(f, P_2) = \int_{-1}^1 \left( \frac{3}{2}x^2 - \frac{1}{2} \right) e^x dx = e - \frac{7}{e} \approx 0.1431$$

$$(f, P_3) = \int_{-1}^1 \left( \frac{5}{2}x^3 - \frac{3}{2}x \right) e^x dx = \frac{37}{e} - 5e \approx 0.2013$$

所以得

$$\begin{aligned} a_0^* &= \frac{(f, P_0)}{2} = 1.1752 \\ a_1^* &= 3 \frac{(f, P_1)}{2} = 1.1036 \\ a_2^* &= 5 \frac{(f, P_2)}{2} = 0.3578 \\ a_3^* &= 7 \frac{(f, P_3)}{2} = 0.07046 \end{aligned}$$

所以

$$\begin{aligned} S_3^*(x) &= 1.1752 + 1.1036x + 0.3578 \left( \frac{3}{2}x^2 - \frac{1}{2} \right) + 0.07046 \left( \frac{5}{2}x^3 - \frac{3}{2}x \right) \\ &= 0.9963 + 0.9979x + 0.5367x^2 + 0.1761x^3 \end{aligned}$$

均方误差为

$$\|\delta_n\|_2 = \|e^x - S_3^*(x)\|_2 = \sqrt{\int_{-1}^1 e^{2x} dx - \sum_{k=0}^3 \frac{2}{2k+1} a_k^{*2}} \leq 0.0084$$

最大误差为

$$\|\delta_n\|_\infty = \|e^x - S_3^*(x)\|_\infty \leq 0.0112$$

□

下面使用 Python 代码演示这道题. 注意, 代码当中的系数为 Legendre 多项式的系数.

```
1  # 使用Legendre多项式进行平方逼近演示(例题解答) Exercise3-1.py
2  import numpy as np
3  from scipy.special import legendre
4  from scipy.optimize import least_squares
5
6  # 计算Legendre多项式的系数
7  def legendre_coefficients(x, y, degree):
8      A = np.zeros((len(x), degree + 1))
9      for i in range(degree + 1):
10         A[:, i] = legendre(i)(x)
11     return np.linalg.lstsq(A, y, rcond=None)[0]
12 # 定义逼近函数
13 def approximation_func(x, coefficients):
14     result = np.zeros_like(x)
15     for i, coeff in enumerate(coefficients):
16         result += coeff * legendre(i)(x)
17     return result
18 def legendre_approximation(x, y, degree):
19     # 计算逼近函数的系数
20     coefficients = legendre_coefficients(x, y, degree)
21     # 使用最小二乘法优化逼近函数的系数
22     result = least_squares(lambda coefficients:
23         approximation_func(x, coefficients) - y, coefficients)
24     return result.x
25
26 x = np.linspace(-1, 1, 100)
27 y = np.exp(x)
28 # 最佳平方逼近
29 degree = 3
30 coefficients = legendre_approximation(x, y, degree)
31 # 计算逼近函数的值
32 approximation = approximation_func(x, coefficients)
33 # 打印结果
```

```
33 print("系数:", coefficients)
```

输出结果为:[1.17530022 1.10367036 0.35831431 0.07053157], 与计算结果一致.

## 3.6 曲线拟合的最小二乘法

### 3.6.1 问题提出

已知一系列测量数据  $(x_i, y_i)$ , 要求简单函数  $f(x)$  使得  $\rho_i = y_i - f(x_i)$  在总体上尽可能小. 这里  $y_i \neq f(x_i)$ , 称  $\rho_i$  为残差, 这种构造近似函数的方法称为曲线拟合,  $f(x)$  为拟合函数.

通常, 使  $\rho_i$  尽可能小的度量准则包括:

- 使  $\max_{1 \leq i \leq m} |P(x_i) - y_i|$  尽可能小;
- 使  $\sum_{i=1}^m |P(x_i) - y_i|$  尽可能小;
- 使  $\sum_{i=1}^m |P(x_i) - y_i|^2$  尽可能小

### 3.6.2 曲线拟合的步骤

1. 根据条件画出散点图;
2. 观察分布, 选择适当的函数类构造拟合函数;
3. 根据某一逼近准则确定拟合函数的未知参数.

### 3.6.3 2-范数度量下的曲线拟合 (最小二乘法)

给定一组数据  $(x_i, y_i), i = 1, 2, \dots, m$ , 确定拟合函数

$$f(x) = c_1\varphi_1(x) + c_2\varphi_2(x) + \dots + c_n\varphi_n(x)$$

使得

$$\|r\|_2^2 = \sum_{i=1}^m \rho_i^2 = \sum_{i=1}^m [y_i - f(x_i)]^2 = \sum_{i=1}^m \left[ y_i - \sum_{j=1}^n c_j \varphi_j(x_i) \right]^2$$

达到极小, 这里  $n \leq m$ .

若记

$$E(c_1, c_2, \dots, c_n) = \sum_{i=1}^m \left[ y_i - \sum_{j=1}^n c_j \varphi_j(x_i) \right]^2$$

则  $E$  是  $c_1, \dots, c_n$  的多元函数, 于是问题转化为求多元函数  $E(c_1, c_2, \dots, c_n)$  的极小值问题.

由多元函数极值必要条件, 在  $E$  的极值点处, 有

$$\frac{\partial E}{\partial c_k} = \sum_{i=1}^m -2 \left( y_i - \sum_{j=1}^n c_j \varphi_j(x_i) \right) \varphi_k(x_i) = 0, k = 1, 2, \dots, n$$

即

$$\sum_{j=1}^n c_j \sum_{i=1}^m \varphi_j(x_i) \varphi_k(x_i) = \sum_{i=1}^m y_i \varphi_k(x_i), k = 1, 2, \dots, n$$

若记

$$\Phi_i = \begin{pmatrix} \varphi_i(x_1) \\ \varphi_i(x_2) \\ \vdots \\ \varphi_i(x_m) \end{pmatrix}, i = 1, 2, \dots, n, b = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

则

$$\sum_{i=1}^m \varphi_j(x_i) \varphi_k(x_i) = (\Phi_j, \Phi_k) \sum_{i=1}^m y_i \varphi_k(x_i) = (\Phi_k, b)$$

于是上式可写为

$$\sum_{j=1}^n c_j (\Phi_j, \Phi_k) = (\Phi_k, b), k = 1, 2, \dots, n$$

于是有关于  $c_1, c_2, \dots, c_n$  的线性方程组

$$\begin{pmatrix} (\Phi_1, \Phi_1) & (\Phi_2, \Phi_1) & \cdots & (\Phi_n, \Phi_1) \\ (\Phi_1, \Phi_2) & (\Phi_2, \Phi_2) & \cdots & (\Phi_n, \Phi_2) \\ \vdots & \vdots & & \vdots \\ (\Phi_1, \Phi_n) & (\Phi_2, \Phi_n) & \cdots & (\Phi_n, \Phi_n) \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix} = \begin{pmatrix} (\Phi_1, b) \\ (\Phi_2, b) \\ \vdots \\ (\Phi_n, b) \end{pmatrix}$$

或等价写作:

$$\begin{pmatrix} \Phi_1^T \Phi_1 & \Phi_2^T \Phi_1 & \cdots & \Phi_n^T \Phi_1 \\ \Phi_1^T \Phi_2 & \Phi_2^T \Phi_2 & \cdots & \Phi_n^T \Phi_2 \\ \vdots & \vdots & & \vdots \\ \Phi_1^T \Phi_n & \Phi_2^T \Phi_n & \cdots & \Phi_n^T \Phi_n \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix} = \begin{pmatrix} \Phi_1^T b \\ \Phi_2^T b \\ \vdots \\ \Phi_n^T b \end{pmatrix}$$

若记

$$A = (\Phi_1, \Phi_2, \dots, \Phi_n) = \begin{pmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \cdots & \varphi_n(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \cdots & \varphi_n(x_2) \\ \vdots & \vdots & & \vdots \\ \varphi_1(x_m) & \varphi_2(x_m) & \cdots & \varphi_n(x_m) \end{pmatrix}$$

$$x = \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix}$$

则上述方程组可表示为

$$A^T A x = A^T b$$

由于  $A$  是列满秩矩阵 (列向量线性无关), 故系数矩阵对称正定, 方程组的解存在唯一, 故可得拟合参数  $c_1, c_2, \dots, c_n$

扩展: 若矩阵  $A \in \mathbb{R}^{m \times n}$ , 则  $A^T A \in \mathbb{R}^{n \times n}$ ,  $AA^T \in \mathbb{R}^{m \times m}$ , 它们具有如下共同特点:

- 对称半正定 ( $\forall x \in \mathbb{R}^n, x^T(A^T A)x \geq 0$ );
- 特征值非负;
- $\text{rank}(A^T A) = \text{rank}(AA^T) = \text{rank}(A)$ ;
- 非零特征值个数相同, 且非零特征值相同;
- $\text{tr}(AA^T) = \text{tr}(A^T A)$

若取  $\varphi_0 = 1, \varphi_1(x) = x, \varphi_2(x) = x^2, \dots, \varphi_n(x) = x^n$ , 则拟合函数

$$f(x) = c_0 + c_1 x + c_2 x^2 + \cdots + c_n x^n$$

称为多项式拟合, 此时

$$A = \begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^n \\ 1 & x_2 & x_2^2 & \cdots & x_2^n \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_m & x_m^2 & \cdots & x_m^n \end{pmatrix}$$

$$b = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

$$x = \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{pmatrix}$$

于是

$$A^T A x = A^T b$$

一些特殊情况下的非线性拟合, 可通过变量代换, 转换为线性拟合. 例如:

1. 双曲拟合

$$\frac{1}{y} = a + b \frac{1}{x} \Rightarrow u = a + bv (u = \frac{1}{y}, v = \frac{1}{x})$$

2. 对数拟合

$$y = a + b \ln x \Rightarrow y = a + bu (u = \ln x)$$

3. 指数拟合

$$y = ae^{bx} \Rightarrow \ln y = \ln a + bx \Rightarrow u = c + bx (u = \ln y, c = \ln a)$$

### 3.6.4 用正交函数作最小二乘拟合

给定

$$\begin{cases} x_0, \cdots, x_m \\ y_0, \cdots, y_m \end{cases}$$



与正交函数系  $\varphi_0, \varphi_1, \dots, \varphi_n$ , 则最小二乘拟合系数为:

$$P_n(x) = a_0\varphi_0(x) + a_1\varphi_1(x) + \dots + a_n\varphi_n(x)$$

其中,

$$a_k = \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)} = \frac{\sum_{i=0}^m \rho(x_i) y_i \varphi_k(x_i)}{\sum_{i=1}^m \rho(x_i) \varphi_k^2(x_i)}$$

最后以一个最小二乘法的例题结束这一章.

**例 3.6.1.** 给定  $(t_i, f_i)$  的一组数据

$t_i$	$f_i$
0	81.4
20	77.7
40	74.2
60	72.4
80	70.3
100	68.8

求拟合函数  $f(x)$

**解.** 作图可知点分布在直线附近, 故使用线性函数拟合. 设

$$\varphi_0(t) = 1, \varphi_1(t) = t$$

将数据代入, 可得

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 20 \\ 1 & 40 \\ 1 & 60 \\ 1 & 80 \\ 1 & 100 \end{pmatrix}, x = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}, b = \begin{pmatrix} 81.4 \\ 77.7 \\ 74.2 \\ 72.4 \\ 70.3 \\ 68.8 \end{pmatrix}$$

代入公式

$$A^T A x = A^T b$$

可得拟合函数为

$$f(t) = 80.3 - 0.1t$$

□

下面的代码实现了上面的计算功能:

```
1  # 演示线性拟合的最小二乘法 Exercise3-2.py
2  import numpy as np
3  import matplotlib.pyplot as plt
4  # 数据
5  x = np.array([0,20,40,60,80,100])
6  y = np.array([81.4,77.7,74.2,72.4,70.3,68.8])
7  # 进行线性拟合
8  coefficients = np.polyfit(x, y, 1)
9  slope = coefficients[0]
10 intercept = coefficients[1]
11 # 绘制拟合曲线
12 x_fit= np.arange(0,100,0.01)
13 y_fit = slope*x_fit+intercept
14 plt.scatter(x,y)
15 plt.plot(x_fit,y_fit,c="red")
16 plt.show()
17 # 打印拟合结果
18 print(f"表达式为{slope:.1f}t+{intercept:.1f}")
```

拟合结果图像如图 3.1所示.

最后作为扩展演示, 下面是一个使用 Legendre 多项式进行三次拟合的程序:

```
1  # 使用Legendre多项式进行三次拟合 Exercise3-3.py
2  import numpy as np
3  import matplotlib.pyplot as plt
4  from scipy.special import legendre
5  # 示例数据
6  x = np.array([3.73,5.63,8.67,10.49,13.26,16.74,
7  19.55,22.19,25.36,28.31,30.83])
8  y = np.array([21.53,21.43,21.43,21.33,21.22,
9  20.71,20.20,19.69,18.78,17.76,16.84])
```




图 3.1: 使用线性拟合结果

```
10 # 进行Legendre拟合
11 coefficients = np.polynomial.legendre.legfit(x, y, 3)
12 # 绘制拟合曲线
13 x_fit = np.arange(3.73,30.83,0.01)
14 y_fit = np.polynomial.legendre.legval(x_fit, coefficients)
15 plt.scatter(x,y)
16 plt.plot(x_fit,y_fit,c="red")
17 plt.show()
```

得到图像如图 3.2所示.




图 3.2: 使用 Legendre 多项式对一组数据进行三次拟合

## 附录 A

# 矩阵分析基础

### A.1 向量范数

#### A.1.1 向量范数的定义

定义 A.1.1. 设  $X \in R^n$ ,  $\|X\|$  表示定义在  $R^n$  上的一个实函数, 称之为  $X$  的范数, 其具有如下性质:

1. 非负性, 即对一切  $X \in R^n, X \neq 0, \|X\| > 0$ ;
2. 齐次性, 即对任何实数  $a \in R, x \in R^n$ , 有  $\|aX\| = \|a\| \cdot \|X\|$ ;
3. 三角不等式, 即对任意两个向量  $X, Y \in R^n$ , 有  $\|X + Y\| \leq \|X\| + \|Y\|$

#### A.1.2 常用的向量范数

设向量  $X = (x_1, x_2, \dots, x_n)^T \in R^n$ , 则定义三种常用范数为

$$\begin{aligned}\|X\|_{\infty} &= \max_{1 \leq i \leq n} |x_i| \\ \|X\|_1 &= \sum_{i=1}^n |x_i| \\ \|X\|_2 &= \left( \sum_{i=1}^n |x_i|^2 \right)^{1/2}\end{aligned}$$

分别称为 $\infty$ -范数, 1-范数和 2-范数

例 A.1.1. 计算向量  $X = (1, 2, -3)^T$  的范数

解.

$$\begin{aligned}\|X\|_1 &= \sum_{i=1}^n |x_i| = 6 \\ \|X\|_2 &= \left( \sum_{i=1}^n x_i^2 \right)^{1/2} = \sqrt{14} \\ \|X\|_\infty &= \max_{1 \leq i \leq n} |x_i| = 3\end{aligned}$$

□

### A.1.3 向量范数性质

定义 A.1.2. 如果  $R^n$  中有两个范数  $\|X\|_s$  与  $\|X\|_t$ , 存在常数  $m, M > 0$ , 使得对任意  $n$  维向量  $X$ , 有

$$m\|X\|_s \leq \|X\|_t \leq M\|X\|_s$$

则称这两个范数等价

可以验证, 向量范数有如下不等式关系:

$$\begin{aligned}\frac{1}{n}\|X\|_1 &\leq \|X\|_\infty \leq \|X\|_1 \\ \|X\|_\infty &\leq \|X\|_1 \leq n\|X\|_\infty \\ \|X\|_\infty &\leq \|X\|_2 \leq \sqrt{n}\|X\|_\infty\end{aligned}$$

定义 A.1.3. 设给定  $R^n$  中的向量序列  $X_k$ , 即

$$X_0, X_1, \dots, X_k, \dots$$

若对任何  $i (i = 1, 2, \dots, n)$  都有

$$\lim_{k \rightarrow \infty} x_i^{(k)} = x_i^*$$

则向量

$$X^* = (x_1^*, x_2^*, \dots, x_n^*)^T$$

称为向量序列  $X_k$  的极限, 或者说向量序列  $X_k$  依坐标收敛于向量  $X^*$ , 记为

$$\lim_{k \rightarrow \infty} X_k = X^*$$

**定理 A.1.1.** 向量序列  $X_k$  依坐标收敛于  $X^*$  的充要条件是

$$\lim_{k \rightarrow \infty} \|X_k - X^*\| = 0$$

注: 若某向量序列在某一范数意义下收敛时, 根据向量范数的等价性, 则在其他范数意义下也收敛.

## A.2 矩阵范数

### A.2.1 矩阵范数的定义

**定义 A.2.1.** 设对任意矩阵  $A \in R^{n \times n}$ , 按一定的规则有一实数与之对应, 记作  $\|A\|$ , 若  $\|A\|$  满足

1. 正定性:  $\|A\| \geq 0$ , 当且仅当  $A = 0$  时有  $\|A\| = 0$ ;
2. 齐次性:  $\|cA\| = |c| \|A\|, \forall c \in R$ ;
3. 三角不等式:  $\|A + B\| \leq \|A\| + \|B\|$ ;
4. 相容性:  $\|AB\| \leq \|A\| \|B\|$

则称  $\|A\|$  为矩阵  $A$  的范数

**定义 A.2.2** (矩阵的算子范数). 设  $x \in R^n, A \in R^{n \times n}, \|X\|_v$  是向量范数 ( $v = 1, 2, \infty$ ), 则

$$\|A\|_v = \sup_{X \neq \theta} \frac{\|AX\|_v}{\|X\|_v}$$

是矩阵的非负函数, 称为矩阵  $A$  的算子范数

注:

$$\|A\|_v = \sup_{X \neq \theta} \frac{\|AX\|_v}{\|X\|_v} = \sup_{X \neq \theta} \|A \frac{X}{\|X\|_v}\|$$

令

$$y = \frac{X}{\|X\|_v}$$

则

$$\|A\|_v = \max_{\|y\|_v=1} \|Ay\|_v$$

**定理 A.2.1.** 设  $\|\cdot\|_v$  是  $R^n$  中的向量范数, 则  $\|A\|_v$  为  $R^{n \times n}$  上的矩阵范数, 且满足

$$\|Ax\|_v \leq \|A\|_v \|x\|_v$$

### A.2.2 常用的矩阵范数

**定理 A.2.2.** 设  $n$  阶方阵  $A = (a_{ij})_{n \times n}$ , 则

1. 与  $\|x\|_1$  相容的矩阵范数是

$$\|A\|_1 = \max_j \sum_{i=1}^n |a_{ij}|$$

2. 与  $\|x\|_\infty$  相容的矩阵范数是

$$\|A\|_\infty = \max_i \sum_{j=1}^n |a_{ij}|$$

3. 与  $\|x\|_2$  相容的矩阵范数是

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$$

其中  $\lambda_{\max}(A^T A)$  为矩阵  $A^T A$  的最大特征值.

上述三种范数又分别称为矩阵的 1-范数,  $\infty$ -范数, 2-范数. 根据求和方式, 又分别称为列和范数, 行和范数, 谱范数

特殊的, 定义 Frobenius 范数为:

$$\|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2}$$

可将该范数看作对向量范数  $\|\cdot\|_2$  的直接推广.

可以证明, 对于方阵  $A \in R^{n \times n}$  和  $x \in R^n$ , 有

$$\|Ax\|_2 \leq \|A\|_F \cdot \|x\|_2$$

注意, F-范数不是算子范数, 但有如下性质:

$$\|A\|_F = \sqrt{\text{tr}(A^T A)} = \sqrt{\text{tr}(AA^T)}$$

**例 A.2.1.** 计算矩阵

$$A = \begin{pmatrix} 1 & -2 \\ -3 & 4 \end{pmatrix}$$

的各种范数



解.

$$\|A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| = \max\{1+2, 3+4\} = 7$$

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| = \max\{1+3, 2+4\} = 6$$

$$\|A\|_F = \left( \sum_{i,j=1}^n a_{ij}^2 \right)^{1/2} = \sqrt{1+2+9+16} \approx 5.477$$

下面计算 2-范数

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$$

$$A^T A = \begin{pmatrix} 1 & -3 \\ -2 & 4 \end{pmatrix} \begin{pmatrix} 1 & -2 \\ -3 & 4 \end{pmatrix} = \begin{pmatrix} 10 & -14 \\ -14 & 20 \end{pmatrix}$$

令

$$\begin{vmatrix} \lambda - 10 & -14 \\ -14 & \lambda - 20 \end{vmatrix} = 0$$

解得

$$\lambda_{1,2} = 15 \pm \sqrt{221}$$

故最大特征值为

$$\lambda_{\max} = 15 + \sqrt{221}$$

所以得 2-范数

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} = \sqrt{15 + \sqrt{221}}$$

□

### A.2.3 矩阵范数与特征值之间的关系

**定义 A.2.3.** 矩阵  $A$  的所有特征值的最大模称为  $A$  的谱半径, 记作

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$$

**定理 A.2.3.** 矩阵  $A$  谱半径不超过  $A$  的任一矩阵范数, 即

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i| \leq \|A\|$$

**证明.** 设  $\lambda$  是矩阵  $A$  的任一特征值,  $x$  为对应特征向量, 则特征方程

$$Ax = \lambda x$$

由矩阵范数的相容性可知,

$$|\lambda| \|x\| = \|\lambda x\| = \|Ax\| \leq \|A\| \|x\|$$

即

$$|\lambda| \leq \|A\|$$

□

**推论 A.2.4.** 若  $A$  为对称矩阵, 则

$$\rho(A) = \|A\|_2$$

注:  $R^{n \times n}$  中任意两个矩阵范数也是等价的.

**定义 A.2.4.** 设  $\|\cdot\|$  为  $R^{n \times n}$  上的矩阵范数,  $A, B \in R^{n \times n}$ , 称  $\|A - B\|$  为  $A$  与  $B$  之间的距离

**定义 A.2.5.** 设给定  $R^{n \times n}$  中的矩阵序列  $A_k$ , 若

$$\lim_{k \rightarrow \infty} \|A_k - A\| = 0$$

则称矩阵序列  $A_k$  收敛于矩阵  $A$ , 记作

$$\lim_{k \rightarrow \infty} A_k = A$$

**定理 A.2.5.** 若  $\|B\| < 1$ , 则  $I \pm B$  为非奇异矩阵, 且

$$\|(I \pm B)^{-1}\| \leq \frac{1}{1 - \|B\|}$$

其中,  $\|\cdot\|$  为矩阵的算子范数.

**证明.** 反证法, 假设  $\det\{(I \pm B)\} = 0$ , 则线性方程组  $(I \pm B)x = 0$  有非零解, 即存在  $x_0 \neq 0$  使得

$$Bx_0 = x_0, \frac{\|Bx_0\|}{\|x_0\|} = 1$$

因此有

$$\|B\| \geq 1$$

与假设矛盾.

又因为

$$(I \pm B)(I \pm B)^{-1} = I$$

有

$$(I \pm B)^{-1} = I \mp B(I \pm B)^{-1}$$

从而

$$\|(I \pm B)^{-1}\| \leq \|I\| + \|B\| \|(I \pm B)^{-1}\|$$

即

$$\|(I \pm B)^{-1}\| \leq \frac{1}{1 - \|B\|}$$

□

**定理 A.2.6.** 设  $B \in R^{n \times n}$ , 则由  $B$  的各幂次得到的矩阵序列  $B^k, k = 0, 1, 2, \dots$  收敛于零矩阵, 即

$$\lim_{k \rightarrow \infty} B^k = 0$$

的充要条件是

$$\rho(B) < 1$$

#### A.2.4 矩阵的条件数

**定义 A.2.6.** 设矩阵  $A$  为非奇异矩阵, 则称

$$\text{cond}(A) = \|A^{-1}\| \|A\|$$

为矩阵  $A$  的条件数, 其中  $\|\cdot\|$  为矩阵的算子范数.

对矩阵  $A$  的任意一个算子范数  $\|\cdot\|$ , 有

1.  $\text{cond}(A) = \|A^{-1}\| \|A\| \geq \|A^{-1} \cdot A\| = \|I\| = 1$ ;
2.  $\text{cond}(kA) = \text{cond}(A)$ ,  $k$  为非零常数;
3. 若  $\|A\| = 1$ , 则  $\text{cond}(A) = \|A^{-1}\|$

注:  $\text{cond}(A)$  与所取范数有关. 常用的条件数有:

$$\begin{aligned}\text{cond}(A)_1 &= \|A^{-1}\|_1 \|A\|_1 \\ \text{cond}(A)_\infty &= \|A^{-1}\|_\infty \|A\|_\infty \\ \text{cond}(A)_2 &= \sqrt{\lambda_{\max}(A^T A) / \lambda_{\min}(A^T A)}\end{aligned}$$

特别地, 当  $A$  对称时, 则

$$\text{cond}(A)_2 = \frac{\max |\lambda_i|}{\min |\lambda_i|}$$

## A.3 初等矩阵

### A.3.1 初等矩阵

**定义 A.3.1.** 设向量  $u, v \in R^n, \sigma \in R$ , 则形如

$$E(u, v, \sigma) = I - \sigma uv^T$$

的矩阵叫做实初等矩阵, 其中  $I$  为  $n$  阶单位矩阵

### A.3.2 初等下三角矩阵

**定义 A.3.2.** 令向量  $u = l_i = (0, \dots, 0, l_{i+1,i}, \dots, l_{ni})^T$ , 向量  $v = e_i, \sigma = 1$ , 则称矩阵

$$L_i = L_i(l_i) = E(l_i, e_i; 1) = I - l_i e_i^T = \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -l_{i+1,i} & 1 & \\ & & \vdots & & \ddots \\ & & -l_{ni} & & & 1 \end{pmatrix}$$

为初等下三角阵

**定理 A.3.1.** 初等下三角阵  $L_i$  具有如下性质:

1.  $L_i^{-1}(l_i) = L_i(-l_i), |L_i| = 1$ ;

2.

$$L = L_1(l_1)L_2(l_2)\cdots L_{n-1}(l_{n-1}) = \begin{pmatrix} 1 & & & \\ -l_{21} & 1 & & \\ \vdots & \vdots & \ddots & \\ -l_{n1} & -l_{n2} & \cdots & 1 \end{pmatrix}$$

为单位下三角阵;

3. 任何一个单位下三角阵  $L \in R^n$  都可分裂成

$$L = I - l_1 e_1^T - l_2 e_2^T - \cdots - l_{n-1} e_{n-1}^T$$

因此, 对任一非奇异下三角阵  $L$ , 都可分裂成一个非奇异对角阵和若干个下三角阵的乘积;

4.  $L_i$  左乘矩阵  $A$  的结果是从  $A$  的各行中减去第  $i$  行乘一个因子.